



アンチパターンで学ぶ データ分析

作家の判別を題材に

久保山 哲二

学習院大学

Version 1.3.0

まえがき

本書は、著者が15年あまりさまざまな授業で使ってきたデータ分析の教材を1冊のテキストにまとめ直したものです。はじめは全学に向けたデータサイエンス科目(選択)のための教材でした。専攻を問わず受講する授業だったので、人文系の受講者にも自分のこととして興味を持ってもらえる題材をと考えて作りました。その後は他大学の集中講義など理系向けの授業でも使い、数理的な内容を足して育ててきました。入門の語り口のまま、ところどころ発展的な内容へ深入りするのは、二つの流れが合わさっているからです。

もともとなった教材は、授業ごとに独立したスライドと実習用の Jupyter Notebook でした(本書に付属するノートブックは marimo で作り直してあり、ブラウザで図や計算の条件を操作できます。使い方は付録 A を参照)。学期が変わるたびに手を入れ、受講者がつまづいた場所に合わせて例を差し替えてきました。それを繰り返すうちに、ばらばらの断片のあいだにいつも同じ筋が通っていることに気づきました。分析は数えるところから始まって、出てきた数字を疑うところで終わります。コロナ禍の時期を中心に書き溜めた大量の教材も、今回まとめて見直しました。生成 AI の助けも借りて、これまでに作成した教材全体を見直し、内容の重複を整理して、1冊の教科書として読める順序にまとめました。

本書のアンチパターンと定石の多くは、著者自身がさまざまな応用データの分析で学んだものです。SNS のデータ、Web 小説のデータ、遺伝子のデータ、公共事業入札のデータ、公文書の移管・廃棄のデータ、結晶の表面構造と安定性のデータ。性質のまるで違うデータを扱ってきたなかで型として身についたことを書きました。

もう一つの源は、授業で受講者の分析につきあってきた経験です。演習や卒業研究の相談を受けていると、同じつまづきが何度も現れます。しかもその多くは、手順の説明からはこぼれ落ちてしまう、ごく初歩的な取り違えです。本書にときどき細かすぎるように見える注意が入っているのは、そのためです。

まとめるにあたって題材を一つに固定しました。文章の特徴から作家を判別するという問題です。作家の判別という題材自体、以前から授業で使ってきたものです。読点の前にどの平仮名が来るか、つまり「～て、」で切るか「～が、」で切るかといった癖を数えるだけで、著者ごとの塊がきれいに分かります。何を書いているかは一切見ていないのに、です。受講者がまず驚くのは、ここです。

もう一つは、その裏返しです。同じデータでも、数える対象を変えれば結論が変わります。本書の第9章では、特徴量を文字の並び(文字 n-gram)に変えると、モデルが文体と一緒に、会話文の閉じかぎ括弧のあとで改行する組み方のような底本の表記の約束まで手がかりにし始めます。作品もモデルも変えていません。変えたのは数える対象だけです。分析の結論は、手法を選ぶより前、何を数えるかを決める段階でおおかた決まってしまう。どの章も同じデータを使うので、第3章で決めた前処理が、第5章のクラスタや第9章の評価の数字をどう変えるかを1冊の中で追いかけられます。一つの分析が始まって終わるまでの判断の連なりとして読んでもらえるように書きました。

分量は多めです。授業で使うときに聞き手に合わせて取捨選択できるだけの厚みを持たせたため、順にすべて読む必要はありません。灰色の枠の「補足」と、濃紺の左罫の「発展」は、飛ばしても本筋がつながるように書いてあります。逆に、独学で読む人は気になった箱にこそ寄り道してください。著者自身、この教材を作る過程で初めて理解できた事柄が(組成データの扱いをはじめ)いくつかあります。

いまは生成 AI がコードを書き、分析を実行し、説明までしてくれる時代です。それでも本書を書いたのは、分析の実行を任せられるようになった一方で、出てきた数字を疑い引き受ける仕事が人の側に残っているからです。AI は、適切な文脈と検査の観点を与えれば、比率どうしの見かけの相関にも評価の漏洩にも気づいてくれます。ただ、何を文脈として渡し、どの観点で検査させるかを決めるのは使い手です。合計が 1 に固定されたデータでは相関が歪むことを知らなければ、それを確認するよう指示は出せませんし、AI が「興味深い発見」として返してきたものが本当に興味深いのかを確かめることもできません(前者は第 3 章、後者は第 9 章で扱います)。本書が扱うのは、そうした判断のほうです。何を問うかを決め、どの前処理が結論を左右するかを見分け、出てきた数字のどこを疑うかを見当づける仕事は、実行の手間が消えていくほど、かえって人の側に濃く残ります。本書は、その検分の目を作るために書きました。

この教材を長年鍛えてくれた、教室で出会った受講者の皆さんに感謝します。

2026 年 9 月

久保山 哲二

目次

まえがき	i
第 1 章 はじめに	1
1.1 この本が答えようとする問い	1
1.2 一つの題材を最後まで追う	2
1.3 アンチパターンから学ぶ	2
1.4 必要な準備	4
1.5 行と列の呼び方	4
1.6 データについて	5
1.7 各章の内容	8
第 2 章 テキストを数える	10
2.1 文章を数値にすること	10
2.2 Zipf の法則	10
2.3 頻度の偏りが、使える語と使えない語を分ける	14
2.4 均しく現れる語と固まって現れる語	15
2.5 日本語には語の区切りがない	23
2.6 章末の課題	24
第 3 章 特徴を設計する	26
3.1 何を数えるかを定める	26
3.2 前処理 — 情報の出どころで捨てるものを定める	26
3.3 特徴設計 1 — 文字種の比率	28
3.4 単体 — 3 つの比率が住む場所	31
3.5 特徴設計 2 — 文の長さ	36
3.6 特徴設計 3 — 読点の打ち方	40
3.7 組成データ — 比率を扱うときの落とし穴	43
3.8 できあがった表	55
3.9 章末の課題	56
第 4 章 距離を測る	57
4.1 「似ている」を数式にする	57
4.2 ミンコフスキー距離	57
4.3 コサイン距離 — 向きだけを見る	59

4.4	標準化 — 文長の 2 列が距離のほとんどを占めてしまう	62
4.5	距離行列を眺める	70
4.6	同著者と異著者を最もよく分けたのはコサイン距離	70
4.7	発展 — 距離の数学的性質	74
4.8	相関係数は偏差ベクトルのコサインである	76
4.9	相関は「伝わらない」	80
4.10	高次元では距離が壊れる	87
4.11	章末の課題	92
第 5 章	まとまりを見つける	93
5.1	正解を見せずに分ける	93
5.2	階層クラスタリング	93
5.3	クラスタ間距離の 4 つの定義	94
5.4	切る高さはデンドログラムだけでは決まらない	97
5.5	答え合わせ — 2 種類の評価	98
5.6	距離と併合方法の相性	102
5.7	k-means	109
5.8	階層クラスタリングと k-means の使い分け	113
5.9	章末の課題	114
第 6 章	次元を減らす	115
6.1	見えないものを見る	115
6.2	主成分分析 — いちばん見晴らしのよい方向から眺める	115
6.3	バイプロット — 点と変数を同時に描く	125
6.4	多次元尺度構成法 (MDS)	127
6.5	非線形の次元削減 — 近傍のつながりを保つ	129
6.6	手法は 1 つに絞らず、並べて描く	149
6.7	章末の課題	150
第 7 章	著者を当てる	152
7.1	正解を与えて学ばせる	152
7.2	まず当てずっぽうの成績を知る	152
7.3	k 近傍法 — 最も単純な分類器	153
7.4	線形モデル — 1 本の境界で分ける	154
7.5	決定木 — 質問を繰り返す	162
7.6	ランダムフォレスト — 木をたくさん作る	163
7.7	勾配ブースティング — 間違いを順に埋める	164
7.8	訓練データで測った正解率は当てにならない	172
7.9	分割のときの注意 — 層別化	173
7.10	モデルを比べる	174

7.11	判別を支えている特徴を突き止める	179
7.12	同じ長編の巻が訓練とテストに分かれている	184
7.13	章末の課題	184
第 8 章	正しく測る	185
8.1	1 回の分割では足りない	185
8.2	交差検証	186
8.3	正解率だけでは足りない	188
8.4	成績の不確かさを添える	191
8.5	指標は「どの誤りが高くつくか」で選ぶ	201
8.6	しきい値を動かす — ROC 曲線と AUC	206
8.7	較正 — 出力された確率が当たっているかを測る	210
8.8	過学習を目で見る	214
8.9	学習曲線 — 作品を増やせばまだ伸びる	215
8.10	評価の手順をまとめる	216
8.11	章末の課題	216
第 9 章	罣を避ける	218
9.1	出来すぎた結果を疑う	218
9.2	データ漏洩 — 本番では手に入らない情報が訓練に混ざる	218
9.3	前処理の漏れ	219
9.4	特徴選択の漏れ	223
9.5	グループの漏れ	224
9.6	特徴の作り方が漏れを招く — n-gram の罣	228
9.7	ハイパーパラメータ選択の漏れ	231
9.8	多重テストの漏れ	234
9.9	そのほかの漏れ — ターゲットと時系列	236
9.10	訓練で見た範囲の外に出られないモデルがある	239
9.11	COVID-19 診断モデルの教訓	241
9.12	誤差を 3 つに分ける — 偏りとばらつき	241
9.13	次元の呪い	246
9.14	生成 AI に分析を手伝わせるときの罣	248
9.15	手順のまとめ	249
9.16	章末の課題	250
第 10 章	学習された表現と比べる	252
10.1	手作りの特徴を埋め込みに置き換える	252
10.2	入力を変えずにモデルだけ深層学習に取り替える	260
10.3	手作りの特徴が残った理由	274

第 11 章	ジャンルを分ける	276
11.1	問いを変えてみる	276
11.2	まず眺める	277
11.3	分類してみる	278
11.4	喜ぶ前に	278
11.5	著者判別に戻ると	282
11.6	候補の外にいる著者を棄却する	283
11.7	2次元で眺める	286
11.8	当てているものと、当てたいものは違うことがある	286
11.9	この本のまとめ	287
11.10	章末の課題	287
付録 A	marimo 教材の使い方	289
A.1	教材の構成	289
A.2	自分のパソコンで実行する	290
A.3	操作するときの注意	290
A.4	困ったときは	291
付録 B	高次元空間の幾何	292
B.1	球の体積は消える	292
B.2	体積は薄い殻に集中する	293
B.3	距離の集中	294
B.4	高次元ではベクトルがほぼ直交する	296
B.5	呪いと祝福	297
B.6	実務での構え方	299
B.7	章末の課題	300
付録 C	不偏性をめぐる補足	301
C.1	二乗誤差を最小にする割る数は $n + 1$ である	301
C.2	標準偏差を不偏にする補正	302
参考文献		303
参考文献		303
アンチパターンと定石の一覧		311

第 1 章

はじめに

1.1 この本が答えようとする問い

誰が書いたのか分からない文章の書き手を、その書きぶりから推し量る。こうした試みは古くからある。『源氏物語』の最後の十帖は、それまでと文章の調子が違うと言われ、紫式部が書いたのかどうか長く議論されてきた。

決着がついた例もある。**ザ・フェデラリスト**は、1787 年から 1788 年にかけてアメリカ合衆国憲法の批准を訴えるために書かれた 85 編の論文で、3 人が匿名で分担執筆した。そのうち 12 編は、ハミルトンが書いたのかマディソンが書いたのかが分からないまま 150 年以上残っていた。1964 年、モステラーとウォレスがこれに統計で答えを出す [1]。彼らが数えたのは主張の中身ではなく、by、to、upon といった、文の骨組みを作るだけで意味をほとんど持たない単語の使用頻度だった。2 人はそうした語の使い方に一貫した癖を持っていて、12 編はすべてマディソンの側に寄った。この仕事は、文体を数えて書き手を調べる**計量文体論** (stylometry) の分野で、統計による著者推定の代表例として今も引かれる。文章を数えて書き手を比べる試みそのものはもっと古く、語の長さの分布を書き手ごとに比べたメンデンホールの研究は 1887 年にさかのぼる [2]。

意味を運ばない語にこそ書き手の癖が出るという発見は、本書の第 2 章と第 3 章でそのまま使う。

本書ではこの問いを、8 名の近代文学作家、74 作品を使って追いかける。夏目漱石、泉鏡花、島崎藤村、太宰治、夢野久作、谷崎潤一郎、柳田国男、吉川英治。すべて青空文庫から入手できるものである。

最後の第 11 章では、ここにライトノベル 60 区間を加えて、問いそのものを立て直す。

本書でやる作業は、次の二つからなる。

1. 作品ごとの文体を数値の並びにする
2. その数値から、作品をまとめる/著者を当てる

並べてしまえば単純だが、この二つの間に、データ分析でつまづくことのほとんどが詰まっている。まえがきでも述べたとおり、何を数えるかを決めた段階で結論はほぼ決まってしまうし、出た数値が正しく測られたものかどうか、測り方しだいで大きく変わる。本書はどちらについても、間違った手順を実際に試し、数字がどれだけ動くかを確かめながら進む。

コラム 宇治十帖を数えた人たち

冒頭で触れた『源氏物語』の最後の十帖 (宇治十帖) は、室町時代の一条兼良の注釈書『花鳥余情』(1472 年) ですでに別の作者の手になるのではないかと疑われていた。この問題は、20 世紀に入ってから数値を数えて調べられてきた。

コラム (続き)

1957年、心理学者の安本美典は、和歌や直喩の使い方、名詞・用言・助詞の使用頻度など12の項目を「雲隠」までの巻と宇治十帖とで比べ、多くの項目で偶然とは言えない違いがあることを示して、宇治十帖は別の作者が書いたと論じた [3]。

その後、土山玄は助詞の出現頻度などを多変量解析で調べ直し、匂宮三帖と宇治十帖の13巻について、作者が他の巻と異なることを支持する積極的な根拠は認められなかったと報告した [4]。あわせて、宇治十帖の前半5巻と後半5巻とのあいだに量的な傾向の違いを見つけ、13巻が段階的に書かれた可能性を示している。

「頻度が違う」という同じ種類の観察が、作者の違いとも、書かれた時期や内容の違いとも読めることになる。頻度の差を書き手の差と読むには、ほかの原因では説明がつかないことを先に確かめる必要がある。本書が内容語を避けて機能語や文字の癖を数えるのも(第2章)、同じ長編の巻を1つのまとまりとして扱って測り直すのも(第9章)、この読み違いを避けるためである。

1.2 一つの題材を最後まで追う

データ分析の入門書は、章ごとに別のデータを使うことが多い。アヤメの花で分類を学び、住宅価格で回帰を学び、手書き数字でニューラルネットワークを学ぶ。手法を一つずつ独立に見せるには、この作りが分かりやすい。

本書は逆に、題材を一つに固定した。最初から最後まで同じ74作品を使うので、**前の章での判断が、後の章の結果を左右する**ようすをそのまま追いかけられる。

特徴の作り方を変えれば距離が変わる。距離が変われば、クラスタも変わり、分類の精度も変わる。評価の設計を誤れば、それまでの手間がすべて無意味な数字になる。第3章で内容語を避けて特徴を作った判断は、第9章でシリーズを分けて測り直したときの落差の小ささとして表れる。




図 1.1 本書の流れ。最後に前へ戻ることになる。

図 1.1 の点線が本書の主張である。分析は一度では終わらない。第9章で評価の甘さに気づけば、特徴の作り方まで戻ることになる。

1.3 アンチパターンから学ぶ

本書は、ありがちな間違いを実際に実行し、**どれだけ数字が変わるかを測ってから正しいやり方**を示す、という順序で書いてある。数字が動くところを一度見ておけば、後で似た場面に出会ったとき

に思い出しやすいだろうと考えた。もちろん、学び方はこれ一つではない。

間違いは赤い箱 (アンチパターン) に、それに対する確立した正しい手筋は緑の箱 (定石) にまとめてあり、巻末に全箱の一覧を付けた (一覧では × と ○ で区別する)。分析の途中で不安になったら、そこから逆引きできる。

ただし、緑の箱も**規則ではない**。定石は「多くの場合にうまくいくと確かめられてきた方法」であり、本書の定石も、本書のデータと本書が想定した目的の上で成り立っている。手元のデータがその条件を満たしているかを確かめるのは読む側の仕事で、定石どおりにやったのに結果がおかしいときは、自分の操作より先に、その定石の前提を疑うのが早い。

箱はもう 2 種類ある。「補足」の灰色の枠は本筋から少し外れる話、濃紺の左罫を付けた「発展」の欄はやや進んだ内容である。見出しの末尾に * が付いた節も同じ扱いで、どれも初読では飛ばして構わない。各章の最後の節は章末の課題で、一部にはヒントを付けた。

補足 赤い箱だけを拾い読みしても身につかない

間違いが害になる理由は、その手前の議論の中にある。箱の結論だけ覚えても、少し形の違う罫は避けられない。

たとえば第 9 章では、次のような実験をする。著者と何の関係もない**乱数の列**を 2000 本用意し、その中から著者とよく対応する 30 本を選び、その 30 本だけを使って 74 作品の著者を層別 5 分割交差検証で当てる。交差検証は、作品を 5 組に分け、4 組で学習して残る 1 組の著者を当てることを 5 回繰り返す測り方である (第 8 章)。元が乱数なのだから、当たるはずがない。ところが、この手順で測った正解率は 0.57 になる。どの作品にも吉川英治だと答え続けるだけの戦略の正解率が 0.284 なので、その 2 倍である。

からくりは、30 本を選ぶ操作とデータを分ける操作の**順番**にある。順番を正しく入れ替えて同じ乱数で測り直すと、正解率は 0.16 まで下がる。8 名から当てずっぽうに選んだときの 0.125 と同じくらいで、吉川英治と答え続ける 0.284 にも及ばない。分析の中身は 1 文字も変えていない。順番を入れ替えただけで正解率が 0.41 変わったことになる (図 1.2)。0.57 という数字を自分の目で見ておくと、同じ間違いはしにくくなる。




図 1.2 第 9 章の乱数実験の正解率。著者と無関係な乱数 2000 列から「著者とよく対応する 30 列」を選ぶ操作を、データを分ける前に行うか、分けた後の訓練側だけで行うかだけが違う。下の 2 本は比べるための基準である。

1.4 必要な準備

数学は高校までの内容を前提にする。平均、分散、対数、簡単な確率。行列やベクトルは使う前に説明する。

プログラムは Python を使うが、読めれば十分である。付属の marimo ノートブックでは、条件を変えながら図と計算結果を比較できる。使い方は付録 A にまとめた。

1.5 行と列の呼び方

本書の作業は、最後には1枚の表になる。行が作品、列が測った量、マスがその値である。機械学習も統計も、たいていは同じ形の表から始まる。

ところが、表の各部分の呼び方が分野ごとに違う。同じものを指しているのに用語が食い違くと、それだけで読めなくなるので、先に整理しておく。

1 列=1 つの測り方。本書では**特徴量**

著者	題名	平仮名	漢字	文長 μ
太宰治	斜陽	0.731	0.247	3.17
夏目漱石	こころ	0.701	0.297	3.34
吉川英治	三国志 (桃園)	0.673	0.325	3.25

1 行=1 件のデータ
本書では**作品**

当てたい列。本書では**正解ラベル**

図 1.3 表の呼び方。同じ場所が分野ごとに違う名前と呼ばれる。平仮名・漢字の列は、平仮名・片仮名・漢字の3種の合計に占める割合、文長 μ は1文の字数の対数の平均で(第3章)、3.17は約24字にあたる。

呼び方の対応を表 1.1 にまとめる。横に並んだものは、どれも同じ場所を指している。

表 1.1 分野による呼び方の違い

	1 行 (1 件のデータ)	入力に使う列	当てたい列
本書	作品 (第 11 章では 区間)	特徴量	正解ラベル
統計学	観測・ケース	説明変数・独立変数	目的変数・従属変数・被説明変数
機械学習	サンプル・インスタンス・事例	特徴量・素性 (そせい)	ラベル・ターゲット・教師信号
データベース	レコード	フィールド・属性	—
幾何として見るとき	点	次元・座標軸	—

とくに**説明変数**と**目的変数**は対で使う語である。「説明変数で目的変数を説明する」という言い方をするので、片方だけを別の分野の語に置き換えると文がねじれる。「特徴量で目的変数を説明する」

は落ち着かない。本書では「特徴量」と「正解ラベル」を対にして使う。

第4章からは、表を**幾何の対象**としても見る。1行に並んだ52個の数を、そのまま**座標**として読む。学校で習う平面の点 (x, y) は2つの数の組だったが、数が52個あれば52次元空間の1点になる、と考える。絵には描けないが、数の扱い方は同じである。

こう読むと、74行×52列の表は、52次元空間に散らばった74個の点になる。2つの作品が似ているかどうかは、2つの点が近いかどうかの問題に翻訳される。表として見るか点の集まりとして見るかは、同じものへの2通りの視線であって、別のデータになるわけではない。

補足 「サンプル」まわりの語は取り違えやすい

表1.1に「サンプル」が出てくるが、この語の周辺には紛らわしいものが集まっている。

統計学で**標本**(sample)といえば、母集団から取り出した**データの集まり全体**を指す。そこから2つの語が出る。

- **サンプルサイズ**(標本の大きさ) — その標本に入っているデータの件数。よく n と書く。本書なら $n = 74$
- **標本数** — 標本そのものの個数。調査を1回しか行っていないければ1である

「サンプル数100」と書かれた文章をよく見かけるが、統計の語法では標本数は普通1なので、これはたいてい**サンプルサイズが100**の意味である。

ややこしいことに、機械学習の実務では**1件のデータ**を「サンプル」と呼ぶ(scikit-learnの`n_samples`は行数である)。機械学習の現場では「サンプル数=行数」で通じてしまう。

同じ語が「全体」と「1件」の両方を指すので、議論の途中でどちらの意味が分からなくなる。本書では1件を指して「サンプル」とは呼ばず、行数のことは**作品数**または**データの件数**と書く。他人の文章を読むときは、その人がどちらの意味で使っているかを先に確かめておく安全である。

1.6 データについて

使う74作品の内訳を表1.2に示す。

表 1.2 コーパスの内訳

著者	作品数	主な作品
吉川英治	21	『三国志』全10巻と篇外余録、『宮本武蔵』全7巻
夏目漱石	10	『こころ』『三四郎』『それから』『道草』
島崎藤村	9	『夜明け前』(第一部上)『破戒』『新生』『嵐』
泉鏡花	9	『高野聖』『紅玉』『化銀杏』『陽炎座』
太宰治	7	『人間失格』『斜陽』『津軽』『走れメロス』
夢野久作	7	『ドグラ・マグラ』『少女地獄』
谷崎潤一郎	6	『細雪』(上巻)『陰翳礼讃』『吉野葛』『盲目物語』
柳田国男	5	『山の人生』『雪国の春』『木綿以前の事』『海上の道』
合計	74	




図 1.4 作品ごとの本文の長さ。1 点が 1 作品である。吉川英治の行は、『三国志』の巻と篇外余録 (上にずらした四角) と『宮本武蔵』の巻 (下にずらした菱形) を分けて描いた。いちばん短い『並木』(島崎藤村) は 9,415 字、いちばん長い『江戸三国志』(吉川英治) は 583,755 字で、60 倍ほど違う。

表 1.2 をよく見てほしい。2 つの点で偏っている。

1 つは**作品数の開き**である。柳田国男の 5 作品に対し、吉川英治は 21 作品と、4 倍以上ある。このとき、何も考えずにどの作品にも「吉川英治」と答え続けるだけで、74 作品に対する正解率が 0.284 になる。3 割近くが当たってしまう。モデルの成績を見るときは、この基準線 0.284 を超えているかどうかを毎回確かめる必要がある (第 7 章)。少数の著者を丸ごと取りこぼしていても、全体の正解率にはほとんど響かないという問題もある (第 8 章)。

もう 1 つは**作品どうしの独立性**である。吉川英治の 21 作品のうち 17 は、『三国志』と『宮本武蔵』という 2 つの長編を巻ごとに分けたもので、もう 1 点は『三国志』に添えられた篇外余録である (図 1.4 の吉川英治の行)。同じ長編の巻どうしは、当然よく似ている。訓練データとテストデータに 1 巻ずつ分かれて入れば、モデルは「文体」ではなく「その長編」を覚えて正解できる余地が生まれ、成績が水増しされるおそれがある。本書の特徴量でどれだけ水増しされるかは第 9 章で測る。

扱いにくいデータである。だが本書ではあえてこのまま使う。きれいに整ったデータでは、第 8 章と第 9 章で扱う問題が起きないからである。現実のデータはたいてい似た形をしている。

補足 このコーパスは二重の選抜を通った後のものである

偏りは表の中だけにあるのではない。そもそも表に載る前の段階で、2 回の選抜が起きている。

1 回目は**著作権**である。青空文庫に収録されるのは保護期間の切れた作品なので、自動的に古い時代のもに限られる。本書の 8 名がいずれも 1960 年代までに没した作家なのは、その時代を選んだからではなく、選べる範囲がそこしかなかったからである。

2 回目は**電子化**である。青空文庫の入力と校正は有志の手で行われている。読まれ続けている作品ほど入力されやすいので、本書の 74 作品も**数十年のあいだ読み継がれてきた側**に寄っている。

したがって本書のモデルが学ぶのは、「近代の日本語作家の文体」ではなく、「読み継がれ、電子化された作家の文体」である。当時の平均的な文章がどうだったかは、このデータからは分からない。残らなかった書き手のほうが、はるかに多いからである。

補足（続き）

このように、**選抜を通ったものだけを見て全体を語る誤りを生存者バイアス**という。第二次大戦中、帰還した爆撃機の被弾箇所を調べてそこを補強しようとした話が有名である。本当に補強すべきなのは、**被弾すると帰還できなくなる箇所**、つまり帰ってきた機体に穴のない場所だった。

手元のデータを見ると、「ここに来られなかったものは何か」を一度考えてみるとよい。

1.6.1 もう一つのデータ

第 11 章では、まったく別のデータを足す。Web 小説投稿サイト「小説家になろう」で連載された 6 シリーズ、60 区間である。

連載小説には青空文庫の「作品」に相当する切れ目がない。そこで各シリーズを、**章の区切りを尊重しながら 8 万～16 万字ずつに区切ったもの**を 1 単位とした。これを本書では**区間**と呼ぶ。区切り目は必ず章か話の境界に置く。青空文庫の作品はルビと注記を除いて約 1 万～58 万字 (中央値 12 万字、図 1.4) なので、1 区間はほぼ 1 作品ぶんの分量になる。

表 1.3 ライトノベルの内訳 (第 9 章と第 11 章で使う)

著者	シリーズ	区間数	元の話数
香月美夜	『本好きの下剋上』	10	186
日向夏	『薬屋のひとりごと』	10	344
長月達平	『Re: ゼロから始める異世界生活』	10	148
理不尽な孫の手	『無職転生』	10	129
佐賀崎しげる	『片田舎のおっさん、剣聖になる』	10	295
依空まつり	『サイレント・ウィッチ』	10	216
合計		60	1318

表 1.2 と見比べてほしい。点の数だけを見れば近代文学と大差ない。だが**構造がまったく違う**。

ライトノベルは、著者一人につきシリーズ一つである。「10 区間」といっても、独立した 10 作品ではなく、一つの長編を 10 個に切ったものである (図 1.5)。

構造の違いが何をもたらすかは、第 9 章と第 11 章で見る。


補足 配布できるデータとできないデータ

近代文学は青空文庫にあり、著作権が切れているのでテキストごと配布できる。

ライトノベルは著作権が生きているので、テキストは配れない。配れるのは第 3 章で作る**特徴量 (feature)**、つまり 52 個の数値だけである。

これは制約であると同時に、実務でよくある状況でもある。個人情報を含むデータを共有できないとき、集約統計量や特徴量だけを渡す。第 11 章で改めて扱う。

近代文学 (74 作品)



ライトノベル (60 区間)



図 1.5 近代文学とライトノベルのデータの形。灰色の四角が表の 1 行 (作品または区間) で、赤い点線の枠は同じ長編・同じシリーズから来た行のまとまりである。第 9 章では、この枠が訓練とテストに分かれないようにして測り直す。

1.7 各章の内容

第2章 テキストを数える

単語の出現頻度に現れる規則。Zipf の法則とポアソン分布。文体を測るのに使える量とそうでない量の見分け方。

第3章 特徴を設計する

文字種の比率、文の長さの分布、読点の打ち方。書き手が意識していない癖を数値にする。合計が 1 に固定された比率 (組成データ) の扱いにも踏み込む。

第4章 距離を測る

「似ている」を数式にする。ユークリッド距離、マンハッタン距離、コサイン距離の違いと、標準化が必要になる理由。

第5章 まとまりを見つける

正解を見せずにグループを作る。階層クラスタリングと k-means、作った結果を評価するしかた。

第6章 次元を減らす

52 次元は見られない。主成分分析と多次元尺度構成法で、情報をなるべく落とさずに 2 次元に写す。

第7章 著者を当てる

正解を与えて予測を学ばせる。k 近傍法、線形モデル、決定木、ランダムフォレスト、勾配ブースティング。どの特徴が判別を支えているかも突き止める。

第8章 正しく測る

交差検証、層別化、適合率と再現率、ROC 曲線、混同行列、確率の較正。「正解率が高い」だけでは何も分らない理由。

第9章 罣を避ける

データ漏洩の 6 つの型、過学習、偏りとばらつき、次元の呪い。出来すぎた結果を疑う習慣。

第 10 章 学習された表現と比べる

手で組み立てた 52 列を、大規模言語モデルの埋め込みや深層学習のモデルと比べる。測り方がそろってからでないと、この比較はできない。

第 11 章 ジャンルを分ける

ライトノベルを加えて問いを立て直す。1 つの特徴で解けてしまう問題に、機械学習が要るかどうか。候補の外にいる著者に「該当なし」と答える方法。

付録 A に付属の marimo 教材の使い方、付録 B に高次元空間の幾何、付録 C に分散や標準偏差を推定するときに何で割るかの補足をまとめた。付録 B では数式を省略していない。次元の呪いがなぜ起きるのかを、球の体積と距離の集中から説明する。

第2章

テキストを数える

2.1 文章を数値にすること

コンピュータは文章をそのまま比べられない。「この二つの文章は似ているか」を判定させるには、まず文章を数値の並びに変換しなければならない。

どんな数値にすればよいかを考える前に、そもそも文章の中で数えられる量にどんな性質があるのかを知っておきたい。

本章では英語の小説を1冊使って、単語の出現頻度のふるまいを調べる。『赤毛のアン』(Lucy Maud Montgomery, 1908)を題材にする。日本語ではなく英語を使うのは、単語の区切りが空白で分かるからである。日本語には空白がないので、まず文を単語に切り分ける処理が要る。これを**形態素解析**という^{*1}。本書では形態素解析を使わずに進む。理由は第3章で述べる。

2.2 Zipfの法則

単語を出現頻度の高い順に並べ、順位を横軸、頻度を縦軸に取って何が起きるかを確かめる。

```
import re
from collections import Counter

text = open("anne.txt", encoding="utf-8").read() # 前書きとライセンス文は除いてある
words = re.sub(r"[.,?!:~\";()'\"]", " ", text).lower().split()
freq = Counter(words).most_common()
```

以下、本章で単語の「出現回数」というときは、『赤毛のアン』の本文 (Project Gutenberg 版から前書きとライセンス文を除いたもの) から記号を除き、空白で切り出した語について、同じ綴りが何回現れたかを数えた値を指す。切り出した語を重複も含めて数えた総数を**延べ語数**、同じ綴りを1語と数えた種類の数を**異なり語数**という。『赤毛のアン』は延べ語数が106,164、異なり語数が8,145である。

結果を図2.1に示す。左は普通の日盛り、右は両対数日盛りである。

左の図はほとんど何も見えない。出現回数は1位の単語 (the) が3905回、2位が3334回と多く、上位の数十語だけが高い位置にある。残りの数千語は底に張り付いている。

こういうときは、縦軸と横軸の両方を対数日盛にしてみる。桁の違う量を1枚に収める常套手段である。そうしたのが右の図で、点がきれいに直線に並んだ。

右下の様子も見ておく。点が横一列に並んだ帯が、何段も重なっている。1回しか出ない語、2回

^{*1} 「形態素」は意味を持つ最小の単位のこと、おおむね単語だと思ってよい。ただし「食べさせられた」が「食べ・させ・られ・た」の4つに切れるように、単語より細くなることもある。




図 2.1 『赤毛のアン』の単語頻度。1 語が 1 点である。右図の破線は傾き -1 の直線。右下で点が横に並んでいるのは、同じ回数しか出ない語が大量にあるためである。

しか出ない語、3 回しか出ない語が、それぞれ大量にあるということである*²。線をつないでしまうとこの段差が潰れて、なめらかな曲線に見えてしまう。

直線に並ぶということは、順位と頻度のあいだに単純な関係があるということである。その関係が **Zipf の法則**で、1932 年に言語学者ジョージ・キングズリー・ジップが報告した [12]。

$$\text{出現順位} \times \text{出現頻度} \approx \text{定数} \quad (2.1)$$

法則どおりなら、2 位の単語は 1 位のおよそ半分、3 位は 3 分の 1 になる。実際の『赤毛のアン』では 1 位 3905 回に対して 2 位が 3334 回で、半分の 1952 回より 71% 多い。Zipf の法則は正確な等式ではなく、広い範囲でおおよそ成り立つ関係として読むものである。

一般には**べき乗則** (power law) の形で書く。

$$f(r) \approx C \cdot r^\alpha \quad (2.2)$$

r が順位、 $f(r)$ がその順位の単語の頻度である。 $\alpha = -1$ とすると $f(r) \approx C/r$ 、つまり $r \cdot f(r) \approx C$ となって最初の式に戻る。

両辺の対数を取ると

$$\log f(r) = \log C + \alpha \log r \quad (2.3)$$

となる。 $\log r$ を横軸、 $\log f(r)$ を縦軸に取れば、これは傾き α 、切片 $\log C$ の直線の式である。両対数グラフで直線に見えたのは、そういうことだった。

*² 1 回しか出ない語を**ハパックス** (hapax legomenon) という。『赤毛のアン』では異なり語の 0.496 がハパックスである。この割合はテキストの長さによって変わるので、長さの違う文書どうしでは比べにくい。

補足 べき乗則はどこにでもある

都市の人口、地震のエネルギー、ウェブサイトの被リンク数、高所得者の所得。べき乗則は言語に限らず広く現れる。共通するのは「極端に大きいものが少数あり、小さいものが無数にある」構造である。

こうした分布では、平均値があまり役に立たない。裾の減り方が特に緩い場合、たとえば値が x 以上になる確率が $1/x$ と同じか、それより緩やかにしか減らない場合には、標本を集めるほど巨大な値が紛れ込んで平均を引き上げ、何件集めても平均が落ち着かない(確率密度を x^{-a} の形で書いたとき $a \leq 2$ にあたる。本文の順位-頻度の指数 α とは別の数である)。そこまで極端でなくても、少数の高額所得者が全体を引っ張って、平均が中央値から大きく離れる。「平均年収」が実感とずれるのはこの歪みのためである。分布が偏っているときは、平均を1つ出すだけでは足りない。中央値と分布の形もあわせて見る。この話は第3章でもう一度扱う。

2.2.1 同じ直線が乱数列からも出る

図 2.1 の右で点がきれいに直線に並んだ。これを見て「言語には法則がある」と言いたくなるところだが、その前に対照を置いておきたい。言語でないものを同じ手続きにかけたときに直線が出るかどうかを、先に確かめる。

やり方は素朴で、『赤毛のアン』の本文の文字を無作為に並べ替える。空白も混ぜたまま並べ替えるので、文字と空白の割合は原文と同じままである。ただし空白が隣り合った箇所は1つの区切りになるので、語の数はやや減り(延べ 106,164 語が 97,577 語に)、平均長は 4.09 字から 4.45 字に伸びる。長さの分布は幾何分布に近い形に変わり、語も文法も意味も残らない。残るのは**どの文字が出やすいかと空白の割合**だけである。これを原文とまったく同じ手続き(空白で切り、頻度順に並べる)にかける。

もう1系列、26文字を等確率で打ち、ところどころで空白を打った列も作った。空白を打つ確率 p は 0.244 とした。空白が続いた箇所は1つの区切りになるので、語の長さは平均 $1/0.244 \approx 4.10$ 字の幾何分布になり、原文の語の平均長 4.09 字にそろそろ。サルがタイプライターを打ち続けるという有名な思考実験を、そのまま実行したものである。

結果が図 2.2 である。

3系列とも同じ手続きで数え、両対数の上で順位 10 位から 1000 位までに最小二乗で直線を当てて、その傾きと決定係数を測る。原文は傾きが -1.178 、決定係数が 0.996 である。文字を並べ替えた列は傾きが -1.097 、決定係数が 0.990 である。語も意味も持たない列が、直線に乗るという点でも、傾きが -1 の近くにあるという点でも、原文と変わらない。図で並べ替えた列のほうが下を通っているのは語彙の大きさの違いで、直線かどうかとは別の話である。

文字を等確率で打った列だけは、階段状になって直線から外れる。傾きは -0.957 で -1 からそう遠くないが、決定係数は 0.622 しかなく、原文の 0.996 を大きく下回る。1文字の語が 26 個あってどれも同じ確率、2文字の語が 676 個あってどれも同じ確率、という作りなので、順位を上げても頻度が段でしか下がらない。文字の出やすさに偏りを入れると、この段がならされて直線になる。それが並べ替えた列である。

なぜ直線になるのかは、語を数えていけば見当がつく。1文字の語は 26 個しかないが、2文字の語は 26×26 で 676 個、3文字の語は 17576 個ある。文字が1つ増えるごとに、語の種類は 26 倍に増えていく。一方で、長い語ほど出にくい。文字をもう1つ引き当てなければならないので、1文字増




図 2.2 同じ手続きで数えた 3 系列の順位-頻度。上位 3000 語まで描いている。文字を並べ替えただけの列も、原文と同じように直線に乗る。原文より下を通るのは、異なり語数が原文の 6 倍あって 1 語あたりの出現回数が薄くなるためである。文字を等確率で打った列は階段状になる。段の高さが変わるのは語の長さが変わるところで、1 文字の語 26 個、2 文字の語 676 個が、それぞれ同じ確率で出る。

えるごとに、その語 1 つが出る確率は 26 分の 1 に薄まる (正確には空白を引かない確率 $1 - p$ も掛かるので、傾きは $-1 + \ln(1 - p)/\ln 26$ で、 $p = 0.244$ なら約 -1.09 になる)。順位のほうは 26 倍ずつ増え、頻度のほうは 26 分の 1 ずつ減る。片方が増えるのと同じ勢いでもう片方が減るのだから、両方の対数を取れば、傾きがほぼ -1 の直線になる。言語の性質は 1 つも使っていない。

図 2.3 には、この計算で決まる段と、文字を等確率で打った列の実際の頻度を重ねて描いた。段の左端を結ぶと、傾き約 -1.09 の直線になる。実測の傾き -0.957 がこれと違うのは、段の上に直線を当てているので、どこからどこまでを使うかで傾きが変わるためである。直線を当てた 10 位~1000 位の大半 (27 位~702 位) は、2 文字の語の段に入っている。




図 2.3 文字を等確率で打った列の順位-頻度と、Miller の議論から計算した段。文字が 1 つ増えるごとに、語の種類は 26 倍になり、1 語あたりの出現回数はおよそ 26 分の 1 になる。そのため段の左端は、両対数の上で傾き約 -1.09 の直線に並ぶ。

これは Miller が 1957 年に指摘し [15]、Li が 1992 年に無作為な文字列で確かめた [16]。

× アンチパターン 2.1 — 両対数の直線を言語の証拠として使う —

順位-頻度が両対数で直線に乗ることは、**分布が極端に偏っている**という以上のことを言わない。この直線を出すのに、語の意味も、文法も、書き手も要らない。文字の出やすさに偏りがあって、語の長さが幾何分布に近ければ、それだけで直線は出る。

「Zipf の法則によく当てはまるので、このデータには言語らしい構造がある」「べき乗則が成り立つので、背後に何らかの生成機構がある」という書き方は、どちらも直線から導けない。べき乗則は生成機構を1つに絞り込まない。まったく違う仕組みからも同じ直線が出る。

原文と乱数列の違いは、直線の形ではなく語彙の大きさと中身に出る。延べ語数は1割も変わらないのに、異なり語数は原文が 8,145 語、文字を並べ替えた列が 50,654 語で、後者が6倍以上多い。異なり語のうち一度きりしか出ない語 (ハパックス) が占める割合も、原文が 0.496、並べ替えた列が 0.919 で、倍近く違う。上位5語を並べれば違いはもっとはっきりする。原文は the, and, i, to, a、並べ替えた列は e, t, a, i, n である。後者は1文字の語が並んでいるだけで、機能語の顔ぶれではない。

本書が Zipf の法則から先に進むときに使うのも、直線の傾きではない。偏っているという事実と、上位に何が並ぶかという中身のほうである。

2.3 頻度の偏りが、使える語と使えない語を分ける

Zipf の法則が教えてくれるのは、**単語の頻度は極端に偏っている**ということである。この偏りが、どの語なら作品をまたいで比べられるかを決めてしまう。

上位を占めるのは the, and, of, to といった**機能語** (function word) である。それ自体では何も指さず、文の骨組みを作る役目だけを負う語で、日本語なら「は」「が」「を」「ので」がこれにあたる。何を書いているかと必ず出てくる。

対になるのが**内容語** (content word) である。「探偵」「馬車」「アリバイ」のように、それ自体が具体的な何かを指す語で、何を書いているかによって出たり出なかったりする。Zipf の分布の下位に大量にあるのは、こちらである。

文体の判別に向いているのはどちらか、性質を並べて比べる。

- 頻度の高い機能語 — どの文章にも出るので比較できる。書き手が意識せずに使うので癖が出やすい。
- 頻度の低い内容語 — 出たり出なかったりするので比較しにくい。そして**題材**を反映してしまう。

「探偵」「犯人」「アリバイ」という単語で分類すれば、探偵小説を書く作家はきれいに分かれるだろう。だがそれは文体ではなくジャンルを見ているだけである。

× アンチパターン 2.2 — 頻出する内容語で著者を判別する —

著者判別で「主人公の名前」や「作品固有の地名」が分類の決め手になってしまうことがある。精度は上がるが、その分類器は**未知の作品には役に立たない**。新しい作品には別の主人公が出てくるからである。

2.4 むらなく現れる語と固まって現れる語

機能語が文体の手がかりになるなら、その現れ方をもう少し詳しく見ておきたい。同じ現象を二通りに観察する。**回数を数える**見方と、**間隔を測る**見方である。

具体的に思い浮かべるには、新聞がよい。紙面を同じ大きさの区画に等分し、区画ごとに接続詞「しかし」が何回現れるかを数える。0 回の区画がいくつ、1 回の区画がいくつ、とヒストグラムにすれば、これが**回数**の見方である。同じ紙面で、「しかし」が出てから次の「しかし」が出るまでの字数を測って並べれば、こちらは**間隔**の見方になる。図 2.4 に、2 つの見方の関係を示す。



図 2.4 同じ紙面の二通りの見方。× が「しかし」の出現位置。(a) は区画 (本文の「ブロック」にあたる) に区切って回数を数え、(b) は出現から次の出現までの間隔を字数で測る (緑の数字)。よく混ざった出現なら、(a) はポアソン分布に、(b) は指数分布に従う。

2.4.1 回数で見る — ポアソン分布

パン生地レーズンを混ぜ込み、よく捏ねてから焼いて、等分に切り分けるとする。一切れに入るレーズンの数は、平均のまわりでばらつく。誰も狙って配置していないのだから、5 個の切れもあるかもしれない、0 個の切れもある。

このばらつき方には決まった形がある。「**全体としては一定の割合で、個々の場所はでたらめ**」という条件さえ満たせば、レーズンでも何でも同じ形の分布になることが知られている。これを**ポアソン分布** (Poisson distribution) という。

『赤毛のアン』の本文を 500 語ずつの**ブロック**に分け、各ブロックの中で特定の単語が何回出るかを数える (212 個のブロックができる。最後の 500 語に満たない端数は使わない)。単語がレーズンで、500 語のブロックが一切れのパンにあたる。書き手がその単語を意識せず、文章のどこにでも満遍なく撒いているなら、回数はポアソン分布に従うはずである。

$$P(X = k) = \frac{m^k e^{-m}}{k!} \quad (2.4)$$

m は 1 ブロックあたりの平均出現回数である。式の細部より、次の 2 つの性質を覚えてほしい。

1 つは、山が平均 m の近くに來ることである。もう 1 つは、**平均と分散が等しい**ことである。

後者が本節の要になる。なぜ等しくなるかは式から出てくることだが、意味のほうを押さえておきたい。ポアソン分布は「でたらめに撒いた」状態を表す分布だった。その状態でのばらつきの大きさ (分散) が、ちょうど m になる。つまり**平均と分散が等しい**というのは、**でたらめに撒いたときの標準的なばらつき方**を指している。

だから、実際に数えたデータの分散が平均を大きく上回れば、でたらめではない何かが起きていることになる。ある場所に固まって出ている。本節ではこの物差しを使って、機能語と内容語を分ける。

交通事故の件数、1年間に落下する隕石の数。「試行の機会是非常に多いが、1回ごとにはめったに起きない事象」がポアソン分布になる。“up”は1語ごとに見れば0.4%ほどしか出ないので、この条件に近い。

図2.5に二つの単語の分布を示す。




図 2.5 機能語と固有名詞の出現分布。500 語のブロック 212 個について、その語が 0 回、1 回、…出たブロックの数を数えた。左はポアソン分布によく合うが、右は合わない。

左の“up”は理論曲線によく乗っている。右の“marilla”(登場人物の名前)は大きく外れる。

外れ方に意味がある。マリラが出てくる場面ではまとめて何度も出て、出てこない場面では一度も出ない。**文章の内容に結びついた単語ほど、ポアソン分布から外れる。**

ただし、機能語ならどれもポアソン分布に乗るわけではない。同じ 500 語のブロックで数えると、“the”の分散は平均の 2.49 倍、“i”は 4.18 倍、“you”は 3.61 倍で、“marilla”の 2.44 倍と変わらないか、それより大きい。“i”や“you”は会話の場面に集まり、地の文ではあまり出ないからである。ポアソン分布からのずれは、題材だけでなく、会話か地の文かといった文章の種類の切り替わりからも生じる。“up”は、そうした切り替わりの影響を受けにくい語の例である。

分散と平均の比には、もう一つ注意がある。この比は、偏りの程度が同じでも、1 ブロックあたりの平均回数が大きい語ほど大きく出る。ブロックごとの出現率が、平均 m のまわりで cm 程度 (率の c 倍) 揺れているとすると、回数の分散はポアソン分布のぶんの m に揺れのぶんの c^2m^2 が足されて $m + c^2m^2$ になり、分散と平均の比は $1 + c^2m$ になる。“the”は 1 ブロックに平均 18.4 回出るので、率の揺れ c が 0.28 程度と小さくても、比は 2 を超える。“marilla”の c は 0.60 で、揺れそのものは“the”の倍以上ある。平均回数の違う語どうしを比べるときは、比から 1 を引いて平均で割った値 c^2 か、次の項で扱う間隔の変動係数を使う。

図 2.6 は、『赤毛のアン』で出現回数の多い語について、次の項で扱う間隔の変動係数を縦軸に取って並べた図である。変動係数は平均回数に左右されにくいので、多い語と少ない語をそのまま比べられる。ポアソンの散らばり方なら 1 の近くに来る。代名詞以外の機能語はおおむね 1 の近くに集まり、人名は 2 から 3 あまりまで離れる。代名詞は機能語でありながら、その中間に広がっている。




図 2.6 語ごとの散らばり方。『赤毛のアン』で出現回数の多い約 50 語と人名を、1 ブロックあたりの平均回数と、出現間隔の変動係数 (標準偏差 ÷ 平均) で並べた。破線の 1 がポアソンの散らばり方の目安である。語の分類は生成スクリプトの中で手で指定した。

コラム モステラーとウォレスもポアソン分布だけでは済ませなかった

第 1 章で紹介したモステラーとウォレスのフェデラリスト研究は、語の回数の確率モデルを正面から扱った仕事でもあった [1]。

識別に使った語の代表が “upon” である。ハミルトンは 1000 語あたり 3 回ほど使うのに、マディソンはほとんど使わない。ちなみに『赤毛のアン』の本文では、延べ 106,164 語のうち “upon” は 17 回しか出ない。

2 人は、決まった長さの文章に語が何回出るかを、ポアソン分布と負の二項分布の 2 通りでモデル化し、両方の結果を示した [20]。負の二項分布は、ブロックごとに出現率そのものが揺れることを許した分布で、分散が平均より大きくなる。分散は $m + m^2/k$ の形をしていて、本節の $m + c^2 m^2$ で $c^2 = 1/k$ と置いたものに当たる。

のちに Albert と Hu は、ベイズ統計の教科書の事例研究でフェデラリストの語の回数を分析し直し、“can” の回数がポアソン分布で予想されるより大きく散らばること、負の二項分布ならその散らばりを説明できることを示している [21]。機能語でもポアソン分布からずれることがあるという図 2.6 の観察と同じことが、200 年以上前の政治論文でも起きている。

この観察から残差 IDF という単語の重要度指標が提案されている [17]^{*3}。ポアソン分布からのずれが大きい単語ほど、内容語らしいと判定する。

○ 定石 2.1 — 著者を当てるなら文書全体に一樣に散らばる単語を選ぶ —

書いた人を当てたい場合の話である。

ポアソン分布によく従う単語 — つまり文章のどこにでも一樣に散らばっている単語 — を選ぶ。これらは書き手の癖を反映し、題材には依存しにくい。

^{*3} IDF (inverse document frequency、逆文書頻度) は情報検索で使う重み付けで、その単語が現れる文書の割合の逆数の対数、つまり少数の文書にしか出ない語ほど大きくなる量である。残差 IDF は、実際に観測された IDF から、ポアソン分布を仮定したときに期待される IDF を引いた差を指す。

当てたいものが話題やジャンルなら、基準は逆になる。ポアソンから外れて特定の箇所に固まる単語こそが、その文書が何について書かれたかを示している。

補足 TF-IDF は「何を当てたいか」を決めてくれない

テキストを数値にするとき、最もよく使われる重みが **TF-IDF** である。文書中の出現回数 (TF) に、その語が何割の文書に出るかの逆数の対数 (IDF) を掛ける。

IDF の働きは、**どの文書にも出る語を軽くすること**である。「は」「が」「の」のような機能語は、すべての文書に出るので IDF がほぼ 0 になり、重みが消える。残るのは少数の文書にしか出ない語、つまり内容語である (ここでの IDF は $\log(N/df)$ の場合である。 N は文書の数、 df はその語が出る文書の数を表す。scikit-learn の `TfidfVectorizer` は既定で $\ln \frac{1+N}{1+df} + 1$ を使うので、すべての文書に出る語の IDF は 0 ではなく 1 になり、重みは消えずに相対的に軽くなる)。

情報検索では、これが正しい設計である。「猫」で検索した人が探しているのは猫の文書であって、「は」を含む文書ではない。

だが本書の目的からすると、**TF-IDF は残すべき語を消してしまう**。著者の癖が出るのは機能語の側だからである。残った内容語を特徴にすれば、モデルは文体ではないものも手がかりにできる。数える対象を広げると、当てたいもの以外を拾う余地が増える。第9章で文字 n-gram を使うと、重要度の上位には接続の言い回しと並んで、会話文の閉じかぎ括弧のあとで改行する組み方のような表記の約束が来る。人名はこのとき上位 500 種類の語彙にも入らないが、語彙を広げれば、人名や地名のような作品固有の並びも候補に入ってくる。

TF-IDF が悪いのではない。検索という目的のために作られた重みを、別の目的にそのまま持ってきたことが問題になる。**既定の重み付けにも、それが想定している目的がある**。

× アンチパターン 2.3 — ワードクラウドや共起ネットワークを分析の結論として出す

テキスト分析の報告でよく見かける 2 つの図には、共通した弱点がある。

ワードクラウドは、語の大きさに頻度を表す。だが面積が頻度に比例しているとは限らず、語の配置や向きにも意味がない。2 つの語の大小を目で比べることも、2 つの図を並べて比べることもできない。何より、**どの語を除外したか**で見た目が大きく変わる。ストップワードの一覧を少し変えれば、まるで違う雲が出てくる。

共起ネットワークも同じ性質を持つ。辺を張る基準 (共起の回数か、相関か、対数尤度比か)、その閾値、描画のアルゴリズム。どれを選ぶかで図の形が変わるのに、出来上がった図はどれも「それらしく」見える。

どちらも、**見た人が意味を読み取れてしまう点**が共通している。出てきた図から物語を作ることはいくらでもできるが、別の設定で作り直せば別の物語ができる。

頻度を比べたいなら棒グラフを使う。語どうしの関係を見たいなら、どの基準でどの閾値を使ったかを明記したうえで、その選択が結論を変えないかを確認する。探索の途中で眺めるぶんには構わないが、**結論の証拠としては弱い**。

2.4.2 間隔で見る — 指数分布

回数を数える代わりに、**同じ単語が次に現れるまでの語数**を記録する方法もある。以下、間隔はすべて『赤毛のアン』の本文を通して語数で測った値である。“up” は本文で 452 回現れるので、隣り

合う出現の間の間隔が $452 - 1$ 個得られる。今度は間隔の分布を見る。

時刻表のないバス停を思い浮かべてほしい。バスは平均すれば 1 時間に 4 本来るが、いつ来るかはでたらめだとする。このとき、あるバスが出てから次のバスが来るまでの間隔が指数分布 (exponential distribution) に従う。いま測ろうとしている単語の間隔と、同じ量である。

指数分布の形は、短い間隔がいちばん多く、そこから長いほうへ向かって減っていく。減り方には特徴があって、間隔が 10 分伸びるごとに確率が同じ割合ずつ減る。10 分から 20 分になるときも、60 分から 70 分になるときも、減る比率は同じである。

この形から、少し意外な性質が出てくる。バス停で 10 分待ったところで、そこから先の待ち時間の分布は、着いた瞬間とまったく同じになる。「もう 10 分も待ったから、そろそろ来るはずだ」は成り立たない。どれだけ待ったかという過去を、分布が覚えていない。この性質を無記憶性 (memorylessness) という。

$$p(x) = \lambda e^{-\lambda x} \quad (2.5)$$

λ は単位長さ (単語の場合は 1 語) あたりの出現率で、間隔の平均は $1/\lambda$ になる。

ポアソン分布と指数分布は、同じ現象を別の側から見たものである。出現が互いに独立で、出現率が場所によらず一定なら (これを「よく混ざった出現」と呼んできた)、どの長さで区切って数えても回数はポアソン分布になり、出現から次の出現までの間隔は指数分布になる。なぜそう言えるのかは、次の発展で導く。理由は、「間隔が x より長い」とことと「長さ x の区間に一度も出ない」ことが同じ事象だからである。逆に、500 語のブロックで数えた回数の分布がポアソン分布に合っても、それだけで間隔が指数分布に従うとまでは言えない。二つの図を両方描くのはそのためである。

発展 ポアソン分布から指数分布を導く

出現率を λ (1 語進むあたり平均 λ 回) とする。よく混ざった出現では、長さ x の区間に入る回数 X は平均 λx のポアソン分布に従う。

$$P(X = k) = \frac{(\lambda x)^k e^{-\lambda x}}{k!} \quad (2.6)$$

本文のポアソンの式の m (1 ブロックあたりの平均回数) は、いまの記法では 500λ にあたる。 m と λ は、ブロック幅 500 語を掛けるかどうかだけが違う同じ「率」である。

いま、ある出現の直後から数えて、次の出現までの間隔 T を考える。「 T が x より長い」とは、「直後の長さ x の区間に一度も出ない」ということである。同じ事象なので確率も等しく、上の式に $k = 0$ を入れるだけで

$$P(T > x) = P(X = 0) = e^{-\lambda x} \quad (2.7)$$

が出る。累積分布は $F(x) = 1 - e^{-\lambda x}$ 、微分すれば密度

$$p(x) = F'(x) = \lambda e^{-\lambda x} \quad (2.8)$$

となって、指数分布そのものである。ポアソン分布の $k = 0$ の項だけから、間隔の分布が丸ごと決まってしまう。

無記憶性も同じ式から 1 行で出る。 s 語待って出なかったという条件の下で、さらに t 語出ない確率は

発展 (続き)

$$P(T > s + t | T > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(T > t) \quad (2.9)$$

となり、すでに待った長さ s が消える。

逆向きも成り立つ。間隔が互いに独立に同じ指数分布に従うなら、区間内の回数はポアソン分布になる。つまり「回数がポアソン」と「間隔が指数」は、同じ確率モデル (ポアソン過程 (Poisson process)) の二つの断面である。おまけとして、次の1回ではなく k 回目の出現までの待ち時間を考えると、指数分布を k 個足したことになる、ガンマ分布 (アーラン分布) が現れる。指数分布はその $k = 1$ の特別な場合である。

指数分布には、目で確かめやすいという利点がある。縦軸を対数にすると $\ln p(x) = \ln \lambda - \lambda x$ となって直線になるからである。「片対数のグラフで直線に乗るか」が、よく混ざっているかどうかの簡便な検査になる。




図 2.7 同じ 2 つの単語を「間隔」で見る。縦軸が対数なので、指数分布は直線になる。“up” は乗るが、“marilla” は短い間隔が多すぎ、長い間隔也多すぎる。

図 2.7 の左、“up” はおおむね直線に乗る。間隔の平均は 235 語、**変動係数** (標準偏差 ÷ 平均) は 1.03 である。指数分布では平均も標準偏差もどちらも $1/\lambda$ になるので、変動係数の理論値はちょうど 1 である。実測の 1.03 は、その理論値を 0.03 上回るだけである。

右の“marilla”は**両端**で直線から外れる。短い間隔が多すぎ (左端の点が直線より上)、そのくせ最長の間隔は 3761 語に達する。マリラは“up”の倍近く登場する (838 回対 452 回) のだから、よく混ざっていれば沈黙はむしろ短くなるはずである。実際には、間隔の中央値は 64 語しかないのに平均は 127 語で、変動係数は 2.07 になる。指数分布の理論値 1 の 2 倍を超えていて、“up”の 1.03 とは大きく違う。**出るときは続けて出て、出ないときは延々と出ない**。この性質を**バースト性** (burstiness) という。マリラの登場する場面と登場しない場面がある、という物語の構造そのものが数値に写っている。

ところで、“up”の側でも、図 2.7 の当てはまりは図 2.5 ほどびたりとは見えない。これには次の事情がある。

- 縦軸が対数だから。裾のビンの度数は 1 や 2 しかなく、そこでの ± 1 個の揺らぎは対数軸の上で

は大きな上下に見える。図 2.5 は線形軸で、しかも度数の大きい山の近くしか目に入らない。

- **集計の量**が違うから。回数の見方は 212 個のブロックを 0~9 回の 10 通りの値に集めるので偶然が均されるが、間隔の見方は 451 個の間隔を 14 本のピンに散らすので、1 本あたりの標本が少なく、ばらつきがそのまま残る。
- “up” 自体が完全なポアソンではないから (変動係数 1.03 はわずかに 1 を超えている)。ずれは、集計で均される回数の図では隠れ、集計しない間隔の図ではそのまま見える。

当てはまりが粗く見えるのは、間隔という見方が偶然のゆらぎにも実際のずれにも敏感であることの裏返しで、検査の道具としては、このずれへの敏感さこそ望ましい。

コラム 待ち時間のパラドックスとマリラ

バスが平均 15 分おきに、でたらめな時刻に来るとする。でたらめな時刻にバス停に着いた人は、平均何分待つことになるか。間隔の半分の 7.5 分と答えたいが、答えは 15 分である。無記憶性から、着いた瞬間から先の待ち時間は、バスが出た直後から測った間隔と同じ分布に従うからである。

別の見方もできる。長い間隔ほど、その途中に着いてしまう確率が高い。着いた人が「当たる」間隔は、平均的な間隔より長いほうに偏る。これを**待ち時間のパラドックス** (inspection paradox) という [22]。一般に、間隔 T の平均を $\bar{T}$ 、変動係数を CV とすると、でたらめな位置から次の出現までの平均は $\bar{T}(1 + CV^2)/2$ になる。指数分布なら $CV = 1$ なので、平均間隔 $\bar{T}$ そのものになる。

『赤毛のアン』で確かめる。本を適当な位置で開いてから次の“up”が出るまでは平均 243 語で、平均間隔の 235 語とほぼ同じである (変動係数 1.03)。“marilla”は平均間隔が 127 語と“up”の半分ほどなのに、適当な位置で開いてから次の“marilla”が出るまでは平均 334 語かかる (変動係数 2.07)。マリラは登場する場面に固まって出るので、適当に開いた位置は、マリラの出ない長い空白に当たりやすい。

バーストする語では、読んでいて感じる出会いにくさと、数えた頻度とが食い違う。平均間隔だけでは語の出やすさを言い表せない理由の一つである。

2.4.3 回数と間隔は同じ現象を別の側から測っている

図 2.5 と図 2.7 は同じ現象の写し方を変えただけだが、実務上の得失がある。

回数方式の弱点は、**ブロック幅を自分で決めなければならない**ことである。本節では 500 語にしたが、これに根拠はない。幅を変えると図の形も変わり、細かすぎればほとんどのブロックが 0 回か 1 回になってバーストが見えにくくなり、粗すぎればブロックの数が減って分布の形が定まらなくなる。図 2.8 は“marilla”を幅 100 語、500 語、2000 語で数え直した結果である。分散と平均の比は 1.21、2.44、4.82 と変わり、幅 100 語ではポアソン分布との違いが目立たなくなる。また、ブロックの境界をまたぐ近接出現は別々のブロックに分かれて、「まとまって出た」という情報が消える。代わりに、集計するぶん個々の値は安定していて、複数のテキストをブロック数を揃えて比べるのも簡単である。

間隔方式にはブロック幅という決めごとがない。図 2.7 のヒストグラムには 100 語のピン幅を使ったが、間隔が x を超える割合を描けば、ピン幅も決めずに済む (図 2.9)。指数分布なら発展で導いた $P(T > x) = e^{-\lambda x}$ のとおり、片対数の上で直線になる。バーストは「短い間隔の過剰」として直接目に見える。

その代わり、標本の数はいくつ出現回数で頭打ちになるので、まれな語では分布の形が定まらない。裾も重いので、平均が少数の長い間隔に引っ張られやすい。




図 2.8 “marilla” の回数をブロック幅を変えて数えた分布 (棒) と、同じ平均のポアソン分布 (破線)。縦軸はブロックの数ではなく割合で、ブロックの数はそれぞれ 1061、212、53 個である。題の「比」は分散と平均の比で、ポアソン分布なら 1 になる。




図 2.9 間隔が x 語を超える割合。ヒストグラムと違ってビン幅を決めずに描ける。指数分布なら片対数の上で直線 (破線) になる。“marilla” は最初に急に落ち (短い間隔が多い)、そのあと破線より上に長く残る (長い沈黙が多い)。

○ 定石 2.2 — 刻み幅を自分で決めたら刻み幅のいらない見方でも確かめる —

ブロック幅、ビンの幅、集計の単位。分析者が決めた刻みは、結果の見え方を左右する。片方だけでは、見たものが現象なのか、自分の決めた刻み幅の産物なのか区別がつかない。本節でいえば、回数の見方はブロック幅に依存し、間隔の見方は依存しない (間隔のヒストグラムにもビン幅はあるが、変動係数や、間隔が x を超える割合の図なら刻みを決めずに済む)。両方描いて同じ結論になるかを確かめるのが安全である。とくに「ポアソン分布に合っている」と主張したいときは、ブロック幅に依存しない間隔の図を添えると強い。

発展 離散と連続とバースト性の指標

語数は整数なので、間隔の分布は厳密には指数分布にならない。各語の位置で**独立に、一定の確率**で出現すると仮定すれば、間隔は指数分布の離散版である**幾何分布**に従う。出現率 λ が小さければ両者はほとんど区別できないので、本節では連続の指数分布で通した。なお、観測した度数分布が幾何分布や指数

発展（続き）

分布に合っていない、それだけで出現の独立性まで確かめたことにはならない。

バースト性の大きさは、変動係数 CV から作った $B = (CV - 1)/(CV + 1)$ という指標で測ることが多い [19]。ポアソンのなら $B \approx 0$ 、バーストが強いほど 1 に近づく。“up” は $B \approx 0.02$ 、“marilla” は $B \approx 0.35$ である。単語の再帰間隔の分布は、指数分布よりワイブル分布のほうがよく当てはまるという報告もある [18]。内容語ほど形状パラメータが 1 から離れる、つまりバーストが強いという結果で、本節の観察と同じことをより精密に測っている。

2.5 日本語には語の区切りがない

ここまでの議論は英語を前提にしていた。日本語には空白による語の区切りがなく、単語を数えるには本章の冒頭で触れた形態素解析が必要になる。

形態素解析は有用な道具だが、辞書を含むソフトウェアの導入に手間がかかり、固有名詞や古い言い回しでは切り方を誤ることもある。本書は環境構築でつまずかずに進めることを優先して、別の道を選ぶ。**単語を数えず、文字を数える。**

日本語には英語にない性質がある。平仮名・片仮名・漢字という 3 種類の文字体系が混在していることである。どの語をどの文字種で書くかには、書き手ごとの選択がある。

- 「わたし」か「私」か
- 「たくさん」か「沢山」か
- 「コンピュータ」か「計算機」か

どちらを選ぶかは、内容とはほとんど無関係に、書き手の習慣で決まる。機能語に求めた「内容に依存せず、書き手が意識しない」という条件を、単語ではなく文字のレベルで満たしているわけである。

2.5.1 単語の代わりに数える単位 — n-gram

「単語を数えず、文字を数える」という方針を道具にしたものが **n-gram**(n-グラム) である。連続する n 個の並びを 1 つの単位として数える。何を 1 個と見るかで 2 種類ある。

- **単語 n-gram** — 語を単位にする。the cat sat から 2-gram を取ると the cat と cat sat の 2 つになる
- **文字 n-gram** — 文字を単位にする。「吾輩は猫である」から 3-gram を取ると「吾輩は」「輩は猫」「は猫で」「猫であ」「である」の 5 つになる

日本語で文字 n-gram がよく使われるのは、語の区切りを決めずに済むからである。形態素解析を通さなくても、 n 文字の窓を 1 文字ずつずらして数えるだけで、表の形になる。 $n = 1$ なら文字そのものの頻度、 n を上げるほど長い言い回しを捉える。

代償として、 n を上げると列の種類が急に増える。常用漢字だけで 2136 字あるので、漢字 2 文字の並びだけで約 456 万通りある。実際に現れるのはその一部だが、それでも数千から数万の列になり、第 9 章で扱う次元の問題が顔を出す。

本書は文字 n-gram を主役にしない。第 9.6 節で確かめるように、文字 n-gram は文法的な並びと

一緒に、改行やかぎ括弧のような表記の約束も拾い（語彙を広げれば登場人物の名前のような**固有名詞**も入ってくる）、モデルが何を手がかりに著者を当てたのかが分かりにくくなるからである。ただし本書が数えるものも、n-gram の一種として書き直せる。字種の比率は $n = 1$ の文字 n-gram を3つの集合にまとめたものであり、読点の直前に来る平仮名は、**2文字目を読点に固定した文字 2-gram** にあたる。n-gram をそのまま全部使うのではなく、条件を付けて絞り込んだものが本書の特徴である、と見ることができる（図 2.10）。

(a) 文字 3-gram(3 文字の窓を 1 文字ずつずらす)



(b) 本書の特徴 (2 文字目を読点に固定した 2-gram)




図 2.10 文字 n-gram と本書の特徴の関係。(a) は窓の中の並びをすべて数える。(b) は読点で終わる 2 文字の並びだけを数え、1 文字目の平仮名で分類する。

発展 n-gram の統計から語彙を取り出す — 分岐エントロピー

n-gram の数え上げだけを使って、辞書も学習データも使わずに語の切れ目を見つける方法がある。

考え方は Harris にさかのぼる [6]。語の切れ目では、**次に来る文字の種類が急に増える**。「自然言」まで読んだ時点では次の文字はほぼ「語」に決まっているが、「自然言語」まで読むと、次には「処」「の」「を」「は」など多くの文字が来る。語の内部では次の文字が絞られ、語の終わりで一気に広がるわけである。

この広がりをエントロピーで測ったものを**分岐エントロピー** (branching entropy) という。ある文字列の後ろに続く文字の分布を n-gram の頻度から求め、その分布のエントロピーを取る。文字列を 1 文字ずつ伸ばしながらこの値を追い、値が減少から増加に転じた位置を語の境界とみなす。Jin と Tanaka-Ishii は、この方法だけで中国語の文を語に分割できることを示した [7]。

こうして得られるのは語の一覧、つまり**語彙**である。数えるだけで、そのテキストに現れる語をある程度まで取り出せる。

ただし本書の課題には向かない。この方法が取り出すのは内容語を含む語彙全体であって、本章で機能語に求めた「内容に依存しない」という条件から外れる。著者ではなく話題を当てる特徴になってしまう。

次章では、文字を数えるという方針で 3 種類の特徴を設計する。

2.6 章末の課題

1. 図 2.1 の両対数グラフから、傾き α を目分量で読み取れ。-1 にどれだけ近いかな。
2. 日本語のテキストで同じことをするには何が必要か。単語ではなく文字単位で Zipf の法則を調べると、どうなると予想するか。
3. 図 2.2 の「文字を並べ替えた列」を自分で作り、順位 10 位から 1000 位の傾きを測れ。次に、文

字ではなく**単語の順序**だけを並べ替えたら順位-頻度がどうなるかを、測る前に予想せよ。予想が当たった理由、あるいは外れた理由を1行で書け。

4. “the” と “said” について、回数 (ポアソン分布) と間隔 (指数分布) の両方で適合を調べよ。分散と平均の比と、間隔の変動係数は、それぞれどちらの単語のほうが1に近い。2つの見方の結論は一致するか。(ヒント: 平均回数の違いが比にどう影響するかは、本文の $1 + c^2 m$ の式で考えるとよい。)
5. 図 2.8 と同じ描き直し (ブロック幅 100 語、500 語、2000 語) を、“up” について行え。“marilla” と比べて、幅による見え方の変わり方はどう違うか。ブロック幅によらない結論を引き出すにはどうすればよい。
6. 手元にある好きな小説の1章分で、助詞「と」の出現間隔を字数で測り、片対数のグラフに描け。直線に乗るか。乗らないなら、どちら側にどうずれているか。(ヒント: 「～と言った」のような会話の受けの「と」は、会話場面にまとまって現れやすい。図 2.7 の “marilla” と見比べるとよい。)

第3章

特徴を設計する

3.1 何を数えるかを定める

前章で方針は決まった。内容に依存せず、書き手が意識しない量を数える。本章ではそれを3種類作る。作業の全体像を図3.1に示す。




図3.1 特徴量を作る手順。3種類の特徴を横に並べて1枚の表にする。

3.2 前処理 — 情報の出どころで捨てるものを決める

青空文庫のテキストには、本文以外の情報が混ざっている。

斜陽
太宰治

【テキスト中に現れる記号について】
《》：ルビ
(例) 生国《しょうごく》

朝、食堂でスープを一さじ、すっと吸って...

本文だけを取り出す。捨てるものを順に挙げる。

1. ヘッダとフッタ — 罫線より前、「底本」以降
2. ルビ — 生国《しょうごく》の《》の中
3. 注記 — [#改ページ] のような編集記号

4. 飾り罫 — 場面の区切りに並べた * や - など

```
RUBY = re.compile(r"《[^》]+》")
ANNOTATION = re.compile(r" [# [^] ]+ ")
DECORATION = re.compile(r"[*\\-| | ]+") # 飾り罫

def strip_annotations(text: str) -> str:
    text = RUBY.sub("", text.replace(" | ", ""))
    text = ANNOTATION.sub("", text)
    return DECORATION.sub("", text)
```

× アンチパターン 3.1 — ルビや注記を取り除かず文字を数える

ルビを残したまま文字種を数えると、平仮名の比率が跳ね上がる。本書の 74 作品で確かめると、ルビを残したまま数えた平仮名の比率は、泉鏡花の 9 作品の平均で 0.662 から 0.712 に上がるが、太宰治では 0.689 から 0.695 にしか上がらない (表 3.1)。上がり方が著者ごとに違うので、その差がそのまま文体の差に見えてしまう。しかもルビの量は**出版社の方針**で決まるので、著者の文体とは関係のない差が入り込む。同じ作家の作品が、収録された全集ごとに別のクラスタに分かれる、ということが起こりうる。

表 3.1 ルビを除いて数えた平仮名の比率と、ルビを残して数えた比率 (著者ごとの平均)。注記と飾り罫はどちらも除いた。上がり方は著者によって大きく違う

著者	ルビを除く	ルビを残す	差 (平均)	差 (最大の作品)
泉鏡花	0.662	0.712	+0.050	+0.078
島崎藤村	0.634	0.666	+0.032	+0.111
夏目漱石	0.668	0.695	+0.027	+0.046
吉川英治	0.667	0.688	+0.021	+0.029
柳田国男	0.645	0.665	+0.020	+0.028
谷崎潤一郎	0.687	0.705	+0.018	+0.042
夢野久作	0.621	0.632	+0.011	+0.019
太宰治	0.689	0.695	+0.006	+0.012

○ 定石 3.1 — 捨てるものはその情報が誰に由来するかで決める

前処理とは、要するに**何を捨てるかを決める**作業である。「よく分からないので全部残す」も「念のため全部消す」も、判断ではない。

物差しの一つが**由来**である。ルビの量を決めているのは著者ではなく編集者や出版社だから、著者を当てたいなら捨てる。読点の位置は著者が決めているので残す。当てたい相手が出版社なら、判断は逆になる。残すか捨てるかは、データの性質ではなく**問いの側**が決める。

× アンチパターン 3.2 — 分析に使う CSV を表計算ソフトで開く

捨てるつもりがないのに捨ててしまうこともある。

CSV を表計算ソフトで開くと、中身を見た瞬間に**型を推測して書き換える**機能が働く。書き換えたという記録は残らないので、以降のすべての分析が汚染されたまま進む。

生物学ではよく知られた事故がある。遺伝子名の SEPT2 が日付の「2-Sep」に、MARCH1 が「1-Mar」に変換されてしまう。2016 年の調査では遺伝子リストを載せた論文の約 2 割 [120]、2021 年に 1 万本以上を再調査したときには 3 割以上がこの変換で汚染されていた [121]。

日本語のデータでも起きる。先頭が 0 の郵便番号や電話番号は 0 が落ち、1E5 のような文字列は指数表記の数値になり、長い数値は勝手に丸められる。

分析に使うファイルは、表計算ソフトで開かない。中身を見たいなら、テキストエディタか、`pl.read_csv` で読んでから確かめる。どうしても開くなら、書き換えられていないかを開く前後で照合する。

コラム 表計算ソフトに合わせて名前を変えた遺伝子

本文の遺伝子名の事故には続きがある。2016 年の調査で、遺伝子リストを付けた論文の約 2 割 (19.6%) が日付への変換で汚染されていると報告された [120]。その 5 年後の再調査では、表計算ソフトの形式で遺伝子リストを付けた 11,117 本の論文のうち、30.9% に誤りが見つかった [121]。調べる論文の範囲と見つける誤りの種類を広げたぶん 2016 年の値より高く出ているが、2014 年から 2020 年までのあいだ、誤りを含む論文の割合は下がらなかった。使い手に注意を呼びかけるだけでは、減らなかったことになる。

2020 年、ヒトの遺伝子の名前を決める HUGO 遺伝子命名委員会 (HGNC) は、表計算ソフトの側ではなく、遺伝子の名前の側を変えることにした [122, 121]。SEPT1 は SEPTIN1 に、MARCH1 は MARCHF1 になり、日付と読まれうる記号が名前の一覧から消えた。

ただし再調査の論文は、新しい記号が論文の中に行き渡るには何か月、あるいは何年もかかるだろうと述べている [121]。すでに出版された論文の表は書き換えられないので、古い記号の汚染はそのまま残る。道具が黙って書き換える経路は、使い手の注意だけでは塞ぎきれない。本文で「開く前後で照合する」と書いたのは、この経路を手順の側で塞ぐためである。

3.3 特徴設計 1 — 文字種の比率

日本語は平仮名・片仮名・漢字が混ざる。その比率を数える。

```
import regex

def count_char_types(text: str) -> dict[str, int]:
    return {
        "平仮名": len(regex.findall(r"\p{Hiragana}", text)),
        "片仮名": len(regex.findall(r"\p{Katakana}", text)),
        "漢字": len(regex.findall(r"\p{Han}", text)),
    }
```

このままでは使えない。長い作品ほど数が大きくなるからである。『三国志』は桃園の巻 1 冊 (約 15.6 万字) でも、『走れメロス』 (約 1 万字) の約 16 倍の文字数がある。数えた回数をそのまま並べ

ば、文体の違いではなく作品の長さの違いを見ることになってしまう。

素直な対処は、**総文字数で割って割合にすること**である。「漢字が 12 万字」ではなく「漢字が全体の 33%」と言え、長さの違いは消える。このように、作品ごとの大きさの違いをそろえる操作を**正規化 (normalization)** という。

3.3.1 正規化は大きさだけを揃えて向きを残す

「総文字数で割る」は正規化の一例でしかない。何で割るかには選択肢があり、選び方で結果が変わる。そこを見るために、いったん幾何の話にする。

2 次元で考えると分かりやすい。点 (x, y) を、原点から見た**方向はそのままに、大きさだけを揃える**。点を原点から見た矢印だと思えば、向きを変えずに長さだけを 1 にそろえる操作にあたる。

その「長さ」の測り方に、2 つの流儀がある^{*1}。

$$\ell_1 \text{ 正規化: } (x, y) \mapsto \left(\frac{x}{x+y}, \frac{y}{x+y} \right) \quad (3.1)$$

$$\ell_2 \text{ 正規化: } (x, y) \mapsto \left(\frac{x}{\sqrt{x^2+y^2}}, \frac{y}{\sqrt{x^2+y^2}} \right) \quad (3.2)$$

どちらも「点を原点方向に動かして、ある図形の上に載せる」操作で、違うのは載せる先である。




図 3.2 正規化は「原点からの方向を保ったまま、決まった図形の上に載せる」操作。載せる先が ℓ_1 では直線、 ℓ_2 では円になる。

図 3.2 で、点 P と Q は原点から見て別の方向にある。正規化しても**方向は変わらない**。破線の上を滑って、直線または円の上に着るだけである。

^{*1} ℓ という字は、数学では**数列の空間**を指す記号である。測度空間の上の関数を集めた空間を L^p と書き、そのノルムは積分 $(\int |f|^p d\mu)^{1/p}$ で定める。このうち、自然数に「1 つ数えたら 1」という測度を入れた場合、関数は数列になり、積分は和になって $(\sum_i |x_i|^p)^{1/p}$ という形をとる。この特別な場合を ℓ^p と書き分ける。連続を L 、離散を ℓ と覚えておけばよい。本書が扱うのは 52 個の数の並びなので、数学の流儀に従えば ℓ のほうである。ただし機械学習では、正規化 (第 4.4.2 項) を指すときだけ大文字で「L1 正規化」「L2 正規化」と書くのが通例になっている。本書もその慣習に合わせ、ノルムと正規化には ℓ 、正規化の呼び名には **L** を使う。記号の由来なので、この脚注は飛ばして構わない。

残るのは方向だけで、 P と Q の「大きさ」の違い、つまり原点からの遠さは消える。

この遠さが、いま消したいものにあたる。文字数の多い作品ほど、どの成分の数も大きくなるので、点は原点から遠いところに置かれる。短い作品は原点の近くに来る。正規化はその差を潰して、**どの字種をどんな配分で使うか**という方向の情報だけを残す。

補足 l_1 と l_2 のどちらで正規化するか

l_1 は「割合」の解釈ができる。(0.66, 0.34) なら「66% と 34%」と読める。合計が 1 になるからである。

l_2 は距離との相性がよい。すべての点が円 (高次元では球) の上に載るので、2 点の隔たりを直線距離で測っても、角度の開きで測っても、同じ順序になる。第 4 章で見るユークリッド距離とコサイン距離の順位が一致する、というのはこの意味である。

本書では字種比率と読点の頻度に l_1 を使う。「割合」として読めるほうが、意味を追いやすいからである。

× アンチパターン 3.3 — 正規化と標準化を混同する —

名前が似ているが、揃える向きが違う。

	何を揃えるか	いつ使うか
正規化	行 (サンプル) ごとの大きさ	作品の長短を消したい
標準化 (standardization)	列 (特徴) ごとのばらつき	特徴どうしの単位を揃えたい

混同すると、2 つの形で害が出る。

1 つは**どちらかで済ませてしまうこと**である。「正規化しておいたから単位はそろっている」と考えると、列ごとの単位が違うまま距離を測ることになる (第 4 章)。逆に「標準化したから作品の長短は消えた」と考えるのも誤りで、列を揃えても行の大きさは残っている。

もう 1 つは**順番を取り違えること**である。本書では両方使う。第 3 章で行方向の正規化、第 4 章で列方向の標準化である。正規化が先で、標準化が後になる。逆順にすると何が壊れるかは、第 4.4.1 項で確かめる。

3.3.2 3 成分の場合

字種は平仮名・片仮名・漢字の 3 つなので、式 (3.1) は 3 成分になる。

$$r_{\text{平仮名}} = \frac{n_{\text{平仮名}}}{n_{\text{平仮名}} + n_{\text{片仮名}} + n_{\text{漢字}}} \quad (3.3)$$

図 3.2(a) の直線 $x + y = 1$ が、3 次元では平面 $x + y + z = 1$ になる。次節で詳しく見る。

結果を図 3.3 に示す。

いくつか読み取れることがある。

- 点がほぼ一直線に並んでいる
- 柳田国男の 5 作品は狭い範囲にまとまる (平仮名の比率 0.635~0.660)
- 島崎藤村は漢字の多い側 (左上、漢字の比率の平均 0.358) に、太宰治は漢字の少ない側 (同 0.285) に寄る




図 3.3 文字種の比率。点は 1 作品。

- 右下に 1 点だけ大きく離れた作品がある (谷崎潤一郎『盲目物語』、第 3.7 節で扱う)
- 重なっている著者も多い

一直線に並ぶのには理由がある。3つの比率の合計が 1 なので、

$$r_{\text{平仮名}} + r_{\text{片仮名}} + r_{\text{漢字}} = 1 \quad (3.4)$$

が常に成り立つ。片仮名の比率は近代文学ではどれも小さいので、実質的に $r_{\text{漢字}} \approx 1 - r_{\text{平仮名}}$ となり、直線に乗る。

3.4 単体 — 3つの比率が住む場所

式 (3.4) は、よく見れば 3 次元空間の中の**平面の方程式**である。

$$x + y + z = 1, \quad x, y, z \geq 0 \quad (3.5)$$

さらに 3 つとも非負という条件がつくので、正規化した点が存在できるのは平面のうち 3 つの座標がすべて 0 以上になる部分、つまり**三角形の内側** (辺の上を含む) だけである。

正規化は、この**三角形の面の上に点を落とす操作**である。

3 つの頂点は $(1, 0, 0)$ 、 $(0, 1, 0)$ 、 $(0, 0, 1)$ 。それぞれ「全部が平仮名」「全部が片仮名」「全部が漢字」という極端な状態を表す。

この三角形を **2 次元単体** (2-simplex) という。成分は 3 つあるのに「2 次元」と呼ぶのは、合計が 1 に固定されているぶん、自由に動けるのが 2 つ分だからである。2 つ決まれば 3 つ目は引き算で決まってしまう。




図 3.4 正規化前の点 P は、原点への破線に沿って三角形の面上の P' に落ちる。図 3.2(a) の 3 次元版である。

補足 合計が 1 なら 3 つの数でも自由に決められるのは 2 つ分

3 つの数を使っているのに、実際に自由に動けるのは 2 つ分しかない。これを「自由度が 1 つ減っている」という。

3 次元空間に点を打っているつもりでも、点は平面上にしか存在しない。第 6 章で扱う主成分分析は、**分散を持たない方向**を自動的に見つけ出す技術でもある。実際、字種の 3 列に PCA をかけると第 3 主成分の寄与率は**厳密に 0**になる。合計 1 の平面と直交する方向には、分散が一切ないからである。第 6 章では組み合わせを変えて (平仮名・漢字・文長 μ) 同じ現象のゆるい版を見る。そちらは合計の制約がないので、第 3 主成分の寄与率が 2.8% だけ残る (図 6.5)。

3.4.1 三角図で描く

点が三角形の上にしかないのなら、その三角形を正面から見れば、情報を失わずに 2 次元で描ける。

これが**三角図** (ternary plot、三角ダイアグラム、三成分図) である。地質学で岩石の鉱物組成を表すのに古くから使われてきた。

読み方は次のとおりである。

- 各頂点は「その成分が 100%」を表す
- ある成分の値は、**その成分の頂点に向かい合う辺からの距離**で読む
- 頂点に近いほど、その成分が多い

図 3.5 の赤い点は、漢字 30%、片仮名 15%、平仮名 55% を表す。3 つを足すと 100% になるので、2 つ読めば残りは引き算で決まる。

実際のデータを重ねたのが図 3.6 である。

図 3.6 を見ると、点が三角形の左下、つまり**平仮名の頂点の近く**に集中している。日本語の文章は平仮名が 6 割前後を占めるので当然ではある。

比較のため、ライトノベル 2 シリーズも重ねてある。『本好きの下剋上』(赤い $\times$) と『薬屋のひと




図 3.5 三角図の読み方。赤い点は平仮名 55%、片仮名 15%、漢字 30% を表す。片仮名は左の辺に平行に、平仮名は右の辺に平行に下の辺まで下ろして読む。左の辺の目盛りは漢字の比率。




図 3.6 三角図に載せた近代文学 74 作品と、ライトノベル 2 シリーズ。全体としては左下の隅に固まっている。

りごと』(緑の+)である。2作を選んだ理由は、次の拡大図で分かる。
だがこれでは著者ごとの違いが見えない。破線の枠を拡大する。




図 3.7 図 3.6 の破線部を拡大。著者ごとのまとまりが見えてくる。縦軸の目盛りは漢字の比率に換算した。横軸方向は特定の成分の比率に対応しないので、目盛りを付けていない。

拡大すると様子が変わる。柳田国男がまとまり、島崎藤村は漢字の多い側に、太宰治は漢字の少ない側に寄っている。吉川英治の 21 作品は図の中ほどに広がる。泉鏡花は難しい漢字を多く使う作家という印象があるが、ルビを除いて数えた漢字の比率の平均は 0.331 で、全作品の平均 0.326 とほとんど変わらない。

そしてライトノベル 2 作の位置が対照的である。

以下に挙げる比率は、すべて表 3.2 の平均値である。『サイレント・ウィッチ』10 区間の片仮名比率の平均は 0.135 で、近代文学 74 作品の平均 0.013 の約 10 倍である。異世界の固有名詞、「モニカ」「フェリクス」「シリル」といった片仮名の人名・地名が絶えず出てくるためである。『本好きの下剋上』の「マイン」「トゥーリ」「ルッツ」も同じである。

一方『薬屋のひとりごと』10 区間の片仮名比率の平均は 0.000 である。表では 0.000 に丸まっているが、厳密なゼロではない。1 万字に 3 文字という水準で、近代文学 74 作品の平均 0.013 の約 40 分の 1 しかない。10 区間のうち 1 つは、10 万字を超える分量で片仮名が 1 文字も出てこない。同じライトノベルでありながら、ここまで違う。

理由は舞台設定と書き方の両方にある。中国の後宮を思わせる世界が舞台で、登場人物名も「猫猫」「壬氏」「羅漢」と漢字である。ただし外来語が出てこないわけではない。作者は「意匠《デザイ

表 3.2 字種比率の平均。近代文学は 74 作品、ライトノベルは各シリーズ 10 区間で平均した。片仮名の比率はライトノベルの中でも大きく違う。各シリーズの内訳は第 1 章の表 1.3 を参照

作品群	平仮名	片仮名	漢字
近代文学 (74 作品)	0.660	0.013	0.326
サイレント・ウィッチ	0.581	0.135	0.285
無職転生	0.640	0.093	0.267
リゼロ	0.631	0.080	0.289
本好きの下剋上	0.645	0.079	0.275
片田舎のおっさん	0.654	0.061	0.285
薬屋のひとりごと	0.697	0.000	0.303

ン」「貢物《プレゼント》」「酒精《アルコール》」のように外来語を漢字で書き、片仮名はルビに回している。人名の読みも「猫猫《マオマオ》」「壬氏《ジンシ》」とルビで示す。本書はルビを除いて数える (第 3.2 節) ので、この片仮名は数に入らない。10 区間を合わせると、ルビの中の片仮名は 8,315 字、ルビの外は 340 字である。

補足 ウェブ小説のルビは著者が振る

第 3.2 節の定石では、ルビを「編集者や出版社が決めるもの」として捨てた。青空文庫の近代文学ではそのとおりだが、小説投稿サイトの作品では、ルビは著者が自分で入力している。由来で決めるなら、ライトノベルのルビは著者の癖として残す側に入る。

ルビの親文字を読み置き換えて数え直すと、『薬屋のひとりごと』の片仮名比率は平均 0.0074(区間ごとに 0.0035 から 0.0119) に上がる。ほかの 5 シリーズは片仮名をルビではなく本文に書くので、置き換えてもほとんど変わらない (シリーズごとの平均で 0.061 から 0.135)。置き換えた後も『薬屋』は近代文学の平均 0.013 を下回るなので、片仮名が少ないという結論は変わらない。変わるのは程度で、「1 万字に 3 文字」という極端さの大部分は、ルビを捨てた前処理から来ている。本書では、近代文学とライトノベルを同じ手順で数えるために、どちらもルビを除いた値を使う。

補足 三角図は 3 成分の関係を 1 枚で見せる

表 3.2 の数字を眺めるだけでも違いは分かる。だが図 3.7 を見ると、**薬屋が近代文学の集団の中に混ざっている**のが一目で分かる。

字種比率という特徴だけでは、『薬屋のひとりごと』と近代文学は区別できない。第 11 章で見るように、ジャンル判別は「時代の違い」を手がかりにしている面があるが、その手がかりも万能ではないということである。

散布図なら 2 変数しか見られない。3 成分の関係を 1 枚で見せられるのが三角図の利点である。

○ 定石 3.2 — 散布図は全体図と拡大図の 2 枚を描く —

全体像を示す図と、注目部分を拡大した図。2 枚を並べるだけで、読者が受け取る情報は大きく増える。

全体図だけでは「どこに何があるか」しか分らない。拡大図だけでは「それが全体のどこなのか」が分らない。

この特徴だけでは著者を分けきれない。次の特徴を足す。

3.5 特徴設計 2 — 文の長さ

文を長く書く作家と短く書く作家がいる。句点・感嘆符・疑問符で文に区切り、空白・句読点・括弧を除いた文字数を数える。

一つの世界 (太宰治『斜陽』) について、文長の分布を見たのが図 3.8 である。




図 3.8 太宰治『斜陽』の文長分布 (2160 文)。左は 1 文字刻みの度数で、120 字までを描いた (これを超える文は 3.1%、最長は 698 字)。右は横軸を文長の対数にし、対数の幅 1 あたりの文の数を描いた。ほぼ左右対称の山になり、山の頂は e^μ (破線) の近くに来る。

左の図は右に長い裾を引いている。裾の長い分布の「代表値」に平均を使うと、少数の長い文に引っ張られる。

横軸を対数にすると、ほぼ左右対称の山になった (細かく見ると、わずかに左に裾を引いている)。つまり **文長の対数が正規分布に近い**。これを **対数正規分布** (log-normal distribution) という。

$$p(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0 \quad (3.6)$$

パラメータは μ と σ の 2 つである。

- μ — 対数をとった文長の平均。 e^μ が文の長さの代表値になる
- σ — 対数をとった文長の標準偏差。長さのばらつき

e^μ は文長の幾何平均で、対数正規分布なら中央値に一致する。『斜陽』では $\mu = 3.17$ なので $e^\mu \approx 24$ 字となり、実際の中央値 25 字に近い。文長をそのまま平均すると 37 字で、少数の長い文に引き上げられている。

何千という文長の値が、たった 2 つの数にまとまる。これが**分布を仮定することの利点**である。

```
NOISE = re.compile(r"[\s,.! ? () 「」 『』 <> ]+") # 空白・句読点・括弧
lengths = np.array([len(NOISE.sub("", s)) for s in sentences])
lengths = lengths[lengths > 0] # 記号だけの文を除く
log_lengths = np.log(lengths)
mu, sigma = log_lengths.mean(), log_lengths.std()
```

発展 $n-1$ で割るべきか — 不偏性と最尤法

上のコードは `std()` をそのまま呼んでいる。NumPy の既定は偏差平方和を n で割る版で、統計の教科書が「不偏分散」と呼ぶ $n-1$ で割る版ではない。どちらを使うべきかを考える。

まず**不偏性** (unbiasedness) とは何かをはっきりさせておく。手元にあるのはデータ 1 組だけだが、同じ条件でデータを取り直せば、推定値は毎回違う値になる。その**取り直しを無限に繰り返したときの平均**が真の値に一致することを、推定量が不偏であるという。真の値を θ 、推定量を $\hat{\theta}$ と書けば

$$E[\hat{\theta}] = \theta \quad (3.7)$$

である。ここで注意がいる。不偏性は**推定量という手続きの性質**であって、いま手元に出た 1 つの値の性質ではない。不偏な推定量でも、1 回の値は真の値から大きく外れうる。「不偏だから正確」とは言えない。

σ^2 の推定では、 $n-1$ で割ると等式が成り立つ。 n で割ると平均は真の値より小さくなる。標本平均 $\bar{x}$ が手元のデータに引き寄せられているぶん、偏差平方和が本来より小さく出ためである。

では、平均が合っていれば良い推定量と言えるのかを確かめる。標準正規分布から n 個取る操作を 40 万回繰り返し、偏差平方和を $n-1$ 、 n 、 $n+1$ で割った 3 通りについて、真の値からの偏り ($E[\hat{\theta}] - \theta$) と、1 回ごとの外れ具合 ($E[(\hat{\theta} - \theta)^2]$ 、二乗誤差) を測った。真の分散は 1 なので、表の偏りは推定値の平均が 1 からどれだけずれたか、二乗誤差は推定値が 1 から外れた量の 2 乗を平均したものである。

n	割る数	偏り	二乗誤差
5	$n-1$ (不偏)	-0.0004	0.5029
	n (最尤)	-0.2003	0.3620
	$n+1$	-0.3336	0.3348
10	$n-1$ (不偏)	-0.0007	0.2221
	n (最尤)	-0.1006	0.1901
	$n+1$	-0.1824	0.1820
30	$n-1$ (不偏)	-0.0007	0.0688
	n (最尤)	-0.0340	0.0655
	$n+1$	-0.0651	0.0645

$n-1$ で割ると偏りは消えるが、二乗誤差は n が 5、10、30 のどれでも **3 通りの中で最も大きい**。つまり不偏性とは、精度をいくらか手放して偏りをゼロにする選択である。第 9.12 節で扱う偏りとばらつきの分解でいえば、偏りを 0 にするために、ばらつきの分を引き受けている。二乗誤差だけを見れば $c = n+1$ で割るのが最良になるが、それは正規分布を仮定したこの形の推定量に限った話である (導出は付録 C)。

n で割る版は、正規分布を仮定したときの**最尤推定量**である。最尤推定は「観測されたデータが最も出やすくなるパラメータ」を選ぶ方法で、不偏とは限らない。実際 σ^2 では下に偏る。それでも標準的に使

発展 (続き)

われるのは、 n が増えれば偏りが消え (一致性)、ばらつきも理論上の下限に近づく (漸近有効性) からである。本書でも第 7.4 節のロジスティック回帰は係数を最尤法で決めている。

ここまで σ^2 の話をしてきたが、本章で特徴にしたのは σ 、つまり標準偏差である。ここで s^2 が不偏でも、 $s = \sqrt{s^2}$ は不偏にならない。不偏という性質は平方根を取ると失われる。平方根が上に凸な関数だからで、イェンセンの不等式から $E[s] = E[\sqrt{s^2}] < \sqrt{E[s^2]} = \sigma$ になる。標準偏差まで不偏にする補正はあるが、実務で使う場面は限られるので付録 C に回す。本書の文長 σ は、作品の文数が 234 から数千 (中央値 2507) である。74 作品それぞれについて、 $n-1$ で割った σ と n で割った σ の相対差を測ると、最大でも 0.21%、中央値で 0.020% であった。平方根の偏りも、文数 234 で $c_4 = 0.999$ 、中央値の 2507 で $c_4 = 0.9999$ と、 $E[s]/\sigma$ が 1 からほとんど離れない。どちらでも結論は変わらない。

× アンチパターン 3.4 — 分散は必ず $n-1$ で割ると覚える

$n-1$ で割ると、データを取り直して推定をやり直すことを無限に繰り返したときの平均が真の分散に一致する。これが不偏性である。 $n-1$ は「正しい割り方」ではなく、この性質がほしいときの割り方にすぎない。しかも、その性質は分散にしか付かない。標準偏差 (平方根) は不偏にならない。現に、1 回ごとの外れ具合 (二乗誤差) で測れば、 $n-1$ は 3 通りの中で最も悪かった。

「必ず $n-1$ 」と覚えていると、害が 2 つの形で出る。

1 つは他人の計算を誤りと決めつけることである。NumPy の `std()` は既定で n で割る。それを見て「バグだ」「直すべきだ」と指摘してしまう。 n で割るのは最尤推定量で、それ自体は誤りではない。何を良しとするかを決めなければ、どちらが良いかは決まらない。

もう 1 つは割り方の違う数値を突き合わせることである。既定はライブラリごとに違う。同じ 4 つの数 (1, 2, 3, 4) から標準偏差を計算しても、NumPy の `std()` は n で割って 1.118 を返し、Polars の `std()` は $n-1$ で割って 1.291 を返す。後者は前者より 15% 大きい。自分の計算、引用した論文の数値、手元の集計表。比べる前に、どれがどちらで割ったものかを確認しておく。

差が問題になるのは n が小さいときだけである。標準偏差にすると、2 つの割り方の違いは比にして $1/(2n)$ ほどなので、 n が 500 を超えれば標準偏差の相対差は 0.1% より小さくなる。本書の文長 σ では、74 作品を通して相対差は最大でも 0.21% であった。どちらで割るかで迷う時間があるなら、 n が 10 前後まで小さくなる集計がどこかに紛れ込んでいないかを探すほうがよい。

全作品について (μ, σ) を計算したのが図 3.9 である。

谷崎潤一郎は右端に寄り、最も長い文を書く (μ の平均 4.17)。柳田国男も右寄りだが、 σ の平均は 0.58 で 8 人の中で最も小さく、長めの文を揃った長さで書く。太宰治は左に寄り、文は短いが長さのばらつきは大きい (μ の平均 3.01、 σ の平均 0.90)。吉川英治の 21 作品は図の中ほど (μ の平均 3.33、 σ の平均 0.83) に広がる。全 74 作品の中央値は、 μ が 3.34、 σ が 0.79 である。




図 3.9 文長分布のパラメータ。右へ行くほど長い文、上へ行くほど長さがばらつく。

× アンチパターン 3.5 — 分布を見ずに平均だけを取る —

文長の平均を特徴にすると、外れ値に弱くなる。1 つだけ 500 文字の文があれば、平均はそれだけで大きく引き上げられる。分布の形を見てから代表値を決める。対数正規なら、対数の平均のほうが安定する。

コラム 文の長さで著者を当てる試み

文長を書き手の手がかりにする研究は、統計学の古典の中にある。G. U. Yule は 1939 年の論文で、文長の分布を文体の指標として調べ、作者が争われていた『キリストに倣いて』に当てはめた [9]。候補のジャン・ジェルソンとトマス・ア・ケンピスの文章の文長を比べ、ジェルソンが書いた可能性は低いと結論した。この結論は、のちに別の分布のモデルを使った研究でも支持されている [11]。

翌 1940 年には C. B. Williams が、同じ Biometrika に、文長の分布を文体の基準として扱う短い論文を書いた [10]。文長の分布を対数正規分布で表すモデルは、Williams が提案したものとして知られている。

ただし対数正規分布は近似である。H. S. Sichel は 1974 年の論文で、文長が整数であることや、長い側の裾が正規分布の予想より速く細ることを挙げて対数正規のモデルを退け、別の分布を提案した [11]。本章の『斜陽』でも、対数をとった文長の山はわずかに左に裾を引く (図 3.8 の右)。μ と σ の 2 つにまとめる利点は変わらないが、仮定した分布からどこがずれているかは、描いて確かめておきたい。

3.5.1 「長い/短い」に潰さない

もう 1 つ、やりがちな加工がある。連続した値を、ある値を境に **2 つのカテゴリに潰す**ことである。文長 μ を中央値で切って「長い作品/短い作品」の 2 値にする、といった操作にあたる。

読みやすくなる。だが情報は確実に減る。中央値のすぐ両側にある 2 作品は、値がほとんど同じなのに別のカテゴリに入り、逆に片側の端と中央値の隣は、大きく違うのに同じカテゴリになる。

どれだけ減るかを測った。字種 3 列と文長 2 列の計 5 列をランダムフォレストに渡し、74 作品の著者を 5 分割の層別交差検証で判別したときの正解率を比べる。交差検証は、作品を 5 組に分け、4 組で学習して残る 1 組で当てる操作を 5 通り繰り返し、正解率を平均する評価法である。「層別」

は、各組の著者の割合をそろえて分けることを指す(第8.2節)。値をそのまま渡したときの正解率は0.635である。同じ5列を、それぞれ74作品の中央値で2値に潰してから渡すと、正解率は0.500に下がる。0.635を0.135下回っている。

境目をどこに置くかをデータを見てから決めると、事情はさらに込み入る。いちばん差が出る位置を探して切れば、その差は「本当にある差」ではなく「探したから見つかった差」になる。第9.8節の多重テストと同じ構造である。

× アンチパターン 3.6 — 連続した値を中央値で2つに割ってから分析する

「高い群」と「低い群」に分けると解釈しやすくなるが、そのために捨てた情報は戻らない。

とくに、切る位置をデータから選ぶのは避ける。どうしても2値にしたいなら、分野の知識で決まる基準(法定速度、診断基準、合格点)があるときに限る。

3.6 特徴設計3 — 読点の打ち方

3つ目が本書で最も判別力の高い特徴である。

「吾輩は猫である」と書くか、「吾輩は、猫である」と書くか。読点をどこに打つかは、文法で決まっているわけではない。書き手ごとの習慣による。

これは本書の思いつきではない。日本語の計量文体論では、読点の打ち方に書き手の個性が出るのが1990年代に報告されている[5]。とくに読点の直前に来る文字に着目する作り方は、その後の日本語の著者識別で標準的な特徴量の一つになった[8]。本書もこれに倣い、読点の直前に来る平仮名を数える。

```
pattern = regex.compile(r"(\p{Hiragana}),")
counter = Counter(pattern.findall(text))
```

「～は、」「～が、」「～て、」「～で、」など、どの助詞や活用語尾の後で区切るかの癖が数値になる。これも作品ごとに合計1で正規化する。

そのうえで、74作品を通した平均の割合が0.1%に満たない文字は落とす。まれにしか現れない文字は、その作品にたまたま1回か2回出たかどうかで値が大きく振れる。書き手の癖ではなく偶然を測ることになるので、外しておく。0.1%という線に理論的な根拠はない。読点の直前に一度でも現れた平仮名は、踊り字(ゝ、ゞ)を除いて73文字あり、平均の割合を大きい順に並べると図3.10のようになる。線の前後に切れ目はなく、すぐ上に「っ」0.120%、「げ」0.117%、「び」0.106%、すぐ下に「む」0.099%、「じ」0.097%、「ぞ」0.093%が並ぶ。どこに線を引くかは判断であって、分布が決めてくれるわけではない。結果として47文字が残り、26文字を落とした。線を0.05%や0.2%に替えて結果が変わらないかを確かめておくのが安全である。

もっとも、「落とす」という操作は見た目より重い。何をしていることになるかは、第3.7節で改めて扱う。

「て」の後で区切るというのが最も多い。だがその割合は作家によって違う。それが判別の手がかりになる。

平均を眺めるだけでは、その「違う」がどれくらいのものか分からない。74作品すべてを1枚に並べたのが図3.11である。




図 3.10 読点の直前に現れた平仮名 73 文字 (踊り字を除く) の平均の割合 (74 作品の平均、縦軸は対数)。横は割合の大きい順。破線の 0.1% より上の 47 文字を残し、下の 26 文字を落とした。線の前で値は切れ目なく続く。「っ」は線のすぐ上に残った文字で、第 3.7.6 項で扱う。

表 3.3 読点前の平仮名 (上位 10 文字と、74 作品での平均割合)

文字	平均割合	文字	平均割合
「て、」	0.175	「で、」	0.064
「は、」	0.121	「ら、」	0.057
「が、」	0.089	「も、」	0.053
「と、」	0.076	「り、」	0.023
「に、」	0.069	「し、」	0.021

補足 この図の色は文字ごとの物差しで塗ってある

色にしたのは割合そのものではない。割合のままだと桁が違いすぎるからである。表 3.3 と同じ 74 作品の平均割合で見ると、「て、」は読点 6 回に 1 回ほど現れるのに、図の右端の「う、」は 150 回に 1 回しか現れない。この 25 倍の開きがあるものを 1 本の物差しで塗ると、「て」の列だけが真っ赤になり、残りの 23 列はどれも白くなってしまう。作家の違いが無いのではなく、「て」に合わせた目盛りでは細かすぎて見えない。

そこで、文字ごとに別の物差しを用意した。どの列でも 74 作品の平均を真ん中 (白) に置き、そこからどれだけ離れているかを赤と青の濃さにしている。学校の点数を科目ごとの平均と散らばりで測り直す偏差値と、考え方は同じである。数学の 70 点と国語の 70 点を並べても比べたことにならないのと同じで、「て、」の平均割合 0.175 と「う、」の平均割合 0.007 を並べても比べたことにならない。だから赤は「この作品はこの文字を平均よりよく使う」という意味であって、違う列どうして濃さを比べるためのものではない。この操作を列ごとの標準化という (第 4 章で改めて扱う)。

引っかかる場所がある。1 行は「読点の前に来た文字の内訳」なので、47 文字ぶんを足すと (ほぼ) 1 になる (図に描いたのは、そのうち頻度の高い 24 文字である)。どれか 1 文字の割合が上がれば、必ずどこか別の文字の割合が下がる。列ごとに平均を引く操作は、この引っ張り合いを無かったことにして、列を 1 本ずつ別々に扱っている。標準化した後の行は、もう内訳ではない。行と列のどちらを揃えるべきかは、第 4.4.1 項で正面から扱う。

この図に関しては、塗り方を変えても読み方が変わらないことを確かめてある。内訳という性質を保ったまま比べる別のやり方 (clr 変換、第 3.7.3 項) で塗り直すと、マス目 1 つ 1 つの色は変わる。図に描いた 74 作品 × 24 文字の全マスについて、いまの図の値と clr で塗り直した図の値を突き合わせると、順




図 3.11 読点の直前に来る平仮名。1 行が 1 作品、1 列が 1 文字で、横は左ほど頻度の高い文字である (上位 24 文字だけを描いた)。色は列ごとに標準化した値で、赤はその文字をよく使う作品、青は使わない作品を表す。著者ごとに横縞が見える。

補足 (続き)

位相関 (スピアマン) は 0.751、赤か青かの符号が一致するマスの割合は 0.775 である。それでも、この後に挙げる濃い薄いの向きはすべて残り、著者ごとに横縞が出るという読みも変わらない。24 列のそれぞれについて、著者の違いで説明できる分散がその列の分散全体に占める割合を求め、24 列で平均すると、いまの図で 0.527、clr で塗り直した図で 0.554 である。

図を見ると、同じ著者の作品が**横縞**になっている。吉川英治は「と、」が濃く「で、」が薄い。島崎藤村は「て、」が濃く「を、」が薄い。泉鏡花は「の、」が濃く「は、」が薄い。柳田国男は「り、」「が、」「く、」の 3 列が濃い (図の中では離れた位置にある)。著者が変わると縞の模様が変わり、同じ著者の中では似た模様が続く。模様の違いが、第 4 章以降で距離やクラスタになる。

模様がどの列で出るかは著者ごとに違う点にも注意したい。「て、」を多用するのは藤村で、太宰治や谷崎潤一郎はむしろ避けている。1 つの列だけを見て「この文字が多いから誰それ」とは言えず、47 列の並び全体が署名として働いている。

読点を打つ位置は文法で決まっているわけではないので、書き手はここを意識せずに選んでいる。その無意識の選択が、47 個の数値の並びとして残る。

○ 定石 3.3 — 著者を当てる特徴に求める 3 条件 —

次の 3 条件は書いた人を当てるという課題に限ったもので、何を当てたいかが変われば条件も変わる。

1. 内容に依存しない — どんな題材を書いても同じように出る
2. どの文書にも現れる — 比較できる
3. 書き手が意識していない — 意図的に変えにくい

読点の癖は、3 つを単語の頻度よりよく満たす。ただし完全ではない。たとえば「あっ、」のような感動詞がらみの読点は、驚きや悲鳴の多い場面、つまり内容に引きずられるし、会話の多い文体かどうかにも左右される。3 条件は満たすか満たさないかの二択ではなく程度の問題で、候補どうしの満たし方を比べて特徴を選ぶ。

目的が変われば条件も変わる。ジャンルを当てたいなら 1 は逆になり、題材によって変わる特徴のほうがよい (第 11 章)。3 が重要になるのは、**当てられる側に隠す動機がある**課題 (著者判定、生体認証、不正検知) に限られる。一般の形に直せば、特徴に求めるものは「当てたいラベルとともに変わり、それ以外の要因では変わらず、どの行でも測れること」である。上の 3 条件は、その著者判定版にとどまる。何が邪魔者かは目的が決める—残すか捨てるかを問いの側が決めるという、前処理の節で見た原理と同じである。

3 種類の特徴がそろった。表にまとめる前に、比率という数値そのものが持つ、扱いに注意の要る性質を見ておきたい。いま作った 52 列のうち 50 列が、その性質を持っている。

3.7 組成データ — 比率を扱うときの落とし穴

合計が一定になるデータを**組成データ** (compositional data) という。比率、割合、パーセント、シェア、得票率、予算の配分。身の回りの数値の多くが組成データである。

本書の特徴量も例外ではない。字種比率の 3 列は合計 1、読点前平仮名の 47 列もほぼ合計 1 になる (「ほぼ」なのは、まれな文字を落としたぶん行の合計が 0.97 から 1.00 の間になるためである)。52 列のうち **50 列が組成データ** である。残る 2 列は文長の μ と σ で、これらは合計の制約を持たない。組成データには、普通の数値と同じつもりで扱うと誤った結論に導かれる性質がある。

3.7.1 合計が固定されると、無関係な成分にも負の相関が出る

74 作品それぞれについて平仮名の比率と漢字の比率を並べ、両者の相関係数を測ると $r = -0.915$ になる。ほとんど直線に乗る強い負の相関である。

素直に読めば「漢字を多用する作家は平仮名を控える」となる。文体の発見に見える。

だが、この負の相関だけでは、**文体の性質を示したことにならない**。

平仮名 + 片仮名 + 漢字 = 1 だから、漢字 = 1 - 平仮名 - 片仮名 である。片仮名の比率は小さく、変動も小さい (近代文学 74 作品の平均は 0.013)。すると漢字はほぼ「1 - 平仮名」に等しく、相関が -1 に近づくのは**足し算の帰結**にすぎない。

3 成分すべての相関を見ると、偏りがはっきりする。

表 3.4 の非対角にある 3 つの相関係数の和は -1.328 である。偶然ではない。

表 3.4 74 作品で測った字種比率どうしの相関係数。非対角の 3 つはすべて負である

	平仮名	片仮名	漢字
平仮名	+1.000	-0.250	- 0.915
片仮名	-0.250	+1.000	-0.163
漢字	- 0.915	-0.163	+1.000

発展 合計が固定された比率は、互いに負の向きに引かれる

$x_1 + \dots + x_D = c$ (定数) とする。任意の j について共分散は第 2 引数について線形だから、

$$\sum_{k=1}^D \text{Cov}(x_j, x_k) = \text{Cov}\left(x_j, \sum_k x_k\right) = \text{Cov}(x_j, c) = 0. \quad (3.8)$$

定数との共分散は 0 なので、**共分散行列の各行の和はちょうど 0** になる。74 作品の字種 3 列から作った共分散行列で確かめると、3 つの行和の絶対値の最大は 2.2×10^{-19} であった。理論値 0 との差は浮動小数点の誤差の範囲にとどまる。

$k = j$ の項を分けると

$$\sum_{k \neq j} \text{Cov}(x_j, x_k) = -\text{Var}(x_j). \quad (3.9)$$

その成分の分散が 0 でなければ、右辺は負である。つまり**各成分は、他の成分との共分散の和が負**になる。どんなデータであろうと、合計が固定されている限り成り立つ。

とくに $D = 2$ なら和の項が 1 つしかないので $\text{Cov}(x_1, x_2) = -\text{Var}(x_1)$ 、すなわち $r = -1$ が**恒等的**に成り立つ。2 成分の組成データの相関を測るのは、何も測っていないに等しい。

表 3.4 の非対角の和 -1.328 にも根拠がある。もし 3 成分の分散がすべて等しければ、上の行和ゼロの式を相関で書き直して、非対角の相関の和 (3 つ) はちょうど $-D/2 = -1.5$ になる。74 作品での実際の標準偏差は平仮名 0.042、片仮名 0.017、漢字 0.041 と完全には揃っていないので、 -1.5 を 0.172 上回る -1.328 が観測される。

この和が $-D/2$ を下回ることはない。各成分の標準偏差を s_j として $u_j = 1/s_j$ とおくと、相関を対角も含めてすべて足した値は $\sum_{i,j} r_{ij} = u^\top \Sigma u$ と書ける (Σ は共分散行列)。共分散行列では $u^\top \Sigma u \geq 0$ が成り立つので、非対角の和 (各組を 1 回ずつ数える) は $(u^\top \Sigma u - D)/2 \geq -D/2$ になる。74 作品の字種 3 列では $u^\top \Sigma u = 0.34$ で、 $(0.34 - 3)/2$ が -1.328 にあたる。

3 成分なら、三角形で見ることもできる (図 3.12)。各成分の平均からのずれを 74 次元のベクトルとみると、合計が一定なので 3 本の和は 0 になり、3 本をつなぐと三角形が閉じる。辺の長さは各成分の標準偏差に比例し、2 成分の相関は、その 2 辺がはさむ内角 θ を使って $r = -\cos \theta$ と書ける。三角形の内角の余弦の和は $3/2$ を超えないので、非対角の和は -1.5 を下回らない。内角の 1 つが鈍角なら、その 2 成分の相関は正になる。3 成分以上で「どの 2 成分も必ず負」とは言えないのはこのためである。

× アンチパターン 3.7 — 比率どうしの相関をそのまま解釈する

「A の比率と B の比率に強い負の相関があった」という報告は、それだけでは文体や行動の性質を示したことになる。合計が固定されていれば、制約だけで負の共分散が生まれるからである (3 成分以上なら、どの 2 成分も必ず負になるわけではない。負の向きに引かれる、と




図 3.12 字種 3 成分の平均からのずれを辺にした三角形 (辺の長さは標準偏差に比例)。2 辺がはさむ内角 θ と、その 2 成分の相関 $r = -\cos \theta$ は、平仮名と漢字で 23.9° と -0.915 、平仮名と片仮名で 75.5° と -0.250 、片仮名と漢字で 80.6° と -0.163 である。

いうのが正確な言い方である)。

売上構成比にも、時間の使い方の割合にも、支持率にも同じ罫がある。

コラム 比率の相関を疑った統計学者たち

比率どうしの相関の罫は、統計学の早い時期から知られていた。Karl Pearson は 1897 年の論文で、器官の大きさを別の器官の大きさと割った指数どうしの相関を取り上げた [23]。互いに無関係な 3 つの量 x, y, z から比 x/z と y/z を作ると、共通の分母 z のせいで、比どうしに相関が現れる。Pearson はこれを見せかけの相関と呼び、器官どうしに本当の関係があるかのように読み違える危険を指摘した。後で見る clr 変換で、共通の分母 $g(x)$ が相関の符号を逆転させるのも同じ仕組みである。

合計が一定の場合の問題は、岩石の化学組成を扱う地質学で長く議論された。Felix Chayes は 1960 年の論文で、合計が一定の変数どうしの相関を論じ、成分の間に関係がなくても合計の制約から負の相関が生じることを示した [24]。上の発展の囲みで導いた、共分散の行和が 0 になる性質にあたる。

罫を指摘するだけでなく、代わりの道具として対数比を体系立てたのが John Aitchison で、1982 年の論文 [25] と 1986 年の本 [26] にまとめた。細菌叢の解析のように比率しか測れない分野では、この罫がいまも指摘され続けている [29]。

3.7.2 一部だけ取り出すと答えが変わる

もっと不気味な性質がある。

字種から片仮名を捨て、平仮名と漢字だけの 2 成分にして、合計が 1 になるよう割り直してみる。元のデータは 1 文字も変えていない。ただ片仮名を見ないだけである。

平仮名と漢字の相関係数は -0.915 から -1.000 に変わる。2 成分の組成データでは、点が直線 $x + y = 1$ の上にしか置けないので、74 作品の点は完全な直線に乗り、相関係数は理論上 -1 になる。

これを**部分組成の非整合性** (subcompositional incoherence) という。組成データでは、**どの成分を分析に含めたかによって、成分どうしの関係が変わってしまう**。

補足 まれな列を落とすのも「部分組成」である

第 3.6 節で読点前の平仮名を数えたとき、74 作品を通した平均の割合が 0.1% に満たない文字を落として 47 列にした。あれも**部分組成を取る**操作である。落とした後は再正規化していないので、47 列の行和は厳密には 1 でなく、作品によって 0.97 から 1.00 の間になる。

補足（続き）

これは手抜きではなく判断である。落とした列の割合の合計は、どの作品でも 3.3% 以下にとどまり、距離や分類への影響は小さい。一方、比率どうしの相関を論じる場面では、どの列を落としたかで数値が変わることを本項で見たとおりである。自分がいまどちらの使い方をしているかを意識しておきたい。なお、成分どうしの比は列を落としても変わらない。対数比 $\ln(x_i/x_j)$ を直接見る分析は、列を落としても揺らがない。clr や ilr の座標値そのものは、どの成分を含めたかで変わる（次項の「clr 変換の性質と限界」を参照）。




図 3.13 同じ 74 作品を 3 通りに描いた。点の位置も相関も変わるが、元の文章は何一つ変えていない。(2) は完全な直線、(3) では相関の符号が逆転している。色とマーカーは図 3.3 と同じ。赤い丸は谷崎潤一郎『盲目物語』で、3 枚とも同じ作品を指している。

図 3.13 の (1) と (2) を見比べてほしい。片仮名という、比率にして平均 1% 余りの成分を外しただけで、散らばりが直線につぶれる。

3 枚を貫いて、赤い丸の 1 点を目で追ってほしい。谷崎潤一郎『盲目物語』である。盲目の按摩の語りをそのまま写すために、谷崎が意図して漢字を抑え仮名書きに寄せた作品で、平仮名比率が 0.8717 と 74 作品の中で最も高く、表 3.2 の平均 0.660 から離れた飛び地になっている。(1) で外れていた点は、(2) でも (3) でも外れたままである。変換は個々の作品の個性を消さない。消えたり現れたりしているのは、点どうしの見かけの関係のほうである。

3.7.3 clr 変換 — 比を見る

組成データの扱い方は Aitchison が体系化した [26]。もともと岩石の化学組成を扱う地質学で発展し、いまではマイクロバイーム (細菌叢) 解析でも使うよう勧められている [29]。細菌の組成はシーケンサの読み取り総数で割った比率でしか得られないから、本節の問題がそっくり現れる。考え方は単純で、比率そのものではなく成分どうしの比を見る。

「比率が 0.1 増えた」という言い方は、元が 0.05 のときと 0.5 のときで意味がまるで違ってしまうが、「2 倍になった」ならどちらの場合でも同じことを指す。だから差ではなく比で見たい。

そこで比の対数をとると、割り算が引き算に変わり ($\ln(a/b) = \ln a - \ln b$)、普通の距離や相関や平均のように引き算しかできない道具を、比を見る目的にそのまま使えるようになる。

比を取る相手、つまり基準も決めなければならない。特定の 1 成分を基準にすると、どれを選ぶかで結果が変わってしまう。そこで全成分を平等に扱うため、**幾何平均** (全部を掛け合わせて成分の根を取った値) を基準にする。こうして作る変換を **clr 変換** (centred log-ratio transformation) という。

$$\text{clr}(x)_j = \ln \frac{x_j}{g(x)}, \quad g(x) = \left(\prod_{k=1}^D x_k \right)^{1/D} \quad (3.10)$$

$g(x)$ が幾何平均、 D が成分の数である。式全体は「その成分が、全体の平均的な水準に比べて何倍あるか」の対数を表す。変換後の点は、合計 1 の三角形の代わりに、成分の和が 0 になる平面の上に載る。この平面は普通のユークリッド空間なので、距離や平均をそのまま使える。clr 変換したあとのユークリッド距離を **Aitchison 距離** という。

図 3.13(3) がその結果である。平仮名と漢字の相関係数は -0.915 から $+0.852$ へ、**符号ごと逆転** した。

逆転の理由は、共通の分母 $g(x)$ にある。値の小さい成分は、対数スケールで見た変動が大きくなりがちである。本書の 3 成分では、74 作品を通した $\ln x$ の分散が平仮名 0.004、漢字 0.023 に対して片仮名 1.19 と、片仮名だけが 50 倍以上大きい。そのため、 $\ln g(x)$ の変動は片仮名の項に支配される。つまり $g(x)$ は事実上、片仮名の多寡を映す量になっている。

そうすると、平仮名も漢字も「片仮名に比べて何倍か」を見ていることになる。片仮名の少ない作品では、平仮名も漢字も相対的に多い。だから両者は同じ向きに動き、正の相関になる。合計 1 という縛りの下では負に見えていた関係が、比で見ると逆の姿を見せる。

発展 clr 変換の性質と限界

clr には次の性質がある。

組成の等価性: x とその定数倍 λx は clr で同じ点に写る。生の個数から比率に直す操作が不要になる。

部分組成の整合性: 成分を一部除いても、残した成分どうしの比は変わらない。clr でも、2 成分の座標の差 $\ln(x_i/g) - \ln(x_j/g) = \ln(x_i/x_j)$ はその対数比に厳密に一致する。ただし、各座標値は全成分の幾何平均 $g(x)$ を基準にしているため、成分を除けば $g(x)$ が変わり、座標値も変わる。座標間の相関や、次元を減らした後の距離まで保存されるわけではない。実際、平仮名と漢字の相関は、3 成分の clr では $+0.852$ だが、片仮名を除いた 2 成分の clr では -1.000 になる (2 成分の clr は $\pm \frac{1}{2} \ln(x_1/x_2)$ で、符号が逆だけの 1 本の量だからである)。一方、対数比 $\ln(x_{\text{平仮名}}/x_{\text{漢字}})$ 自体は 3 成分でも 2 成分でも同じ値である。ilr は、同じ組成を直交座標で表す方法であり (次項)、座標値が部分組成で保存される点で clr に勝るわけではない。ただし分け方を工夫すれば、特定のバランスは部分組成に移っても変わらない。次項の b_1 は平仮名と漢字だけから作るのだから、片仮名を除いた 2 成分の ilr 座標と同じ値になる。

制約: clr 変換後のベクトルは成分の和が必ず 0 になる。 $\sum_j \ln(x_j/g) = \ln(\prod_j x_j/g^D) = 0$ だからである。 D 次元に見えて実質は $D-1$ 次元で、共分散行列は特異になる。線形回帰など、逆行列を必要とする手法にそのまま入ると破綻する。これを避けたければ、次に述べる ilr 変換を使う。

3.7.4 ilr 変換 — バランスとして読む*

clr の「和が 0」という制約を取り除くには、 $D-1$ 本の**直交した対数比**を座標に選べばよい。これを **ilr 変換** (isometric log-ratio transformation) という。

座標の選び方は一つではないが、成分を2つのグループに割っていく方法が読みやすい。字種の3成分なら、「平仮名と漢字のバランス」と「片仮名とそれ以外(平仮名と漢字)のバランス」の2本に割ると

$$b_1 = \frac{1}{\sqrt{2}} \ln \frac{x_{\text{平仮名}}}{x_{\text{漢字}}}, \quad b_2 = \sqrt{\frac{2}{3}} \ln \frac{x_{\text{片仮名}}}{\sqrt{x_{\text{平仮名}} x_{\text{漢字}}}} \quad (3.11)$$

となる。 b_1 は平仮名と漢字のどちらに寄った文体か、 b_2 は片仮名を平仮名と漢字に比べてどれだけ使うかを表す。 b_1 や b_2 のような座標をバランスと呼ぶ。2本の座標が直交するのは、成分を2つのグループに割っていく作り方から来ている。平方根の係数は、各座標の目盛りの長さを1にそろえるためのもので、これがあるおかげで **ilr 座標上のユークリッド距離は Aitchison 距離にちょうど一致する**。74 作品で両者を突き合わせると、差は 10^{-15} の桁にとどまり、浮動小数点の誤差しかない。

対数比の座標で等間隔に目盛りを取ると、三角図の上では等間隔にならない。図 3.14 は、 b_2 を 1 ずつ変えた線を三角図の拡大部分に重ねたものである。片仮名の少ない左の縁に近づくほど線が詰まり、 $b_2 = -5$ から -3 までの3本は、縁からわずかな幅の中に収まる。生の比率ではほとんど区別できない片仮名の差が、ilr 座標では同じ間隔に引き延ばされる。




図 3.14 図 3.7 と同じ範囲に、ilr の b_2 が一定の線を重ねた (灰色の点は近代文学 74 作品)。 b_2 は 1 ずつ変えてあるが、片仮名の少ない左の縁に近づくほど線の間隔が詰まる。

図 3.15 を図 3.3 と見比べよう。生の比率では片仮名は数 % 以下の幅に押し込められて、著者差はほとんど見えなかった。対数比にすると、「小さいが情報を持つ」成分が主役になる。夢野久作がひ




図 3.15 ilr のバランス座標に載せた 74 作品とライトノベル 2 シリーズ。生の比率 (図 3.3) では潰れて見えなかった片仮名の使い方の差が、縦軸いっぱい広がる。『薬屋のひとりごと』の最下点は片仮名が 1 文字も出てこない区間で、後で述べる乗法的置換 (式 (3.12)) で埋めた値を描いた。この点の縦の位置は、置換量の選び方で変わる。

とかたまりで上に浮いているのは、擬音や台詞の片仮名書きを多用する文体のためである。片仮名比率の差でいえば数パーセントの違いが、比で見れば 10 倍以上の開きだったことになる。

三角図 (図 3.7) で対照的だったライトノベル 2 シリーズは、ここでは上下に引き裂かれる。『本好きの下剋上』は夢野久作のさらに上、『薬屋のひとりごと』は 1 点を除いて全著者より下にある。三角図では「近代文学の集団に混ざって」見えた薬屋が、対数比では一目で異質だと分かる。微量成分の癖は、比で見て初めて特徴になる。

薬屋の 10 点だけでも縦に大きくばらついている。上に飛び出した 1 点は異国 (砂欧) を舞台にした区間で、地名と人名の片仮名がここだけ増える。比で見ると、舞台の違いが他の著者どうしの差より大きく出る。ただし、この縦のばらつきをすべて舞台の違いと読むことはできない。『薬屋のひとりごと』の区間には、十数万字の中に片仮名が 1 文字か 2 文字しか現れないものがある。回数がこれだけ少ないと、1 文字増えるか減るかで対数比の値は大きく変わる。対数比は小さい成分の癖を拾うが、小さい成分の偶然の揺れも同じように拡大する。

じつはこの図には、すでに対数が取れない点が 1 つ混ざっている。『薬屋のひとりごと』の最下点は、片仮名が 1 文字も出てこない区間である。図の各点は連載を 8 万～16 万字ずつに区切った区間だが、これを 1 話ずつまで細かくすると、『薬屋のひとりごと』の 395 話 (10 区間に入らなかった末尾の話も含む) のうち 370 話は片仮名が **1 文字も出てこない**。厳密にゼロである (図 3.16 の上段)。片仮名が出る話はまばらに散らばっていて、第 286 話より後の 109 話には 1 文字も出てこない。

図 3.16 の下段は、同じ話のルビの中の片仮名である。こちらはほとんどの話に十数字から数十文字ずつ現れ、ルビの中まで数えても片仮名が 1 文字もない話は 4 話しかない。上段のゼロの多くは、作者が外来語や人名の読みを片仮名のルビに回す書き方と、ルビを除いて数える本書の前処理が重なって生じたものである (表 3.2 の後の補足「ウェブ小説のルビは著者が振る」)。

同じ作品でも、どの粒度で数えるかによってゼロが現れる。それをどう扱うかが次項の主題である。




図 3.16 『葉屋のひとりごと』の話ごとの片仮名の字数。上段は本書の前処理どおりルビを除いた本文、下段はルビの中である。破線は 10 区間の境目、灰色の帯は 10 区間に入らない末尾の 51 話。上段の上に並ぶ数字は、区間ごとに上段の字数を合計した値である。1 話ずつ数えると 395 話のうち 370 話がゼロだが、区間にまとめるとゼロは 10 区間のうち 1 区間 (赤の 0) だけになる。第 163 話は縦軸の上端で切った。

補足 小さい成分ほど比で見ると情報が出る

生の比率のままだと、大きい成分 (平仮名) の増減が図の大半を占め、小さい成分 (片仮名) の増減はスケールに埋もれる。対数比はどの成分の「2 倍」も同じ距離として扱うので、小さい成分の癖を拾える。微量成分こそが決め手になる分析 (地球化学の微量元素、細菌叢の希少種) で対数比変換が標準になっているのは、小さい成分の癖を拾えるからである。

3.7.5 ゼロがあると対数が取れない

式 (3.10) には弱点がある。 $x_j = 0$ だと $\ln 0 = -\infty$ になる。

そして実データにゼロは頻繁に現れる。組成データ 50 列 $\times$ 74 作品 = 3700 マスのうち、255 マス (6.9%) がゼロだった。ゼロはすべて読点前平仮名の列に出る。たとえば「っ、」は 74 作品中 42 作品で一度も現れない。「あっ、と叫んだ」のような書き方は、作品の数でいえば使わないほうが多い。74 作品のうち 55 作品が、どこかにゼロを含んでいる。ゼロの出方は著者によって大きく違う (表 3.5)。著者ごとに回数を合算すると、「っ、」を一度も使っていないのは 8 名のうち 3 名である。

字種比率でも起きる。『葉屋のひとりごと』を 1 話ずつ数えると、395 話のうち 370 話で片仮名比率が**完全なゼロ**になる。中国風の後宮が舞台で、外来語や人名の読みの片仮名はルビに回されるので、ルビを除いた本文に片仮名が 1 文字も出てこない話のほうが多い (図 3.16)。

3.7.6 ゼロには数え足りないものと、構造として出ないものがある

ゼロを埋める話に入る前に、片付けておくことがある。そのゼロが何を意味しているかである。

「っ、」に戻る。「っ、」が一度も現れなかった作品で、直前が平仮名 (残した 47 文字) の読点の本数は、中央値で 2563 本である。これだけの読点がありながら 1 回も出ないのが、数え足りないせいなのか、使わないという癖なのかを分けたい。「っ、」が 1 回でも現れる 32 作品 (うち 20 作品が吉川英治) では、こうした読点 408 本に 1 回ほどの割合で現れる (作品ごとの割合の中央値)。この割合

表 3.5 読点前平仮名 47 列のゼロの数。作品ごとに数えた場合と、同じ著者の作品の回数を合算してから数えた場合。合算すると 255 個のゼロは 4 個に減る

著者	作品数	作品ごとのゼロ	著者で合算したゼロ	合算しても残る文字
島崎藤村	9	66	1	「っ、」
夢野久作	7	55	1	「っ、」
夏目漱石	10	35	0	—
泉鏡花	9	32	0	—
柳田国男	5	26	2	「っ、」、「ゃ、」
谷崎潤一郎	6	21	0	—
太宰治	7	13	0	—
吉川英治	21	7	0	—
計	74	255	4	

は、ほぼ吉川英治の書き方で決まっている。同じ割合なら、2563 本のあいだに 1 回も現れない確率は 2×10^{-3} である。小さいが、ありえない話ではない。

ところが「っ、」がゼロの 42 作品には、この読点を 12983 本含むもの (夢野久作『ドグラ・マグラ』) がある。同じ割合なら、12983 本のあいだに 1 回も現れない確率は 1×10^{-14} 。事実上ゼロである。ゼロの由来は、数え足りたかどうかではない。この著者は「あっ、」という書き方をしないという事実の反映である。

同じ 0 という数字でも、由来が 2 通りある。

- **数え上げゼロ** (count zero) — 本当は正の割合で起きるが、観測した量が足りずに 1 回も出なかった。量を増やせば (粒度を粗くすれば) ゼロは消える
- **構造ゼロ** (essential zero) — その書き手・その条件では原理的に起きない。いくら量を増やしてもゼロのまま

見分け方は素朴である。**粒度を粗くしてゼロが消えるかどうか**を見る。『薬屋のひとりごと』の片仮名比率は、1 話ずつ数えると大半の話がゼロだが (連載全体で 395 話のうち 370 話)、10 区間にまとめると 9 区間でゼロが消える (図 3.16)。数え上げゼロである*2。「っ、」は、12983 本の読点を集めてもゼロのままだった。構造ゼロに近い。

区別が要する理由は、扱いが逆になるからである。数え上げゼロは「観測できなかった小さな正の値」なので、小さな値で埋めるのが理にかなう。構造ゼロを同じように埋めると、**存在しないものを存在することにしてしまう**。しかもゼロであること自体が著者の癖なのだから、埋めた瞬間にその情報は、埋めるのに使う小さな共通の値 (後述の δ) に均される。

どれくらいの情報は測れる。読点前 47 列を「ゼロか否か」の 0/1 に潰して比率の値を全部捨て、74 作品を階層的クラスタリングにかけて著者数と同じ 8 クラスタに切る。できたクラスタと正解の著者の分かれ方との一致を **ARI***3で測ると 0.355 になる。でたらめに分けたときの期待値 0 よりは

*2 残る 1 区間だけは、10 万字を超える分量でも片仮名が 1 文字も出なかった。粒度をもう一段粗くすれば消えるともてよい。

*3 Adjusted Rand Index (調整ランド指数) の略。作られたクラスタが正解の分かれ方とどれだけ一致するかを表す指標である。完全に一致すれば 1、でたらめに分けたときの期待値が 0 になるよう調整してある。定義は第 5.5 節で述べる。

高い。数値を捨てても著者がある程度分かるのだから、ゼロの位置は無視できる情報ではない。

○ 定石 3.4 — ゼロを埋める前にそのゼロの由来を確かめる —

ゼロの置換は、対数比変換を使うために必要になる操作であって、それ自体が望ましい処理ではない。埋める前に3つ確かめる。

1. **そもそも埋める必要があるか。** ゼロを埋めるのは、対数を取るときだけである。生の比率のまま距離を測るなら、決定木やランダムフォレスト (第7章) に渡すなら、ゼロは0のままでもいい
2. **粒度を粗くしてゼロが消えるか。** 消えるなら数え上げゼロで、小さな値で埋めてよい。消えないなら構造ゼロを疑う
3. **ゼロの位置に情報があるか。** 「ゼロか否か」の0/1だけでどれだけ分けられるかを測っておく。分けられるなら、埋めることでその情報が失われる

構造ゼロが多い列は、埋めるより次のどれかを選ぶ。

- その列を落とし、残りで**部分組成**を作り直す
- 「ゼロか否か」を別の2値の列として残し、値の列は正の行だけで扱う
- ゼロの多い列をまとめて1つの成分に合算する

本書では、読点前47列に出た255個のゼロを乗法的置換で埋めた。同じ著者の作品の回数を合算するとゼロは4個に減り (表3.5)、粒度を粗くすると大半が消えるので、多くは数え上げゼロだと判断したためである。埋める扱いと、ゼロを含む列を落として部分組成にする扱いの両方について、clr変換したうえでユークリッド距離 (Aitchison 距離) を使い、74作品を階層的クラスタリング (Ward法、第5章) にかかけ、8クラスタに切ったときのARIを比べた。ゼロを含まない17列だけの部分組成では0.756、47列すべてを埋めた場合は0.655である。この課題では、埋めるよりゼロを含む列を落とすほうが、著者の分かれ方に近かった。どちらの扱いで報告するかを決める前に、両方を測って並べておくのが安全である。

発展 乗法的置換の式

数え上げゼロだと判断したうえで埋めるなら、**残りの成分を縮めて合計1を保つ**のが要点である。

$$\tilde{x}_j = \begin{cases} \delta & (x_j = 0) \\ x_j \left(1 - \frac{z\delta}{\sum_{k: x_k > 0} x_k} \right) & (x_j > 0) \end{cases} \quad (3.12)$$

z はその行のゼロの個数である。単に δ を足すだけでは合計が1を超え、組成データでなくなってしまふ。

δ の決め方は、ゼロの出方によって変わる。化学分析のように**測定器の下限**があってゼロになる場合 (丸めゼロ) は、検出限界の0.65倍程度が使われる [27]。本書のように数え上げでゼロになる場合は検出限界という概念がないので、観測された最小の正の値の0.65倍を代用した。本書の50列では、最小の正の値は 8.8×10^{-5} で、読点の多い1作品 (『宮本武蔵』円明の巻) で、ふだんは残す列に入る「す、」がたまたま1回だけ出たときの割合である。読点前の典型的な割合 (0.01前後) の百分の1ほどにあたる。数

発展（続き）

え上げゼロなら、その行で「半回だけ出た」とみなして $\delta_i = 0.5/n_i$ (n_i はその行の読点前平仮名の総数) とする決め方もある。行ごとの観測数が違うなら、数え上げゼロ専用のベイズ的な置換法もある [28]。

いずれにしても δ は恣意的な値である。ゼロの割合が大きいときは、置換の値が結果を左右する。 δ を 10 倍・1/10 倍して結論が変わらないか確かめるとよい。本書のデータで確かめた結果は、第 3.7.7 項の図 3.17 に示す。

× アンチパターン 3.8 — 対数比を保ちたいのに、比率へ一律に 1 を足す

$\ln(1+x)$ そのものが悪いわけではない。問題になるのは、比率どうしの対数比を使いたいの、ゼロを避けるため一律に 1 を足しても、元の対数比が保たれると考える場合である。

例えば 0.001 と 0.01 は 10 倍違う。対数の差は $\ln(0.01/0.001) \approx 2.303$ だが、1 を足してから差は $\ln(1.01/1.001) \approx 0.009$ に縮む。小さな x では $\ln(1+x) \approx x$ なので、対数比を測るつもりが、ほぼ元の比率の差を測ることになる。

一方、カウントデータにゼロが含まれ、大きな値と小さな値の差を圧縮したい場合には、 $\ln(1+n)$ を使える。この用途では、元の対数比を保たないこと自体は問題にならない。 n が十分大きければ $\ln(1+n)$ と $\ln n$ は近いが、小さなカウントでは加えた 1 の影響が残る。

ただし、 $\ln(1+x)$ では、単位を変えると加えた 1 の影響も変わる。例えば割合の 0.01 を百分率の 1 に直してから変換すると、1 を足す前後の値の比が変わる。比率の対数比を調べる処理と、カウントの大きな値を圧縮する処理を区別して使う。

3.7.7 clr 変換の効果はゼロ置換量しだいで変わる

理屈は分かった。残るのは、実際に精度が上がるかどうかである。

50 列の組成データに clr 変換を施し、本書のあとの章で使う 3 つの評価をそのまま実行した。どれも対象は 74 作品である。

表 3.6 clr 変換の効果。74 作品の組成データ 50 列で測った。距離の効果量はユークリッド距離で測った値、ARI は Ward 法の階層的クラスタリングを 8 クラスに切ったときの値で、この 2 つは全作品を一度に変換して測った（探索なので構わない）。正解率はランダムフォレストを 5 分割の層別交差検証にかけたときの値で、ゼロ置換量 δ と標準化の平均・標準偏差は各分割の訓練側だけから決めた。 δ はどの行も既定値（最小の正の値の 0.65 倍）である。最下行は、字種 3 列と読点前 47 列を別々の組成として変換した場合である

前処理	距離の効果量	ARI	正解率
標準化のみ	1.354	0.595	0.918
clr 変換	1.389	0.655	0.960
clr 変換 + 標準化	1.418	0.696	0.960
群ごとの clr 変換 + 標準化	1.447	0.637	0.932

「距離の効果量」は、同じ著者どうしの距離と別の著者どうしの距離がどれだけ離れているかを標準偏差を単位に測ったものである（第 4 章）。ARI はクラスタリングが著者の分かれ方とどれだけ一

致するか指標 (第5章)、正解率はランダムフォレストによる著者判定を5分割の層別交差検証で測った値 (第7章) である。3つとも値が大きいほどよい。

この表だけを見れば、3つとも改善している。標準化のみの行と clr 変換 + 標準化の行を比べると、距離の効果量は 1.354 から 1.418 へ 0.064、クラスタリングの ARI は 0.595 から 0.696 へ 0.101、著者判定の正解率は 0.918 から 0.960 へ 0.042、それぞれ上がった。正解率は clr 変換だけで 0.960 になり、標準化を重ねても同じ値である。ランダムフォレストの分岐は各列の値の大小の順序だけで決まり、列ごとに定数を引いて定数で割っても順序は変わらないからである。標準化を重ねて上がるのは、距離の効果量と ARI のほうである。

ただし、この比較はゼロ置換量 δ を1つの値に決めたうえでの結果である。 δ の倍率だけを変えて、clr 変換 + 標準化の3つの評価を測り直したのが図 3.17 である。 δ を 1/10 にすると、距離の効果量は 1.109、ARI は 0.442、正解率は 0.906 になり、3つとも標準化のみ (1.354、0.595、0.918) を下回る。10 倍にすると、効果量は 1.921 に上がるが、ARI は 0.661、正解率は 0.947 で、既定値のとき (0.696、0.960) より下がる。倍率を 1/100 から 100 倍まで変えると、ARI は 0.364 から 0.696、正解率は 0.866 から 0.987 の間を上下し、倍率に対して単調にも変わらない。ARI が最も高かったのは、既定値の倍率 1 のときである。

このデータからは、clr 変換で3つの評価が上がるかどうか自体が δ の選び方に左右される、というところまでしか言えない。距離の効果量は、 δ を既定値以上にすれば標準化のみを上回るが、既定値より小さくすると下回る。ARI と正解率は倍率に対して単調にも変わらない。表 3.6 の改善は既定の δ での結果にとどまる。




図 3.17 ゼロ置換量 δ を既定値 (最小の正の値の 0.65 倍) の何倍にするかだけを変え、clr 変換 + 標準化で測った3つの評価。条件は表 3.6 と同じで、正解率では訓練側だけから決めた δ に倍率を掛けた。破線は標準化のみの値。倍率 1 が表の値にあたる。

50 列をひとまとめに変換するか、群ごとに変換するかは判断の分かれる点である。字種 3 列と読点前 47 列は分母が違う (全文字数と読点の数) ので、別々の組成として扱うほうが筋は通る。ところが最下行のとおりに、群ごとに変換すると距離の効果量は 1.447 へさらに上がるが、ARI は 0.637、正解率は 0.932 へ下がる。ひとまとめに変換したときの幾何平均は、字種と読点前の両方をまたいだ基準になる。群ごとの変換で ARI と正解率が下がる理由は確かめていない (δ が群ごとに別の値になることも、理由の候補である)。どちらが正しいというより、何を基準にした対数比を見たいかで決まる。本節の比較では、表の3つの評価がそろって上がったひとまとめの変換を使った (第4章以降

は、次の補足の理由で生の比率に戻す)。

補足 本書が clr ではなく生の比率を使い続ける理由

表 3.6 だけを見れば clr のほうが良い。にもかかわらず、第 4 章以降では標準化した生の比率を使い続ける。

理由は 2 つある。一つは、ゼロ置換という恣意的な操作が入ること。図 3.17 のとおり、 δ の選び方で ARI は 0.364 から 0.696 まで変わり、標準化のみとの優劣も入れ替わる。手法そのものの比較をしたい場面では余計な変数になる。しかも δ は最小の正值から決めるので、データを見て決める量である。未知の作品への性能を測るときは、 δ も訓練側だけから決めなければならない (表 3.6 の正解率はそうしてある。第 9 章の前処理の漏れを参照)。

もう一つは、読み手が生の値を頭の中で追えること。「平仮名の比率が 0.68」は文章のイメージと結びつくが、「平仮名の clr 変換後の値が 1.42」はそうではない。

生の比率を選ぶことは**正しさと分かりやすさの取り引き**である。現実の分析でも同じ判断を迫られる。取り引きをしていると自覚したうえで選べばよい。避けたいのは、黙って生の比率を使ったまま、負の相関を文体の発見として報告してしまうことである。

3.8 できあがった表

3 種類の特徴を横に並べると、74 行 × 52 列の表になる。

表 3.7 特徴量テーブルの一部

著者	題名	平仮名	漢字	文長 μ	文長 σ	て	が
太宰治	斜陽	0.731	0.247	3.17	0.98	0.172	0.058
夏目漱石	こころ	0.701	0.297	3.34	0.53	0.190	0.100
吉川英治	三国志_桃園の巻	0.673	0.325	3.25	0.84	0.170	0.072

できあがった表が本書の残りすべての出発点である。以後、テキストそのものには戻らない。74 個の点が 52 次元の空間に散らばっているという見方だけで進む。

補足 本章でやってきた作業の名前 — 特徴量エンジニアリング

本章の作業には名前がある。**特徴量エンジニアリング** (feature engineering)、生のデータをモデルが扱える数値の表に加工する工程である。振り返ると、特徴量エンジニアリングの定番の道具を一通り使っている。数える対象を領域の知識で選ぶ (読点前の平仮名)、大きさを比率に直す (正規化)、分布の形を見てから少数の数に要約する (対数正規分布の μ と σ)、まれすぎる列を落とす。第 2 章の対数目盛りも、第 3.7 節の対数比も、同じ仲間である。

深層学習は特徴を生データから自動で学ぶ (表現学習) ので、特徴量エンジニアリングはもう不要になった、と言われることがある。画像や音声ではおおむねそのとおりである。だが本書のような表形式・小標本のデータでは、いまま「手作りの特徴 + 木のモデル」が強いことが多い。モデルを取り替えるより、良い特徴を 1 つ足すほうが成績を大きく引き上げるという場面は、実務にも多い。

これは言い切りにはできる話ではない。本章の 52 列と、大規模言語モデルが作る表現とを実際に突き合わせるのは第 10.1 節である。比べるには分類器と交差検証が要るので、そこまで待つことになる。

補足 本書が形態素解析を使わない理由

単語の頻度を使えば、もっと精度は上がるかもしれない。だが、次の理由で本書では使わない。

- 環境構築が要る。辞書のインストールでつまづく人が必ず出る
- 解析には誤りが混ざる。古い文語調のテキストでは特にそうである
- 単語を使うと**内容語が紛れ込む危険**が高まる

文字レベルの特徴だけで、著者判別は十分な精度に達する。それを本書で確かめる。

3.9 章末の課題

1. 図 3.3 で、片仮名の比率を縦軸にすると何が見えるか。近代文学とライトノベルを比べるとどうなるか予想せよ。
2. 文長を「句点・感嘆符・疑問符で区切り、句読点と括弧を除いた文字数」と定義した。会話文の「」をどう扱うべきか。定義を変えると結果は変わるか。
3. 読点前の平仮名のほかに、著者の癖が出そうな量を 3 つ挙げよ。それぞれが上記の 3 条件を満たすか検討せよ。
4. 特徴の数を 47 から 10 に減らすとしたら、どの文字を残すか。判断の基準を述べよ。
5. 表 3.7 の『斜陽』の行 (平仮名 0.731、漢字 0.247。片仮名は残りとする) に clr 変換を手計算で適用し、3 成分の和が 0 になることを確かめよ。(ヒント: 幾何平均の対数は、対数の算術平均に等しい。先に 3 成分の $\ln$ を取ってしまうのが早い。)

第 4 章

距離を測る

4.1 「似ている」を数式にする

74 作品が 52 次元の空間に散らばっている。ここから「似た作品」を見つけたい。

そのためには、2 つの作品がどれだけ離れているかを 1 つの数で表す必要がある。その数を距離という。

距離は好きに定義してよいわけではない。次の 4 条件を満たすものを距離と呼ぶ。

$$d(x, y) \geq 0 \quad \text{非負性} \quad (4.1)$$

$$d(x, y) = 0 \iff x = y \quad \text{同一性} \quad (4.2)$$

$$d(x, y) = d(y, x) \quad \text{対称性} \quad (4.3)$$

$$d(x, z) \leq d(x, y) + d(y, z) \quad \text{三角不等式} \quad (4.4)$$

最後の三角不等式は「A と B が近く、B と C が近ければ、A と C もそれなりに近い」ことを保証する。近傍探索の高速化 (候補の枝刈り) や、一部のアルゴリズムの理論保証はこの性質に頼っている。ただし、4 条件を守らない指標が実務で使えないわけではない。本章の実験で最もよく著者を分けるのは、実は三角不等式を満たさない指標である。この折り合いは第 4.7.2 項で付ける。

4.2 ミンコフスキー距離

最もよく使われる距離の族である。

$$d_p(x, y) = \left(\sum_{j=1}^n |x_j - y_j|^p \right)^{1/p} \quad (4.5)$$

p を変えると性格が変わる。

言葉で説明するより、**原点から等距離にある点の集合** (単位球) を描くほうが分かりやすい。図 4.1 に示す。

$p = 1$ のとき、原点から距離 1 の点はひし形の上に乗る。(1, 0) も (0.5, 0.5) も同じ距離 1 である。 $p = 2$ では円になり、(0.5, 0.5) の原点からの距離は $\sqrt{0.5} \approx 0.71$ になる。(1, 0) の距離 1 より 0.29 小さい。

つまり p が小さいほど、複数の次元に分散した差を重く見る。 p が大きいと、一つの次元の大きな差が支配的になる。

表 4.1 p の値による違い

p	名前	性格
1	マンハッタン距離	各次元の差の絶対値を足すだけ。外れ値の影響が小さい
2	ユークリッド距離	直線距離。最もよく使われる
4	—	大きい差を強調する
∞	チェビシェフ距離	最大の差だけで決まる




図 4.1 原点からの距離が 1 になる点の集合。 p が大きくなるほど正方形に近づく。

4.2.1 マンハッタン距離の直感

$p = 1$ を「マンハッタン」と呼ぶのは、碁盤の目の街路を歩くとき、斜めには進めないからである。




図 4.2 マンハッタン距離。街路をどう曲がっても合計は同じ 8 になる。

図 4.2 で大事なのは、経路が違っても距離が同じという点である。右に 5、上に 3 進むという内訳は変わらない。ユークリッド距離が「一直線の長さ」なのに対し、マンハッタン距離は「各方向にどれだけ動いたかの合計」である。

2 つの距離のもう 1 つの違いは、差を 2 乗するかどうかである。そして、この違いが外れ値への強さを分ける。

いま 2 つの作品を 52 次元で比べているとする。51 個の特徴はほぼ同じで、1 個だけ極端にずれているとしよう。その大きなずれを δ と書く。

$$d_1 \approx (\text{小さな差の和}) + \delta \quad (4.6)$$

$$d_2 \approx \sqrt{(\text{小さな差の 2 乗和}) + \delta^2} \approx \delta \quad (4.7)$$

2 つ目の式の後半の $\approx$ を確かめておく。 δ が他の差より桁違いに大きければ、それを 2 乗した δ^2 はさらに桁が離れる。根号の中身はほとんど δ^2 で占められ、残りの 51 項は誤差のようなものになる。だから d_2 は δ そのものにほぼ等しくなる。

差が桁違いとまではいなくても、同じ向きの偏りは出る。たとえば残りの 51 個の差がどれも δ の $1/10$ だとすると、 d_2 の根号の中では δ^2 が全体の約 3 分の 2 を占める ($1/(1 + 51/100) \approx 0.66$)。 d_1 では 51 個の差の和が 5.1δ になり、 δ が占めるのは全体の約 6 分の 1 である ($1/6.1 \approx 0.16$)。

つまりユークリッド距離では、たった 1 つの大きなずれが他の 51 次元の情報を押し流してしまう。マンハッタン距離のほうは δ を 2 乗しないので、あくまで 52 項のうちの 1 項として足されるだけで済む。

補足 1 文字の誤植が作品を孤立点に変えることがある

テキスト分析では、1 文字の誤植や記号の混入で、1 つの特徴だけが極端な値になることがある。

そのとき、ユークリッド距離だとその作品が「どの作品からも遠い孤立点」になってしまう。マンハッタン距離ならその影響は限定的である。

第 4.6 節で $p = 1$ が $p = 2$ よりよく分けている理由は、本書では測り分けていない。誤植への強さも候補の 1 つだが、高次元では 1 つの列にたまたま大きな差が出やすいこと (第 4.10.1 項) も同じ向きに働くので、どちらがどれだけ寄与したかは分からない。

コラム ずれの絶対値の和で線を引いた 18 世紀の天文学者

データに直線を当てはめるとき、今日の標準は、ずれの **2 乗の和** を最小にする最小二乗法である。これを初めて印刷物で示したのはルジャンドルで、1805 年のことだった [30]。それより前に、ずれの**絶対値の和**を小さくする当てはめを考えた人がいる。

ラグーサ共和国 (いまのクロアチアのドゥブロヴニク) 生まれのイエズス会士で、天文学者・数学者でもあった R. J. ボスコヴィッチである。ボスコヴィッチは 1750 年から約 2 年をかけて、ローマとリミニのあいだで子午線の長さを測る測量を行い、1755 年に報告をまとめた。そのボスコヴィッチが 1757 年に概要を、1760 年に詳しい形で示したものに、2 つの変量の観測に直線を当てはめる手順がある。観測の数が決めた値の数より多いときに、ずれの絶対値の和を (ずれの合計が 0 になるという条件のもとで) 最小にする、幾何的な手順である [31]。この手順は、のちにラプラスが代数の形で広めた。条件を外した形は、今日「最小絶対偏差法」や「L1 ノルムによる当てはめ」と呼ばれている。

ずれの絶対値の和は、本節のマンハッタン距離そのものである。1 つの大きなずれを 2 乗で増幅しないので、外れ値に引きずられにくい。最小二乗法より半世紀近く早く、外れ値に強い側の基準が使われていたことになる。

4.3 コサイン距離 — 向きだけを見る

ミンコフスキー距離とは発想の違う測り方がある。ベクトルの**向きだけ**を比べ、長さを無視する。

$$\cos \theta = \frac{x \cdot y}{\|x\| \|y\|} = \frac{\sum_j x_j y_j}{\sqrt{\sum_j x_j^2} \sqrt{\sum_j y_j^2}} \quad (4.8)$$

これは2つのベクトルのなす角の余弦である。同じ向きなら1、直交していれば0、正反対なら-1になる。距離にするには1から引く。

$$d_{\cos}(x, y) = 1 - \cos \theta \quad (4.9)$$

4.3.1 長さを残すと、別の作家のほうが近くなる

図4.3で違いを見る。




図4.3 AとBは同じ作家の長編と短編。ユークリッド距離ではBとCのほうが近い。

AとBは同じ作家が書いた長編と短編だとする。すべての単語の出現回数が、長編では単純に多くなる。向きは同じで、長さだけが違う。

図4.3の座標をそのまま使ってユークリッド距離を測ると、同じ作家の2作品が $d_2(A, B) = 1.79$ 、作家の違う2作品が $d_2(B, C) = 1.43$ になる。後者のほうが0.36小さく、別の作家Cのほうが近いという結果になってしまう。

コサイン距離なら $d_{\cos}(A, B) = 0$ である。向きが同じだからである。

○ 定石 4.1 — 長さの違いを消したいときにコサイン距離を選ぶ —

- 文書の長さがばらばら
- 特徴が「回数」で、全体の量に比例して増える
- 高次元でスパース (ほとんどの成分が0)

情報検索や文書分類でコサイン類似度が定番なもの、長さを消せるからである。

4.3.2 ℓ_2 正規化すればコサイン距離と順位が一致する

本書の特徴量のうち、字種3列と読点前47列は、第3章で行ごとに割合に直してある (ℓ_1 正規化)。それでも後の表4.3では、コサイン距離がユークリッド距離よりよく分ける。両者の差が残るのは、表4.3の比較が、列ごとに標準化した値 (次節) で行われているからである。標準化すると行の和はもう1ではなく、行の長さは作品によって3.8から15.3までばらつくので、長さを無視するコ

サイン距離と、長さも数えるユークリッド距離とで結果が分かれる。なお、標準化する前でも両者は一致しない。 ℓ_1 正規化は「成分の和を 1 にする」操作で、コサイン距離が無視する ℓ_2 ノルム (ベクトルの長さ) を 1 にするわけではないからである。

もし ℓ_2 正規化 ($\|x\| = 1$) してあれば、両者は完全に対応する。

$$\|x - y\|^2 = \|x\|^2 + \|y\|^2 - 2x \cdot y = 2 - 2\cos\theta = 2d_{\cos}(x, y) \quad (4.10)$$

つまり単位球面上では $d_2 = \sqrt{2d_{\cos}}$ となり、片方が小さいときもう片方も小さい。順位付けの目的なら、どちらを使っても同じ結果になる。

補足 コサイン距離と ℓ_2 正規化の使い分け

ℓ_2 正規化してからユークリッド距離を使うのと、生のベクトルにコサイン距離を使うのは、実質的に同じことである。

どちらで書くかは、後段のアルゴリズムが何を要求するかで決める。Ward 法や k-means はユークリッド距離を前提とするので、「 ℓ_2 正規化 → ユークリッド距離」の形にしておく使いやすい。

補足 コサイン距離が定番になった由来とその限界

コサイン距離の地位は、情報検索のベクトル空間モデル (Salton らの SMART システム) に由来する [32]。文書を単語頻度のベクトルで表す世界では、文書の長さを自動的に打ち消せること、ほとんどの成分が 0 の疎なベクトルなら内積が「両方に現れた単語」だけの和になり計算が軽いこと、値が -1 から 1 に収まり解釈しやすいこと。実務的な利点の束が、定番の座を作った。

現代的な理由も一つある。単語や文の埋め込みベクトルは、学習の目的関数そのものが内積 (またはコサイン) で類似度を測る形をしているので、**学習時に使った距離で結果も測る**ためにコサインが選ばれる。裏を返せば、コサインが「意味の類似度の正しい定義」だから使われているわけではない。実際、正則化つきの線形モデルで学習した埋め込みでは、コサイン類似度が正則化のかけ方しだいで恣意的な値を取りうる事が示されている [34]。

ただし、注意すべき点もある。コサインは**次元の呪いの対策ではない**。高次元ではランダムなベクトル対の角度が 90° に集中し (付録 B)、角度もまた「みな同じ」へ向かう。表 4.3 でコサインが勝つのは、本書のデータでは長さの情報が判別の邪魔だからであって、呪いを退治したからではない。ノルムを捨てるので、量の絶対値が意味を持つ課題でも損になる。そして万能でもない。確率分布どうしの近さを測る尺度を、まだ観測されていない単語の組の確率を推定する課題で比べた計算言語学の研究では、コサインは中位、ユークリッド距離は最下位で、L1 距離 (本章の $p = 1$) や Jensen-Shannon divergence のほうが良い成績を出した [33]。上位の尺度に共通していたのは、2 つの分布の両方に現れる成分に重みを置く点だった。和が 1 に固定された分布どうしを比べるなら、コサインを既定にする理由はない。

× アンチパターン 4.1 — 定番だからという理由で距離を選ぶ

ある距離が定番の座にあるのは、それが生まれた分野の問題に都合がよかったからにすぎない (コサイン距離については直前の箱で見た)。手元のデータが、その分野と同じ単位や分布の形を持っているとは限らない。

チェビシェフ距離が表 4.3 で最下位に沈むのも、その設計が「最悪の 1 項目で決める」場面向けだからで、距離そのものの優劣ではない。

距離はデータの構造と、(学習器を使うなら) その目的関数に合わせて選ぶ。候補を2つか3つ実際に走らせ、効果量なり正解率なりの数字で決める。表4.3は、そのための比較を1枚にしたものである。

4.4 標準化 — 文長の2列が距離のほとんどを占めてしまう

距離を計算する前に、必ず確認すべきことがある。列ごとの値の大きさが揃っているかである。

図4.4に、52列それぞれの標準偏差を大きい順に並べた。




図4.4 列ごとの標準偏差。最大と最小で300倍以上の開きがある。

標準偏差が最大の列(文長 μ)と最小の列で、300倍以上の開きがある。

式(4.5)を見返すと、各項が同じ重みで足されている。ばらつきの大きい列は差も大きくなるので、その列だけで距離がほぼ決まってしまう。

文長 μ の差が0.5あったとして、「あ」の割合の差0.005など距離にはまったく現れない。47個の読点の特徴を苦労して作った意味がなくなる。

本当にそうなるか、74作品を生のまま(標準化せずに)測ってみた。全2701ペアの二乗ユークリッド距離を列ごとの寄与に分解すると、文長 μ が80.0%、文長 σ が11.4%を占め、字種3列は合わせて2.6%、残る読点47列は全部合わせても6.1%しかない。文長の2列だけで9割を超えている。52次元の距離を測っているつもりで、**実質は2次元**だった。図4.5の上の帯がこの内訳である。




図4.5 距離のうち、どの列の差がどれだけを占めるか。生のままでは文長の2列で9割を超える。列ごとに標準化すると、どの列も全ペアの二乗差の和が同じになるので、各群の割合は列の数の割合(1列なら $1/52 \approx 1.9\%$ 、47列なら $47/52 \approx 90.4\%$)に等しくなる。

同じ生のままのユークリッド距離で、同著者ペアの距離と異著者ペアの距離がどれだけ分かれているかを効果量 (第 4.6 節で定義する) として測ると、値は 1.24 である。

対処が**標準化**である*¹。

$$z_j = \frac{x_j - \mu_j}{\sigma_j} \quad (4.11)$$

各列を平均 0、標準偏差 1 に揃える。これで全列が対等になる。図 4.5 の下の帯が標準化後の内訳で、読点前 47 列が距離の 90.4% を占めるようになった。本書の 74 作品で同じ効果量 (ユークリッド距離で測った、同著者ペアと異著者ペアの分離の度合い) を測り直すと、生のままの 1.24 に対して標準化後は 1.42 になった。0.18 の増加である。

× アンチパターン 4.2 — 単位の違う列を混ぜたまま距離を測る

単位の違う量を混ぜれば、この偏りは必ず起きる。身長 (cm) と体重 (kg) と年収 (円) を並べて距離を測れば、年収だけで結果が決まる。

「なぜか 1 つの変数でしか分類されない」という症状が出たら、まずスケールを疑ってみる。

4.4.1 行の標準化と列の標準化とその両方*

読点前平仮名の 47 列は、第 3 章で**行ごと**に割合に直した (合計はほぼ 1)。いま行った標準化は**列ごと**の操作である (名前の似た 2 つの操作の違いは、第 3 章のアンチパターン「正規化と標準化を混同する」にまとめた)。ここで一度、行と列の操作を整理しておきたい。「行を z 化したらどうなるのか」「両方やったらどうなるのか」は、実際の分析で必ず一度は迷う点だからである。

行を z 化したときに測っているもの z 変換を列でなく行に施す、つまり各作品のベクトルから自分の行内平均を引き、行内標準偏差で割ってみる。

こうすると、どの行も平均 0・標準偏差 1 になる。ここでの標準偏差は、2 乗和を列数 n で割ってから平方根を取ったもの (第 3 章の n で割る版) である。したがって標準偏差が 1 ということは、 n 個の成分の 2 乗和が n に固定されるということである。つまり**どの作品のベクトルも、原点から同じ距離のところ**に並ぶ。長さがそろってしまうので、残る違いは向きだけになる。

この状態で 2 つのベクトルのユークリッド距離を測ると、式 (4.10) と同じ展開ができて

$$d_2(\tilde{x}, \tilde{y})^2 = \|\tilde{x}\|^2 + \|\tilde{y}\|^2 - 2\tilde{x} \cdot \tilde{y} = 2n(1 - r(x, y)) \quad (4.12)$$

となる (r は行どうしの相関係数)。 $\|\tilde{x}\|^2 = \|\tilde{y}\|^2 = n$ を代入し、内積 $\tilde{x} \cdot \tilde{y}$ が nr に等しいことを使った。平均を引いて標準偏差で割ったベクトルどうしの内積が相関係数になる、というのは相関係数の定義そのものである。

結論として、**行の標準化 + ユークリッド距離は、相関距離 $1 - r$ (この章の後半、第 4.8 節) と同**

*¹ 標準化して得た値を z 得点 (z-score、標準得点) と呼び、この操作を z 変換や「 z 化」と言うことがある。文字 z は、平均 0・標準偏差 1 の正規分布 (標準正規分布) に従う変数を z と書く慣習に由来する。統計の教科書の巻末にある正規分布表の見出しが z になっているのも同じ理由である。同じ名前の別物が 2 つあるので、検索するときは注意がいる。信号処理の **Z 変換** は離散時間の信号を複素数の級数に直す操作で、これとは無関係である。統計にも **Fisher の z 変換** があるが、そちらは相関係数 r を $\frac{1}{2} \ln \frac{1+r}{1-r}$ に直して分布を正規分布に近づける操作で、本節の標準化とは別物である。

じ順位を与える距離になる。「行を z 化する」という前処理のつもりの操作が、距離の選択として再登場することになる。本書の 74 作品を、列の標準化をせずに行ごとに z 化してからユークリッド距離を測ると、同著者ペアと異著者ペアの分離の効果量は 1.72 になった。列ごとに標準化したときの 1.42 より 0.30 高い。

同じ生の行どうしに相関距離 $1-r$ をそのまま使うと、効果量は 1.33 になり、1.72 と一致しない。 $1-r$ と $\sqrt{2n(1-r)}$ は単調変換で結ばれているので近い順の並びは同じだが、効果量は平均の差を標準偏差で割った比なので、分子と分母が別々に伸び縮みすれば値も変わる。順位は同じでも、効果量の値は距離の定義に依存する。なお、後述の表 4.3 に載る相関距離の効果量 2.40 は、列ごとに標準化した後の行どうしで測ったもので、ここの値とは入力が違う (同じ標準化後の行を z 化してユークリッド距離を測ると 2.19 である)。

ただし意味には注意が要る。行内平均は「52 個の特徴の平均」であって、文長 μ と「て」の割合を混ぜて平均した量に単位はない。単位の無い量を引いたり割ったりしているのだから、本来なら意味を問われてもおかしくない。

それでもこの操作が働くのは、次のように読めるからである。1 作品の 52 個の数値を、左から順に並べた折れ線だと思ってほしい。行の z 化は、その折れ線の高さと振れ幅をそろえる操作にあたる。そろえたあとに残るのは折れ線の形だけで、2 つの作品の形がどれだけ似ているかを表すのが相関係数である。つまり測っているのは「文体の全体的な濃さ」ではなく、「どの特徴が相対的に高く、どれが低いか」というでこぼこの一致度である。

ただし、生の値のまま行を z 化すると、折れ線の形は、値の大きい文長 μ (3 前後) と文長 σ 、平仮名の割合の数本でほぼ決まってしまう。読点前の列は、どれも 0 に近い高さに並ぶだけである。列を先に標準化しておけば、どの列も同じくらいの振れ幅で形に加わる。同じ行の z 化でも、列を標準化してから行くと効果量が 1.72 から 2.19 に上がるのはこのためである。

行と列の両方を z 化する 行も z 化し列も z 化した「完全に揃った」行列は、一度ずつの操作では作れない。列を z 化すると各行の平均と分散が崩れ、行を z 化すると各列のそれが崩れる。互い違いに繰り返す方法を逐次標準化という。Olshen と Rajaratnam は 2010 年、成分が乱数で作られた行列について、この反復が収束することを論じた [37] (その証明の一部には誤りがあり、2013 年に訂正が出ている [38])。どんな行列でも収束するという保証ではないので、手元のデータでは実際に確かめる。本書のデータでは 33 回の反復で、全行・全列が機械精度で平均 0・分散 1 になった (図 4.6)。

この行列でユークリッド距離を測ると、同著者ペアと異著者ペアの分離の効果量は 1.86 である。列だけの標準化 (1.42) より 0.44、行だけの z 化 (1.72) より 0.14 高い。

収束すること自体は確かだが、使いどころは選ぶ。収束後の各値は「行から見ても列から見ても相対的な位置」としか言いようがなく、元の単位との対応をたどれない。探索でクラスタを見つける道具としては強力だが、「この値は何か」と問われて答えられない前処理を、報告書に黙って入れるのは避けたい。




図 4.6 逐次標準化の収束 (本書の 74 作品・52 列)。縦軸は対数で、変化の幅が反復ごとにほぼ一定の比で縮み、33 回目で 10^{-12} を下回った。

× アンチパターン 4.3 — 順序を考えずに正規化と標準化を混ぜる

第 3 章の正規化 (行)→ 本章の標準化 (列) という順序には意味がある。逆に、**列を z 化したあとで行を合計 1 に正規化すると破綻する**。z 化した値には負の数が入るので、行の合計は 0 の前後に散らばる。合計が 0 に近い行では、それで割った瞬間に値が発散し、符号も反転する。「とりあえず両方かけておく」前処理をパイプラインに積むときは、順序を入れ替えても同じだとは限らない点に気をつける。

× アンチパターン 4.4 — 標準化すれば組成データの制約が消えると思う

第 3 章で見た「合計 1 の縛り」は、列の標準化では消えない。合計が 1 なら、z 化後も $\sum_j \sigma_j z_j = 0$ という線形の縛りがそのまま残る (超平面の法線が $(1, \dots, 1)$ から $(\sigma_1, \dots, \sigma_D)$ に変わるだけである)。実際、字種 3 列を z 化して共分散行列の 3 つの固有値を計算すると、最小の固有値は 1.0×10^{-16} で、計算誤差の範囲で 0 である。負の相関も、部分組成の非整合も、標準化後の世界にそのまま持ち込まれる。制約を外したければ、clr や ilr のような**組成のための変換** (第 3 章) を使うしかない。

4.4.2 列をまたいで足し合わせる手法には標準化が要る

標準化は儀式ではないので、要る手法と要らない手法がある。さらに「要らない」の中にも、**やっても結果が変わらない場合と、やらないほうがよい場合がある**。

なお、本項には第 5 章から第 7 章で扱う手法の名前が先に出てくる。中身を知らなくても、**列の単位を変えたときに何が起きるか**という一つの見方だけで要否が決まるという点が読めれば足りる。個々の手法は、それぞれの章で改めて説明する。

見分ける鍵は、列の単位を変えたとき、その変化をモデルが係数の側で吸収できるかどうかである。距離や分散のように、列の値をそのまま足し合わせて 1 つの数を作る計算には、単位の変化を吸収する係数がない。和を取る前に単位を揃えていなければ、大きい単位の列が和のほとんどを占めてしまう。係数を掛けてから足す計算 (回帰の予測値) なら、係数が単位の変化を打ち消せる。ただし係数の大きさに罰を与える正則化項があると、打ち消すために大きくなった係数や小さくなった係数

が、そのまま罰の大きさに響く。逆に、列を 1 つずつ見て大小を比べるだけの手法なら、どの列に正の数を掛けても順序が変わらないので影響を受けない。この見方で手法を分けたのが図 4.7 である。




図 4.7 標準化の要否。赤が必須、緑が不要、灰色はデータで決まる。

理屈だけでは決まらないので、本書の 74 作品・52 列で実測した。第 7 章で登場する 5 つの分類器を先取りして、74 作品の著者を 5 分割の層別交差検証で判別したときの正解率を、標準化なしと標準化ありで並べたのが表 4.2 である。比べる相手は、最頻クラスを答え続ける基準線 0.284 である。

表 4.2 標準化の有無による正解率の変化 (5 分割の層別交差検証)。標準化は交差検証の内側で行っている (理由は第 9 章)。参考: 基準線 (最頻クラス) は 0.284

手法	なし	あり	何が起きたか
ランダムフォレスト	0.987	0.987	完全に同じ
k 近傍法 ($k = 5$)	0.664	0.877	距離が文長 μ に支配される
SVM(RBF カーネル)	0.284	0.959	基準線と同じ=何も学べない
ロジスティック回帰 (L2 正則化)	0.351	0.986	正則化が係数を単位ごと罰する
ロジスティック回帰 (L1 正則化)	0.351	0.946	使う特徴が 2 列だけになる

表 4.2 を図にしたのが図 4.8 である。線が長いほど、標準化で正解率が変わったことを表す。

木のモデルに標準化は要らない ランダムフォレストの交差検証正解率は、標準化なしでも標準化ありでも 0.987 で、小数第 3 位まで完全に一致する。偶然ではない。決定木の分割は「文長 $\mu \leq 3.4$ か?」のように 1 列の大小関係だけを見るので、列ごとにどんな単調増加の変換 (標準化、対数、順位




図 4.8 標準化の有無による正解率の変化 (表 4.2 の図)。ランダムフォレストは2点が重なり、SVM の標準化なしは基準線の上に乗る。

化) をしても、訓練データの分け方の候補は変わらない。標準化のような1次変換なら、しきい値も同じ位置に移るので、予測まで完全に一致する (対数や順位化では、しきい値を隣り合う2つの値の midpoint に置く実装のため、訓練データにない値を持つ作品の予測がわずかに変わることがある)。決定木・ランダムフォレスト・勾配ブースティングは、すべてこの単調増加の変換への不変性を持つ。

正則化項が付いたモデルには標準化が要る ここが最も大事な分かれ目なので、理由から述べる。Ridge 回帰は予測誤差に $\alpha \sum_j \beta_j^2$ を、Lasso 回帰は $\alpha \sum_j |\beta_j|$ を足して学習する (α は正則化の強さで、scikit-learn の Ridge や Lasso の引数名に合わせた)。この足す項を**正則化項**という。足しているのは、**係数を並べたベクトルのノルム**である。Lasso が ℓ_1 ノルム、Ridge が ℓ_2 ノルムの2乗を使うので、それぞれ **L1 正則化**・**L2 正則化**とも呼ぶ (第3章の脚注で断ったとおり、正則化の名前だけ大文字で書く慣習に従う。scikit-learn でも小文字で書き、ロジスティック回帰では以前の版では `penalty="l1"` と指定した。1.8 以降の版では `l1_ratio=1` で指定する)。係数が大きいほど値が増える項なので、**大きい係数に罰を与える働きをする***2。正則化項が見ているのは**係数の大きさ**である。ところが係数の大きさは、対応する列を何の単位で測ったかで決まる。長さを cm で測れば m で測るより係数は 1/100 になり、正則化項も L2 なら 1/10000、L1 なら 1/100 になる。

つまり単位を揃えないと、**どの係数を強く縮めるかを、列の単位の選び方が決めてしまう**。分析者が意図していない重み付けが、測り方の都合から入り込むことになる。正則化つきのモデルで標準化が必須なのは、**正則化項と係数の単位を揃えるため**である。

実測でもそのとおりになった。表 4.2 の L1 正則化つきロジスティック回帰について、係数が 0 にならなかった列を数えると、標準化なしでは 52 列のうち **2 列 (文長 μ と文長 σ)** しか使わないモデルになっていた (標準化ありでは 34 列)。交差検証正解率も、標準化なしの 0.351 に対して標準化ありは 0.946 で、0.595 の開きがある。第7章で使うロジスティック回帰や SVM は、既定で正則化が入っている。「ロジスティック回帰だから標準化は不要」と覚えていると、ここで誤る。

*2 罰を与えるという見方から**罰則項** (penalty term) とも呼ぶ。本書では手法を分類するときは正則化、項の働きを説明するときは罰という言い方をする。係数を 0 に向かって縮めるので、訓練データに合わせすぎる過学習 (第7章) を抑えられる。とくに Lasso 回帰は係数を厳密に 0 にできるため変数選択を兼ねる。

正則化の強さ α を大きくしていくと係数がどう変わるかを描いたのが図 4.9 である。「太宰治かどうか」を 52 列から当てるロジスティック回帰に、L1 と L2 の正則化項を付けて当てはめた (74 作品を標準化してから)。scikit-learn の `LogisticRegression` では正則化の強さをその逆数 c で渡すので、 $\alpha = 1/C$ として描いている。 α は 0.004 から 7.9 まで動かした。




図 4.9 正則化を強くしたときの係数の動き (正則化つきロジスティック回帰。正則化が弱いときに値の大きい 8 列を描いた)。L1 では係数が次々に 0 へ落ちる。L2 はどれも 0 に近づくが、0 にはならない。

左右で形が違う。L1 では、係数が次々に 0 へ到達する。係数が 0 でない列の数は、正則化が最も弱い $\alpha = 0.004$ のときで 15 列、最も強い $\alpha = 7.9$ のときで 3 列 (読点前の「き」と「は」) である。ただし、正則化を強めると 0 でない列が減る一方とは限らない。最後まで残る 3 列のうち読点前の「き」は、図に描いた 8 列には入っていない。 $\alpha = 0.77$ までは係数が 0 で、 $\alpha = 0.93$ から 0 でない値を持つようになった列である。どの列を使うかを決める働きを兼ねているので、L1 正則化 (Lasso 回帰など) は変数選択の道具としても使われる。L2 では、すべての係数が 0 へ向かって縮むが、 α が最も強いところでも係数が 0 でない列は 52 列、つまり 52 列すべてである。

L1 だけが係数を厳密に 0 にできる理由 (動ける範囲の角) と、関連した列があるときの読み方の注意は、第 7 章の第 7.11 節で図解する。

ここで標準化の話に戻る。正則化項が見ているのは、図 4.9 の縦軸の高さである。列の単位を変えれば縦軸の目盛りが変わるので、どの線が先に 0 へ落ちるかも変わってしまう。単位を揃えずに α を選ぶことは、測り方の都合で変数選択をするのと同じである。

距離とマージンを使う手法にも標準化が要る k 近傍法は距離そのものを使うので、本節で見たとおり標準化が要る。サポートベクトルマシン (SVM) も同じで、マージン (境界からの距離) を最大化する手法であるうえ、RBF カーネルは $\exp(-\gamma \|x - x'\|^2)$ とユークリッド距離を直接使う。表 4.2 の SVM の交差検証正解率は、標準化なしでは基準線と小数第 3 位まで同じ 0.284 で、**最頻クラスを答え続けるだけの箱**になっている。標準化すると 0.959 になり、基準線を 0.675 上回る。k-means などの距離ベースのクラスタリングも同様である。ニューラルネットワークも、重みに罰を与える正則化 (重み減衰) を使うことが多く、勾配法での学習も列の尺度がそろっているほうが安定するので、同じ側に置く。

正則化のない回帰に標準化は要らない 正則化項を外すと話が変わる。正則化なしの線形回帰やロジスティック回帰は、予測に関して**スケール不変**である。ある列を 100 倍したとする。同じ予測値を出すには、その列の係数が $1/100$ になればよい。掛け算の相手が 100 倍になったのだから、係数がその分だけ小さくなれば積は元のままである。最適化はその係数を見つけるので、当てはめる直線もあてはめ値も 1 つも変わらない。本書の 74 作品で、読点前の 47 列から文長 μ を予測する正則化なしの線形回帰を組み、5 分割交差検証の**決定係数**^{*3}を測ると、標準化なしと標準化ありのどちらも -0.927 で、**小数第 3 位まで一致**した。値が負なので、読点から文長を当てる課題では平均を答えるより悪い。確かめたかったのは当たるかどうかではなく、2 つが一致することのほうである。同じ列に正則化つきの Ridge 回帰 ($\alpha = 1$) をかけて同じ決定係数を測ると、標準化なしで -0.051 、標準化ありで $+0.025$ になり、今度は一致しない。

予測が変わらないなら、標準化するかどうかは**何を読みたいか**で決めてよい。係数を「この変数が 1 単位増えると何が起きるか」として読みたいなら、標準化しないほうが解釈しやすい。「1 標準偏差あたりの効果」として変数間で比べたいなら標準化する。どちらも正しく、目的が違うだけである。

なお、スケール不変性は理屈の上での話で、実装では崩れることがある。本書の 74 作品・52 列に正則化なしのロジスティック回帰を当てはめ、著者を判別したときの交差検証正解率を測ると、標準化なしで 0.826 、標準化ありで 0.972 になる。理屈のうえでは一致するはずの 2 つが、 0.146 ずれている。

理由は、52 列に対して点が 74 個しかないことにある。これだけ次元が多いと、訓練データを 1 つも間違えずに分ける直線が引けてしまう。完全に分けられると、係数を大きくすればするほど「自信のある正解」になって尤度が上がり続ける。上がり続けるので最大値がない。最大値がなければ、最適化はどこかで打ち切るしかなく、打ち切る位置が列のスケールに左右される。そもそも正則化を外した線形モデルを高次元で使うこと自体に無理がある。

PCA では、どちらの行列を分解するかを選択になる 第 6 章で扱う主成分分析も同じ影響を受ける。本書の 74 作品・52 列を生のまま (標準化せずに) PCA かけると、第 1 主成分の寄与率 (その軸だけでデータ全体の散らばりの何割を説明できるかという値。第 6 章で定義する) は 0.820 で、散らばりの 8 割をこの 1 軸が占める。第 1 主成分に対する文長 μ の負荷は 0.986 で、上限の 1 にほぼ等しい。「主成分」と呼んではいるが、**いちばん分散の大きい 1 列を言い換えただけ**になる。同じデータを標準化してから PCA かけると、第 1 主成分の寄与率は 0.191 まで下がり、多数の列に寄与が散る。

「PCA の標準化はケースバイケース」と言われるのは、これが**共分散行列を分解するか、相関行列を分解するか**の選択だからである。標準化してからの PCA は相関行列の PCA に等しい。全列が同じ単位で測られ、分散の大小そのものに意味がある場合 (同一条件で測ったスペクトル強度、同じ満点のテスト得点など) は、共分散のまま分解するのが正当である。単位の違う列が混ざるなら、相関 (=標準化) を選ぶしかない。

なお、PCA は正規分布を仮定しない。PCA の計算に出てくるのは、分散と内積だけである。ど

^{*3} R^2 と書く、回帰の当てはまりの指標である。1 なら完全な予測、0 なら「つねに平均を答える」と同じ、負ならそれより悪い。

ちらもデータの形がどうであれ計算できるので、どんな分布のデータにも当てはめられる*4。

正規分布が要るのは、PCA に確率モデルを重ねたいときだけである。たとえば主成分どうしが**無相関**であることは計算から必ず言えるが、これを**独立**だと読み替えられるのは、データが多変量正規分布に従う場合である。一般には、無相関から独立は出てこない。「PCA は正規分布が前提」という言い回しは、この2つを混ぜた俗説である。

○ 定石 4.2 — 標準化の要否を1行で判定する —

その手法は、距離や分散のように列の値をそのまま足し合わせるか、係数の大きさに罰を与えるか。どちらかに当たるなら標準化する (kNN、k-means、SVM、正則化つき回帰、ニューラルネットワーク)。PCA は、単位のそろわない列なら標準化する (単位がそろっていれば共分散のままでよい)。1列ずつの大小しか見ないなら不要である (木とそのアンサンブル)。迷ったら標準化しておく。木のモデルは標準化しても何も壊れない。

細かい注意を2つ。ほとんどの要素が0であるようなデータは、0でない場所だけを覚えておく形式で保存する。ところが平均を引くと、0だった要素がすべて0でない値に変わり、その形式が使えなくなってメモリが溢れる。こういうデータでは、平均を引かずに割り算だけを行う。外れ値が強いデータでは、平均と標準偏差の代わりに中央値と四分位範囲で揃える方法 (ロバストスケールリング) がある。そして標準化は必ず交差検証の**内側**で行う (第9章)。

4.5 距離行列を眺める

標準化した74作品について、すべての組み合わせのユークリッド距離を計算する。74×74の行列になる。これを著者順に並べて色で示したのが図4.10である。

対角線に沿って暗い正方形が並んでいれば、同じ著者の作品が互いに近いということである。左上の大きなブロックが吉川英治で、21作品と数が多いのでひととき目立つ。同じ著者の作品どうしの平均距離がいちばん小さいのは柳田国男の5作品で (3.42。吉川英治は5.51)、右下寄りの小さな正方形がとくに暗い。逆に泉鏡花の9作品は平均距離が11.21と大きく、ブロックがほとんど見えない。こうした著者ごとのまとまり方の違いは、後の章で重要になる。

4.6 同著者と異著者を最もよく分けたのはコサイン距離

距離の種類を変えると結果は変わる。選ぶときの目安の一つは、**同じ著者の作品どうしの距離と違う著者の作品どうしの距離**が、どれだけ分かれているかである。2つの分布が離れているほど、著者の識別に向いている。

分離の度合いを**効果量** (effect size) で測る。2つの平均の差を、両群の分散を平均した標準偏差で割った値である (Cohen's d の通例と違い、群の大きさを重み付けしない版を使う)。

$$\text{効果量} = \frac{\bar{d}_{\text{異著者}} - \bar{d}_{\text{同著者}}}{\sqrt{(s_{\text{同}}^2 + s_{\text{異}}^2)/2}} \quad (4.13)$$

*4 「分散が最大の向きを選ぶ」ことと「元のデータにいちばん近い低次元の近似を作る」ことが一致するのも、分布によらず成り立つ (Eckart-Young の定理 [42])。




図 4.10 距離行列 (列ごとに標準化した値のユークリッド距離)。暗いほど近い。左上の大きなブロックが吉川英治 21 作品。軸の名前は各著者の区間の中央に置いた。

$\bar{d}$ は各群の距離の平均、 s^2 は各群の距離の分散 (平均からの偏差の 2 乗和を組の数で割ったもの) である。

1 つの数にする前に、もとの 2 つの分布を見ておきたい。74 作品から作れるペアは全部で 2701 組あり、うち 394 組が同じ著者、2,307 組が違う著者である。標準化した 74 作品の全 2701 ペアについてコサイン距離を測り、同著者と異著者に分けて分布を描いたのが図 4.11 である。




図 4.11 同じ著者どうしの距離と、違う著者どうしの距離。効果量は、2 つの山の平均の差を、山の幅 (標準偏差) で割った値である。

コサイン距離の平均は、同著者 394 組が 0.542、異著者 2,307 組が 1.088 で、差は $1.088 - 0.542 = 0.55$ である。標準偏差は同著者側が 0.255、異著者側が 0.195 である。差を共通の幅で割ると 2.404

になる。これが後述の表 4.3 に載る効果量 2.40 の中身である。山どうしが離れているほど、幅が狭いほど大きくなる量だと読める。

2つの山は重なりを残している。かりにコサイン距離ひとつで「同じ著者か否か」を判定するなら、距離が 0.657 以下なら同じ著者、と判定するのが最良である (同じ 2701 組を見て選んだしきい値なので、新しい組に対しては少し甘めの見積もりになる)。それでも同著者 394 組のうち 120 組を遠いと判定し、異著者 2,307 組のうち 52 組を近いと判定してしまう。誤りは全 2701 組のうち 172 組、割合にして 0.064 である。効果量 2.40 は**完全に分かれた**という意味ではない。

同じ 74 作品・全 2701 ペアについて、標準化した値のまま距離の種類だけを取り替えて、同じ効果量を測り直した。結果を表 4.3 に示す。

表 4.3 距離の種類による分離度 (標準化済みデータ)。相関距離は、2つの作品の 52 個の値を並べたベクトルどうしの相関係数 r を 1 から引いたもの (第 4.8 節)

距離	同著者の平均	異著者の平均	効果量
マンハッタン ($p = 1$)	35.60	56.91	1.59
ユークリッド ($p = 2$)	6.68	10.41	1.42
$p = 4$	3.56	5.37	1.18
チェビシェフ ($p = \infty$)	2.81	4.15	0.97
コサイン	0.54	1.09	2.40
相関距離 ($1 - r$)	0.54	1.09	2.40

はっきりした傾向がある。

- コサイン距離が最も良く分ける (効果量 2.40。既定値として使われるユークリッド距離の 1.42 より 0.98 高い)
- ミンコフスキー距離では p が小さいほど効果量が高い ($p = 1$ で 1.59、 $p = 2$ で 1.42、 $p = 4$ で 1.18)
- チェビシェフ距離が最も悪い (0.97)

p が大きいほど効果量が下がるのは、52 次元という高次元では「一つの次元の大きな差」が偶然に生じやすいためだと考えられる。著者の癖は多数の特徴に薄く広がっているので、それらを均等に足し合わせる $p = 1$ やコサイン距離のほうが拾える。ただし、どの機構がどれだけ寄与したかまでは本書では測り分けていない。

補足 チェビシェフ距離の使いどころ

表 4.3 で最下位に沈んだ距離だが、使いどころはある。最悪の 1 項目がすべてを決める場面である。

元祖はチェス盤である。キングがマス目 (x_1, y_1) から (x_2, y_2) へ移動するのに必要な手数は、縦の差と横の差の**大きいほう**に等しい (斜めに動けるので、小さいほうの差は道中で消化できる)。チェビシェフ距離が**チェス盤距離**とも呼ばれる理由である。下の図の左は、中央のマスからキングが 1 手、2 手、3 手で行けるマスを濃い順に塗ったもので、同じ手数のマスは正方形の輪に並ぶ。右は同じことを縦横にし

補足（続き）

か進めない駒 (マンハッタン距離) で描いたもので、ひし形になる。

3	3	3	3	3	3	3
3	2	2	2	2	2	3
3	2	1	1	1	2	3
3	2	1	0	1	2	3
3	2	1	1	1	2	3
3	2	2	2	2	2	3
3	3	3	3	3	3	3

			3			
			3	2	3	
		3	2	1	2	3
3	2	1	0	1	2	3
		3	2	1	2	3
			3	2	3	
			3			

キング (チェビシェフ距離) 縦横だけ (マンハッタン距離)

同じ構造は機械の駆動にある。プロッタや倉庫のクレーンのように **X 軸と Y 軸が独立に同時に動く** 装置では、移動にかかる時間は各軸の所要時間の最大値で決まる。つまり「時間で測った距離」がチェビシェフ距離になる。プロッタが点を順に巡る経路を短くしたいとき、移動時間で比べるなら、チェビシェフ距離で測るのが実態に合う。

製造の検査も同じ型である。各寸法のずれをその公差で割って揃えておけば、「全寸法が公差内なら合格」は、基準点からのチェビシェフ距離が 1 以下、と言い換えられる。図 4.1 の $p = \infty$ の単位球が正方形になるのは、「どの軸も ± 1 以内」という条件の形そのものである。画像処理で画素の周囲 8 マスを近傍とする (ムーア近傍) のも、チェビシェフ距離 1 以内という意味になる。

数値計算では、誤差の**最大値**を最小化する近似 (ミニマックス近似) で ∞ ノルムが主役になる。これを最初に体系化したのがチェビシェフその人で、名前はここに由来する。

共通するのは、平均的な違いではなく**最悪ケースを管理したい**という動機である。本書の著者判別のように「癖が多数の特徴に薄く広がる」データとは正反対の状況だから、ここで最下位になるのは欠陥ではなく設計どおりである。

なお効果量は、単調変換で結ばれた距離どうし (ユークリッドと二乗ユークリッドなど) でも値が変わる (第 4.4.1 項)。この表の順位は目安であって、距離の族をまたぐ厳密な優劣ではない。

補足 計量文献学の定番 — Burrows の Delta

文体の統計分析 (計量文献学) には、著者判別のための距離の定番がある。Burrows が 2002 年に提案した [40] **Delta** で、高頻度語の出現率を列ごとに z 化し、その差の絶対値の平均を取る。つまり**標準化 + マンハッタン距離** (のスケール違い) であり、表 4.3 の 1 行目と同じ構成である。

その後の検証で、 z 化した頻度に**コサイン距離**を使う変種 (Cosine Delta) が最も頑健だと報告されている [41]。表 4.3 でコサイン距離が最上位に來たのは、計量文献学の 20 年分の経験則を、手元の 74 作品で追試した格好である。

ユークリッド距離は既定値としてよく使われるが、それが最良である保証はどこにもない。本書のデータでは、効果量がユークリッド距離の 1.42 に対してコサイン距離は 2.40 で、1.7 倍の開きがある。本章のはじめのアンチパターン「定番だからという理由で距離を選ぶ」で書いたとおり、候補を 2 つか 3 つ実際に走らせて数字で決める。

ただし、その「数字で決める」にも落とし穴がある。

× アンチパターン 4.5 — 距離を正解ラベルで選ぶ —

表 4.3 を作るには**著者名を使っている**。だがクラスタリングは本来、正解を知らない場面で使う手法である。

正解を見て距離を選び、その距離でクラスタリングして「よく分かれました」と報告するのは循環論法である。

正解を持っているのは、本書が教材だからである。実務では、距離の選択は**列の単位と分布の形、そして何を「近い」と呼びたいか**から決める。

4.7 発展 — 距離の数学的性質

ここまで「距離の4条件」を前提に話を進めてきた。実際にそれが満たされているか、確かめておく。

発展 ミンコフスキー距離が距離であること

$p \geq 1$ のとき、式 (4.5) が三角不等式を満たすことは**ミンコフスキーの不等式**から従う。

定理 4.1 (ミンコフスキーの不等式) $p \geq 1$ のとき、任意のベクトル u, v に対して

$$\left(\sum_j |u_j + v_j|^p \right)^{1/p} \leq \left(\sum_j |u_j|^p \right)^{1/p} + \left(\sum_j |v_j|^p \right)^{1/p} \quad (4.14)$$

$u = x - y, v = y - z$ と置けば $u + v = x - z$ なので、そのまま $d_p(x, z) \leq d_p(x, y) + d_p(y, z)$ が得られる。

$p = 1$ のときは、各成分の三角不等式 $|u_j + v_j| \leq |u_j| + |v_j|$ を足し合わせれば済む。 $p > 1$ のときの証明の骨子はヘルダーの不等式による。 $q = p/(p-1)$ として

$$\sum_j |u_j + v_j|^p \leq \sum_j |u_j| |u_j + v_j|^{p-1} + \sum_j |v_j| |u_j + v_j|^{p-1} \quad (4.15)$$

と分け、各項にヘルダーの不等式 $\sum |a_j b_j| \leq (\sum |a_j|^p)^{1/p} (\sum |b_j|^q)^{1/q}$ を適用する。 $(p-1)q = p$ なので、右辺は $(\|u\|_p + \|v\|_p) \|u + v\|_p^{p-1}$ で押さえられる ($\|u\|_p$ は式 (4.5) の形で原点からの距離を測ったもの)。両辺を $\|u + v\|_p^{p-1}$ で割れば不等式が出る。 $p < 1$ では q が負になり、ヘルダーの不等式がこの形では使えない。実際に不等式そのものが破れることを、次の項で確かめる。

4.7.1 $p < 1$ では距離にならない

$p = 0.5$ を試してみるとどうなるか。2次元で $x = (0, 0), y = (1, 0), z = (1, 1)$ とすると

$$d_{0.5}(x, y) = (1^{0.5})^2 = 1 \quad (4.16)$$

$$d_{0.5}(y, z) = (1^{0.5})^2 = 1 \quad (4.17)$$

$$d_{0.5}(x, z) = (1^{0.5} + 1^{0.5})^2 = 4 \quad (4.18)$$

$4 > 1 + 1$ なので**三角不等式が破れている**。

図 4.1 を $p < 1$ まで延長すると、単位球が内側にへこんだ星型になる。凸でない図形が現れたら、

三角不等式は成り立たないと思ってよい。




図 4.12 $p < 1$ の単位球はへこむ。凸でなければ三角不等式は成り立たない。

補足 距離の公理を満たさなくても $p < 1$ を使うことがある

高次元では $p < 1$ のほうが「近い点」と「遠い点」を区別しやすい、という報告がある [36]。距離の公理を満たさなくても、近傍探索の指標としては機能する。

ただし三角不等式に依存するアルゴリズム (多くの高速化手法、一部のクラスタリング) は正しい答えを返さなくなる。使うなら、何が壊れるかを把握したうえで使う。

4.7.2 コサイン距離は三角不等式を満たさない

$d_{\cos} = 1 - \cos \theta$ は三角不等式を満たさない。反例を作るのは簡単で、 $x = (1, 0)$, $y = (1, 1)/\sqrt{2}$, $z = (0, 1)$ とすると

$$d_{\cos}(x, y) = 1 - \frac{1}{\sqrt{2}} \approx 0.293 \quad (4.19)$$

$$d_{\cos}(y, z) = 1 - \frac{1}{\sqrt{2}} \approx 0.293 \quad (4.20)$$

$$d_{\cos}(x, z) = 1 - 0 = 1 \quad (4.21)$$

$1 > 0.586$ である。

角度そのものを使えば、三角不等式は満たされる。

$$d_{\text{ang}}(x, y) = \arccos \left(\frac{x \cdot y}{\|x\| \|y\|} \right) \quad (4.22)$$

これは単位球面上の測地線距離 (球面に沿って測った最短距離) なので、三角不等式を満たす。ただし $d_{\cos}$ も d_{ang} も、長さだけが違う 2 つのベクトル (図 4.3 の A と B) に 0 を返すので、同一性も満たさない。 d_{ang} で 4 条件がすべてそろえるのは、ベクトルを長さ 1 に正規化して「向き」どうしの距離として見たときである (長さ 0 のベクトルには向きがないので定義できない)。 $d_{\cos}$ のほうは、長さ 1 に正規化しても三角不等式を満たさない (上の反例の 3 点は、どれも長さ 1 である)。 $d_{\cos}$ は d_{ang} の単調変換なので、順位だけが問題なら $d_{\cos}$ で構わない。

ここで章の冒頭の 4 条件と折り合いを付けておく。第 4.6 節で同著者と異著者を最もよく分けたコサイン距離は、距離の公理を満たしていない。それで困らなかったのは、あの実験でやったことが、距離の値を同著者と異著者に分けて平均と散らばりを比べることだけで、三角不等式を使う操作を含

んでいなかったからである。近い順に並べる、平均を比べる、といった操作に公理は要らない。一方、三角不等式を前提に候補を枝刈りする近傍探索や、距離の値そのものを足し引きする手法に公理を破る指標を持ち込むと、高速化が誤った答えを返したり、保証が失われたりする。4条件は守らなければならない決まりではなく、その指標でどの操作までが安全かを示す仕様である。

4.8 相関係数は偏差ベクトルのコサインである

表 4.3 でコサイン距離と相関距離の効果量が小数第 2 位まで一致した。偶然ではないが、式の上で等しいわけでもない。理由はこの節の後半で述べる。

ピアソンの相関係数 (correlation coefficient) は次のように書ける。

$$r(x, y) = \frac{\sum_j (x_j - \bar{x})(y_j - \bar{y})}{\sqrt{\sum_j (x_j - \bar{x})^2} \sqrt{\sum_j (y_j - \bar{y})^2}} \quad (4.23)$$

式 (4.8) と見比べると、形がまったく同じである。

$$\cos \theta = \frac{\sum_j x_j y_j}{\sqrt{\sum_j x_j^2} \sqrt{\sum_j y_j^2}} \quad (4.8)$$

違いは、相関係数のほうが x_j の代わりに $x_j - \bar{x}$ を使っている点だけである。

そこで**偏差ベクトル**を定義する。

$$\tilde{x} = x - \bar{x}\mathbf{1} = (x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}) \quad (4.24)$$

$\mathbf{1}$ はすべての成分が 1 のベクトルである。これを使うと、相関係数は次の一行で書ける。

$$r(x, y) = \cos \theta(\tilde{x}, \tilde{y}) = \frac{\tilde{x} \cdot \tilde{y}}{\|\tilde{x}\| \|\tilde{y}\|} \quad (4.25)$$

相関係数とは、偏差ベクトルどうしのなす角の余弦である。

相関係数を 1 から引いた $d_{\text{corr}}(x, y) = 1 - r(x, y)$ を**相関距離**と呼ぶ。表 4.3 の相関距離は、2つの作品の 52 個の値を並べたベクトルどうして測ったこの距離である。

図 4.13 が示すように、平均を引く操作はベクトルの向きを大きく変える。(a) では 2 つのベクトルがほぼ同じ方向を向いているが (9.3°)、(b) ではちょうど 90° 開いている。値がどれも 10 前後と大きく正なので、生のベクトルはどちらもすべての成分が等しい向き $\mathbf{1}$ に寄っている。平均を引くと、その共通の向きが取り除かれ、「どの成分が自分の平均より高いか」の並びだけが残る。 x は成分 3 が高く成分 1 が低い、 y は成分 2 だけが低い、という並びである。成分ごとに偏差を掛けて足すと $(-1) \cdot 1 + 0 \cdot (-2) + 1 \cdot 1 = 0$ なので、相関は 0 になる。

成分が 2 つしかないときは、偏差ベクトルがいつも 1 本の直線 ($x_1 + x_2 = 0$) の上に乗るので、相関係数は 1 か -1 しか取らない (値が一定のときは計算できない)。図を 3 成分で描いたのはこのためである。




図 4.13 3つの成分を持つ $x = (9, 10, 11)$ と $y = (11, 8, 11)$ 。(a) 生のベクトルはどちらも **1** の向きに近く、なす角は 9.3° ($\cos \theta = 0.987$)。(b) 平均を引いた偏差ベクトルは **1** に直交する平面に乗り、なす角は 90° になる。相関係数が測っているのは (b) の角度で、この例では $r = 0$ である。

補足 なぜ平均を引くのか

アンケートで5段階評価をつけてもらったとする。Aさんは全体に甘く、平均4.2をつける。Bさんは辛く、平均2.1である。

生の点数でコサインを取ると、2人とも「全部の項目に正の値をつけている」という共通点だけで高い類似度が出てしまう。

平均を引けば、「Aさんが自分の基準より高くつけた項目」と「Bさんが自分の基準より高くつけた項目」が一致するかを見ることになる。これが相関係数の意味である。

使い分けは1点で決まる。値の**0に意味がある**(0なら「その語が出ない」)ならコサイン、サンプルごとの**基準の違い**(全体をかさ上げする甘辛)も消したいなら相関である。どちらも長さは無視する。違いは、平均を引いて原点を動かすかどうかにある。

表4.3の距離は、列ごとに標準化した値で測っている。列ごとに平均を0にしたので、1作品の行の平均は52個の標準化値の平均になり、行の中のばらつき(標準偏差0.93前後)に比べて小さい(絶対値の平均0.15)。平均を引いても偏差ベクトルの向きはわずかしかわ変わらないので、コサイン距離と相関距離がほぼ同じ値になった。ただしペアごとに比べると差は最大0.17あり、2つが同じ量になったわけではない(図4.14)。

4.8.1 散布図の細さは相関の強さではない

ここからは、表の列どうし(変数どうし)の相関を考える。 x と y は、観測ごとの2つの変数の値を並べたベクトルである(本書なら、74作品それぞれでの2つの特徴の値)。相関係数を式(4.25)のように角度として読むと、1つ注意すべきことが出てくる。**ベクトルの長さを変えても角度は変わらない**。つまり、どちらかの変数に正の数を掛けても相関係数は変わらない(負の数を掛けると符号だけが反転する)。

このことは、散布図の見た目と食い違う。図4.15の4枚は、**まったく同じ点の集まり**を、軸の目盛りの範囲だけ変えて描いたものである。

(b)は縦方向につぶれて傾いた細い帯になり、雲のように広がった(a)より相関が強そうに見える。




図 4.14 列ごとに標準化した 74 作品の全 2701 ペアについて、コサイン距離 (横) と相関距離 (縦) を並べた図。破線は 2 つが等しい線。点はほぼ破線に沿うが、ずれは最大 0.17 ある。




図 4.15 同じデータを、軸の目盛りの範囲だけ変えて描いた 4 枚。(b) は縦方向だけ、(c) は縦横とも同じ割合で範囲を広げ、(d) は縦をさらに広げた。見た目はまるで違うが、4 枚の相関係数はまったく同じ値である。

(c) は形が (a) と同じまま小さくまとまっている。人が散布図から読み取る相関の強さは、両軸の範囲を広げて点の雲を小さく描くと強めに出ることが、実験で確かめられている [110]。(d) まで縦をつぶすと、今度はほぼ水平な線になり、「 y は x によらずほぼ一定」、つまり関係がないように見える。だが 4 枚は同じ点を描いていて、相関係数はどれも同じ値になる。変えたのは軸の目盛りだけだからである。

見た目の細さや傾きを決めているのは、図の上での縦の広がりとの横の広がりの比と点の雲の大きさであって、相関ではない。2 つを混同すると、次のような読み違いが起きる。

- 単位を変えただけの図を見て「相関が強くなった」と言う
- 縦軸を切り詰めた図を見て「はっきりした関係がある」と言う

- 逆に、縦軸の範囲を大きく取った図を見て「関係がない」と言う

× アンチパターン 4.6 — 散布図の見た目の細さから相関の強さを判断する

帯が細いかどうかは、軸の縮尺しだいでいくらでも変わる。判断したいなら**数値を計算する**。逆方向の間違い (数値だけを見て図を描かない) は、次項のアンスコム の例で確かめる。

補足 軸の縮尺は図を作る側の裁量である

同じことが、相関以外の図でも起きる。

棒グラフの縦軸を 0 から始めずに途中で切ると、わずかな差が大きな差に見える。支持率 45% と 48% を、縦軸 40% からの目盛りで描けば、棒の高さの比は 5 対 8 になる。実際の比は 45 対 48 である。棒グラフは面積で量を伝える図なので、0 から始めないと約束が崩れる (折れ線グラフは変化の向きを伝える図なので、切ってもよいことが多い。ただし切ったことは明示する)。

2 つの系列を左右別の縦軸で重ねる図も同じ性質を持つ。軸を独立に伸縮できるので、無関係な 2 つの線を「連動している」ように見せることができる。広告費と売上を重ねて因果があるかのように描くのは、その典型である。

図は嘘をつかなくても、**縮尺の選び方で印象を作れる**。自分が図を作るときは、選んだ縮尺が結論を作っていないかを一度疑う。

4.8.2 同じ数値からまるで違う形が作れる

前項とは逆向きの話をする。縮尺を変えても相関係数は変わらなかった。では相関係数が同じなら、データの形も同じかというと、そうではない。

統計学者 Anscombe は 1973 年、**平均・分散・相関係数・回帰直線がすべてほぼ一致するのに、散布図はまったく違う** 4 組のデータを作ってみせた [111]。Anscombe の四重奏と呼ばれる。

図 4.16 の 4 組は、どれも x の平均 9.0、 y の平均 7.5、相関係数 0.816、回帰直線 $y = 3.00 + 0.500x$ である。それでも中身は次のように違う。

- (a) 素直な直線的関係。相関係数を読んでよい唯一の組
- (b) 実際には曲線。直線を当てはめること自体が間違い
- (c) 1 点の外れ値が直線を引っ張っている。その 1 点を除けば完全な直線
- (d) x が 1 つの値に固まっており、離れた 1 点だけが傾きを決めている

(c) と (d) では、**たった 1 点を消すだけで結論が変わる**。それでも要約統計量には何の変化も現れない。

2017 年には、同じ発想をさらに推し進めて、恐竜の絵の形に並んだ点を、平均・標準偏差・相関を小数第 2 位まで保ったまま、星や円、平行線の形へ変形してみせた研究がある [112]。

○ 定石 4.3 — 要約した数値を報告する前に必ず散布図を描く

平均、分散、相関係数、決定係数。どれも分布を数個の数に潰したもののなので、潰す前の形を復元できない。

散布図やヒストグラムは、外れ値、非線形な関係、二峰性、打ち切りといった**要約統計量で**




図 4.16 Anscombe の四重奏。4 組とも平均・分散・相関係数 ($r = 0.816$)・回帰直線 (灰) がほぼ一致するが、散布図の形はまるで違う。

は見えないものを 1 枚で見せてくれる。描くのに数秒しかかからない。

4.9 相関は「伝わらない」

式 (4.25) から、意外な結論が出てくる。

A と B の相関が 0.7、B と C の相関が 0.7 だったとしても、
A と C の相関は負になりうる。

これは直感に反する。「A と B が似ていて、B と C も似ているなら、A と C も似ているはずだ」と考えたくなる。

だが相関係数は推移律を満たさない。

4.9.1 角度で考えると分かる

相関係数が余弦なら、角度に直して考えればよい。

$$r(A, B) = 0.7 \implies \theta_{AB} = \arccos(0.7) = 45.6^\circ \quad (4.26)$$

$$r(B, C) = 0.7 \implies \theta_{BC} = \arccos(0.7) = 45.6^\circ \quad (4.27)$$

角度は三角不等式を満たす (第 4.7.2 項)。したがって θ_{AC} の取りうる範囲は

$$|\theta_{AB} - \theta_{BC}| \leq \theta_{AC} \leq \theta_{AB} + \theta_{BC} \quad (4.28)$$

$0^\circ \leq \theta_{AC} \leq 91.1^\circ$ である。

上限の 91.1° に注目してほしい。 90° を超えている。 $\cos(91.1^\circ) = -0.020$ なので、相関係数は負になりうる。




図 4.17 A と C が B の反対側を開くと、両者の角度は 90° を超える。

図 4.17 が状況を示している。A も C も B から 45.6° 離れているが、**反対方向に**離れることができる。そのとき両者は 91.1° 開き、相関は負になる。

4.9.2 3次元で見る — 相関が捉えていない角度*

図 4.17 では話を平面に押し込めたが、偏差ベクトルは本来もっと高い次元にいる。ベクトルが 3 本なら、その 3 本が張る空間は高々 3 次元なので、3 次元の図で全体を正確に描ける。すると、2 次元の図では見えなかったものが見えてくる。

$r(A, B)$ が決めるのは $\tilde{B}$ と $\tilde{A}$ のなす角 θ_{AB} **だけ**である。つまり $\tilde{A}$ は「 $\tilde{B}$ の周りに角度 θ_{AB} で立てた円錐」の上ならどこにいてもよい。 $\tilde{C}$ も同様である。自由に残っているのが、 O, B, A が張る平面と O, B, C が張る平面のなす角 (二面角) φ である。

図 4.18 で、2 枚の面を蝶番のように $\tilde{B}$ の周りで開閉してみしてほしい。閉じれば ($\varphi = 0$) $\tilde{A}$ と $\tilde{C}$ は同じ面の同じ側に来ても近づき、開ききれば ($\varphi = 180^\circ$) 反対側に来ても最も離れる。3 つの角の関係は、球面三角法の余弦定理そのものである。

$$\cos \theta_{AC} = \cos \theta_{AB} \cos \theta_{BC} + \sin \theta_{AB} \sin \theta_{BC} \cos \varphi \quad (4.29)$$

$\cos \varphi$ が $+1$ から -1 までの値を取ることが、 $r(A, C)$ に幅を生む。相関係数 $r(A, B)$ と $r(B, C)$ は θ を固定するだけで、 φ の情報をまったく持っていない。これが、相関が推移しない幾何的な理由である。

4.9.3 一般の場合*

$r(A, B) = a$ 、 $r(B, C) = b$ のとき、 $r(A, C) = c$ の取りうる範囲は次の式で与えられる。




図 4.18 左: 3本の偏差ベクトルを3次元で描く。2枚の面は $\tilde{B}$ を蝶番として屏風のように手前へ折れており、 $r(A, B)$ と $r(B, C)$ が固定するのは2つの角 θ だけ。開き角 (二面角) φ は自由に残る。右: 同じ配置を $\tilde{B}$ の真上から見下ろすと、 $\tilde{B}$ は点につぶれ、2枚の面は2本の線になる。この φ の余弦が偏相関係数である。

$$ab - \sqrt{(1-a^2)(1-b^2)} \leq c \leq ab + \sqrt{(1-a^2)(1-b^2)} \quad (4.30)$$

発展 相関の取りうる範囲 (式 (4.30)) の導出

3変数の相関行列

$$R = \begin{pmatrix} 1 & a & c \\ a & 1 & b \\ c & b & 1 \end{pmatrix} \quad (4.31)$$

は半正定値でなければならない。相関行列は $R = \frac{1}{n} \tilde{Z}^T \tilde{Z}$ ($\tilde{Z}$ は各列を平均0・標準偏差1(n で割る)にした行列で、 $\tilde{Z}^T \tilde{Z}$ はそのグラム行列。第6章で改めて扱う) の形をしているので、任意のベクトル u に対して $u^T R u = \frac{1}{n} \|\tilde{Z} u\|^2 \geq 0$ である。

半正定値の必要条件として $\det R \geq 0$ が要る。

$$\det R = 1 + 2abc - a^2 - b^2 - c^2 \geq 0 \quad (4.32)$$

c についての2次不等式に整理する。

$$c^2 - 2abc - (1 - a^2 - b^2) \leq 0 \quad (4.33)$$

2次方程式 $c^2 - 2abc - (1 - a^2 - b^2) = 0$ の解は

$$c = ab \pm \sqrt{a^2 b^2 + 1 - a^2 - b^2} \quad (4.34)$$

$$= ab \pm \sqrt{(1-a^2)(1-b^2)} \quad (4.35)$$

平方根の中を因数分解しているところが要点である。 $a^2 b^2 - a^2 - b^2 + 1 = (1-a^2)(1-b^2)$ が成り立つ。

したがって c は2解の間になければならない。これが式 (4.30) である。逆に、この範囲のどの値も実際に現れうる。式 (4.29) で二面角 φ を 0° から 180° まで動かせば、 c は上限から下限まで途切れずに変わるからである。

発展（続き）

角度で書き直すと、加法定理そのものになる。 $a = \cos \alpha$, $b = \cos \beta$ と置けば $\sqrt{(1-a^2)(1-b^2)} = \sin \alpha \sin \beta$ なので

$$\cos \alpha \cos \beta - \sin \alpha \sin \beta \leq c \leq \cos \alpha \cos \beta + \sin \alpha \sin \beta \quad (4.36)$$

つまり $\cos(\alpha + \beta) \leq c \leq \cos(\alpha - \beta)$ である。先ほどの三角不等式による議論と完全に一致する。そして式 (4.29) で $\varphi = 180^\circ$, 0° と置いたものが、ちょうどこの下限と上限になっている。行列式の条件・三角不等式・二面角の開閉という3つの見方が、同じ式に合流するわけである。

$a = b = r$ とすると、下限は

$$c_{\min} = r^2 - (1 - r^2) = 2r^2 - 1 \quad (4.37)$$

これがゼロになるのは $r = 1/\sqrt{2} \approx 0.707$ のときである。




図 4.19 $r(A, C)$ が取りうる範囲。 $r < 1/\sqrt{2}$ では負になりうる。

図 4.19 から読み取れることをまとめる。

表 4.4 $r(A, B) = r(B, C) = r$ のときの $r(A, C)$ の下限

r	角度	$r(A, C)$ の下限	負になりうるか
0.9	25.8°	+0.62	いいえ
0.8	36.9°	+0.28	いいえ
$1/\sqrt{2} \approx 0.707$	45.0°	0.00	境界
0.7	45.6°	-0.02	はい
0.6	53.1°	-0.28	はい
0.5	60.0°	-0.50	はい
0.3	72.5°	-0.82	はい

2つの相関が等しい場合、 $r = 1/\sqrt{2}$ が境界である。これより強い相関なら、間接的な相関も必ず

正になる。これより弱ければ、負になる余地が残る。

相関 0.7 は「かなり強い」と言われることが多い。

だがそれでも、推移律を保証するにはわずかに足りない。

4.9.4 本書のデータでの実例

理論だけでは実感が湧かない。実際に本書の 52 個の特徴から 3 列の組をすべて取り出し、2 組の相関係数がどちらも 0.45 を超えていて、残る 1 組の相関係数が負になっているものを探すと、2 組見つかった。そのうち残る 1 組の相関が最も負に振れた組を挙げる。

読点の直前に来る平仮名のうち、「え」「ゃ」「ら」の 3 つである。

表 4.5 実データに現れた非推移性

組	相関係数	角度
「え」と「ゃ」	0.474	61.7°
「ゃ」と「ら」	0.548	56.8°
「え」と「ら」	-0.090	95.2°

2 つの角度を足すと $61.7 + 56.8 = 118.5^\circ$ になる。これが θ_{AC} の上限である。実際の 95.2° は上限を 23.3° 下回って範囲に収まっており、それでいて 90° は 5.2° 超えている。だから相関が負になった。




図 4.20 実データの散布図 (標準化済み)。左 2 つはゆるやかな右上がり、右は無相関に近い。

× アンチパターン 4.7 — 相関を連鎖させて推論する —

「A と B に相関がある。B と C にも相関がある。だから A と C にも関係があるはずだ」

推論は成り立たない。 $r(A, B) = a$ 、 $r(B, C) = b$ (どちらも正) のとき、 $a^2 + b^2 < 1$ なら A と C の相関は負になりうる。2 つが同じ値なら、その境目が $1/\sqrt{2} \approx 0.707$ である。逆に $a = 0.9$ 、 $b = 0.5$ のように片方が十分に強ければ、式 (4.30) の下限は $+0.07$ で、A と C の相関は必ず正になる。

特徴選択で「目的変数と相関の高い特徴を集める」だけでは不十分なもの、相関が 2 変数ず

つしか見ていないという点で根は同じである。個々に相関が高くても、特徴どうしが同じ情報を持っていれば足しても増えず、単独では相関の弱い特徴が、他と組み合わせたときに役に立つこともある。

4.9.5 どの単位で数えたかで相関は変わる

相関について、もう1つ落とし穴がある。何を1件と数えるかで値が変わることである。

本書のデータで、平仮名の比率と漢字の比率のピアソン相関係数を2通りの数え方で計算してみる。

- 作品を1件と数える — 74作品それぞれの値で計算する。 $r = -0.915$
- 著者を1件と数える — 著者ごとに作品の平均を取り、8個の点で計算する。 $r = -0.717$

2つの数え方の点を1枚に重ねたのが図4.21である。




図 4.21 平仮名の比率と漢字の比率。小さい印が74作品(作品単位、 $r = -0.915$)、黒で縁取った大きい印が各著者の平均(著者単位、8点、 $r = -0.717$)。

作品単位では、74個の点がほぼ1本の右下がりの帯に乗る。字種3列の合計が1なので、片仮名の少ない作品ほど帯に近づく。著者単位で残るのは大きい印の8点だけである。そのうち夢野久作の平均は、片仮名が多いぶん帯から左下に外れている。この1点を除いた7点で計算し直すと、相関係数は -0.948 になる。点が少ないと、1点の位置で相関係数が大きく変わる。

同じデータから、絶対値で0.198違う2つの相関係数が出た。どちらも計算は正しい。測っているものが違う。

作品単位の -0.915 は「どの作品でも、平仮名が多ければ漢字が少ない」という関係の強さを表す。第3章で見たとおり、これは合計がほぼ1という制約から来る構造的な負相関である。

著者単位の -0.717 は「どの著者でも、平仮名をよく使う人は漢字をあまり使わない」という関係の強さである。ただし、著者ごとに平均を取った時点で点は8個しか残らない。8点での相関係数は標本を取り直せば大きくぶれるので、弱まったという向きそのものに意味を読み取ることはできない。

向きが決まっているわけではない。集約すると相関が強くなることもある。個体内のばらつきが消

えて、集団どうしの違いだけが残るからである。本書では逆に弱く出た。どちらに転ぶかは、データの構造しだいでは予測できない。

値の大小より、**集団で計算した相関をそのまま個体にあてはめられないこと**のほうが重い。「著者単位で見ると平仮名と漢字が連動している」からといって、「ある作家が平仮名を多く使った作品では漢字が少ない」とは限らない。前者は著者の間の話、後者は1人の著者の中の話で、別の問題である。

これは**生態学的誤謬** (ecological fallacy) と呼ばれる。都道府県別に集計した相関から個人の傾向を語る、企業別の平均から社員個人の傾向を語る、といった形でよく現れる。

× アンチパターン 4.8 — 集計した単位の相関をその中の個体の話として読む

県ごとの平均所得と平均寿命に相関があっても、「所得の高い人ほど長生きする」とは言えない。測ったのは県の性質であって、人の性質ではない。

報告するときは何を1件として数えたかを必ず書く。読むときも、そこを確かめてから解釈する。

コラム 州で集計すると符号が逆になった — Robinson の生態学的相関

生態学的誤謬の古典的な例として知られるのが、社会学者 W. S. Robinson が1950年に発表した論文である [113]。Robinson は1930年の米国国勢調査を使い、同じ2つの量の相関を、個人を1件とする数え方と、地域を1件とする数え方で計算した。

1つ目の組は「外国生まれかどうか」と「読み書きができないかどうか」である。個人を1件とする相関係数は0.118で、外国生まれの人のほうが読み書きのできない割合がわずかに高い。ところが州ごとの割合を1件として計算すると−0.526になり、符号が逆になった。9つの地域区分で集計すると−0.619である。州の単位で見ると「外国生まれの多い州ほど識字率が高い」ように見えるが、それは個人の性質ではない。外国生まれの人が、もともと識字率の高い州に多く住んでいた、と考えれば個人単位の正の相関と両立する。

2つ目の組 (黒人であるかどうかと、読み書きができないかどうか) では、逆に集計するほど相関が強くなった。個人単位で0.203、州単位で0.773、地域区分単位で0.946である。のちに、Robinson の州単位の集計には誤りがあったことが指摘され、計算し直すと州単位の値は少し変わる [114]。それでも、符号が逆になることと、集計で相関が強まることは変わらない。

本節の平仮名と漢字の例で集計が相関を弱めたのとは逆向きに、Robinson の例では集計が符号を変え、あるいは相関を強めた。

補足 偏相関という道具 — 測っているのは二面角の余弦

「A と C の相関は、B を介した見かけ上のものではないか」を調べたいときは**偏相関係数** (partial correlation) を使う。B の影響を取り除いた上での相関である。

説明としては「B の値を固定したときの A と C の相関」という言い方をよく見かける (厳密にこの意味になるのは、3つが多変量正規分布に従うときなどに限られる)。条件付きの分布を思い浮かべると身構えてしまうが、幾何の像で見れば、測っているのは1つの角度にすぎない。

$$r_{AC \cdot B} = \frac{r_{AC} - r_{AB}r_{BC}}{\sqrt{1 - r_{AB}^2}\sqrt{1 - r_{BC}^2}} \quad (4.38)$$

補足 (続き)

分子と分母は、式 (4.30) とそっくりである。それもそのはずで、球面三角法の式 (4.29) を $\cos \varphi$ について解くと

$$\cos \varphi = \frac{\cos \theta_{AC} - \cos \theta_{AB} \cos \theta_{BC}}{\sin \theta_{AB} \sin \theta_{BC}} = \frac{r_{AC} - r_{AB} r_{BC}}{\sqrt{1 - r_{AB}^2} \sqrt{1 - r_{BC}^2}} \quad (4.39)$$

となり、右辺は式 (4.38) そのものである。つまり

偏相関係数とは、図 4.18 の開き角 φ の余弦である。

偏相関を測るとは、 $\tilde{B}$ の真上に視点を移して、そこから A と C を見下ろすことである (図 4.18 右)。真上からの視点では 3 つのことが同時に起きる。

- $\tilde{B}$ は 1 点につぶれて見えなくなる。視線と同じ方向を向いたベクトルは、長さを失うからである。「B の影響を取り除く」という言い回しの、これが文字どおりの姿である
- $\tilde{A}$ と $\tilde{C}$ は、それぞれ $\tilde{B}$ 方向の成分 (回帰でいえば「B で説明できる部分」) を視線方向に失い、**残差だけが影として床に残る**。青い面と緑の面は、真上から見れば 2 本の線である
- その 2 本の線のなす角こそが、屏風の開き角 φ である。だから「残差どうしの相関」(偏相関の教科書的な定義) と「 B の周りの開き角の余弦」(図の読み方) は同じ量になる

相関係数 $r(A, B)$ と $r(B, C)$ が捉えそこねていた「残りの 1 つの角」を測る道具が、ちょうど偏相関だったわけである。 $\cos \varphi$ が -1 から 1 に収まることから、偏相関の値域も、式 (4.30) の範囲も同時に出る。

4.10 高次元では距離が壊れる

もう一つ、知っておくべき性質がある。次元が上がると、距離という概念そのものが働かなくなる。 d 次元の単位立方体に点をランダムに撒き、すべてのペアの距離を測って、その分布を描いてみる。比べやすいように、次元数 d ごとに、その d での全ペアの平均距離で割ってある。




図 4.22 ランダムな点どうしの距離の分布。次元が上がるほど平均のまわりに突き刺さるように集中していく (距離の標準偏差を平均で割った変動係数は $d = 2$ で 0.47、 $d = 1000$ で 0.02)。

図 4.22 を低い次元から順に追う。 $d = 2$ では距離は幅広く散らばっている。近いペアも遠いペアもある。 $d = 100$ になると分布は細い山になり、 $d = 1000$ ではほとんど 1 本の針である。**どのペアを取っても、距離がほぼ同じになっていく**。これを**距離の集中** (concentration of distances) という。

「近い」「遠い」という区別が、次元とともに意味を失っていく。

同じことを別の切り口で測る。次元ごとに単位立方体へ 200 点を撒き、全ペアのユークリッド距離のうち最も小さいものを $d_{\min}$ 、最も大きいものを $d_{\max}$ として、 $(d_{\max} - d_{\min})/d_{\min}$ を見る。




図 4.23 次元と距離の相対的な広がり。次元が上がるほど、最も近い点と最も遠い点の差が消えていく。

1 次元では、最も遠いペアの距離が最も近いペアの 3 万倍ある。1000 次元では、 $d_{\max}$ と $d_{\min}$ の差が $d_{\min}$ の 15% しかない。**すべての点がほぼ等距離になる。**

「近い点を探す」という操作が意味を失う。これが**次元の呪い** (curse of dimensionality) の一つの側面である。第 9 章でこれが実際の分類精度にどう影響するかを測り、付録 B でその数学的な背景を扱う。

4.10.1 p を下げても集中が遅くなるだけで消えない

第 4.6 節では、高次元では p の小さいミンコフスキー距離のほうがよく分ける、と述べた。ならば p を工夫すれば次元の呪いから逃げられるかということ、半分だけ正しい。 $p = 1$ が高次元で相対的に有利なのは、定性的な理由がある。次元が増えるほど、**どこか 1 つの次元で、たまたま大きな差が出る**機会が増える。52 次元で 2 作品を比べるのは、くじを 52 回引くようなもので、外れ値めいた成分が紛れ込む余地は次元とともに広がっていく。大きな p は、その偶然の 1 つの差を増幅して距離全体を支配させてしまう ($p = \infty$ はその極限で、最大の差しか見ない)。 $p = 1$ なら、偶然の差も 1 票としてしか数えないので、多数の次元に薄く広がった本物の差が生き残る。外れ値に対するマンハッタン距離の強さと同じ理屈が、高次元では「外れ値的な成分が確率的に必ず混ざる」という形で常時はたらく。

だがこれは呪いの**緩和**であって、解決ではない。図 4.22 で見た**距離の集中**は、どの p を選んでも起きる。集中の速さが変わるだけで、「全ペアがほぼ等距離」へ向かう流れそのものは止められない。

4.10.2 p を決めているのは次元ではなく、データのずれ方である

p を次元の問題として扱うのをやめると、選び方の見当がつく。

同じものを指しているはずの 2 つのベクトルの値がずれるとき、そのずれ方には型がある。すべての座標が少しずつ揺れる型と、少数の座標だけが大きく壊れる型である。後者は身の回りに多い。文字認識の読み違い、センサの値の飛び、写真に散る白黒の点。1 か所か 2 か所だけが大きくずれて、

残りは無傷である。

100 次元・800 点の人工データで確かめた。もとの点にずれを加えたものを問い合わせにして、 L_p の最も近い点がもとの点を返す割合を測る。ずれの大きさ (二乗和の期待値) は両条件でそろえてあり、片方は 100 座標すべてに薄く配り、もう片方は無作為な 4 座標に集めた。




図 4.24 ずれ方の型ごとの、最も近い点の当たり方。次元は両条件とも 100 で、ずれの総量もそろえてある。それでも最適な p が 2 付近から 1.5 以下まで移る。

全座標が少しずつ揺れるときは、もとの点を返す割合が $p = 1.5$ から 2 で最も高く 0.998、 $p = 0.25$ では 0.686、 $p = 8$ では 0.730 と両側で下がる。4 座標だけが壊れるときは、同じ割合が $p \leq 1.5$ ではすべて 1.000、 $p = 2$ で 0.948、 $p = 3$ で 0.147、 $p = 8$ で 0.011 である。 $p = 1.5$ と $p = 3$ のあいだで、割合が 1.000 から 0.147 へ落ちる。

理屈は $p = 2$ が差を二乗することにある。4 つの座標が大きくずれていると、その 4 つだけで距離が決まってしまう、無傷の 96 座標が一致していることが結果に表れない。 p を下げると大きい成分の支配力が下がるので、96 座標の一致が生き残る。逆に、全座標が薄く揺れているときに p を下げすぎると、本物の差まで薄まって当たらなくなる。

次元は両条件とも 100 である。それでも最適な p が移るのだから、 p を決めているのは次元ではない。見るべきは、そのデータがどうずれるかである。

4.10.3 集中を決めるのは列の数ではなく内在次元

本書の表は 74 行 × 52 列である。列が 52 もあるのだから集中も深刻だろう、と考えたくなる。だが列が 52 個あることと、点が 52 次元いっぱいには散らばっていることは別である。

確かめるには**列シャッフル**という操作を使う。列ごとに、行の順番をばらばらに入れ替える。こうすると各列のヒストグラムはそのまま、列どうしの連動だけが消える。「平仮名の多い作品は漢字が少ない」のような結び付きが無くなり、点は本当に 52 次元へ散らばる。

表 4.6 の数値を読む。もとのデータは、ばらつきの 9 割を主成分 18 本で説明できる。列シャッフルで連動を壊すと、同じ 9 割に主成分が 31 本要る。主成分の本数と累積の割合の関係を描いたのが図 4.25 である。

相対コントラストは 3.180 から 0.749 へ、4 分の 1 以下に下がる。連動をまったく持たない独立乱

表 4.6 列の連動を壊すと集中が強まる (74 作品、列ごとに標準化)。相対分散は中心からの距離のばらつきを平均で割った量、相対コントラストは、各点から見た最も遠い点と最も近い点のユークリッド距離の差を最も近い距離で割り、全点で平均した量である。どちらも大きいほど近傍を区別しやすい。

データ	相対分散	相対コントラスト	9 割に要る成分数
本書の 52 列	0.317	3.180	18
列シャッフル後	0.183	0.749	31
同じ大きさの独立乱数	0.107	0.540	31




図 4.25 主成分を多い順に足していったときの、ばらつきの累積の割合 (列ごとに標準化した 74 作品)。赤線が 9 割。もとのデータは 18 本で 9 割に達し、列の連動を壊すと 31 本要る。

数の 0.540 に近い値である。同じ 74 行 × 52 列の形をしていても、連動があるほうが近傍をはっきり区別できる。

つまり呪いの深刻さを決めているのは列の数ではなく、データが実際に広がっている自由度の数である。これを**内在次元**という (第 6 章)。François らはこの点を示して、実際の場面での深刻さは数学の予想より軽い、と述べている [13]。

× アンチパターン 4.9 — 列の数だけを見て次元の呪いを心配する —

「52 列もあるから距離が壊れているはずだ」とは言えない。列がいくつあっても、それらが連動していれば点は低い次元の面の上に乗っていて、近傍は区別できる。

逆も言える。列を 10 個に減らしても、その 10 個が互いに無関係なら集中は残る。減らすべきなのは列の数ではなく、無関係な方向である。

心配する前に測る。相対コントラストか、主成分分析で累積寄与率 9 割に要る成分数を見れば見当がつく。

4.10.4 みんなの近傍に何度も現れる点がある

集中とは別に、高次元ではもう一つのこと起きる。 k 近傍をすべての点について求めると、どの点も平均すればちょうど k 回だけ誰かの近傍リストに載るはずである。ところが高次元では、この回数が特定の点に偏る。

独立な乱数 1500 点について $k = 10$ の近傍リストを作り、各点が何回載ったかを数えた (図 4.26)。

表 4.7 ユークリッド距離で求めた k 近傍リストに、各点が現れた回数。歪度が大きいほど偏っている。平均は次元によらず k である。

データ	k	出現回数の歪度	最大
独立乱数 $n = 1500, d = 3$	10	-0.49	19
独立乱数 $n = 1500, d = 20$	10	3.25	123
独立乱数 $n = 1500, d = 100$	10	3.84	160
本書の 52 列	5	0.24	13
列シャッフル後	5	1.09	20

3 次元では最大が 19 回で、平均の 10 回の 2 倍に満たない。100 次元では最大が 160 回で、1 つの点が 1500 点の 1 割以上の近傍リストに載っていた。一方で、どの近傍リストにも 1 回も載らない点も増える。




図 4.26 独立乱数 1500 点で、各点が他の点の 10 近傍リストに何回載ったかの分布。どちらも平均は 10 回だが、100 次元では右に長い裾が伸び、0 回の点も多い。縦軸は対数で、0 件の回数は描いていない。

こういう点を**ハブ** (hub) と呼ぶ [14]。ハブになりやすいのはデータの中心に近い点で、 k 近傍法はこの点を答えとして返しがちになる。正規化やコサイン距離への切り替えでは消えない。

本書の 74 作品を列ごとに標準化して $k = 5$ で同じ数え方をすると、出現回数の歪度は 0.24、最大は 13 回で、偏りは出ていない。列シャッフルで連動を壊すと歪度が 1.09、最大が 20 回になる。偏りが出ていない理由は前項と同じく、内在次元が低いことにある。

対処としては、距離を近傍の分布に照らして測り直す方法が知られている。各点の k 番目の近傍までの距離で正規化する局所スケーリングや、「互いに近いと思っているか」を対称に測る相互近接度がある。どちらもハブを減らすことが確かめられている [39] (相互近接度はそのために考えられた方法で、局所スケーリングはもともとスペクトルクラスタリングの尺度合わせのために考えられた)。

4.10.5 呪いの弱い低次元の構造を探して、そこで勝負する

呪いを正面から解く方法は知られていない。実務での対処は、どれも「高次元空間をそのまま相手にしない」ことに帰着する。

1. **低次元の構造に賭ける。** データが 52 次元いっぱい広がっていることは実際には少なく、多くは低い内在次元の面の上に乗っている (多様体仮説、第 6 章)。特徴選択と次元削減が働くのは、

賭けが当たるときである。

2. **モデルの自由度を絞る**。正則化、木の深さの制限、単純なモデル。高次元で好き放題に境界を引ける自由こそが過学習の源なので、その自由を削る (第7・8章)。
3. **データを増やす**。ただし高次元空間を点で「埋める」には次元に対して指数的な数が要る (付録B)。10 倍程度に増やしたくらいでは足りないことが多い。
4. **距離のいらない情報を足す**。距離の定義をいじり続けるより、判別に直結する特徴を1つ作るほうが早いことが多い (第3章)。

4 つとも、呪いを解くのではなく避けている。第6章の次元削減と、第7・8章の正則化は、そのための道具である。

○ 定石 4.4 — 距離を使う手法にかけける前に次元を落とす

k 近傍法、k-means、コサイン類似度による検索。どれも距離が意味を持つことを前提にしている。次元が高いままこれらにかけると、第9章で見るとおり、無関係な列に埋もれて成績が落ちる。

順序を決めておく。**次元を落としてから距離を測る**。落とし方は特徴選択でも次元削減でもよい。落とさずに済ませたいなら、木ベースの手法のように距離を使わない手法を選ぶ。

4.11 章末の課題

1. $p = 0.5$ で、本文とは別の3点を選んで三角不等式が破れる例を作れ。また、同じ $p = 0.5$ でも三角不等式が破れない3点の組を、2次元で1つ挙げよ。
2. 標準化する前と後で距離行列がどう変わるか、図4.10を作り直して比べよ。
3. コサイン距離と相関距離の効果量がほぼ同じになった。列を標準化する前の生の値で同じ2つの効果量を計算すると、どうなるか。2つの定義を見比べ、結果を説明せよ。
4. 第3章の特徴のうち、文長 μ と文長 σ を除いて表4.3を作り直せ。順位は変わるか。
5. 表4.2で、標準化なしのSVMの正解率0.284が「最頻クラスを答え続ける箱」であることを、混同行列 (第8章。行を正解、列を予測として数えた表) を描いて確かめよ。(ヒント: 予測列がすべて同じ著者になっているはずである。なぜ吉川英治なのかも考えよ。)

第5章

まとまりを見つける

5.1 正解を見せずに分ける

ここまでで、74 作品それぞれが 52 個の数値になり、作品どうしの距離が測れるようになった。

本章では**著者名を一切使わずに**、作品をグループに分ける。これを**クラスタリング (clustering)** という。

正解を隠すのは、実際の場面では正解がないことが多いからである。著者不明の文書群を整理したい、顧客をタイプ分けしたい、遺伝子の発現パターンをまとめたい。どれも正解ラベルは存在しない。

本書では著者名という正解を持っているが、それは**答え合わせのため**だけに使う。分ける作業そのものには使わない。

5.2 階層クラスタリング

考え方は素朴である。一番近いもの同士をくっつける。それを繰り返す。

アプローチは 2 種類ある。

- **凝集型 (agglomerative)** — 各点を 1 つのクラスタとして始め、近いものから併合していく。1 つになるまで続ける
- **分割型 (divisive)** — 全体を 1 つのクラスタとして始め、分割していく。点の数だけのクラスタになるまで続ける

実際に使われるのはほぼ凝集型である。分割型は「どこで 2 つに割るか」の候補が多すぎる。 n 点を 2 つに割る方法は $2^{n-1} - 1$ 通りあり、74 点なら約 9×10^{21} 通りになる。すべてを試すことはできないので、分割型は近似の手順に頼ることになる。以下では凝集型を扱う。




図 5.1 凝集型階層クラスタリングの手順。

5.2.1 5 点で追いかける

5 個の点で実際に動かしてみる。図 5.2 の各段階を追ってほしい。

併合の順番と距離を表にする。

併合の履歴を木の形に描いたものが**デンドログラム**である。横軸 (この図では縦軸) が併合したと




図 5.2 凝集型階層クラスタリングの過程 (群平均法)。数字は併合したときの距離。(2) の 1.50 は、 P_3 から P_4 までの 1.77 と P_5 までの 1.22 の平均である。

表 5.1 併合の履歴

段階	併合したもの	距離	併合後の大きさ
1	P_4, P_5	1.118	2
2	$P_3, \{P_4, P_5\}$	1.496	3
3	P_1, P_2	1.676	2
4	$\{P_1, P_2\}, \{P_3, P_4, P_5\}$	2.791	5

きの距離になる。

補足 デンドログラムはトーナメント表として読める

デンドログラムはトーナメント表と同じ構造である。下から勝ち上がっていく代わりに、近いもの同士が合流していく。

高さは「どれだけ離れていたか」を表す。低い位置で合流したペアは似ており、高い位置まで別々だったものは似ていない。

5.3 クラスタ間距離の 4 つの定義

図 5.1 の手順のうち「クラスタ間距離を更新」の段では、**クラスタとクラスタの距離**を決めなければならない。点と点の距離は第 4 章で決めたが、複数の点を含む集まりどうしの距離は別に定義しなければならない。

主に 4 つの流儀がある。クラスタを C_i, C_j とし、点間の距離を $d(x, y)$ とする。




図 5.3 図 5.2 に対応するデンドログラム。

はじめの 3 つは、点と点の距離から**クラスタ間の距離**を作る。

$$\text{単連結 (最短距離法)} \quad D(C_i, C_j) = \min_{x \in C_i, y \in C_j} d(x, y) \quad (5.1)$$

$$\text{完全連結 (最長距離法)} \quad D(C_i, C_j) = \max_{x \in C_i, y \in C_j} d(x, y) \quad (5.2)$$

$$\text{群平均法} \quad D(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{y \in C_j} d(x, y) \quad (5.3)$$

4 つ目の **Ward 法**だけは、発想が違う。測るのは距離ではなく、**併合するとどれだけ損をするか**である。クラスタ内の平方和 (各点から重心までの距離の 2 乗の和) を E と書くと、 C_i と C_j をくっつけたときの増分は次の形になる。

$$\Delta E(C_i, C_j) = \frac{|C_i||C_j|}{|C_i| + |C_j|} \|\bar{r}_i - \bar{r}_j\|^2 \quad (5.4)$$

$\bar{r}_i$ は C_i の重心である。毎回、増分が最も小さい組を選んで併合する。

式の形を言葉にしておく。後ろの $\|\bar{r}_i - \bar{r}_j\|^2$ は 2 つの重心の隔たりで、離れた塊どうしをくっつけるほど大きくなる。前の $\frac{|C_i||C_j|}{|C_i| + |C_j|}$ はクラスタの大きさによる重みで、どちらも大きい塊どうしをくっつけるほど大きくなる。**遠いものをくっつけても、大きいものをくっつけても損をする**、という形をしている。図 5.4 に、2 つの要素を分けて描いた。

式 (5.4) を上の 3 つと見比べてほしい。**量の種類がそろっていない**^{*1}。上の 3 つは距離そのもの、つまり長さの量だが、 ΔE は**ユークリッド距離の 2 乗**に比例するので、面積にあたる量である。Ward 法だけを「クラスタ間距離」と呼ぶのは、正確には言い過ぎである。

デンドログラムの縦軸に何を置くかも、この違いから来る。多くの実装は、長さの量に戻した $\sqrt{2\Delta E}$ を高さに使う (後の図 5.6 もそうである)。2 点をくっつける場合、式 (5.4) で $|C_i| = |C_j| = 1$ とすると係数が $\frac{1 \times 1}{1+1} = \frac{1}{2}$ になるので、 $\Delta E = \frac{1}{2}d^2$ である。これを $\sqrt{2\Delta E}$ に入れば d に戻る。つまり高さはちょうど点間の距離になる (実際、 $(0, 0)$ と $(1, 0)$ の 2 点を `scipy` に渡すと、デンドログラムの高さは 1.000 になり、2 点のユークリッド距離 1 に一致する)。

^{*1} ここでいう「種類」は、長さ・面積・体積のような量の区別のことで、空間の次元の話ではない。




図 5.4 Ward 法の併合の費用。左は重心 (×) どうしの隔たりで、離れた塊ほど大きい。右は大きさによる重みで、1 点を大きな塊に足しても 1 を超えないが、大きな塊どうしを合わせると重心の隔たりが同じでも費用が何倍にもなる。




図 5.5 クラスタ間距離の測り方。赤い線が採用される距離。

それぞれに癖がある。

表 5.2 4 つの方法の得失

方法	長所	短所
単連結	細長い形のクラスタも見つけられる	近い点が 1 つあれば次々に併合する。鎖効果 (chaining effect) で細長く伸び、外れ値に弱い
完全連結	直径のそろったクラスタができる	直径をそろえようとするので、本来ひとつの大きなクラスタを割ってしまう。球形のクラスタを作る傾向
群平均	外れ値に強い。単連結と完全連結の折衷	球形のクラスタを作る傾向
Ward	外れ値に強く、大きさのそろったクラスタ。k-means と似た結果	球形のクラスタを作る傾向。ユークリッド距離が前提 (第 5.6 節)

発展 Lance-Williams の漸化式

4 つの方法は、実は一つの式で書ける [43] (Ward 法の係数は、少し後に Wishart が示した [44])。 C_i と C_j を併合して C_{ij} を作ったとき、別のクラスタ C_k との距離は

$$D(C_{ij}, C_k) = \alpha_i D(C_i, C_k) + \alpha_j D(C_j, C_k) + \beta D(C_i, C_j) + \gamma |D(C_i, C_k) - D(C_j, C_k)| \quad (5.5)$$

で与えられる。 $n_i = |C_i|$ として、係数は次のとおりである。

発展 (続き)

方法	α_i	α_j	β	γ
単連結	1/2	1/2	0	-1/2
完全連結	1/2	1/2	0	1/2
群平均	$\frac{n_i}{n_i+n_j}$	$\frac{n_j}{n_i+n_j}$	0	0
Ward	$\frac{n_i+n_k}{n_i+n_j+n_k}$	$\frac{n_j+n_k}{n_i+n_j+n_k}$	$\frac{-n_k}{n_i+n_j+n_k}$	0

漸化式の形にしておくと、距離行列を毎回作り直さずに更新できる。実装が一つで済むのも利点である。

なお、単連結と完全連結は $\min$ と $\max$ しか取らないので、**距離の順序**しか使わない。群平均も距離の値をそのまま平均するだけである。この 3 つは任意の距離と組み合わせられる。一方 Ward は重心の差の 2 乗を使うので、ユークリッド距離を前提とする。

Ward の行を使うときは、**何を漸化式に入れるか**に注意がいる。式 (5.4) が 2 乗の量なので、表の係数は**距離の 2 乗**に対して書かれている。距離をそのまま入れると、Ward の基準を実装していないことになる。

歴史的な混乱がここにある。R の `hclust` には `ward.D` と `ward.D2` の 2 つがあり、前者は距離をそのまま、後者は 2 乗してから漸化式に入れて最後に平方根を取る。Ward の基準を実装しているのは後者だけである [66] (`scipy` の `linkage(method="ward")` も後者にあたる)。R 3.0.3 以前 (2014 年春まで) の R では、前者が単に "ward" という名前で提供されていた。

本書のデータで両方を計算する。74 作品をクラスタリングして $k = 8$ で切り、正解の著者との一致度を ARI で測った (ARI は第 5.5 節で定義する指標で、完全一致で 1 になる)。読点前 47 列を行ごとに合計 1 へ正規化し、ユークリッド距離を使った場合、ARI は `ward.D2` で 0.703、`ward.D` で 0.522 である。52 列を列ごとに標準化した場合も、0.872 対 0.691 になる。どちらの入力でも、**同じ「Ward 法」という名前で ARI が 0.18 も違う**。論文や報告で「Ward 法を使った」とだけ書かれていても、どちらなのかは分からない。

5.3.1 計算量

n 点に対して、すべてのペアの距離を保持するので空間は $O(n^2)$ 必要である*2。時間は素朴な実装で $O(n^3)$ 、工夫して $O(n^2 \log n)$ になる。

74 点なら一瞬だが、数万点を超えると現実的でなくなる。そこで次節の k-means が使われる。

5.4 切る高さはデンドログラムだけでは決まらない

デンドログラムを、高さのある位置で水平に切る。図 5.3 のように縦軸に距離を取った図なら、横線を 1 本引くことになる。線が枝を横切った本数が、そのときのクラスタ数である。高い位置で切れば少数の大きなクラスタ、低い位置で切れば多数の小さなクラスタになる。

図 5.6 は、本書の 74 作品 (52 列を列ごとに標準化) を Ward 法で併合した木である。高さ 17.4 で切ると 8 個、高さ 10.4 で切ると 18 個のクラスタに分かれる。葉の下の色が正解の著者で、著者名は木を作るのには使っていない。

利点は**クラスタ数を先に決めなくてよい**ことである。木を作ってから、後で切る位置を選べばよい。

*2 $O(n^2)$ は「点の数が 10 倍になると、必要な量がおよそ 100 倍になる」という増え方を表す記法である。 $O(n^3)$ なら 1000 倍になる。




図 5.6 74 作品の Ward 法のデンドログラム (52 列を標準化、ユークリッド距離)。高さは scipy の $\sqrt{2\Delta E}$ 。破線は 8 クラスと 18 クラスに切る高さ。葉の下の色は著者で、木を作るときには使っていない。

問題はどこで切るのが正しいのかである。デンドログラムは答えを教えてくれない。切る位置を選ぶには別の物差しが要る。次節で 2 種類用意する。

5.5 答え合わせ — 2 種類の評価

クラスタリングの結果を評価する方法は 2 種類ある。正解を使うものと、使わないものである。

5.5.1 正解を使う — Adjusted Rand Index

評価の前に、1 つ困ったことがある。クラスタリングが出すのは「クラスタ 1」「クラスタ 2」という番号だけで、どの番号が誰にあたるかは教えてくれない。番号の付き方は実行するたびに変わる。だから、著者名とクラスタ番号を直接つき合わせるができない。

そこで **2 作品の組** を単位にして比べる。「この 2 作品が同じ組に入ったかどうか」なら、番号の付き方に関係なく決まるからである。

Rand Index は、すべての作品ペアについて次を数える。

- 同じ著者で、同じクラスタに入った (a 組)。正解
- 違う著者で、違うクラスタに入った (b 組)。これも正解
- それ以外 (誤り)

$$RI = \frac{a + b}{\binom{n}{2}} \quad (5.6)$$

分母はペアの総数である。

小さな例で数えてみる。4 作品のうち 1 と 2 が著者 A、3 と 4 が著者 B で、クラスタリングが $\{1, 2, 3\}$ と $\{4\}$ に分けたとする。ペアは $\binom{4}{2} = 6$ 組ある。 $\{1, 2\}$ は同じ著者で同じクラスタなので

$a = 1$ 、 $\{1, 4\}$ と $\{2, 4\}$ は違う著者で違うクラスタなので $b = 2$ である。残る $\{1, 3\}$ 、 $\{2, 3\}$ 、 $\{3, 4\}$ の 3 組が誤りで、 $RI = (1 + 2)/6 = 0.5$ になる。

ただしこれには問題がある。クラスタを細かく割るほど、「違う著者どうしがたまたま違うクラスタに入る」ペアが自動的に増える。 b の項がひとりでに膨らむので、でたらめに分けても k が大きければ高い値が出てしまう。実際に 74 作品をくじ引きで 8 個のクラスタへ振り分けると、RI の平均は 0.77 になる。74 個へばらばらに振り分ければ 0.84 まで上がる (図 5.7)。




図 5.7 著者を見ずに、74 作品を k 個のクラスタへくじ引きで振り分けたときの RI と ARI(500 回の平均)。RI は k とともに上がるが、ARI は 0 のままである。

そこで、でたらめに分けたときに期待される値を引いてから、完全一致が 1 になるように割り直す。これが **Adjusted Rand Index (ARI)** である。

$$ARI = \frac{RI - E[RI]}{\max(RI) - E[RI]} \quad (5.7)$$

$E[RI]$ がでたらめな分割での期待値、 $\max(RI)$ が完全一致のときの値である。引き算と割り算で目盛りを付け直しただけで、完全一致で 1、でたらめな分割で 0 前後になる。偶然より悪ければ負にもなる。ここでいう「でたらめな分割」は、クラスタの数と大きさはそのままにして、どの作品がどのクラスタに入るかだけをくじ引きで決め直したものである [45]。図 5.7 の実験でも、ARI の平均はどの k でも 0 になっている。

5.5.2 正解を使わない — シルエット係数

実務では正解がない。そのときは「クラスタがどれだけよくまとまっているか」を測るしかない。各点 i について 2 つの量を計算する。

$$a(i) = \frac{1}{|C_i| - 1} \sum_{j \in C_i, j \neq i} d(i, j) \quad (\text{同じクラスタ内の平均距離}) \quad (5.8)$$

$$b(i) = \min_{C_k \neq C_i} \frac{1}{|C_k|} \sum_{j \in C_k} d(i, j) \quad (\text{最も近い他クラスタへの平均距離}) \quad (5.9)$$

C_i は点 i が属するクラスタである。 $a(i)$ は同居している仲間との近さ、 $b(i)$ はいちばん引越したくなる隣のクラスタとの近さを表す。この 2 つを比べる。




図 5.8 シルエット係数が見ている 2 つの距離。 $a(i)$ は同じクラスターの仲間まで (実線) の平均、 $b(i)$ は他のクラスターのうち最も近いものまで (破線) の平均である。遠いほうの隣は $\min$ を取る時点で捨てられるので、値には現れない。実線が短く破線が長いほど $s(i)$ は 1 に近づく。

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (5.10)$$

分子は「隣より仲間のほうがどれだけ近いか」で、分母は値を -1 から 1 に収めるための割り算である。点 i が 1 点だけのクラスターにいるときは、 $a(i)$ が決まらないので $s(i) = 0$ と決めておく (scikit-learn もそうしている)。

- 1 に近い — 自分のクラスターによくまとまっている
- 0 付近 — クラスターの境界上にいる
- 負 — 別のクラスターに入れたほうがよい

全点の平均がシルエット係数 (silhouette coefficient) である [46]。

5.5.3 2 つの指標は一致しない

52 列を列ごとに標準化した 74 作品を、Ward 法とユークリッド距離で階層クラスタリングする。クラスター数 k を 2 から 20 まで変えて切り、そのつど ARI とシルエット係数を計算したのが図 5.9 である。

ARI は $k = 7$ から $k = 9$ で頭打ちになり、著者数と同じ $k = 8$ では ARI が 0.87 である。ARI は完全一致で 1、でたらめな分割で 0 前後になる目盛りなので、0.87 は正解の著者分けにかなり近い。字種の比率、文の長さ、読点の打ち方だけで、ここまで著者が分かれるのは注目してよい。

どこを間違えた 0.87 なのかは、クラスターと著者の対応表で分かる (表 5.3)。泉鏡花の 9 作品は $7 \cdot 1 \cdot 1$ に割れ、1 作品は夢野久作のクラスターに入り、もう 1 作品は 1 作品だけのクラスターになった。谷崎潤一郎の 6 作品のうち 5 作品は、柳田国男の 5 作品と同じクラスターに入った。太宰治のクラスターには、谷崎と吉川英治の作品が 1 つずつ混ざっている。

図 5.10 は、同じ $k = 8$ の分割で各作品の $s(i)$ を並べたものである。平均のシルエット係数は 1 つ




図 5.9 クラスタ数と 2 つの評価指標 (Ward 法)。

表 5.3 $k = 8$ で切ったときの著者とクラスタの対応 (Ward 法、52 列を標準化)。数字は作品数。クラスタの番号は、最も多く含む著者の順に振り直した。

著者 \ クラスタ	1	2	3	4	5	6	7	8
夏目漱石	10							
泉鏡花		7	1			1		
島崎藤村				9				
太宰治					7			
夢野久作						7		
谷崎潤一郎					1		5	
柳田国男							5	
吉川英治					1			20

の数だが、中身は作品ごとに大きく違う。 $s(i)$ が負の作品は 6 作品で、他の著者のクラスタに紛れ込んだ作品がそこに入っている。

一方シルエット係数が最大になるのは $k = 18$ である。著者数の倍以上に細かく割ったところである。

細かく割ると、同居している仲間との距離 $a(i)$ は小さくなるが、最も近い他クラスタとの距離 $b(i)$ も同時に小さくなるので、細かいほど $s(i)$ が上がると一般には言えない。本書のデータで何が起きているかは、18 個のクラスタを著者と突き合わせると分かる (表 5.4)。18 個のうち 17 個は 1 人の著者の作品だけからなり、7 個は 1 作品だけのクラスタである。 $k = 8$ で他の著者のクラスタに紛れ込んでいた作品や、仲間から離れた作品が切り離され、 $s(i)$ が負の作品は 6 作品から 1 作品に減った。平均で見ると、 $a(i)$ は 7.28 から 5.61 へ、 $b(i)$ は 9.22 から 7.97 へ下がり、 $a(i)$ の減り方のほうが大きい。その代わり、吉川英治の 21 作品は $9 \cdot 11 \cdot 1$ に、泉鏡花の 9 作品は 5 つに割れ、ARI は 0.63 まで下がる。シルエット係数は著者という正解を見ていないので、「割りすぎだ」と判断する材料をそもそも持っていない。




図 5.10 $k = 8$ での各作品の $s(i)$ (Ward 法、52 列を標準化)。棒 1 本が 1 作品で、クラスごとにまとめて $s(i)$ の大きい順に並べ、クラスの間は少し空けた。上のクラスほど $s(i)$ の平均が大きい。色は正解の著者で、分割には使っていない。

表 5.4 $k = 18$ で切ったときの著者とクラスとの対応。表 5.3 と同じ木を低い位置で切った。

著者 \ クラス	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
夏目漱石	8	2																
泉鏡花			5	1	1	1	1											
島崎藤村							7	2										
太宰治									6	1								
夢野久作											6	1						
谷崎潤一郎													5	1				
柳田国男																5		
吉川英治										1							11	9

× アンチパターン 5.1 — シルエット係数が最大の k を採用する

シルエット係数は「球状にまとまったクラス」を高く評価する。実際の構造が細長かったり、大きさがばらばらだったりすると、正しい k で最大にならない。

内的指標は参考であって決定基準ではない。分野の知識、後段の使い道、結果の解釈しやすさを合わせて決める。

5.6 距離と併合方法の相性


評価の道具がそろったので、ここで距離と併合方法の組み合わせに戻る。最もよく使われる Ward 法は、式 (5.4) のとおりユークリッド距離を前提にしている (他の距離を渡すと何が起きるかは本節の発展で、実務上の扱いは節末の定石で詳しく見る)。

第4章で、本書の題材ではコサイン距離のほうがよく分けることを見た。では Ward 法 + コサイン距離にすればよいかというと、そう単純ではない。

図 5.11 に、方法を変えた 2 つのデンドログラムを並べる。



(a) 単連結・ユークリッド距離



(b) 群平均・コサイン距離

図 5.11 方法を変えると木の形が変わる (各著者の最初の 2 作品、計 16 作品。52 列を列ごとに標準化)。上の単連結は鎖状に伸びている。

(a) の単連結では、木が一方方向に伸びている。表 5.2 で述べた鎖効果である。点が数珠つなぎに併合されていき、クラストラしいまとまりが見えにくい。74 作品全体を単連結で併合して 8 個に切ると、67 作品の 1 つの塊と、1 作品だけのクラスター 7 個に分かれる。ARI は 0.03 で、でたらめに分けたのとはほとんど変わらない。

(b) の群平均 + コサイン距離では、まとまりがはっきりしている。74 作品全体でも、この組み合わせで 8 個に切ったときの ARI は 0.933 になる。

発展 Ward 法にユークリッド距離以外を渡すと何が起きるか

式 (5.4) は重心の差の 2 乗で書かれていて、そこには「距離が 2 乗和で測られている」という前提が入っている。

ところが実務では、 $p = 1$ のマンハッタン距離と Ward を組み合わせることがある。筋の通らない組み合わせに見える。確かめてみる。

読点前の平仮名 47 列だけを取り出し、行ごとに合計 1 へ正規化したものを入力にする (字種と文長は混ぜない)。つまり各行は **47 文字の上の確率分布**である。これを距離と併合方法のすべての組み合わせでクラスタリングし、正解の著者との一致度を ARI で測った ($k = 8$ で切った)。

距離	生の比率 (行和 1)			列を標準化		
	完全連結	群平均	Ward	完全連結	群平均	Ward
$p = 0.5$	0.425	0.079	0.600	0.642	0.085	0.633
$p = 1$ (マンハッタン)	0.592	0.310	0.891	0.363	0.029	0.661
$p = 2$ (ユークリッド)	0.338	0.576	0.703	0.109	0.029	0.621
$p = 4$	0.384	0.570	0.434	0.094	0.034	0.692
コサイン	0.330	0.464	0.654	0.612	0.911	0.617

生の比率のままなら、 $p = 1$ と Ward の組み合わせの ARI が **0.891** で最も高い。 $p = 2$ (ユークリッド距離) と Ward の 0.703 を 0.188 上回っている。

$p = 1$ が良い理由は、データが確率分布だからである。2 つの分布 u, v のあいだのマンハッタン距離^aは総変動距離の 2 倍に等しい。総変動距離は「一方の書き手の癖をもう一方に作り変えるのに、どれだけの確率の質量を移せばよいか」と読める量なので、マンハッタン距離はその移す量の 2 倍を測っていることになる。分布どうしを比べるのに素直な量である。第 4.3 節の補足で触れた計算言語学の研究でも、名詞と動詞の共起の確率を推定する課題で分布どうしの近さの尺度を比べたところ、 ℓ_1 距離は上位の一群に入り、ユークリッド距離が最も悪かった [33]。

$p = 2$ が劣るのは、2 乗が頻度の高い数文字を強調するからである。47 列の比率を 74 作品で平均すると、「て」が 0.176、「は」が 0.122、「が」が 0.089 で、この 3 文字だけで各行の合計 1 のうち 4 割近くを占める。その 3 文字の差だけで距離がほぼ決まってしまう。マンハッタン距離なら、どの文字も比率の差そのままの重みで距離に加わる。

では p は小さいほどよいかというと、そうではない。Ward 法のまま $p = 0.5$ にすると、ARI は 0.600 に下がる。 $p = 1$ の 0.891 を 0.291 下回っている。1 を下回ると、めったに出ない文字のわずかな差が過大に扱われる。比率 0.001 と 0.002 の違いは、たいてい書き手の癖ではなく数え上げの揺らぎである。最良の p は 1 のあたりにある。

Ward が良い理由は距離とは別である。併合の費用に $|C_i||C_j|/(|C_i| + |C_j|)$ という係数が掛かるので、**大きいクラスタどうしの併合が高つく** (図 5.4)。これが単連結の鎖効果を抑え、完全連結のように大きなクラスタを割ることも少ない。距離の選択と併合規則の選択は別々の問題を担当しているので、組み合わせても打ち消し合わない。

計算そのものは、前の発展「Lance-Williams の漸化式」に任意の距離行列を入れれば回る。ただしそのとき得られているのは平方和の増分を 1 段ずつ最小にする手順ではなく、**大きい併合を罰する併合規則**である。デンドログラムの高さを「クラスタ内平方和の増加量」としては読めない。

上の表の数値は、距離を 2 乗してから漸化式に入れる実装 (scipy の `ward`、R の `ward.D2`) で計算した。距離をそのまま入れる古い実装 (R の `ward.D`) では別の数値になる。その違いは前の発展の末尾で測ったとおりである。

^a 同じ距離が 3 通りに呼ばれるので、ここで整理しておく。手法として呼ぶときは第 4 章で導入したマンハッタン

発展 (続き)

ン距離、ミンコフスキー距離の族の中での位置を示すときは $p = 1$ 、ノルムの性質そのものを指すときは ℓ_1 距離である。とくに分布どうしの比較や、正則化との対応を論じる文脈では ℓ_1 と書く慣習が強い。本書も 3 つを文脈で使い分ける。なお、 $p = 1$ の p はミンコフスキー距離の指数であって、確率を表す p ではない。紛れないう、ここでは分布を u, v と書いた。

5.6.1 前処理は ARI の高さでは選べない*

前の箱の表には、まだ説明していない列がある。右半分、**47 列を列ごとに標準化した場合**である。測り方は左半分と同じで、 $k = 8$ で切ったときの ARI である。そこではコサイン距離と群平均法の組み合わせの ARI が 0.911 で最も高く、生の比率での最良である $p = 1 + \text{Ward}$ の 0.891 を 0.020 上回っている。

結果だけ見れば標準化したほうが良い。ところが第 4.4.2 項の場合分けに従うなら、**47 列はすべて同じ単位の比率であり、標準化する理由がない**。しかも合計が 1 という制約があるので、列ごとに平均を引いて標準偏差で割れば、その制約は壊れる。組成データには `clr` 変換を使えというのが第 3.7 節の話でもあった。結果と原則が食い違っている。どちらを信じるかを決める前に、標準化が実際に何をしているかを見る。

標準化は列の重みを 44 倍まで変える 標準化は各列を $1/s_j$ 倍する。 s_j は列の標準偏差なので、おおむね比率の小さい文字ほど大きく引き伸ばされる。

文字	平均比率	実測 SD	$1/s_j$	数え上げ SD	揺らぎの割合 (%)	F 値
て	0.1760	0.0419	24	0.0083	4	17.2
は	0.1217	0.0465	22	0.0071	2	26.5
が	0.0892	0.0322	31	0.0062	4	21.0
ん	0.0073	0.0082	122	0.0018	5	12.4
う	0.0070	0.0054	184	0.0018	11	6.6
っ	0.0012	0.0020	492	0.0008	14	22.4
げ	0.0012	0.0012	852	0.0007	40	5.1
び	0.0011	0.0011	945	0.0007	45	9.9

$1/s_j$ が最も小さいのは「は」の 22 倍、最も大きいのは「そ」の 950 倍で、両者の倍率の比は 44 倍になる。標準化は**列どうしの相対的な重みを最大 44 倍まで書き換える**操作である。前処理というより、特徴量の作り直しに近い。表は 47 列から 8 列を抜き出したもので、47 列すべてを図 5.12 の上段に描いた。

引き伸ばされる列ほど数え上げの揺らぎが混ざる 問題は、引き伸ばされる列に何が入っているかである。比率は数え上げの結果なので、読点 N 個から推定した比率 $\hat{p}$ には分散 $p(1-p)/N$ の揺らぎが必ず乗る。ここでの N は、直前が 47 文字のどれかである読点の数で、作品によって 291 本から 27546 本まで違う (中央値 4474 本)。作品ごとの揺らぎを 74 作品で平均し、その平方根を表の「数

え上げ SD」に載せた。

数え上げの揺らぎの分散を実測の分散で割った値が、「観測された散らばりのうち、数え上げの揺らぎで説明できる割合」の目安になる。これを表の「揺らぎの割合」に載せた。その中央値は、平均比率の上位 10 列で 6%、下位 10 列で 33% である。最も大きい「そ」では 53% に達する (図 5.12 の下段)。まれな文字の列ほど、見えている散らばりのうち揺らぎの占める割合が大きい。ただし下位 10 列でも、散らばりの大半は揺らぎでは説明できず、作品ごとの違いが残っている。

著者を分ける力そのものを F 値^{*3}で測っても同じ向きになる。 F 値の中央値は、平均比率の上位 10 列で 16.6、下位 10 列で 7.4 である。47 列について比率の対数と F 値の対数の相関を取ると +0.43 で、頻度の高い文字のほうが著者の情報を多く持っている。下位 10 列の 7.4 も、著者が関係ないときに 0.1% の確率でしか超えない値 4.0 を上回っているので、まれな文字にも著者の情報はあ




図 5.12 読点前 47 列の標準化の倍率 (上) と、実測の分散のうち数え上げの揺らぎが占める割合 (下)。横軸は平均比率の大きい順。まれな文字ほど大きく引き伸ばされ、その列ほど揺らぎの割合が大きい。

それでも ARI は上がる にもかかわらず ARI は良くなる。矛盾ではない。生の比率では、平均比率の上位 3 文字だけで 47 列の合計の 39% を占め、距離のほとんどがその 3 文字で決まってしまう。残り 44 列は、1 列ずつなら弱いが、誤差の向きがそろっていないので、44 本まとめれば 3 本より強くなりうる。弱い判定器を多数束ねると強くなるのと同じ理屈である。標準化は、その束ね方をたまたま用意している。

「たまたま」と書いたのには理由がある。74 作品の 80% を無作為に抜き出してクラスタリングし、 $k = 8$ で切ったときの ARI を測る。これを 300 回繰り返す。300 回の ARI の平均と標準偏差は、生の比率での $p = 1 + \text{Ward}$ が 0.813 ± 0.091 、標準化でのコサイン + 群平均が 0.869 ± 0.072 である。同じ抜き出しどうして比べて標準化のほうが高いのは 300 回のうち 70% で、3 回に 1 回は逆転する

^{*3} 分散分析で使う統計量で、著者どうしの平均の開きを同じ著者の作品どうしのばらつきで割った比である。その列の値が著者ごとにまとまって離れているほど大きくなる。scikit-learn の `f_classif` が計算するのも F 値で、第 9 章の特徴選択にも同じものが出てくる。

(図 5.13)。同じコーパスの中の揺れでもこれだけ入れ替わるのだから、別のコーパスでどちらが勝つかまでは、この結果から言えない。




図 5.13 74 作品の 80% を無作為に抜き出して 2 通りの前処理でクラスタリングしたときの ARI (300 回、 $k = 8$)。点 1 つが 1 回の抜き出しで、破線より上なら標準化のほうが高い。

原則どりの前処理が勝つとも限らない では組成データの作法どおり clr 変換を使えばよいかというと、そうでもない。clr のあとでコサイン距離と Ward を組み合わせると ARI は 0.740、ユークリッド距離なら 0.655 である。生の比率での最良 0.891 にも、列の標準化での最良 0.911 にも及ばない。clr は比率の比を保つ変換なので、「0.001 が 0.002 になった」という、まれな文字の 2 倍の変化を大きく扱う。まれな文字ほど数え上げの揺らぎの割合が大きいのので、その揺らぎも大きく扱われる。加えて、読点前 47 列には 0 が 255 個あり、clr の結果はゼロを何に置き換えるかに左右される。第 3 章と同じ置換量 δ を 1/10 倍にするとコサインと Ward の ARI は 0.411、10 倍にすると 0.542 になり、どちらでも上の 0.891 と 0.911 に及ばない。

○ 定石 5.1 — 前処理は結果ではなく測り方の理屈で選ぶ —

本節で並べた 3 つ (生の比率・列の標準化・clr) のうち、ARI が最も高かったのは列の標準化である。しかしクラスタリングを使う本当の場面には正解ラベルがない。ARI を見て前処理を選ぶことは、答えを見て問題の解き方を選ぶことに等しい。

選ぶ根拠にできるのは、ARI ではなく次のような問いである。

- 列の単位はそろっているか (そろっていれば標準化は不要)
- 合計が固定されているか (組成データなら clr 系を検討する)
- 各列の値は、どれくらいの数から推定されたか (少ない数から推定した列を引き伸ばすと、数え上げの揺らぎも一緒に引き伸ばされる)
- 引き伸ばした列に、引き伸ばすだけの情報があるか (F 値や効果量で先に確かめられる)

比率の表なら、まず生の比率と clr を試し、列ごとの標準化は「理由を言えるとき」に限るのが安全である。

× アンチパターン 5.2 — 合計が 1 に固定された比率の表を列ごとに標準化する

すべての列が同じ単位の比率で、しかも合計が 1 に固定されている表では、標準化は単位をそろえる操作ではなく**列の重みを付け替える操作**になる (上の例では最大 44 倍の付け替えが起き、引き伸ばされた列ほど数え上げの揺らぎの割合が大きかった)。それでも ARI が上がったのはたまたまで、別のコーパス、別の文字集合では逆に転ぶ。選ぶ根拠は、直前の定石に挙げた問いに求める。

○ 定石 5.2 — Ward 法はユークリッド距離と組み合わせる

- Ward 法 — ユークリッド距離とだけ使う
- 単連結・完全連結・群平均 — 任意の距離と使える

scipy の linkage は、渡された距離行列がユークリッド距離かどうかを確かめずに計算してしまうので、自分で気をつけるしかない (scikit-learn の AgglomerativeClustering は、Ward にユークリッド以外を渡すとエラーで止まる)。

定石が守っているのは**式 (5.4) の意味**である。Ward 法に他の距離を渡しても計算は回るし、本節の発展「Ward 法にユークリッド距離以外を渡すと何が起きるか」で見たように、ARI が上がることさえある。デンドログラムの入れ子構造も壊れない (Lance-Williams の Ward の係数は、高さが逆転しないための条件を満たしている)。

壊れるのは**解釈**のほうである。ユークリッド距離でなければ、そもそも重心も平方和も定義できないので、得られた高さが何の増分なのかを言えなくなる。残るのは「大きいクラスタどうしの併合を重く見る併合規則」という手続きだけである。

それでも使うなら、次の 3 つを報告に残す。

1. 渡した距離 (ユークリッドでないなら、その旨を明示する)
 2. 使った実装 (ward.D か ward.D2 か。発展「Lance-Williams の漸化式」で見たとおり、読点前 47 列にユークリッド距離を使うと、同じデータで ARI が 0.703 対 0.522 になる)
 3. 高さを読んでいないこと (切ったクラスタだけを使ったのか、高さの大小も解釈したのか)
- 高さを読まないなら支障は小さいが、再現できる形で書き残すところまでが手順である。

コラム 文体計量のデンドログラムは設定しだいで変わる

文体計量では、高頻度語の相対頻度から作品どうしの距離を測り、階層クラスタリングのデンドログラムで「どの作品とどの作品が近いか」を示すことが、長く定番の手順だった (第 4 章で触れた Burrows の Delta もこの流れにある)。

ところがデンドログラムの形は、使う語の数 (上位 100 語か 1000 語か)、距離、併合方法の選び方で変わる。設定をいくつか試して、仮説に合う 1 枚を選んで載せてしまえば、どんな結論でも図で「示せて」しまう。この問題を正面から扱ったのが、ポーランドの Maciej Eder である [47]。

Eder は、語の数などの設定を少しずつ変えて多数のデンドログラムを作り、そのうち一定の割合以上の図で繰り返し現れるまとまりだけを残す**合意木** (bootstrap consensus tree) を使い、さらに、各作品を最も近い作品と 2 番目・3 番目に近い作品とに線で結んで重ねる合意ネットワークへ広げた。本物のまとまりは設定を変えても現れ続け、偶然のまとまりは一部の図にしか現れない、という考え方である。こ

コラム (続き)

の方法は、文体計量で広く使われている R のパッケージ `stylo` に入っている。

本章で、Ward 法の実装の違い (`ward.D` と `ward.D2`) だけで ARI が 0.18 変わったのも同じ現象である。Eder の合意木は、こうした違いを多数の設定にわたってならしてから読むための手順である。

5.7 k-means

階層クラスタリングは $O(n^2)$ 以上かかる。数万点では現実的でない。

k-means はクラスタ数 k を先に決めて、次を繰り返す。

(0) クラスタ中心 $\mu_1, \dots, \mu_k$ をランダムに決める

1. 各点を、最も近い中心のクラスタに割り当てる
2. 各クラスタの中心を、所属する点の平均に移動する

1 と 2 を、中心が動かなくなるまで繰り返す。

最小化しているのは**クラスタ内平方和**である。 C_c は c 番目のクラスタ、 μ_c はその中心である。

$$J = \sum_{c=1}^k \sum_{x \in C_c} \|x - \mu_c\|^2 \quad (5.11)$$

手順 1 は中心 μ を固定したまま、各点を最も近い中心に付け替える。より近い中心に移すのだから、その点の $\|x - \mu\|^2$ は減るか同じである。手順 2 は割り当てを固定したまま、中心を各クラスタの平均に置き直す。平均は**そこからの 2 乗距離の和を最小にする点**なので、これも J を減らす。

つまり反復のたびに J は減るか、同じ値にとどまる。ただしそれだけでは、いつまでも少しずつ減り続ける可能性がある。止まることが言えるのは、**点の割り当ての仕方が有限通りしかない**からである。


割り当てが 1 つでも変われば、 J は必ず**狭義**に減る (同じ距離で迷ったときは、いま属しているクラスタに留まると決めておく。こうすると割り当てが変わるのは、いまの中心より真に近い中心が見つかったときだけになる)。 J が減ったのなら、その割り当ては過去に現れたどの割り当てとも違う。つまり同じ割り当てには二度と戻らない。候補は k^n 通りしかないのだから、戻らずにたどっていればいつかは打ち止めになる。打ち止めになるのは、割り当てが 1 つも変わらなくなったときである。

5.7.1 反復を目で追う


仕組みが見えるように、はっきり 3 つの塊がある人工データ (各 40 点) で $k = 3$ として動かす。中心の初期値は乱数で、**3 つとも図の下半分に寄った状態**から出発させる。1 つは下の塊の上にあるが、残りの 2 つは右下の何もない場所にある。

動きを追ってみる。(0) では、左の塊と下の塊が、どちらも下の中央の中心にいちばん近い。79 点がこの 1 つの中心に割り当てられている。右上の塊は、右下の中心の片方に割り当てられる。(1) では、右上の塊を受け持った中心が、その重心へ大きく跳ぶ。1 回の更新で中心が動いた量を、3 つの中心の座標の変化のうち最大のもので測ると、このときは 5.33 である。下の中央の中心は、左と下の 2 つの塊の間へ引き寄せられ、下の塊の真上という正しい位置からかえって離れる。以後、(2)(3)


(0) 初期値 (乱数、下半分に寄る)



(1) 1 回目の更新後



(2) 2 回目の更新後



(3) 収束 (5 回目)




図 5.14 k-means の反復。黒い十字がクラスタ中心。下半分に寄って出発した 3 つの中心が、点を取り合いながら動き、5 回の更新で塊に 1 つずつ収まった。

と中心どうしが点を取り合いながら移動し、同じ測り方での移動量は 2 回目以降、順に 0.99、2.58、1.84、0.31 になる。その 1 つ前の更新で割り当てが 3 つの塊に 1 つずつそろい、5 回目の更新で中心がそれぞれの重心に移って、次の割り当てで何も変わらずに停止した。**どの中心も、正解の位置を教わっていない。**「割り当て」と「重心への移動」を交互に繰り返すだけで、自然に塊の中心へたどり着くのが k-means の仕組みである。

この間の J を、手順 1 と手順 2 のそれぞれの直後で測ったのが図 5.15 である。出発時の 3187 から最後の 175 まで、一度も増えていない。前の項で示した「反復のたびに J は減るか、同じ値にとどまる」がそのまま見える。減り方は一様ではない。右上の塊を受け持った中心が大きく跳んだ最初の置き直しで 3187 から 990 まで下がり、中心の移動が小さかった 2 回目の前後ではほとんど減らない。そのあと、下の塊の点の取り合いが決着する横軸の 2.5 から 3.5 にかけて、ふたたび大きく減っている。

5.7.2 初期値に依存する

k-means は必ず収束するが、**たどり着く先が最良とは限らない**。式 (5.11) を最小化する問題は NP 困難^{*4}であり、実際に得られるのは局所最適解である。

3 つの明確な塊がある人工データ (各 40 点) で確かめる。 $k = 3$ とし、初期中心を手で置いて `n_init=1` で 1 回だけ実行する。

^{*4} 現実的な時間で厳密な最適解を求める方法が知られていない問題の一群を指す。点の数が増えると、すべての分け方を試す計算量が爆発する。





図 5.15 図 5.14 の反復でのクラスタ内平方和 J 。割り当て (手順 1) でも中心の置き直し (手順 2) でも、 J は減るか同じにとどまる。

(a) 良い初期値 $J = 49.2$



(b) 悪い初期値 $J = 549.7$




図 5.16 同じデータ、初期値だけが違う。赤い丸が初期中心。(b) では左の塊を 2 つに割り、右の 2 つを 1 つにまとめたしまった。

(b) では初期中心のうち 2 つが同じ塊の中にあったため、その塊を 2 つに割ってしまった。式 (5.11) のクラスタ内平方和は $J = 549.7$ で、正しい解の $J = 49.2$ の 11 倍である。

○ 定石 5.3 — k-means は初期値を変えて複数回試す

- `n_init` を大きくして複数回試し、 J が最小の結果を採る
- `k-means++` を使う。初期中心が互いに離れるように選ぶ手法で、scikit-learn の既定値になっている

× アンチパターン 5.3 — k-means を 1 回だけ実行する

自分で実装したり `n_init=1` を指定したりすると、図 5.16(b) のような解を掴んだまま気づかない。scikit-learn 1.4 以降の `KMeans` は、既定の `n_init="auto"` では `k-means++` の初期化で 1 回しか実行しないので、指定しなければ同じことになる。

目的関数 J の値は必ず記録しておく。複数回実行して J がばらつくなら、一部の実行が局所解に落ちている。

コラム k-means は社内の技術メモだった

k-means の手順を最初にしたのは、ベル研究所の Stuart Lloyd である。1957 年、信号をデジタルに送るパルス符号変調 (PCM) の研究で、信号の値を k 段階に丸めるときに、どの値を代表にすれば丸めの誤差の 2 乗和が最小になるかを考えた。各値をいちばん近い代表値に割り当て、代表値を割り当てられた値の平均に置き直す。これを繰り返す手順は、本章の手順 1 と手順 2 そのものである。このメモは社内で回覧され、同じ年の学会で一部が発表されたが、学術誌に載ったのは 25 年後の 1982 年だった [48]。

その間に、同じ考えは何度も独立に現れた。さかのぼれば 1956 年に数学者 Steinhaus が物体を部分に分ける問題として論じており [49]、「k-means」という名前は 1967 年の MacQueen の論文で付いた [50]。

初期値の問題への実用的な答えが出たのは、さらに 40 年後である。2007 年に Arthur と Vassilvitskii は、すでに選んだ中心から遠い点ほど選ばれやすくなるように初期中心を 1 つずつくじ引きで選ぶ k-means++ を提案し、それだけで得られる J の期待値が最適値の $O(\log k)$ 倍以内に収まることを示した [51]。scikit-learn の既定の初期化はこの方法である。

5.7.3 k-means の制約

もう一つ、押さえておきたい性質がある。k-means ではユークリッド距離が構造的に前提になっていて、他の距離に差し替えることができない。

理由は手順 2 にある。中心を各クラスターの平均に置き直しているが、平均とは「そこからの 2 乗距離の和を最小にする点」のことである。2 乗距離、つまりユークリッド距離を測っていることが、平均を使うと決めた時点で確定してしまう。距離だけをコサイン距離に取り替えても、中心の置き方はユークリッド距離のままなので、辻褄が合わなくなる。

コサイン距離で k-means を回したければ、先にベクトルを ℓ_2 正規化する (第 4 章の式 (4.10))。すべての点が半径 1 の球面に乗り、球面上ではユークリッド距離とコサイン距離が対応するので、実質的に同じことになる。ただし平均を取ると球面から内側へ外れてしまうので、中心を求めるたびに ℓ_2 正規化して球面へ戻す。これを球面 k-means と呼ぶ。

5.7.4 エルボー法とその限界

k を決める目安としてエルボー法がよく紹介される。式 (5.11) の J を k に対してプロットし、「肘」を探す。

なぜ肘を探すのかを先に説明する。 k を 1 つ増やすと、クラスターが 1 つ細かく割れて J が減る。その減り方に注目する。

データに k^* 個の塊が本当にあるなら、 k が k^* に達するまでは、1 つ増やすたびに別の塊どうしが切り離されるので J は大きく減る。 k^* を超えると、今度は 1 つの塊を無理に 2 つに割ることになるので、減り方は鈍くなる。つまり減りの勢いが変わる位置が k^* の目印になる。グラフではそこが折れ曲がって見えるので、肘と呼ばれる。

理屈は通っている。問題は、その肘が実際に見えるかどうかである。

図 5.17 に、はっきりした折れ曲がりは見当たらない。 $k = 4$ にも $k = 6$ にも見えるし、そもそもなめらかに減っているだけにも見える。本書のデータには著者という 8 つの塊があるはずなのに、 $k = 8$ に目印は出ていない。




図 5.17 エルボー法。折れ曲がりの位置を探すが、はっきりしないことが多い。

× アンチパターン 5.4 — エルボー法だけでクラスタ数を決める

k を増やせば J の最適値は必ず下がる。 $k = n$ 、つまり全部の点を別々のクラスタにすれば 0 になる。だから「 J が小さいほど良い」では決まらない。

正確には、単調に下がるのは最適値のほうである。k-means が返すのは初期値に依存する局所解なので、 k を増やしたのにかえって悪い解に落ち、 J が増えることもありうる (本書は $n_{\text{init}}=20$ で 20 通りの初期値から最良を採っているのので、図 5.17 では起きていない)。どちらにせよ「小さいほど良い」で k は決まらない。

決め手は減り方の変化のはずだが、その変化がどこで起きたかを読む作業に客観的な基準がない。

はっきりした肘が出ないほうが普通だと思ったほうがよい。本書のデータのように、塊どうしの境目がぼやけている場合はとくにそうである。

5.8 階層クラスタリングと k-means の使い分け

表 5.5 2つの手法の比較

	階層クラスタリング	k-means
クラスタ数	後から決められる	先に決める
計算量	$O(n^2)$ 以上	$O(nkdt)$ 、 d は次元、 t は反復回数
結果の安定性	決定的	初期値に依存
距離の自由度	任意 (Ward 除く)	ユークリッドのみ
出力	木構造 (階層)	平坦な分割
向く場面	数千点まで、構造を見たい	大規模、 k が既知

本書のデータは 74 点なので階層クラスタリングで十分である。ただし k-means の反復は、第 10.2.2 項で扱う勾配降下法と同じく、目的の値を反復のたびに下げていくという形をしている。違いは、勾配降下法が傾きの向きに少しずつ進むのに対し、k-means は割り当てと中心を交互に、そのときの最良の値へ一度に置き直すところである。機械学習の学習の多くは「目的の値を下げる反復」の

形なので、ここで押さえておきたい。

5.9 章末の課題

1. 図 5.2 の 5 点について、単連結と完全連結でも併合の履歴を作れ。群平均法 (表 5.1) と順序は変わるか。
2. Ward 法とコサイン距離を組み合わせてデンドログラムを描き、図 5.11 と比べよ。どこがおかしいか説明できるか。
3. $k = 10$ で切って、表 5.3 と同じ著者とクラスタの対応表 (混同行列) を作れ。 $k = 8$ から増えた 2 つのクラスタは、どの著者のどの作品を切り離したもののか。
4. k-means を `n_init=1`、乱数の種を変えて 30 回実行し、 J のヒストグラムを描け。何種類の局所解があるか。
5. Lance-Williams の漸化式 (発展) で、単連結の場合に $\alpha_i = \alpha_j = 1/2$, $\gamma = -1/2$ が $\min$ を与えることを確かめよ。
6. 図 5.14 の人工データで $k = 2$ と $k = 4$ を試し、収束後の J と見た目を $k = 3$ と比べよ。 J の値だけで k を選べない理由を、この実験結果から説明せよ。(ヒント: k を増やすと J の最適値は必ず下がる。エルボー法とシルエット係数の項を見直すとよい。)

第 6 章

次元を減らす

6.1 見えないものを見る

52 次元の空間に 74 個の点が散らばっている。散らばりを「見る」ことはできない。人間が直接見られるのはせいぜい 3 次元、紙の上なら 2 次元である。

そこで**次元削減** (dimensionality reduction) を使う。高次元の配置をできるだけ壊さずに、低次元に写し取る技術である。

代表的な考え方が 2 つある。

- **主成分分析 (PCA、principal component analysis)** — データの**分散**が大きい方向を残す
- **多次元尺度構成法 (MDS)** — 点どうしの**距離**を保つ

どちらも「何を捨てて何を残すか」の判断が違うだけである。章の後半では、この 2 つでは扱えない、曲がった構造のための非線形手法 (t-SNE・UMAP など) へ進む。

6.2 主成分分析 — いちばん見晴らしのよい方向から眺める

PCA の発想は単純である。

データを、いちばん全貌を捉えやすい位置から眺める。

写真を撮るときのことを考えてほしい。細長い建物を真横から撮れば形がよく分かるが、真正面から撮ると奥行きが潰れて何も見えない。データにも同じことが言える。

ここから、比喩を数値に置き換える一段が必要になる。「奥行きが潰れて見えない」とは、その方向に点が散らばっていないということである。逆にいえば、**点が最もばらけて見える向きこそ、潰さずに残すべき向き**である。そして「点のばらけ具合」を 1 つの数で表したものが、第 3 章で使った**分散**である。

つまり「いちばん全貌を捉えやすい位置」は、**射影したときの分散が最大になる方向**と言い換えられる。言い換えたとたんに、計算で探せる問題になる。

6.2.1 手順を 3 次元で追う

第 3 章で作った特徴のうち 3 つだけ取り出す。平仮名の比率、漢字の比率、文長 μ の 3 つである。これを標準化して 3 次元空間に置く。

手順を言葉にする。

(0) **センタリング**。データの平均を原点に平行移動する

1. データの中心を通して、もっとも分散の大きい方向に串を通す。これが PC1




図 6.1 PCA の手順を 2 次元の 12 点で描いた模式図。平均を原点に移し、分散が最大になる方向に軸を通す。(4) の点線は、各点から PC1 へ下ろした垂線である。

2. データの中心を通り、**PC1** が点になる位置から眺めて、もっとも分散の大きい方向に串を通す。これが PC2

3. PC1 と PC2 の両方に直交する方向に串を通す。これが PC3

「PC1 が点になる位置から眺めて」というのが要点である。串の根元から串の先を覗き込む姿勢を思い浮かべてほしい。そこから見えるのは、串に垂直な平面である。PC1 方向の広がりには点に潰れて見えない。

PC2 はその平面の中から選ぶことになる。平面は PC1 に垂直なのだから、その中のどの方向も PC1 と直交する。**PC1 と PC2 が必ず直交するのは、探す場所をそう決めたからである。**直交するように後から調整しているのではない。

「分散が最大になる方向」を、図 6.1 の 12 点で実際に探してみる。原点を通る直線の向きを、横軸から測った角度 θ で表す。12 点をその直線に射影し、射影した値の分散を θ ごとに計算すると、図 6.2 の曲線になる。分散は $\theta = 33^\circ$ で最大の 0.436 をとり、そこから 90° 回った $\theta = 123^\circ$ で最小の 0.021 をとる。最大をとる向きが PC1 である。2 次元では PC1 に直交する向きは 1 つしかないの、PC2 はその向きに決まる。最大値と最小値は、第 6.2.4 項で出てくる分散共分散行列の 2 つの固有値に等しい。




図 6.2 図 6.1 の 12 点を、向き θ の直線に射影したときの分散。最大の向きが PC1、最小の向きが PC2 で、2 つは 90° 離れている。

6.2.2 見る向きを変えてみる

手順が言葉だけでは掴みにくいので、本書のデータを実際に回してみる。平仮名の比率・漢字の比率・文長 μ の3列を標準化し、74作品を3次元空間に置いた。

図6.3は、同じ点の集まりを3つの向きから見たものである。点は1つも動かしていない。動かしたのは見る位置だけである。




図 6.3 同じ 74 作品を 3 つの向きから見たもの。(b) では点が細い帯に潰れ、(c) では横いっぱい広がる。

(b) の向きから見ると、点は細い帯に潰れる。この向きには、作品どうしの違いがほとんど現れていない。逆に (c) からは、点が横いっぱいには散らばって見える。

潰れる理由ははっきりしている。74 作品について平仮名の比率と漢字の比率の相関係数を取ると -0.91 で、一方が増えればもう一方が減る関係にある。(b) の向きでは、図の横方向が 2 つの比率を足した量にあたるので、増えた分と減った分が打ち消し合う。視線は、2 つの差が大きく開く向きに沿っている。(c) では逆に、図の横方向が 2 つの差にあたり、視線は和の向きに沿っている。図の横軸方向に測った 74 点の標準偏差は、(b) が 0.29、(c) が 1.38 で、(c) が (b) の 4.7 倍である。

写真の比喻に戻れば、(b) が「細長い建物を真正面から撮った」、(c) が「同じ建物を真横から撮った」状態である。PCA がやっているのは、(c) のような向きを計算で見つけることである。

図 6.4 に、見つかった 3 本の軸を重ねた。矢印の長さは、その向きに点がどれだけ広がっているか、つまり標準偏差に比例させてある。第 k 主成分の向きの分散を λ_k と書くと、長さは $\sqrt{\lambda_k}$ に比例する (λ_k は第 6.2.4 項で固有値として出てくる。分散そのものではないので、長さの比と寄与率の比は一致しない)。

3 列 (平仮名の比率・漢字の比率・文長 μ) を標準化した 74 作品について、3 本の軸が説明する分散の割合、すなわち寄与率は、順に 65.6%、31.5%、2.8% である。第 3 主成分の矢印は、第 1 主成分の 5 分の 1 ほどの長さである (分散の比 2.8/65.6 の平方根が、およそ 1/5 になる)。この向きの情報を捨てても、失われるのは 2.8% だけである。残りの 97.2% は、はじめの 2 本が張る平面に乗っている。




図 6.4 PCA が見つけた 3 本の軸 (赤の矢印)。矢印の長さは、その向きの標準偏差に比例させてある。第 1 主成分の向きにいちばん広く散らばっており、第 3 主成分の向きはその 5 分の 1 ほどしかない。

6.2.3 実際に 3 次元から 2 次元へ

図 6.5 の左が 3 次元の配置 (斜めから平面に写したもの)、右が第 1・第 2 主成分の平面に射影した結果である。




図 6.5 3 次元から 2 次元へ。第 3 主成分の寄与率は 2.8% なので、捨てて失われる分散は全体の 2.8% である。

3 つの主成分の寄与率は、順に 65.6%、31.5%、2.8% であった。第 3 主成分を捨てて失われるのは、全分散のうちの 2.8% である。ただし、失われるのは**分散**であって、課題に必要な情報の割合ではない。分散の小さい方向に著者を見分ける手がかりが隠れていることもあるので、著者の手がかりが残っているかは、近傍の変化や分類の成績で別に確かめる (付録 A の教材で、第 3 主成分を軸に加えたときの近傍の変化を見られる)。

第 3 主成分が余る理由は、第 3 章で作ったデータの性質にある。平仮名・片仮名・漢字の比率は合計が 1 になるよう正規化してあった。片仮名の比率は小さいので、平仮名と漢字はほぼ $r_{\text{漢字}} \approx 1 - r_{\text{平仮名}}$ という直線関係にある。

つまりこの3次元データは、もともとほぼ平面上に乗っていた。PCAはそれを見つけ出した。

補足 次元を落としても情報が残る理由 — 多様体仮説

高次元のデータが、実はもっと低い次元の構造の上に乗っていることは多い。これを**多様体仮説** (manifold hypothesis) という。ここでいう**多様体**は、「局所的に見れば平らな面と同じように扱える図形」くらいに読んでおけばよい。地球の表面は球だが、足元の数メートルだけを見れば平面と変わらない。

たとえば手書き数字の画像は $28 \times 28 = 784$ 次元だが、「どの数字か」「傾き」「太さ」「大きさ」といった数十個の要素でほぼ説明できる。784次元の空間の中で、実際のデータはずっと低い次元の面のような領域の上になにしか存在しない。

いま扱った平仮名・漢字・文長 μ の3列は、ほぼ平面に乗っていた。第3章の字種3列 (平仮名・片仮名・漢字) は別の例で、こちらは合計が1という制約があるので、点は**厳密に**平面の上になにしか乗らない。このように、データが住んでいる面そのものの次元は、それを取り囲む空間の次元と別の量である (後の節で内在次元として定式化する)。両者がずれているとき、次元削減には意味がある。

ここまでの例では面が平らだったので、PCAのような線形の手法で足りた。面が**曲がっている**とどうなるかは、第6.5.2項のスイスロールで扱う。そこが線形と非線形の分かれ目になる。

6.2.4 数式で書く*

m 個のデータ、 n 次元とする。センタリング済みのデータ行列を $A \in \mathbb{R}^{m \times n}$ と書く (各行が1つのデータ)。

主成分 v ($\|v\| = 1$) の方向にデータを射影した値は Av である。その標本分散は

$$\text{Var}(Av) = \frac{1}{m} \|Av\|^2 = \frac{1}{m} v^\top A^\top A v = v^\top \Sigma v \quad (6.1)$$

ここで $\Sigma = \frac{1}{m} A^\top A$ は**分散共分散行列** (covariance matrix) である。

第1主成分を求める問題は、次の制約付き最大化になる。

$$\max_v v^\top \Sigma v \quad \text{subject to} \quad \|v\|^2 = 1 \quad (6.2)$$

発展 第1主成分をラグランジュ未定乗数法で求める

制約 $\|v\|^2 = 1$ のもとで $v^\top \Sigma v$ を最大化する。ラグランジュ関数は

$$L(v, \lambda) = v^\top \Sigma v - \lambda(v^\top v - 1) \quad (6.3)$$

v で微分してゼロと置く。

$$\frac{\partial L}{\partial v} = 2\Sigma v - 2\lambda v = 0 \implies \Sigma v = \lambda v \quad (6.4)$$

式 (6.4) は**固有値問題**そのものである。つまり主成分は分散共分散行列の固有ベクトルであり、そのときの分散は

$$v^\top \Sigma v = v^\top (\lambda v) = \lambda \|v\|^2 = \lambda \quad (6.5)$$

すなわち**固有値そのものが、その方向の分散**になる。

発展 (続き)

微分してゼロと置いた式は、最大の点だけでなく、すべての固有ベクトルで成り立つ。どの固有ベクトルでも $v^T \Sigma v$ はその固有値に等しいので、いちばん大きな値を与えるのは、最大の固有値の固有ベクトルである。これが PC1 になる。PC2 は「PC1 と直交する」という制約を加えて同じ最大化を解いたもので、答えは 2 番目に大きい固有値の固有ベクトルになる。本文の「PC1 が点になる位置から眺める」は、この直交の制約を言葉にしたものである。

Σ は対称かつ半正定値なので、固有値はすべて実数で非負であり、固有ベクトルは互いに直交するように取れる。固有値の大きい順に並べれば、それが PC1, PC2, ... である。

発展 $A^T A$ と AA^T —— 列の類似度と行の類似度

分散共分散行列 $\Sigma = \frac{1}{m} A^T A$ の中身をよく見ると、 (j, k) 成分は「列 j と列 k の内積を m で割ったもの」である。列は特徴なので、 $A^T A$ は**特徴どうしの類似度**の表にほかならない (列を z 化してあれば相関行列そのものになる)。

行列の順序を入れ替えた AA^T のほうも見ておく。 (i, ℓ) 成分は行 i と行 ℓ の内積で、行は作品なので、こちらは**作品どうしの類似度**の表である (**グラム行列** (Gram matrix) と呼ぶ。行を z 化してあれば、第 4.8 節の相関距離の世界とつながる)。

同じ行列 A を、列の側から見るか行の側から見るかの違いでしかない。実際、両者は固有値を共有する。 $A^T A v = \lambda v$ の両辺に左から A を掛けると

$$(AA^T)(Av) = \lambda(Av) \quad (6.6)$$

となり、 $\lambda \neq 0$ なら $u = Av$ がそのまま AA^T の固有ベクトルになる (逆向きも同様。サイズが違う分だけ、余った固有値は 0 が埋める)。

対応から、使える手が 3 つ出てくる。

- **小さいほうを解けばよい。** m 作品 $\times n$ 特徴で n が巨大なとき (遺伝子データの検体 $300 \times$ 遺伝子 2 万など)、 $n \times n$ の $A^T A$ ではなく $m \times m$ の AA^T を固有分解すれば足りる。顔画像認識の固有顔 (eigenface) で有名になった計算法である。
- **座標がなくても主成分が出る。** AA^T は内積の表なので、点どうしの距離の表から逆算できる。距離だけから PCA と同じ配置を復元する流儀が**古典的 MDS**であり、第 6.4 節で扱う MDS の原点にあたる。
- **行と列を同じ図に置ける。** 2 つの固有分解は $u = Av$ で結ばれているので、作品の座標と特徴の座標が同じ軸の上で対応する。第 6.3 節のバイプロットが 1 枚の図に点と矢印を同居させられるのも、同じ対応による。

6.2.5 もう一つの見方 —— 射影誤差の最小化

PCA には等価な別の定式化がある。

主成分 v の方向にデータを正射影したとき、もとの点と射影点の間の距離の 2 乗和が最小になる。

図 6.1(4) の点線が、その「誤差」にあたる。

2 つの定式化が一致するのは、三平方の定理による。点 x について、 $\|x\|^2$ は「射影の長さの 2 乗」と「誤差の長さの 2 乗」の和に分解される (図 6.6)。




図 6.6 射影誤差と射影の長さは、 $\|x\|$ を斜辺とする直角三角形の 2 辺になる。斜辺の長さは v の向きによらないので、一方を長くすることと他方を短くすることは同じである。


$$\underbrace{\|x\|^2}_{\text{一定}} = \underbrace{(v^T x)^2}_{\text{射影の長さの 2 乗}} + \underbrace{\|x - (v^T x)v\|^2}_{\text{射影誤差}} \quad (6.7)$$

全点で足すと、左辺はデータで決まる定数になる。右辺の第 1 項の和を m で割ったものが射影の分散である。だから、右辺の第 1 項を最大にすることと第 2 項を最小にすることは同じである。


補足 PCA と最小二乗回帰の違い

「誤差を最小にする直線」と聞くと最小二乗法を思い浮かべるかもしれないが、測っている誤差が違う。最小二乗回帰は y 方向のずれを測る。 x は誤差なしと仮定している。PCA は直線への垂直方向のずれを測る。どの変数も対等に扱う。

だから同じデータでも、回帰直線と第 1 主成分は一致しない。同じ 14 点に 2 本の直線を引いてみる。



(a) 縦のずれを最小にする



(b) 垂直のずれを最小にする

細い線が、それぞれ何を最小にしているのかを示している。薄い破線はもう一方の直線で、傾きが違うことが見て取れる。(b) の垂直なずれは x と y を入れ替えても変わらない。だから PC1 は変数の役割を入れ替えても同じ直線になるが、回帰直線は x で y を説明するか y で x を説明するかで別の直線になる。2 つの変数の散らばりが同じ大きさなら (この 14 点はそうになっている)、PC1 の傾きは 1 のままで、相関が弱いほど回帰直線は水平に寝ていき、PC1 との開きは大きくなる。

コラム 1901 年の「最もよく当てはまる平面」と 1933 年の「主成分」

PCA の原型は、Karl Pearson が 1901 年に書いた論文 “On lines and planes of closest fit to systems of points in space” にある [59]。題のとおり、空間に散らばった点に最もよく当てはまる直線や平面を求める論文で、「よく当てはまる」を、点から直線・平面へ下ろした垂線の長さの 2 乗和で測った。本章の射影誤差の定式化そのものである。ただし Pearson の数値例は 2 変数・10 点に直線を当てはめる小さなもので、多くの変数を扱う計算の手順はまだ示されていなかった。

「主成分」という名前は、Harold Hotelling が 1933 年に *Journal of Educational Psychology* に発表した論文による [60]。心理学や教育のテストでは、1 人の受験者について多くの得点が並ぶ。Hotelling はそれを少数の成分にまとめる目的で、分散の大きい順に成分を 1 つずつ取り出す反復の計算法を示した。本章の分散の最大化の定式化は、こちらの系譜にあたる。

同じ手法は、その後も分野ごとに別々に使われ、別の名前では呼ばれてきた。信号処理ではカルーネン・レーベ変換、気象学では経験直交関数と呼ばれる。本章で見た 2 つの定式化 (射影誤差の最小化と分散の最大化) は、歴史の上でも別々の入口から見つかったものである。

6.2.6 寄与率 — 52 列では 2 軸で 3 割ほどしか説明できない

第 k 主成分の寄与率 (explained variance ratio) は

$$\frac{\lambda_k}{\sum_{j=1}^n \lambda_j} \quad (6.8)$$

で定義される。その軸がデータ全体の分散のうち何割を説明しているかを表す。

52 次元すべてを使ったときの寄与率を図 6.7 に示す。




図 6.7 52 列を標準化した 74 作品の寄与率 (スクリープロット)。上位 20 軸のみを示す。累積寄与率は 2 軸で 34%、8 割を超えるのは 12 軸目である。

3 列だけのときは、第 2 主成分までの累積寄与率が 97% だった。52 列を列ごとに標準化した場合の累積寄与率は 2 軸で 34% にしかならず、8 割を超えるのは 12 軸目、9 割を超えるのは 18 軸目である。つまり情報が特定の少数の方向に集中していない。

読点前の平仮名 47 文字は、互いにあまり相関していない。それぞれが独立した情報を持っているとも言えるし、低次元にまとめにくいとも言える。

6.2.7 2 次元の散布図

それでも 2 次元に落として眺めてみる。




図 6.8 52 次元を PCA で 2 次元にした結果。

著者ごとにある程度まとまって見える。吉川英治の作品は右寄りに並び、なかでも『三国志』の各巻は右上に小さく固まっている。右下の小さな塊は柳田国男の 5 作品である。

だが軸のラベルを見てほしい。第 1 主成分と第 2 主成分の寄与率を合わせても、52 列全体の分散の 34.0% しか説明していない。

図の上の距離がどれだけ当てになるかは、全 2701 組について 52 次元の距離と図の上の距離を並べれば確かめられる (図 6.9(a)。このような散布図をシェパード図と呼ぶ)。点が右上がりの細い帯に乗っていれば、図の上の距離から元の距離が読める。実際の帯は太い。図の上でほぼ同じ距離の組どうしても、52 次元の距離は大きくばらつく。たとえば太宰治『お伽草紙』と谷崎潤一郎『盲目物語』は、図 6.8 の上では 1.07 しか離れていないが、52 次元では 13.64 離れている。全組の 90% はこの 2 作品より近い (52 次元の距離の中央値は 9.53)。2 つの距離の順位相関は 0.687 である。点がすべて対角線より下にあるのは、PCA が直交射影で、射影すると距離は縮むことはあっても伸びることはないためである。

× アンチパターン 6.1 — 寄与率を見ずに 2 次元の図で「近い」と判断する —

図 6.8 で重なって見える 2 作品が、52 次元空間では遠く離れていることは十分あり得る。逆もある。

散布図を出したら必ず寄与率を確認する。寄与率が高いほど図の上の距離は当てになるが、それは全体の平均としての話で、個々の 2 点についての保証ではない。図 6.8 のように累積寄与率が 34% なら、図はヒントであって証拠ではない。




図 6.9 シェパード図。74 作品の全 2701 組について、横軸に 52 次元 (標準化) での距離、縦軸に 2 次元の図の上での距離をとった。2 次元の配置は図 6.26 と同じもので、括弧内は 2 つの距離の順位相関。(a) の破線は 2 つの距離が等しい線、赤い点は本文で挙げた 1 組。縦軸の目盛りは手法ごとに単位が違う。

補足 寄与率が低くても図を描く意味はある

では図 6.8 は無意味かという、そうではない。


「吉川英治の『三国志』の各巻が 1 か所に固まっている」という観察は、図 6.8 から得られた。これは第 7 章と第 9 章で重要になる手がかりである。可視化は仮説を思いつくために使い、結論を出すためには使わない。

補足 色で量を表すときは明るさが順に変わる配色を選ぶ

本書では読点のヒートマップ (第 3.6 節) のように、色の濃さで量を表す図をいくつか使っている。配色の選び方には、意外なほど落とし穴がある。

長らく既定だったのが **レインボー (jet)** と呼ばれる、青から緑・黄を経て赤へ向かう配色である。下に、レインボーと **viridis** を並べ、それぞれのすぐ下に **同じ配色を白黒に変換したもの** を置いた。

補足（続き）



上段のレインボーは、白黒にすると真ん中がいちばん明るく、両端が暗い。左から右へ増える量を表していたはずなのに、明るさだけを見れば左端と右端がほとんど同じになってしまっている。このため、白黒印刷では大小の区別がつかなくなる。

色のままでも問題が残る。緑から黄への変り目だけ明るさが急に変わるので、データには何もない値域に縞や境界が見えてしまう。気象や医用画像でこの配色を使うと、その値域にだけ偽の構造が現れることが知られている。

下段の viridis は、白黒にしても左から右へ一様に明るくなる。明るさの折れ線を重ねると、レインボーが山型なのに対し、viridis は単調に上がっている。

対処は簡単で、**明るさが端から端まで単調に変わる配色**を選べばよい。matplotlib は 2015 年に viridis(紫から黄へ)を導入し、バージョン 2.0(2017 年)で既定にした。正負の両方向に意味があるデータには、中央が白で両端に向かって濃くなる発散型の配色を使う。本書のヒートマップも、単色の濃淡で描いてある。

明るさが単調な配色を選ぶことは、**色覚多様性**への配慮でもある。日本人男性のおよそ 5%、女性のおよそ 0.2% は赤と緑の区別が付きにくい型の色覚を持つ [78]。レインボーの赤と緑は、この読者には近い色に見える。一方、明るさで順序がつく配色なら、色の見え方によらず大小が読み取れる。赤と緑で「良い・悪い」を描き分けるのも同じ理由で避け、色に加えて位置・形・濃淡のいずれかで区別をつける。

6.3 バイプロット — 点と変数を同時に描く

PCA には、本章の後半で扱う非線形の手法にはない利点がある。**軸の意味を解釈できる**ことである。

第 1 主成分は、もとの変数の線形結合で書ける。

$$\text{PC1} = w_1x_1 + w_2x_2 + \cdots + w_nx_n \quad (6.9)$$

係数 w_j (固有ベクトルの成分)の絶対値が大きい変数ほど、その軸への寄与が大きい。矢印を描くときは、 w_j をそのまま使う流儀と、軸の標準偏差 $\sqrt{\lambda}$ を掛けた**負荷量**を使う流儀がある。本書は後者を使う。標準化したデータでは負荷量がその変数と主成分の相関に一致し、表示のために掛けた定数を除けば、矢印の長さや角度を統計量として読めるからである。この矢印を点の上に重ね描きしたものが**バイプロット**である。

矢印の読み方は次のとおりである。




図 6.10 バイプロット。赤い矢印は変数（読点前の平仮名）の負荷量を表す。破線の円は、負荷量が1(変数と主成分の相関が1)にあたる長さである。円に近い矢印ほど、その変数はこの2軸の平面によく乗っている。縦と横の目盛りの幅はそろえてあり、矢印どうしの角度は図の上の角度のまま読める。

- **長さ** — その変数が、この2軸の平面にどれだけよく乗っているか。短い矢印は、この平面では表現しきれていない変数なので、向きを読んでも当てにならない
- **向き** — その変数が増える方向
- **矢印どうしの角度** — 変数間の相関（第4.8節）。同じ向きなら正の相関、逆向きなら負の相関、直交なら無相関。ただしこの読みは近似で、2軸によく乗っている（＝長い）矢印どうしでしか成り立たない
- **点と矢印の関係** — 矢印の方向にある点は、その変数の値が大きい

図 6.10 の矢印は、方角ごとに負荷の大きい変数を1本ずつ選んで描いた（すべて重ねると束になって読めないためである）。ここで見るのは、矢印どうしの**角度**である。「み」と「ら」はほぼ逆向き、つまり負の相関で、「み、」で区切る作家は「ら、」では区切らない傾向がある。「ば」と「げ」のように直交に近い組は、ほぼ無相関に使われる。

ただし角度から読めるのは相関の向きまでで、大きさまでは読めない。負荷量で描いた矢印では、2本の長さ（円の半径を1とした長さ）と角度の余弦を掛けた値、つまり矢印の内積が、相関のおよその値になる。「み」と「ら」は角度が 176° でほぼ真逆だが、実際の相関は -0.52 で、矢印の内積の -0.58 がそれに近い。「ば」と「げ」は 94.5° で、相関は -0.03 （内積は -0.04 ）である。読点の癖が1本の軸に沿って強弱するのではなく、互いに独立ないくつかの方向を持っていることが、矢印の開き方から読み取れる。

○ 定石 6.1 — 分かれた理由を説明したいときはバイプロットを使う —

「なぜこの2つのグループが分かれたのか」を説明したいときは、分かれた方向に伸びている矢印を見ればよい。どの変数が違いを作っているかが読み取れる。

t-SNE や UMAP ではこれができない。軸に意味がないからである。

補足 バイプロットの矢印は長さを何倍しても図の意味が変わらない

点と矢印は単位が違うので、そのまま重ねるとどちらかが極端に大きくなる。そこで矢印側に適当な定数を掛けて見やすくするのが慣習である。

矢印の絶対的な長さには意味がない。比較できるのは矢印どうしの相対的な長さと向きだけである。

6.4 多次元尺度構成法 (MDS)

PCA が「分散」を残すのに対し、MDS は「距離」を保とうとする。

m 個の点があり、その間の距離 D_{ij} が与えられているとする (PCA の節と同じく、点の数を m と書く)。低次元空間に配置 $z_1, \dots, z_m$ を作り、そこでの距離 $\|z_i - z_j\|$ が D_{ij} に近くなるようにする。

最小化する量は**ストレス関数**である。

$$\text{Stress} = \sqrt{\frac{\sum_{i < j} (D_{ij} - \|z_i - z_j\|)^2}{\sum_{i < j} D_{ij}^2}} \quad (6.10)$$

分子は「もとの距離と配置での距離のずれ」を全ペアについて足したものである。分母で割るのは、**全体の大きさの影響を消す**ためである。距離をすべて2倍したデータを渡せば、最適な配置も2倍に伸びるので、分子と分母がともに4倍になり、値は変わらない。そのおかげで、単位の違うデータどうしてもストレスの値を比べられる。

解き方は反復である。点をとりあえずでたらめな位置に置き、すべての点をストレスが下がる位置へ一斉に移す。これを全体が落ち着くまで繰り返す^{*1}。

補足 距離だけあれば配置が作れる

MDS では、**もとの座標が分からなくてもよい**。点どうしの距離さえあれば配置を復元できる。

たとえば都市間の距離表だけから地図を復元できる。札幌・東京・大阪・福岡の4都市のあいだの直線距離は6つある(札幌と東京が832km、東京と大阪が396km、大阪と福岡が485kmなど)。これだけから4都市の相対的な位置が決まる(図6.11)。ただし決まるのは形だけで、どちらが北か、東西が裏返っていないかは、距離の表からは分からない。どの向きに回しても裏返しても、距離は変わらないからである。なお東京・大阪・福岡の3都市だけでは、東京と大阪(396km)と大阪と福岡(485km)を足すと東京と福岡(881km)にほぼ等しく、3点はほぼ一直線に並ぶ。平面の地図にするには、列から外れた札幌が要る。

DNA 配列の類似度、アンケートの回答の似ている度合いなど、座標がそもそも存在しないデータにも

^{*1} 代表的な手順に SMACOF がある。名前は Scaling by MAjorizing a COmplicated Function の略で、扱いにくい関数を、それより上にある扱いやすい関数で押さえながら最小化していく方法を指す。

補足 (続き)

使える。

距離がユークリッド距離なら、反復に頼らず一度の固有値計算で配置が求まる (古典的 MDS)。距離の表を内積の表に直すと、第 6.2.4 項の発展で見た AA^T の固有分解に帰着するからである (図 6.11(a))。




図 6.11 4 都市の直線距離だけから作った配置。(b) は古典的 MDS が返した座標そのまま、北がどちらかは決まっていない。(c) は (b) を回転させるだけで、実際の位置 (灰色の丸。上が北、単位は km) に重ねたもの。ずれはいちばん大きい都市でも 17km である。

MDS は PCA と違って、三角不等式を満たさない「距離」も埋め込むことができる。ストレスを小さくするだけの手続きなので、**距離の公理を一度も使っていない**からである。公理を破った表を渡しても、手続きは止まらずに配置を返す。ひずみは大きくなるが、とにかく絵は出てくる。




図 6.12 三角不等式が破れている例。ユークリッド空間には正確には埋め込めない。

コラム 14 色の「似ている度合い」から色相環が現れた

1954 年、心理学者の Gösta Ekman は、被験者に 14 のスペクトル色 (虹の光を細く切り出した単色光) を 2 つずつ見せ、どれくらい似ているかを答えさせた。得られたのは色どうしの「似ている度合い」の表だけで、色に座標はついていない。

コラム (続き)

Roger Shepard は 1962 年、距離の値そのものではなく、その**大小の順序**だけを保つように点を置く MDS を発表した [61]。本章のストレス関数が距離の値のずれを測るのに対し、こちらは「A と B のほうが C と D より似ている」という順序が配置の上でも守られるかだけを見る。Shepard がこの方法を早くからかけた実データの 1 つが、Ekman の色の表である [62]。

2 次元に置いた 14 色は、波長の順に円を描いて並んだ。Newton が光の色を円周上に並べた色相環に近い形である。スペクトルの両端にある紫と赤が円の上で近づくことも、似ている度合いの表だけから出てきた。Ekman 自身は同じ表を因子分析で 5 次元にまとめていたが、Shepard の 2 次元の配置のほうが少ない次元で同じ表を説明できた。座標のない表から地図を作るといふ、本節の側注の考え方の早い実例である。

6.5 非線形の次元削減 — 近傍のつながりを保つ

PCA は**線形**の手法である。データが曲がった面の上に乗っていると、面に沿った距離を直線距離と取り違える。




図 6.13 線形手法 (a) と非線形手法 (b)。後者は曲がった構造をほどく。

UMAP (Uniform Manifold Approximation and Projection, 2018)[53] と **t-SNE** (t-distributed stochastic neighbor embedding, 2008)[52] は、非線形の次元削減として広く使われている。

本章で扱う手法を、何を保とうとするかと、線形かどうかで並べると図 6.14 のようになる。章の後半では、中央の 3 列 (面に沿った距離、近所での混ぜ方、近傍のつながり) に入る手法を順に見る。

6.5.1 UMAP の考え方

原論文の理論的な裏づけは圏論とリーマン幾何に頼っているが [53]、実際にやっていることは 3 段階に分けられる。

1. **近傍グラフを作る**。各点について最も近い k 個 ($n_neighbors$) を探し、辺を張る。辺の重みは距離が近いほど大きい
2. **重みを確率に直す**。各点から見た「つながりの強さ」を $\exp(-(d - \rho)/\sigma)$ の形で表す。 ρ はその点から最も近い点までの距離、 σ は点ごとに決める物差しである。ここでいう「確率」は辺ごとに 0 から 1 のあいだの値で、全体を足して 1 になるようにはそろえない
3. **低次元で同じつながりを再現する**。低次元での距離も、別に決めた関数で 0 から 1 のあいだの値




図 6.14 本章の次元削減法を、何を保とうとするか (列) と、線形かどうか (行) で並べたもの。線形の手法は、もとの変数の線形結合を座標にするので、軸の意味を読める。線形のオートエンコーダが PCA と同じ平面を学ぶことは本章の末尾で扱う。




図 6.15 UMAP の手順。距離ではなく「つながり」を保とうとする。

に直し、高次元での値にできるだけ近づくよう点を動かす

手順 2 の ρ と σ の役割を補っておく。 ρ を引くと、どの点でも最も近い相手とのつながりの強さがちょうど 1 になり、どの点も少なくとも 1 本は太い辺を持つ。 σ は、 k 個の近傍へのつながりの強さの合計が $\log_2 k$ になるように、点ごとに決める [53]。点が密集した場所では近傍までの距離が短いので σ が小さく、まばらな場所では大きくなる。この割り算で密集しているかどうかの違いがならされ、どの点も同じだけの近所を持っているかのように扱えるようになる。

手順 3 で最小化する量は次の形をしている。

$$\mathcal{L} = \sum_{(i,j)} \left[p_{ij} \log \frac{p_{ij}}{q_{ij}} + (1 - p_{ij}) \log \frac{1 - p_{ij}}{1 - q_{ij}} \right] \quad (6.11)$$

p_{ij} が高次元でのつながりの強さ、 q_{ij} が低次元でのそれである。2 つの確率のずれを測る量で、**交差エントロピー**と呼ばれる。

第 1 項が「高次元でつながっていた点は低次元でも近づける」引力、第 2 項が「つながっていない点は離す」斥力にあたる。

補足 UMAP と t-SNE は何が違うのか

t-SNE が最小化するの**は KL ダイバージェンス** $\sum p_{ij} \log(p_{ij}/q_{ij})$ である (これも 2 つの確率分布のずれを測る量で、交差エントロピーと近い親戚にあたる)。

違いは、UMAP の式にある第 2 項の有無である。t-SNE にも点を離す働きはあるが、確率を全体で 1 に正規化することを通じた間接的なものとどまる。UMAP は「つながっていない点を離す」項を明示的に持つので、クラスタどうしがより大きく離れた図になりやすい。

第 6.5.7 項で見る「大域構造の保存」の指標での UMAP と t-SNE の違いにも、この差が絡みうる。ただし、大域構造の差の大半は初期値の置き方だけで説明できるという報告もある (第 6.5.6 項の末尾で紹

補足 (続き)

介する)。また、UMAP は離す相手を全部ではなく一部だけ選ぶ工夫 (負例サンプリング) で t-SNE より計算が速い。

6.5.2 スイスロール — 曲がった面をほどく

非線形手法の威力を見るのに、**スイスロール**という人工データがよく使われる。2次元の長方形を、渦巻き状に巻いて3次元に埋め込んだものである。




図 6.16 スイスロール。色は巻きに沿った位置。(b) の2次元の面を巻いて、3次元空間に埋め込んだものである。

(a) は3次元の複雑な形に見えるし、実際、点の座標を書き下すには3つの数が要る。だが形そのものは、(b) の長方形を巻いて3次元空間に配置したものである。つまりこのデータは、**本質的には2次元の面が3次元空間に埋め込まれた状態**にある。埋め込み先の空間の次元 (3) と、データが実際に住んでいる面の次元 (2) は別の量である。面の上の住所は「巻きに沿ってどれだけ進んだか」と「奥行き」の2つで書ける。2という数を**内在次元** (intrinsic dimension) と呼ぶ。

これが第 6.2.3 項で触れた**多様体仮説**の状況である。字種の3列と違うのは、面が**曲がっている**ことである。平らな面なら線形の射影で開けるが、巻かれた面を平らに戻すには、面に沿った距離を測り直す必要がある。

問題は、**渦巻きの内側と外側**である。3次元空間では近いが、面に沿って歩けば遠い。逆に、面に沿って隣どうしの点は、必ず3次元でも近い。

ここで保ちたいのは、**面に沿った近さ**のほうである。

6枚を見比べると、次のことが分かる。

- **PCA** — 巻きを横から押し潰したような形になる。色が重なり、内側と外側が混ざっている。線形変換では巻きをほどけない。標準化した3列の寄与率はほぼ等しく (第 6.5.3 項の超立方体と似た状況)、どの平面を選んでも巻きはほどけない
- **MDS** — PCA と似た結果。3次元での直線距離を保とうとするので、渦巻きの内外を「近い」と判断してしまう
- **t-SNE** — 色ごとにまとまって並ぶ。局所的な近さを保つので、面に沿った構造が現れる。ただ




図 6.17 スイスロールを 6 つの手法で 2 次元に。色が図 6.16(b) のように帯状に並べば成功である。1500 点の 3 列を標準化してから写した。t-SNE は `perplexity=30`、`init="pca"`。UMAP は `n_neighbors=12`、`min_dist=0.1`。Isomap と LLE は近傍数 10。乱数の種はすべて 0。

しこの設定では帯がいくつか切れている

- **UMAP** — 同じく色の順に並ぶが、この設定では帯がいくつかの断片に切れている
- **Isomap** — 巻きがほどけて長方形に戻り、色が左から右へ順に並ぶ。6 つのうち、図 6.16(b) にいちばん近い
- **LLE** — 色の順は保たれるが、奥行きの向きが潰れて折れ線のような形になる

補足 測地距離という考え方

スィスローを正しくほどく古典的な手法に **Isomap** がある。考え方は明快で、**直線距離の代わりに面に沿った距離を使う**。

近傍グラフを作り、その上の最短経路長を「距離」として MDS にかける (図 6.17 の Isomap)。これを**測地距離**という。地球上の 2 都市の距離を、地中を貫く直線ではなく地表に沿って測るのと同じ発想である。

UMAP も近傍グラフを作る点で共通している。「近くのつながりだけを信じ、遠くは推測する」というのが、近傍グラフに基づく非線形手法 (Isomap・LLE・t-SNE・UMAP) に共通する戦略である。

6.5.3 超立方体 — 次元を上げながら眺める

もう一つ、次元そのものの効果を見る例を挙げる。

d 次元の**超立方体**の頂点をすべて取る。座標が 0 か 1 の点なので、 2^d 個ある。辺は「1 ビットだけ違う頂点对」を結んだもので、 $d \cdot 2^{d-1}$ 本になる。

$d = 2$ なら正方形、 $d = 3$ なら立方体。ここまでは絵に描ける。 $d = 4$ 以上は描けないので、次元削減して 2 次元で眺めるしかない。

この図形をわざわざ持ち出すのには理由がある。実際のデータでは、**もとの空間でどうつながっていたかが分からない**。分からないから次元削減して眺めるのであって、出てきた絵が正しいかどうかを確かめる相手がいない。

超立方体では、この確かめる相手が最初から手元にある。どの頂点とどの頂点が隣り合っているかは定義から決まっており、高次元でありながら、そのつながり方を人が完全に把握できる。だから**答えを知ったうえで手法を試せる**。出てきた絵ともとの形を突き合わせれば、その手法が何を保ち、何を作り変えたのかが分かる。本節で超立方体を使うのは、手法の性質を測るための**物差し**としてである。

ここで大事なのは、**頂点だけでなく辺の上にも点を打つ**ことである。頂点だけを写しても、どの頂点とどの頂点が隣り合っていたかは失われる。辺を細かく分けた点列として一緒に写せば、低次元でも**辺がつながった線**として残るかどうかが目に見える。

色には各点のハミング重み (座標の和、つまり 1 が立っているビット数) を使う。超立方体は重みでレベル分けされるので、これが構造の目印になる。

まず PCA で試すと、意外なことが起きる。

$d = 3$ と $d = 5$ では、 2^d 個の頂点が**正方形の 4 隅**に潰れてしまった。 $d = 8$ だけは違う平面に写っているが、どの向きに情報が残ったかを読み取ることはできない。

向きが読み取れないのは、超立方体の頂点が各座標 0 か 1 の点で、**どの軸の分散も等しい**からである。PCA は分散が最大の方を選ぶが、どの方向も同じなので、**選ぶべき方向が決まらない**。 $d = 3$ と $d = 5$ では座標軸そのものが選ばれ、 $d = 8$ では別の 2 方向が選ばれた。実装が返す平面が違うだけで、どれも同じ資格を持つ。いずれにせよ、残りの $d - 2$ 次元の情報はそのまま捨てられる。




図 6.18 超立方体を PCA で 2 次元に。辺も点列として一緒に写している。色は「1 の個数」(ハミング重み)。 $d = 3$ と $d = 5$ は正方形に潰れ、 $d = 8$ は別の平面に写っている。どちらも PCA の出力として正しい。

補足 PCA に向かないデータ

PCA は「分散に偏りがある」ことを前提にしている。すべての方向が対等なデータでは、選ぶべき方向が存在しない。

第 6.2.4 項の式 (6.4) を思い出そう。分散共分散行列の固有値がすべて等しいとき、固有ベクトルは一意に決まらない。超立方体がちょうどその状況にあたる。

距離を保とうとする MDS なら、様子が変わる。

$d = 2$ は正方形、 $d = 3$ は立方体を斜めから見た形になる。ここまでは直感どおりである。

$d = 4$ で少し怪しくなり、 $d = 6$ 、 $d = 8$ では何が描いてあるのか分からない。頂点が円周上に均等に並び、辺が中を埋め尽くしている。

これは投影の失敗ではない。高次元の超立方体は、2 次元にはどうしても収まらない。 $d = 8$ なら 256 頂点と 1024 本の辺を、平面の上で交差させずに配置することはできない。

表 6.1 超立方体の頂点間距離

d	頂点数	辺の数	平均距離	変動係数	$(d_{\max} - d_{\min})/d_{\min}$
2	4	4	1.138	0.172	0.414
3	8	12	1.282	0.207	0.732
4	16	32	1.428	0.216	1.000
5	32	80	1.571	0.214	1.236
6	64	192	1.710	0.206	1.449
8	256	1024	1.970	0.186	1.828

表 6.1 を見ると、頂点間距離の平均はおよそ $\sqrt{d/2}$ で増える。変動係数 (標準偏差を平均で割った、ばらつきの相対的な大きさ) は $d = 4$ の 0.216 を境に、 $d = 5$ で 0.214、 $d = 6$ で 0.206 と減り始めている。距離の大半が平均のまわりに寄ってくるという意味で、第 4 章で見た距離の集中 (付録 B で




図 6.19 超立方体を MDS で 2 次元に。線が 1 本の辺にあたる。色はハミング重み (濃紺=0 に近い、黄土= d に近い)。次元が上がるほど辺が絡まり合って構造が読めなくなる。

詳しく扱う)が始まっている。一方、最右列の $(d_{\max} - d_{\min})/d_{\min}$ は $\sqrt{d} - 1$ に等しく、次元とともに大きくなる。隣り合う頂点の距離はいつも 1、正反対の頂点の距離は $\sqrt{d}$ だからである。第 4 章の乱数で打った点と違い、格子の上の点では、最小と最大の 2 つの値だけを見ても集中は分からない。

6.5.4 手法を変えると見え方が変わる

同じ $d = 6$ の超立方体を、4 つの方法で描いてみる。

PCA は辺をすべて直線のまま写す。ただしどの平面に写るかは決まらない。先ほど述べたとおり 6 つの固有値がすべて等しいので、2 本の軸の選び方は無数にあり、実装が返した平面がたまたまこれである。どの平面が返っても、直線が直線に写ることだけは変わらない。

MDS は対称性を保ち、円形に近い配置になる。すべての頂点が対等なので、MDS の振る舞いが正しい。

t-SNE と UMAP は、辺のつながりは残すものの、どの辺がどの辺の隣にあるかを作り替えてしまう。6 次元では対等だった 64 個の頂点が、平面上では数個ずつの小さな塊に分かれ、塊と塊のあいだに隙間ができる (t-SNE で特にはっきりしている)。この塊を見て「ここにクラスタがある」と読むことはできない。超立方体の頂点に密度の差など存在しない。すべて対等である。




図 6.20 6次元超立方体 (64 頂点、192 辺) を 4 つの方法で。黒い丸が頂点、色のついた丸が辺の途中に等間隔で取った点 (1 本の辺につき 11 個) である。色はもとの辺の上での位置を表す。頂点のとなりが濃紺で、辺の中央へ向かうほど黄土に近づく (図 6.18・図 6.19 のハミング重みとは色の意味が違う)。線の濃さは点の間隔で、まばらな区間ほど薄い。t-SNE は `perplexity=24`、`init="pca"`。UMAP は `n_neighbors=60`、`min_dist=0.3`。乱数の種はすべて 0。t-SNE では辺の中央の色をした点が頂点に貼りついており、辺が潰れたことが色で分かる。

6.5.5 辺がまっすぐに見えるのは、点が両端に潰れているから

この図からは、辺の形についてもう一つのことが読み取れる。6次元での辺はまっすぐな線分であり、その上に 13 個の点を等間隔に並べてある。それが写った先で曲がっていれば、その手法は直線を直線のまま写していない、つまり非線形だということになる。

曲がり具合は、折れ線の長さを両端を結ぶ直線の長さで割った値で測れる。以下ではこれを「曲がり」と呼ぶ。1.00 なら直線のまま、大きいほど曲がっている。192 本の辺すべてについて曲がりを測った中央値は、PCA が 1.00、MDS が 1.15、t-SNE が 1.02、UMAP が 1.08 である。

素直に読めば「t-SNE はほとんど曲げていない」となる。だがこれは読み違いである。

図 6.21 に、13 個の点が辺のどこに来たかを 1 本の帯で描いた。PCA の縦線は等間隔のままであ

表 6.2 6 次元超立方体の辺 192 本が、写った先でどう並んだか (中央値)。最長区間の割合は、1 本の辺の長さのうち、隣り合う 2 点のあいだのいちばん長い区間が占める割合

手法	曲がり	最長区間の割合	端 4 区間の割合
PCA	1.00	0.08	0.33
MDS	1.15	0.15	0.39
t-SNE	1.02	0.78	0.07
UMAP	1.08	0.23	0.14
等間隔なら	1.00	0.08	0.33




図 6.21 1 本の辺を長さ 1 に伸ばし、13 個の点が来た位置に縦線を引いたもの (192 本の辺の中央値)。両端の太い黒線が頂点。もとは等間隔なので、素直に写っていれば縦線も等間隔に並ぶ。t-SNE では 11 本が両端に張りついて、真ん中が大きく空いている

る。t-SNE では 11 本が両端に貼りつき、帯の真ん中は縦線が 1 本もない空白になっている。

表 6.2 の 2 列目「最長区間の割合」は、これを数にしたものである。13 点が等間隔のまま写っていれば、1 区間は辺の長さの $1/12 = 0.08$ を占めるはずである。PCA の最長区間の割合は、192 本の辺の中央値でちょうど 0.08 である。

t-SNE は 0.78 で、等間隔の 0.08 を 0.70 上回る。1 本の辺の長さの 8 割近くを、たった 1 区間が占めている。残る 11 区間は合わせて 2 割しかない。つまり **13 点のほとんどが両端の頂点に吸い寄せられ、真ん中は一度の飛躍で結ばれている**。3 列目「端 4 区間の割合」も同じことを裏から言っている。両端から 2 区間ずつが辺に占める割合は、等間隔なら 0.33 のところ、t-SNE では 0.07 しかない。

だから「曲がりが 1.02」は、**直線が直線のまま写ったことを意味しない**。線分が 2 つの点と 1 本の渡り線に潰れた結果、測りようがなくなっているだけである。ここで図 6.20 を見直す。点の色は**もとの辺の上でその点がどこにいたか**を表している。頂点のとなりの点は濃紺、辺のいちばん中央の点は黄土である。

PCA と MDS では、1 本の辺をたどると濃紺から黄土へ変わってまた濃紺に戻る。色が辺に沿って並んでいるので、点も辺に沿って散っている。

t-SNE と UMAP では色の並び方が違う。**黄土の点が黒い頂点に貼りついて**いる。辺の中央にいるはずの点が、頂点と同じ場所にまで引き寄せられている。点の間隔が開いた区間の線を薄くしてある

ので、辺の中ほどは線も消え、格子ではなく**点の塊**に見えてくる。もしすべての区間を同じ濃さの線で描き、点を打たなければ、t-SNE の図はきれいに繋がった格子に見える。その見た目は、描き方が作り出したものである。

MDS は曲がり角が 1.15、最長区間の割合が 0.15 で、両方とも中くらいである。距離の食い違いを全体で減らそうとするので、点は辺に沿って残るが、線は素直に曲がる。UMAP の最長区間の割合は 0.23 で、等間隔の 0.08 は上回るものの、t-SNE の 0.78 ほど極端ではない。潰れの向きは t-SNE と同じである。

× アンチパターン 6.2 — t-SNE や UMAP が見せた図を、そのまま信じる

局所構造を保つ手法は、**近くの点をさらに近づける**。その結果、もとは連続していたものが**点の塊と隙間**に変わり、**構造がないところにも塊が生まれる**。

図 6.20 の t-SNE は、線だけ描けば「辺がまっすぐ保たれた美しい図」に見える。実際には辺の上の点の大半が頂点に潰れており、線はその隙間を結んだだけである。同じ図から「頂点がいくつかの集団に分かれている」と報告することもできない。実際には、頂点はすべて対等で、密度の差は存在しない。設定を変えれば、はっきり分かれた塊が現れることもある。

対策は次のとおりである。

1. **線ではなく点を描く**。塊と隙間はそれで見える
2. 隣り合う点の間隔を測る。等間隔だったものが等間隔で写っているか。1 つの要約値 (ここでは曲がり 1.02) だけでは「歪んでいない」とは判断できない
3. 複数の手法で描いて比べる (図 6.20 のように)
4. パラメータを変えて安定性を見る (第 6.5.6 項)
5. 見つけた塊が本物か、**もとの高次元空間で確かめる**

補足 「曲がっていないから線形だ」とは言えない

非線形な手法でも、辺の曲がりだけを見ると小さく出ることがある。上で見たとおり、点が潰れていれば曲がりようがないからである。UMAP を既定の `min_dist=0.1` で走らせると (`n_neighbors=60` のまま)、潰れがさらに進む。最長区間の割合は図 6.24 のとおり 0.6 前後まで上がり、曲がりの中央値は表 6.2 の `min_dist=0.3` での 1.08 より 1 に近づく。

この向きの推論だけが成り立つ。**曲がっていれば線形ではない**。曲がっていないことは、線形であることの証拠にならない。

6.5.6 パラメータを振ってみる

前項の測定は、t-SNE と UMAP をそれぞれ 1 つの設定で走らせた結果である。設定を変えれば絵は変わる。どう変わるのかを、同じ 6 次元超立方体で確かめておく。

振るパラメータは 3 つである。t-SNE の `perplexity`、UMAP の `n_neighbors`、そして UMAP の `min_dist` である。前の 2 つは「どれくらいの範囲を近所とみなすか」を、最後の 1 つは「写った先で点をどこまで詰めてよいか」を決める。

3 枚の図から読み取れることを順に見る。




図 6.22 t-SNE の `perplexity` を変えて、同じ 6 次元超立方体を写したもの (`init="pca"`、乱数の種 0)。黒い丸が頂点、色のついた点が辺の上の点で、色は図 6.20 と同じくもとの辺の上での位置 (頂点=濃紺、辺の中央=黄土)

t-SNE は、どう設定しても辺を潰す `perplexity` を 5 から 120 まで 24 倍に広げても、192 本の辺の最長区間の割合の中央値は、0.69 から 0.80 のあいだを動くだけである (等間隔に写っていれば 0.08)。変わるのは塊の大きさと配置であって、辺が潰れること自体は変わらない。`perplexity` を選り直しても、この潰れを避けることはできない。

補足 t-SNE に `min_dist` にあたる設定が無いのはなぜか

どちらの手法も、2 つの段階を踏んで平面に写している。第一段階では、もとの高次元空間で「どの点とどの点を近いとみなすか」を決める。第二段階では、写った先の平面で「近い点どうしをどこまで近づけてよいか」を決める。2 つの手法の違いは、この第二段階にある。

第一段階を決めるのが、t-SNE の `perplexity` と UMAP の `n_neighbors` である。名前は違うが役割は同じで、どちらの手法もこの段階の設定を持っている。

第二段階では、平面上の距離 d を「近さ」に直す関数を使う。t-SNE はこの関数を、自由度 1 の t 分布 $q \propto (1 + d^2)^{-1}$ に固定している。この式には調整できる値が入っていないので、使う側が詰まり具合を指定する手段は用意されていない。

UMAP は同じ役割の関数に $(1 + a d^{2b})^{-1}$ という形を使い、 a と b を `min_dist` から当てはめて決めている^a。第二段階の関数そのものが `min_dist` で変わるので、使う側が詰まり具合を指定できる。

2 つの関数の形を図 6.25 に重ねた。`min_dist` を大きくすると、曲線の肩が右へ広がる。近い点どうしを、それ以上は詰めなくなるということである。

前項で見た辺の潰れの程度を、使う側が直接指定できるのは、この第二段階の関数である。UMAP では `min_dist` でその関数を変えられるので、潰れ方も変わる。t-SNE では関数が固定されているので、`perplexity` を振っても最長区間の割合は 0.69 から 0.80 の範囲にとどまる。ただし第一段階の設定も潰れと無関係ではない。UMAP でも `min_dist=0` のまま `n_neighbors` を変えると、最長区間の割合は 0.24 から 0.78 まで変わる (すぐあとで見る)。

したがって、t-SNE でも第二段階の関数を差し替えれば潰れ方は変わる。実際、t 分布の自由度 ν を 1 から動かせるようにした研究があり、 ν を小さくして裾を重くするとより細かい塊が見えるようになると報告されている [76]。ただし scikit-learn の t-SNE にこの設定はない (openTSNE という実装には `dof` として用意されている)。

scikit-learn の t-SNE にも `early_exaggeration` や `learning_rate` といった設定はあるが、これらは最適化をどう進めるかを定めるものである。初期値 (`init`) のように結果を大きく変えるものもある (第 6.5.7 項)。ただし、平面上でどこまで詰めてよいかを指定する設定は、この中には含まれていない (openTSNE の `exaggeration` は、初期の段階を終えたあとの最適化でも引力を強め、塊をより密に詰




図 6.23 UMAP の 2 つのパラメータを組み合わせた 25 通り (乱数の種 0)。行が `n_neighbors`、列が `min_dist` である。色の意味は図 6.22 と同じ。左端の列 (`min_dist=0`) では点が団子になっており、右へ行くほどほけていく

補足 (続き)

める働きをする)。

^a 正確には `min_dist` と `spread` の 2 つを与えると、「`min_dist` までは 1、そこから先は指数的に減る」という区分的な曲線に最も近くなるように a と b を数値的に当てはめる。

UMAP で潰れを決めているのは `min_dist` である 図 6.23 を列の方向に見ていくと、左端の `min_dist=0` では点が頂点のまわりで団子になり、右へ行くほどほけて辺に沿って並ぶ。`n_neighbors`




図 6.24 辺の潰れ具合を、パラメータの関数として測ったもの。縦軸は前項の「最長区間の割合」の中央値で、点が等間隔のまま写っていれば 0.08 になる。上に行くほど、辺の上の点が両端に潰れている




図 6.25 平面上的距離を「近さ」に直す関数。t-SNE は 1 本に固定されている。UMAP は $(1 + a d^{2b})^{-1}$ の a, b を min_dist から決めるので (spread=1 のとき、min_dist=0.1 なら $a = 1.58, b = 0.90$)、曲線の形を変えられる。

を $5 \cdot 15 \cdot 30 \cdot 60 \cdot 120$ と振ったときの幅で見ると、最長区間の割合の中央値も、左端の min_dist=0 での 0.24~0.78 から、右端の min_dist=0.9 では 0.12~0.16 へ下がる。min_dist は「写った先で近い点をどこまで詰めてよいか」の目安なので、これが小さいほど点は団子になる。既定値の 0.1 は、まだ潰れが残っている領域にあたる (n_neighbors=15 での最長区間の割合は 0.18 で、等間隔の 0.08 を上回っている)。

2つのパラメータは独立に働かない 2つが独立に働くのであれば、行と列を 1 本ずつ見れば全体が分かるはずである。だが図 6.23 の左端の列は、上 2 行と下 3 行で様子が違う。n_neighbors が 5 と 15 のうちは min_dist=0 でも辺が残っているのに、30 以上になると、同じ min_dist=0 で団子になる。近所を広く取るほど、詰めてよいという指示が強く働くためである。min_dist を 0.3 にすると、n_neighbors を 5 から 120 まで振ったときの最長区間の割合の幅は、0.09 に縮む。つまり min_dist の影響の大きさ自体が n_neighbors で変わる。片方を固定したまま他方だけを振った結果から、そのパラメータの働きを結論することはできない。

主なパラメータの既定値と、本章の図で使った値を表 6.3 にまとめておく。

表 6.3 t-SNE(scikit-learn 1.5 以降) と UMAP(umap-learn 0.5) の主なパラメータ。左が既定値、右が本章の図で使った値

パラメータ	既定値	本章の図
t-SNE		
perplexity	30	15(図 6.26)、24(図 6.20)、30(図 6.17)、5・15・30(図 6.27)、5~120(図 6.22)
init	"pca"(1.2 から)	すべて "pca"(比較のための "random" を除く)
learning_rate	"auto"(1.2 から)	既定値
early_exaggeration	12	既定値
max_iter	1000	既定値
UMAP		
n_neighbors	15	15(図 6.26)、60(図 6.20)、12(図 6.17)、5・15・40(図 6.27)、5~120(図 6.23)
min_dist	0.1	0.35(図 6.26)、0.3(図 6.20)、0.1(図 6.17)、0.05・0.35・0.8(図 6.27)、0~0.9(図 6.23)
spread	1.0	既定値
init	"spectral"	既定値

○ 定石 6.2 — t-SNE や UMAP の図には、必ずパラメータを書き添える —

図 6.22 と図 6.23 の 30 枚は、すべて同じデータである。どれか 1 枚だけを見せられたら、そのデータについてまったく違う印象を受ける。

図のキャプションに書くのは次の 3 つである。

- 手法名と実装 (t-SNE は実装によって既定の初期化が違う)
- 主要なパラメータ (t-SNE は perplexity と init、UMAP は n_neighbors と min_dist)
- 乱数の種

読むときも同じで、書いていない図から構造を読み取らない。

補足 構造のないデータに塊が現れるのは有名な落とし穴

t-SNE が構造のないデータに塊を作ることは、Wattenberg らの “How to Use t-SNE Effectively” (2016) で詳しく示されている [58]。正規分布からランダムに取った点の集まり、つまり構造がまったくないデータでも、perplexity の設定次第で「きれいに分かれたクラスター」が現れる。

UMAP にも同じ性質があり、同じ趣旨の解説が用意されている (Coenen と Pearce の “Understanding UMAP” [56])。そこでも、塊の大きさと塊どうしの距離には意味がないこと、n_neighbors と min_dist の設定しだいで絵の印象が変わることが強調されている。

もう一つ、両者に共通する落とし穴がある。「UMAP は t-SNE より大域構造をよく保つ」と言われることがあるが、Kobak と Linderman は、その差が初期値の置き方だけで説明できることを示した [57]。Kobak と Linderman が調べた当時、t-SNE の多くの実装は乱数から始めていた。UMAP の既定はスペクトル埋め込みから始める設定である。t-SNE も情報のある初期値から始めれば、差はほぼ消える。

補足 (続き)

scikit-learn もバージョン 1.2 で t-SNE の既定を `init="pca"` に変えた。本書が第 6.5.7 項で t-SNE を `init="pca"` で走らせているのも、この指摘に沿った設定である。

論文の図を見せられて「クラスタが見つかりました」と言われたら、まずどの手法で、どのパラメータで、どの初期値から描いたかを確認するとよい。

6.5.7 4つの手法を並べる

入力を確認してから比べる。1 点は 1 作品で、その座標は第 3 章で作った 52 次元のベクトルである (字種の比率 3 列、文長分布の μ と σ の 2 列、読点前の平仮名 47 列)。列ごとに単位も桁も違うので、各列を平均 0・標準偏差 1 に標準化してある (第 4.4.2 項)。この 74 行 $\times$ 52 列の表を、4 つの方法で 2 次元にした。主なパラメータは t-SNE が `perplexity = 15`、UMAP が `n_neighbors = 15`、`min_dist = 0.35` である (2 つの値をどう変えると結果がどう変わるかは次項で確かめる)。

補足 読点前 47 列を列ごとに z 化してよいか

読点前の平仮名 47 列は、足すとほぼ 1 になる組成データである (まれな列を落としてあるので、正確には部分組成である。第 3 章)。列ごとに平均 0・標準偏差 1 へ揃える操作は、合計の制約を壊すし、めったに出ない文字の列を、よく出る文字の列と同じ重みまで引き上げる。筋としては clr 変換のほうがよい。第 3 章で測ったとおり、clr を通すと著者判別の正解率 (組成 50 列、ランダムフォレスト、5 分割層別交差検証) は 0.918 から 0.960 へ上がった (表 3.6。ただしゼロ置換量を 1/10 にすると 0.906 に下がる)。

それでもここで標準化を使うのは、52 列に文長の 2 列が混じっているためである。生のままでは文長 μ (対数で 3.4 前後) が他を圧倒し、標準化なしの PCA では第 1 主成分の寄与率が 0.820 になる (第 4 章)。列ごとに標準化した場合の第 1 主成分の寄与率 0.191 (図 6.7) の 4 倍以上である。桁を揃える操作は避けられない。

では図の読みが前処理に依存しているかどうかを確かめる。読点前 47 列と字種 3 列に clr をかけ、文長 2 列だけ標準化した表で次項の図 6.27(a) を計算し直すと、数値は変わり、中位の手法の順も入れ替わるが、次の読みは変わらない。大域構造の保存 (距離の順位相関) は MDS の 0.847 が最も高く、局所構造の保存 (5 近傍の一致率) は t-SNE (`perplexity = 30`) の 0.686 が最も高い。LLE とスペクトル埋め込みは左に沈む。

見た目には t-SNE と UMAP のほうが「きれいに分かれている」。だが、見た目に分かれていることと、元の構造を保っていることは別である。

図 6.26 の 4 枚には目盛りを描いていない。PCA 以外の 3 枚は、軸に読むべき意味がないためである。

× アンチパターン 6.3 — t-SNE や UMAP の軸に意味を読む

PCA の軸は元の変数の線形結合として書けるので、「この方向は漢字の比率が高い側」と言える。第 6.3 節のバイプロットは、それを図にしたものだった。

t-SNE、UMAP、そして SMACOF 法で解く MDS は違う。これらが最小化するのは点どうしの距離や近さのずれだけで、その量は配置全体を回しても裏返しても変わらない。軸の向き




図 6.26 同じ 74 作品を 4 つの方法で 2 次元に。色と記号は著者 (図 6.8 と同じ)。

を決める力が目的関数の中にない。

52 列を標準化した 74 作品を、同じ設定で乱数の種だけを変えて 2 回 2 次元にする。1 回目と 2 回目で第 1 軸の座標がどれだけ対応するかを、相関係数の絶対値で測った (軸が裏返っただけなら 1 になる。UMAP の設定は図 6.26 と同じ。比較のため、74 作品それぞれの 5 近傍が 1 回目と 2 回目でどれだけ一致するかも並べる)。

手法	第 1 軸の相関	5 近傍の一致率
PCA	1.000	1.000
MDS(SMACOF 法)	0.467	0.622
t-SNE(init="pca")	1.000	1.000
t-SNE(init="random")	0.305	0.892
UMAP	0.543	0.695

t-SNE を乱数から始めると、第 1 軸の相関は 0.305 にとどまる。2 回の座標が完全に対応していれば PCA と同じ 1.000 になるので、同じ図を 2 枚描くと、横軸の値はほとんど別物になっている。それでも 5 近傍の一致率は 0.892 で、9 割近くが保たれている。**誰と誰が近いかは保たれ、軸だけが毎回変わる。**MDS も同じで、第 1 軸の相関 0.467 に対して 5 近傍の一致率は 0.622 である。

`init="pca"` にすると第 1 軸の相関は 1.000 になるが、これは t-SNE が軸を見つけたからではない。その第 1 軸の座標は PC1 の座標と相関 0.741 で、初期値に置いた PCA の軸の向きが大筋で残っている。乱数を変えても結果が変わらないのは、**乱数の入る余地を初期値が奪っているからにすぎない。再現することと、意味があることは別である。**

だから、これらの図から読んでよいのは**塊があるか、どの点と同じ塊に入るか**までである。「横軸の右にあるほど文が長い」のような読み方をしたければ、PCA のように軸の意味が定義される手法を使う。塊どうしの間隔についても同じ制限がかかることは、第 6.5.8 項の末尾で改めて扱う。

6.5.8 大域と局所はトレードオフになる

2 つの指標で評価する。

- **大域構造** — 高次元での点对距離と、低次元での点对距離の**順位相関**^{*2}。全体の位置関係をどれだけ保っているか
- **局所構造** — 高次元での 5 近傍と、低次元での 5 近傍がどれだけ一致するか

大域構造の指標は、図 6.9 のシェパード図の点の並びを 1 つの数にしたものである。同じ図の (c) の t-SNE と (d) の UMAP では、52 次元で近い組は図の上でも近いが、52 次元で中くらいより遠い組になると、図の上の距離が上下に大きく散らばる。近くは保つが遠くは揃えない、という性質が、この散らばり方に現れている。

手法も増やしておく。ここまでの 4 手法に、多様体仮説を前提とする 3 つを加える。いずれもまず各点の近傍グラフを作り、その上で何を保つかが違う。

- **Isomap**[54] — 近傍グラフ上の最短経路長を**測地距離**の近似とみなし、その距離を MDS で再現する。スイスロールの図 6.16 で「面に沿った距離」と呼んだものである
- **LLE**(局所線形埋め込み、locally linear embedding) [55] — 各点を近傍点の重み付き和で表し、**その重みを保ったまま低次元に置き直す**。距離ではなく「近所での混ぜ方」を保つ
- **スペクトル埋め込み** [63] — 近傍グラフをグラフラプラシアンという行列で表し、その固有ベクトルを座標にする。つながりの強い点どうしが近くに置かれる

この 3 手法は近傍数を 10 に固定し、振っていない。

比べ方には一工夫が要る。t-SNE の perplexity と UMAP の `n_neighbors`(以下 k) はどちらも「どれくらいの範囲を近所とみなすか」を決める値で、これを変えると塊の数も塊どうしの間隔も変わる。片方だけ調整して比べては公平にならないので、t-SNE は perplexity を $5 \cdot 15 \cdot 30$ と振る。

UMAP にはもう一つ、写った先で点をどこまで詰めてよいかを決める `min_dist` がある。第 6.5.6 項で見たとおり、この 2 つは独立に働かない。そこで UMAP は k を $5 \cdot 15 \cdot 40$ 、`min_dist` を $0.05 \cdot 0.35 \cdot 0.8$ として 9 通りすべてを走らせた。

ただし 9 点をそのまま図に描くと読めなくなる。そこで、両軸とも同じかそれ以上で、少なくとも

^{*2} 値そのものではなく、小さい順に並べたときの順位に直してから相関係数を計算したもの。スピアマンの順位相関係数という。直線関係でなくても、一方が増えれば他方も増えるという関係が保たれていれば 1 に近づく。

一方の軸で上回る設定が他にあれば、その設定を外す。残るのは**他のどの設定にも両軸で負けていない設定**だけなので、「この手法はここまでは伸ばせる」という上限が線として見える。9通りのうち残ったのは、近代文学で3通り、ライトノベルで5通りだった。

もう一つ、これらの手法は乱数で初期値を決めるので、同じ設定でも実行のたびに結果が変わる。そこで乱数の種を5通り変えて実行し、平均を点、標準偏差を誤差棒で示す。PCA と Isomap には乱数が入らないので1回だけ実行している。

さらに、傾向が本書のデータ固有でないことを確かめるため、**別のデータ**でも同じ図を描く。ライトノベル 60 区間を、近代文学と同じ作り方で 52 次元のベクトルにしたものである。ただし列の選び方(まれすぎる平仮名を落とす基準)はライトノベルだけで決め直しているの、47 文字の顔ぶれは同じではない。




図 6.27 点は乱数の種 5 通りの平均で、誤差棒は縦横それぞれの標準偏差である(横棒が大域構造の指標のばらつき、縦棒が局所構造の指標のばらつき)。縦棒が短いのは、局所の指標が種を変えてもほとんど変わらないためである。右上に行くほど良い。t-SNE に添えた数字は perplexity、UMAP の数字は `n_neighbors/min_dist` である。UMAP は 9 通り試したうち、**他のどの設定にも両軸で負けていない設定**だけを細い線で結んで載せた。近代文学では右上の角が空くが、まとまりの強いライトノベルでは t-SNE がそこに近づく。トレードオフの強さはデータで変わる。

図 6.27(a) が示すのは**トレードオフ**である。

- MDS は大域構造の保存、すなわち距離の順位相関が 0.824 で最も高い。距離を直接保とうとするので当然
- t-SNE は局所構造の保存、すなわち 5 近傍の一致率が 0.751 で最も高い。perplexity を 5 から 30 に上げると、距離の順位相関が 0.390 から 0.650 へ 0.260 上がる
- UMAP も同じ調整ができる。 k を小さくすれば局所寄り、大きくすれば大域寄りになる。残った 3 通りを結んだ線が、そのまま調整の幅を表している
- PCA・Isomap・LLE は 5 近傍の一致率が下位に並ぶ(それぞれ 0.460、0.430、0.465 で、いずれも t-SNE の 0.751 を 0.28 以上下回る)
- Isomap は PCA の近くに来るが、LLE とスペクトル埋め込みは左に沈む。局所の関係「だけ」

を保つ設計の手法は、本書のデータでは大域をほとんど捨てている

誤差棒からも別のことが読み取れる。なおここで描いたのは、乱数の種を5通り変えたときの標準偏差である(第8.4.2項)。横棒が大域構造の保存(距離の順位相関)のばらつき、縦棒が局所構造の保存(5近傍の一致率)のばらつきを表す。まず**横棒と縦棒で長さの桁が違う**。図に描いた点でみると、種を5通り変えたときの標準偏差は、距離の順位相関では最大0.117((b)のUMAP $k=5$)に達するのに、5近傍の一致率は最大でも0.032にとどまる。どの点が誰の近所かは種を変えてもほぼ同じで、その塊を平面のどこに置くかだけが毎回変わるということである。乱数に振り回されているのは**全体の配置のほう**だと分かる。

横棒の長さは手法によっても大きく違う。t-SNEは**誤差棒が点になっている**。本書は `init="pca"` で走らせているので、初期値に乱数が入らないためである(前項のアンチパターンで見たとおり、これは安定して**見える**だけで、軸に意味が出たわけではない)。一方UMAPは、初期値こそスペクトル埋め込みで決まるが、最適化の途中で離す相手を乱数で選ぶ(負例サンプリング)。そのため種を変えると結果が変わり、 $k=5$ の設定では、距離の順位相関の標準偏差が(a)で ± 0.095 、(b)で ± 0.117 になる。近所とみなす範囲を狭く取るほど、塊どうしの置き場所が種ごとに変わりやすい。手法間の差がこの幅に収まるなら、1回の実行の値では優劣は区別できない。

(b)は別のデータでの追試である。距離の順位相関も5近傍の一致率も、全体に上がる。60区間はシリーズごとのまとまりが強く、どの手法にも易しいためである。並び方も似ているが、同じではない。t-SNEはperplexityを5から15に上げると大域も局所も高く出て、右上の角に近づく。まとまりがはっきりしたデータでは2つの指標が衝突しにくくなる。PCAが大域構造の保存で首位に立ち、距離の順位相関が0.860になるのも(a)にはなかったことで、シリーズごとの塊がはっきりしていれば線形の射影で足りるという意味である。トレードオフがどれだけきついかはデータで変わる。1枚のデータで見た傾向を別のデータで確かめる。一手間かければ、「たまたま」への反論を先回りできる。

× アンチパターン 6.4 — 片方の手法だけ調整して次元削減を比べる

図6.27で、t-SNEのperplexityを1つしか試さずに描くと、(a)ではperplexity = 15の1点、すなわち(距離の順位相関、5近傍の一致率) = (0.487, 0.751)だけが残る。「局所は強いが大域は弱い手法」という結論がそこから出てしまう。perplexityを30まで上げれば(0.650, 0.738)に移り、順位相関が0.163上がって一致率は0.013下がるだけなので、その結論は手法の性質ではなく設定の選び方から来ていたことになる。

比較の相手にだけ調整の機会を与えれば、自分の推したい手法はいくらでも良く見せられる。論文や記事で「提案手法が既存手法を上回った」と読むときは、**既存手法の設定がどこまで振られているか**を先に確かめる。自分で比べるときは、各手法の主要なパラメータを同じ本数だけ振ってから並べる。

発展 大域保存と局所保存の 2 指標が測っていないもの

図 6.27 の横軸は「もとの空間での点对距離をどれだけ保つか」である。だが第 6.5.2 項のスイスロールでは、目的は**巻きをほどく**ことだった。ほどくとは、渦の内側と外側で偶然近くにある点对を引き離すことであり、もとの空間の距離を**壊す**ことにほかならない。巻きをほどきたい場面では、横軸の値が高いのはむしろ失敗である。

スイスロールは正解が分かっているのので、両方を測って比べられる。「もとの 3 次元空間での距離」との順位相関と、「展開図 (巻き位置と高さ) での距離」との順位相関である。

手法	もとの空間の距離	展開図の距離
PCA	0.816	0.536
MDS	0.840	0.520
t-SNE	0.372	0.594
UMAP	0.309	0.655
Isomap	0.360	0.756
LLE	0.349	0.640
スペクトル	0.348	0.554

どちらの距離を相手にするかで、7 手法の順位が入れ替わる。以下の数値はいずれも距離の順位相関である。MDS はもとの距離で 0.840 の首位なのに、展開図では 0.520 で最下位になる。展開図で首位に立つのは Isomap の 0.756 で、こちらはもとの距離では 0.360 と下位 4 手法の中にいる。UMAP も同じ向きで、もとの距離では 0.309 で最下位、展開図では 0.655 で 2 位になる。そもそも、もとの距離と展開図の距離のあいだの順位相関自体が 0.422 しかない。2 つの「大域構造」は別物である。

Isomap が展開図で首位に来るのは偶然ではない。Isomap は点对距離を**近傍グラフ上の最短経路長**で測る。巻かれた面の上では、その最短経路が面に沿って回り込むので、渦の内側と外側で偶然近くにある 2 点を「遠い」と判定できる。測るものを変えたから、ほどけた。

つまり図 6.27 の 2 軸は、**もとの距離の配置をそのまま 2 次元で眺めたい**という目的に対する指標である。多様体を展開したいなら、測るべきは測地距離との一致になる。正解の座標が手に入らない実データでは、近傍グラフ上の最短経路長でそれを代用する (Isomap が内部でやっていることである)。

本書の 74 作品で 2 軸を使ったのは、作家の文体に「巻かれた面」のような構造を仮定する理由がなかったからである。仮定を変えれば、測る量も変えなければならない。

同じことは手法の側にも言える。図 6.27 では t-SNE の最良の設定が UMAP のどの設定よりも右上に来ているが、これも「UMAP を使う理由がない」という話にはならない。UMAP が広く使われる理由の一つは**規模**にある。scikit-learn の t-SNE は点の数が増えると重くなり、数十万点になるとつらい。UMAP は大規模データでも速く、メモリも少なくて済む。74 点や 60 点の比較では、規模の差は原理的に見えない。もう一つ、UMAP は学習した写像を保持できるので、**あとから来た新しい点を同じ地図に落とせる (transform)**。scikit-learn の t-SNE では全点を作り直しになる。分類の前段に組み込むなら、差は大きい。

まとめると、**ベンチマークは、軸に選んだ性質しか測らない**。軸の選び方が目的と食い違っていることもあれば (スイスロールの例)、軸の外に長所があることもある (UMAP の例)。「この比較は何を測っていて、何を測っていないか」を言えるようにしてから、図の結論を使う。

× アンチパターン 6.5 — t-SNE や UMAP の図で距離を語る

「A と B のクラスタは近いから似ている」とは言えない。これらの手法はクラスタ**内**の近さを保つが、クラスタ**間**の距離は保存しない。

図 6.27(a) のとおり、UMAP の大域構造の保存、すなわち距離の順位相関は、2 つのパラメータを 9 通りに振っても 0.37 から 0.49 にとどまる。同じ図での MDS の 0.824 には遠く及ばない。クラスタの大きさと塊どうしの間隔も、近傍の広さを決める設定を変えるだけで伸び縮みする。

軸に意味がないこと (前掲のアンチパターン) と合わせると、これらの図で信用してよいのは「どの点とどの点が同じ塊に入るか」だけになる。

コラム 1 細胞の地図をめぐる論争 —— 象の形にも埋め込める

生命科学では、1 つ 1 つの細胞で数千の遺伝子の働きを測る 1 細胞 RNA-seq が広く使われている。その論文には、数千次元のデータを t-SNE や UMAP で 2 次元にした図がほぼ必ず載り、細胞の塊の位置や塊どうしの距離が議論に使われてきた。

Tara Chari と Lior Pachter は 2023 年の論文で、この習慣に異を唱えた [64]。実際の 1 細胞データで 2 次元の図を調べると、高次元での近傍と図の上での近傍は大きく食い違い、細胞の種類どうしの遠近の順位も、元の空間の順位とあまり相関しなかった。さらに 2 人は、元の空間の距離を UMAP や t-SNE と同じ程度に保ったまま、データを **象の輪郭の形** に埋め込む方法を作った。距離の保ち具合が同じなら図の形は自由に選べる、というのが 2 人の主張である。

これに対して Jan Lause、Philipp Berens、Dmitry Kobak は 2024 年に反論した [65]。t-SNE や UMAP の図で、2 次元での近所の細胞から各細胞の種類を当てると、9 割以上が当たる。2 次元の図は高次元の距離を再現しないが、近所のまとまりは保っている。象の図は距離の指標では同じくらいの値を取るが、このまとまりは保たない。2 つの論文は、どちらも「図のどこまでを読んでよいか」を数で測って論じており、違いは何を測るかにある。本章の 2 つの指標 (距離の順位相関と 5 近傍の一致率) は、この 2 つの立場がそれぞれ重く見た性質に対応している。

6.6 手法は1つに絞らず、並べて描く

○ 定石 6.3 —— 次元削減は複数の手法を並べて見る ——

どれか一つを選ぶ必要はない。図 6.26 のように並べて描くのが最も安全である。

- すべての手法で同じ構造が見えたら、それは本物らしい
- 一つの手法でしか見えない構造は、その手法の産物かもしれない

そして**必ず定量指標も見る**。図 6.27 のような評価を一度すれば、どの図をどこまで信じてよいか分かる。

補足 オートエンコーダと PCA の関係

オートエンコーダは、入力を低次元に圧縮してから復元するニューラルネットワークである。

$$x \xrightarrow{\text{エンコーダ}} z \xrightarrow{\text{デコーダ}} \hat{x}, \quad \min \|x - \hat{x}\|^2 \quad (6.12)$$

途中の変換を掛け算と足し算だけで組み、非線形な関数を挟まずに作ると、PCA と同じ平面を学習することが知られている。非線形な関数を挟むことで、PCA では表せない曲がった構造まで扱えるように

表 6.4 次元削減法の比較。「保存が最良」は近代文学 74 作品での結果 (図 6.27(a)) による。

手法	長所	短所	向く場面
PCA	軸を解釈できる。パイプロットが描ける。速く決定的。新しいデータも同じ変換で写せる	線形変換のみ。局所構造の解像度が低い。分散が代表値として不適切な分布では弱い	変数の意味を知りたい。前処理として
MDS	距離を直接保つ。座標がなく距離行列だけでも使える。大域構造の保存が最良	計算量が点の数の 2 乗以上で、大規模データに弱い。局所構造は t-SNE ほど保てない	距離しかないデータ。全体の位置関係が重要
t-SNE	局所構造の保存が最良。クラスタが見やすい	遅い。大域構造・クラスタ間距離が保存されない。scikit-learn の実装では新しいデータを写せない。乱数依存	クラスタの存在を確認したい
UMAP	t-SNE より速い。n_neighbors で局所と大域のバランスを調整できる。新しいデータも写せる	クラスタ間距離は保存されない。パラメータに敏感。理論が難しい	大規模データの探索的可視化
オートエンコーダ	任意の非線形変換。次元削減と復元を同時に学習	訓練データが大量に必要。設計と学習の手間	画像・音声など大規模データ

補足 (続き)

なる。

第 6.2.5 項では「射影誤差の最小化」という定式化を見た。式 (6.12) の $\min \|x - \hat{x}\|^2$ は、「もとに戻したときのずれを最小にする」という同じ形をしている。オートエンコーダは、PCA の当てはめを非線形に拡張したものだと理解できる。

6.7 章末の課題

- 図 6.5 で使った 3 列に片仮名の比率を加えて 4 次元にし、寄与率がどう変わるか調べよ。
- 標準化せずに PCA を行くと何が起きるか。第 4 章の図 4.4 を踏まえて予想し、確かめよ。
- 第 1 主成分の係数 (固有ベクトルの成分) を大きい順に並べ、どの特徴が寄与しているか調べよ。文体の言葉で解釈できるか。
- MDS で 2 次元に落とし、PCA の結果と比べよ。どちらが著者ごとのまとまりを見せるか。
- PCA で 2 次元に落としてから距離を測るのと、52 次元のまま距離を測るのでは、第 4 章の効果量 (表 4.3) はどう変わるか。
- 字種 3 列 (平仮名・片仮名・漢字) だけに、標準化せずセンタリング (平均を引く) のみで PCA

をかけ、第 3 主成分の固有値が (浮動小数点の誤差を除いて) 0 になることを確かめよ。固有ベクトルはどの方向を向いているか。(ヒント: 合計 1 の平面の法線方向、つまり $(1, 1, 1)/\sqrt{3}$ に平行になるはずである。第 3 章の共分散の行和ゼロの議論から導ける。) さらに、標準化してから同じことをすると、固有値は 0 のままだが、固有ベクトルの向きが変わることを確かめよ。向きは 3 列の標準偏差とどう関係するか。

第7章

著者を当てる

7.1 正解を与えて学ばせる

前章では著者名を隠してグループを作った。今度は逆に、著者名を教えて**未知の作品の著者を当てるモデル**を作る。

これを**教師あり学習** (supervised learning) という。手順を図 7.1 に示す。




図 7.1 教師あり学習の基本手順。

図の下注記が肝心である。テストデータは学習に使わない。理由は本章の後半で実際に見る。

7.2 まず当てずっぽうの成績を知る

モデルを作る前にやることがある。**何も学習しない戦略の成績**を計算しておく。

考えられる最も単純な戦略は、「いつも最も作品数の多い著者だと答える」ことである。吉川英治が 21 作品なので、正解率は $21/74 = 0.284$ になる。

表 7.1 基準線

戦略	正解率
8 名から一様ランダムに選ぶ	0.125 ^{*1}
つねに最頻クラス (吉川英治) と答える	0.284

何も考えずに吉川英治と答え続けるだけで、74 作品の正解率は一様ランダムに選んだときの **2 倍以上**になる。

^{*1} 1/8 という理論値である。第 8 章では同じ基準線を実際に 2000 回引いて測っており、そちらは 0.126 になる。

× アンチパターン 7.1 — 基準線を置かずに精度を報告する

「正解率 50% を達成した」と言われても、それが良いのか悪いのか分からない。クラスが偏っていれば、最頻クラスを答えるだけで 50% を超えることもある。

クラス数が K のとき、当てずっぽうの水準を $1/K$ だと思ってしまいがちである。それはすべてのクラスが同じ大きさのときの話で、偏りがあれば**最頻クラスの割合**のほうが高くなる。モデルを超えるべきなのは、高いほうである。ここを取り違えると、無意味なモデルを成功と誤認する。

本章の成績の測り方 本章では、成績として 74 作品の著者を当てた正解率を測る。74 作品を 5 つに分け、4 つで学習して残り 1 つで試すことを 5 回繰り返して平均する (**交差検証**。詳しくは第 8 章で扱う)。分けた 1 つ 1 つの塊を**フォールド** (fold) と呼ぶ。以下、表の中では交差検証 (cross-validation) を **CV** と略す*2。

5 つに分けるととき、どの塊にも各著者が元の比率どおり入るようにしている (**層別**。理由は第 7.9 節で述べる)。以下、単に「層別 CV」あるいは「層別 5 分割の交差検証」と書いたものはこの分け方である。

7.3 k 近傍法 — 最も単純な分類器

k 近傍法 (kNN、*k*-nearest neighbors) は、モデルらしいモデルを作らない。新しい作品が来たら、**最も近い k 個の訓練データを探し、その多数決で答える**。手続きはこれだけで終わる。

第 4 章で距離を定義したので、そのまま使える。




図 7.2 k 近傍法。円内の 5 点の多数決で「？」の著者を決める。この例では著者 A が 3 点、著者 B が 2 点なので、判定は著者 A になる。

k の値で性格が変わる。

- $k = 1$ — 最も近い 1 点をそのまま真似る。訓練データには完璧に合う
- k が大きい — 広い範囲の多数決になり、なめらかな境界になる

本書の 74 作品で、 k を 1 から 25 まで変えて正解率を測ったのが図 7.3 である。訓練データそのものを当てさせると、 $k = 1$ では 1.000 になる。自分自身がいちばん近い点なので、答えを写すだけで済むからである。学習に使っていない作品で測る層別 CV では、同じ $k = 1$ が 0.973 になる。 k を大きくすると 2 本とも下がり、 $k = 25$ では訓練で 0.460、CV で 0.379 になる。2 本の差は $k = 1$ では

*2 第 2 章で変動係数を CV と書いたが、これとは無関係の同じ略語である。

0.03 ほどだが、 k を上げるにつれて開き、 $k = 11$ で 0.24 と最も大きくなって、その先は少しずつ狭まる ($k = 25$ で 0.08)。訓練データで測るときは、どの作品も自分自身を近傍の 1 つに数え、自分の著者に 1 票を入れる。訓練側の線が CV より高いのはこの 1 票のためである。訓練データで測った数字と、学習に使っていないデータで測った数字は別物である。この差は第 7.8 節で改めて扱う。




図 7.3 k 近傍法の k と正解率 (74 作品、52 列、標準化あり)。赤は学習に使ったデータで測った値、青は学習に使っていない作品で測った値。 $k = 1$ の赤が 1 になるのは、訓練データの点にとって最も近い点が自分自身だからである。

補足 kNN は訓練のときに何もしていない — 怠惰学習

kNN は訓練の段階で何もしない。データを覚えるだけである。計算は予測のときに全部行う。訓練を先送りする手法を**怠惰学習** (lazy learning) と呼ぶ。

利点は、モデルの形を仮定しないので複雑な境界も表現できること。欠点は、予測のたびに全データとの距離を計算するので遅いこと、そして第 9 章で見るように**次元の呪い**に弱いことである。

7.4 線形モデル — 1 本の境界で分ける

kNN は境界を式として持たない。境界は、訓練データの点の並びから予測のたびに決まる。もう一方の極に、**空間を 1 本の境界で仕切る**という考え方がある。

2 つのクラスを分ける境界を、直線 (3 次元なら平面、52 次元なら超平面) で書く。

$$s(x) = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b \quad (7.1)$$

$s(x) > 0$ なら一方のクラス、 $s(x) < 0$ ならもう一方とする。学習とは、係数 w と切片 b を決めることである。 w_j は「その特徴が 1 増えるとスコアがどれだけ変わるか」なので、**どの特徴をどちら向きに使ったかが読める**。決定木と並んで、説明のしやすい手法である。

決め方が 2 通りある。

7.4.1 ロジスティック回帰 — 確率に直して最尤法で決める

式 (7.1) のスコアは $-\infty$ から $+\infty$ までの値を取るなので、そのままでは確率として読めない。そこで**シグモイド関数**で 0 から 1 に押し込める。

$$P(\text{クラス 1}) = \frac{1}{1 + e^{-s(x)}} \quad (7.2)$$




図 7.4 シグモイド関数。 $-\infty$ から $+\infty$ までの値を取るスコアを、0 から 1 の確率に押し込める。原点付近では急に、両端ではゆるやかに変化する。

図 7.4 のとおり、スコアが 0 のとき確率 0.5、大きいほど 1 に近づく。境界そのもの ($s = 0$) では「どちらとも言えない」と答え、境界から離れるほど自信のある確率を返す。係数は**最尤法**で決める。手元のデータが最も出やすくなる w と b を選ぶという基準である (第 3 章の発展「 $n - 1$ で割るべきか」でも触れた)。これが**ロジスティック回帰** (logistic regression) である。

本書のように著者が 8 名いる場合は、著者ごとに線形スコアを 1 本ずつ、計 8 本用意し、予測のときは 8 本のスコアを比べて、最大の著者を答える。学習のさせ方には 2 つの流儀がある。著者ごとに「その人か、そうでないか」の二値問題を別々に解く流儀 (one-vs-rest) と、8 本のスコアをまとめて確率に変換し、全体を 1 つの尤度として最大化する流儀 (多項ロジスティック回帰) である。scikit-learn の既定は後者で、本書の実験もそれに従う。

後者では、著者 k のスコアを $s_k(x)$ として、確率を

$$P(\text{著者 } k) = \frac{e^{s_k(x)}}{\sum_{j=1}^K e^{s_j(x)}} \quad (7.3)$$

で計算する (**ソフトマックス関数**)。 K は著者の数で、本書では 8 である。指数を取るのですべて正の数になり、合計で割るので足すと 1 になる。 $K = 2$ で $s_2 = 0$ と置けば、式 (7.2) のシグモイドに戻る。なお実際に解かれるのは、正則化項 (第 4.4.2 項) を足した罰則付きの最尤推定である。

発展 二値の結果を確率で答えるモデルは交差エントロピーで測る

「太宰治か、そうでないか」のように答えが 2 つに 1 つで、モデルの出力が 0 から 1 の確率 p である場合を考える。その良し悪しを 1 つの数にまとめる基準が**交差エントロピー** (cross entropy) である。**対数損失** (log loss) ともいう。正解を $y \in \{0, 1\}$ 、モデルの答えを p と書くと、 N 件の平均は次の量である。

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)] \quad (7.4)$$

y_i が 1 なら $-\ln p_i$ 、0 なら $-\ln(1 - p_i)$ だけが残るので、**正解のほうに与えた確率の対数**を集めていることになる。正解に 0.5 を与えたときの損失は 0.69、0.1 しか与えなければ 2.30、0.01 なら 4.61 と、言い切って外すほど急に大きくなる (図 7.5(a))。

発展 (続き)




図 7.5 交差エントロピーと二乗誤差の比較。(a) は正解に与えた確率 p と 1 件ぶんの損失。 $-\ln p$ は p が 0 に近づくほど際限なく大きくなるが、 $(1-p)^2$ は最大でも 1 にとどまる。(b) は正解が $y = 1$ のとき、スコア s についての勾配の大きさ。交差エントロピーは $|p - y|$ で、大きく外している左端ほど大きい。二乗誤差は $2|p - y|p(1 - p)$ で、左端では 0 に近づき、外しているのに動けなくなる。

クラスが K 個ある場合も同じ形から出る。正解のクラスだけ 1、ほかを 0 にした K 個の数 $y_{i1}, \dots, y_{iK}$ (one-hot 表現) を使うと、次のように書ける。

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \ln p_{ik} \quad (7.5)$$

$K = 2$ とし $y_{i2} = 1 - y_{i1}$ 、 $p_{i2} = 1 - p_{i1}$ を入れれば式 (7.4) に戻る。内側の和は正解のクラス以外がすべて 0 倍で消えるので、実際に残るのは**正解のクラスに与えた確率の対数** 1 項だけで、次のように書き直せる。

$$L = -\frac{1}{N} \sum_{i=1}^N \ln p_i(\text{正解のクラス}) \quad (7.6)$$

この形が選ばれる理由を 2 つ挙げる。

最尤法と同じものである 1 件の観測が確率 p で表が出るコイン投げだとすると、 N 件が観測される確率 (尤度) は $\prod_i p_i^{y_i} (1 - p_i)^{1 - y_i}$ である。対数を取り、符号を変え、 N で割ると式 (7.4) そのものになる。「手元のデータが最も出やすくなる係数を選ぶ」という最尤法の言い方と、「交差エントロピーを最小にする」という言い方は、同じ手続きの別名である。ロジスティック回帰が最尤法で係数を決めるのは、この損失を最小にしていることにほかならない。

勾配が飽和しない シグモイド (式 (7.2)) と式 (7.4) を組み合わせると、係数についての勾配は $(p - y)x$ という簡単な形になる。1 件ぶんの損失 $\ell = -[y \ln p + (1 - y) \ln(1 - p)]$ を p で微分すると $\frac{p - y}{p(1 - p)}$ 、シグモイドを s で微分すると $p(1 - p)$ なので、連鎖律で掛け合わせると $\partial \ell / \partial s = p - y$ が残る。 $s = w_1 x_1 + \dots + w_n x_n + b$ なので、 w_j についての勾配は $(p - y)x_j$ になる。外している量にそのまま比例するので、大きく外していれば大きく動く (図 7.5(b))。ここで二乗誤差 $(p - y)^2$ を使うと、連鎖律でシグモイドの微分 $p(1 - p)$ が掛かる。 p が 0 や 1 に近い領域ではこれがほぼ 0 になるので、**確信を持って間違えているときほど動けなくなる**。交差エントロピーはこの $p(1 - p)$ をちょうど打ち消す。式の見え目より、この性質のほうが実務では大きい。

なお $-\ln p$ は「その結果を知ったときの意外さ」と読める。確率 0.5 の出来事が起きても意外ではないが、0.001 と言っていた出来事が起きれば大きく驚く。その平均が交差エントロピーである。底を 2 に

発展 (続き)

取れば、結果を符号化するのに要するビット数になる。第6章のt-SNEが高次元と低次元の2つの分布のずれを測っていたのも、定数の差を除いてこれと同じ量である(あちらはKLダイバージェンスで、交差エントロピーからエントロピーの項を引いたものにあたる)。

ここでは学習の目的関数として見たが、交差エントロピーは出来上がったモデルの確率を測る側にも使う。Brierスコアとの比較は第8.7節で扱う。

関連した列があると係数の符号が入れ替わる 線形モデルの利点は、係数が読めることだとされる。「 w_j が大きい列ほど、判定を強く左右している」という読み方である。

その読み方が壊れる場合がある。**強く関連した列が同時に入っているとき**である。

本書のデータで確かめる。平仮名の比率と漢字の比率は、第3章で見たとおり $r = -0.915$ と強く負に相関している。合計が1に近い比率どうしなので、片方が増えれば他方は減る。

この2列で「太宰治かどうか」を当てるロジスティック回帰を組む。2列とも標準化してあるので、係数は「その列が1標準偏差だけ増えたときに**ログオッズ**がどれだけ動くか」を表す。ログオッズは、確率 p を $\ln \frac{p}{1-p}$ に直した量で、式(7.1)のスコア $s(x)$ そのものである(本節の補足「分類のになぜ『回帰』と呼ぶのか」でロジットとして改めて扱う)。係数の変わり方だけを見たいので、ここでは罰の影響をほぼ外した設定 ($C = 10^6$ 。 C は罰の弱さで、既定値は1) で当てはめた。74作品から重複を許して74作品を引き直し、そのたびに係数を求める操作を300回繰り返した(ブートストラップ)。ただし引き直した結果、太宰の作品が1回以下しか引かれない標本が3回出た。片方のクラスがほぼ空では係数が意味をなさないので、それらは除いて297回とした。比べるのは、**平仮名の係数が2つの場合でどう変わるか**である。

結果は2つの形で現れた。

まず**振れ幅が広がった**。297個の標本にわたる平仮名の係数の四分位範囲(小さいほうから4分の1と4分の3にあたる値の差。中央の半分が収まる幅)は、平仮名だけを入れたモデルで0.88、漢字も入れたモデルで1.45である。同じ列の係数なのに、相方がいるだけで散らばりが大きくなる。標準偏差で比べなかったのは、太宰の作品がたまたま少ない標本では2つの著者群がほぼ完全に分かれてしまい、係数がいくらでも大きくなるからである(漢字も入れたモデルの平仮名の係数は、絶対値で最大39に達した)。標準偏差はこうした少数の標本でほとんど決まってしまう。

係数の不安定さより重いのが、2つ目の変化である。**符号が逆になった**。平仮名だけのモデルでは係数の符号が一方に定まる(中央値は+0.59)のに対し、漢字も入れたモデルでは89%の標本で反対向きになる。「平仮名が多いほど太宰らしい」が「少ないほど太宰らしい」に化ける。

ここで気をつけたいのは、89%という数字である。コインを投げるように符号が揺れているだけなら、反対向きになる割合は50%前後になるはずである。9割近いということは、揺らぎではなく**ほぼ毎回そうなる**、つまり系統的な入れ替わりである。既定の $C = 1$ で同じ実験をしても、反対向きになる割合は75%ある。既定の強さの罰を入れただけでは、符号の入れ替わりは消えない。一方、散らばりの広がりには罰を入れると消え、標準偏差は1列で0.46、2列で0.48とほぼ同じになる。罰は係数の大きさを抑えるが、係数が何を表すかまでは変えない。

符号が入れ替わるのは、平仮名と漢字がほとんど同じ情報を裏返しに持っているためである。平仮名が多い作品ほど漢字が少ないので、2つの係数に同じ数を足しても、平仮名で増えた分を漢字で

減った分がほぼ打ち消す。「平仮名に +2、漢字に -1」と置いても「平仮名に -2、漢字に -5」と置いても、足し合わせたスコアはほとんど変わらない(漢字の値はほぼ平仮名の値の符号を変えたものなので、どちらも平仮名の値のおよそ3倍になる)。平仮名の係数の符号は、この2つで逆である。そのうえ漢字の係数が入ることで、平仮名の係数が担う役割そのものが置き換わる。

2列モデルの平仮名の係数が表しているのは、もはや「平仮名の多さの効果」ではない。**漢字の値を固定したうえで、平仮名の相対的な位置**である。1列モデルの係数とは、そもそも別の量を測っている。値が違うのも符号が違うのも、それで説明がつく。

損失の形を描くと、何が起きているかが見える。




図 7.6 2つの係数を動かしたときの予測誤差の等高線(模式図)。中心の点が最も誤差の小さい組合せである。相関がなければ等高線は丸く、中心から外れるとすぐ誤差が増える。強く相関していると等高線は細長くなり、赤い破線の向きにはどこまで動かしてもほとんど誤差が変わらない。標本が少し変われば、中心はこの谷に沿って大きく滑る。

図 7.6 の右が、平仮名と漢字を並べたときの状況である。 $r = -0.915$ の2列では、予測誤差の等高線が描く楕円の長軸が、短軸の約5倍の長さになる。谷に沿って滑るので、標本を引き直すたびに係数の組は大きく動く。それでも**足し合わせたスコア**は谷の底に沿ってほぼ一定なので、予測の当たり方は変わらない。壊れるのは係数の読みだけである。

図 7.7 は、実際に297回のブートストラップで得た係数の組を並べたものである。点は右上がりの向きに細長く伸びていて、図 7.6(b) の谷の向きと一致する。平仮名の係数(横軸)は大半が0より左にあり、平仮名だけのモデルの中央値(縦の破線)とは反対の側に来ている。

この状態を**多重共線性**(multicollinearity)という。強さの目安には**VIF**という量があり、2列の場合は $1/(1-r^2)$ で計算できる。本書の平仮名と漢字では6.1になる。5を超えたら係数の解釈に注意、というのが慣用の目安である。

× アンチパターン 7.2 — 相関の強い列を並べたまま係数の大小を比べる —

係数は「他の列を固定したときの効果」を表すことになっている。だが平仮名と漢字のように連動する列では、**片方だけを動かす**という状況が現実には存在しない。存在しない状況についての数字なので、大小を比べても意味が薄い。

紛らわしいのは、**予測の性能そのものは落ちない**ことである。足し合わせたスコアは安定しているので、当たり方は変わらない。壊れるのは解釈のほうだけで、成績を見ても気づけ




図 7.7 ブートストラップ 297 回ぶんの係数の組 (平仮名と漢字の 2 列で太宰治かどうかを当てる、罰をほぼ外したロジスティック回帰)。1 点が 1 回の引き直しである。点は右上がりの谷に沿って並ぶ。絶対値の大きい 11 点は描画の範囲外にある。

ない。

係数を読みたいなら、相関の強い列は片方に絞るか、まとめて 1 つの指標にするか、正則化 (第 4.4.2 項) で係数の大きさを抑える。ただし上で見たとおり、既定の強さの罰では符号の入れ替わりまでは防げなかった。

ただし L1 正則化で列を絞る場合は、別の注意が要る。関連した列のどれが残るかは標本しだいで入れ替わるので、残った列を「重要な列」と読むことはできない (第 7.11 節のアンチパターン)。

補足 分類なのになぜ「回帰」と呼ぶのか — 一般化線形モデル

式 (7.1) の線形の当てはめをそのまま使っているからである。違いは、出力を確率に直す関数を 1 枚かぶせた点だけにある。

見方を枠組みにしたものが**一般化線形モデル** (generalized linear model、GLM) で、部品は 3 つある [79]。

- **線形予測子** $\eta = w_1x_1 + \dots + w_nx_n + b$
- 当てたい値が従う**分布** (正規分布、二項分布、ポアソン分布など)
- 両者を結ぶ**リンク関数** g 。 $g(\text{当てたい値の期待値}) = \eta$ と置く

線形回帰は「正規分布 + 恒等リンク ($g(\mu) = \mu$)」、ロジスティック回帰は「二項分布 + ロジットリンク」である。**ロジット**とは

$$g(p) = \ln \frac{p}{1-p} \quad (7.7)$$

つまり**オッズの対数**で、これを η と等しいと置いて p について解くと、式 (7.2) のシグモイドが出てくる。シグモイドはロジットの逆関数である。回数を当てたいなら「ポアソン分布 + 対数リンク」を選ぶ (ポアソン回帰)。どれも中身は同じ線形の当てはめで、当てたい値の性質に合わせてリンクを取り替えているだけなので、まとめて「回帰」と呼ばれている。

補足（続き）

ロジットが比の対数であることにも注目してほしい。第3.7節で組成データに使った対数比と同じ形である。 p と $1-p$ は合計が1の2成分の組成データなのだから、同じ道具が出てくるのは自然なことである。

名前が紛らわしいのだが、一般線形モデル (general linear model) という別の語もある。そちらは正規分布と恒等リンクに限った枠組み (重回帰や分散分析を含む) を指す。「一般化」の3文字があるかどうかで、指すものが違う。

7.4.2 サポートベクトルマシン — 隙間を最大にする

2つのクラスがきれいに離れているなら、境界の引き方は1通りではない。図7.8(a)のように何本でも引ける。




図 7.8 境界の引き方。2枚とも同じ点である。(b)の破線は、境界から左右に等しく離れたマージンの縁で、赤い輪をかけた2点がちょうどその上に乗る。この2点が境界を決めており、これより境界に近い点は存在しない。

サポートベクトルマシン (SVM) は、境界と最も近い点との距離、すなわちマージンを最大にする位置に境界を引く (図7.8(b))。境界を決めているのは、境界の近くにある少数の点だけである。境界を支える少数の点をサポートベクトルと呼び、名前の由来になっている。遠くの点をいくら動かしても境界は変わらない。

直線で分けられないデータにはカーネルを使う。データを高次元の空間に写してから直線で分けるという発想である。もとの空間に戻して見れば、境界は曲がって見える。

いちばん小さな例で見る。数直線の上に、原点の近くに青い丸が、その両外側に赤い四角が並んでいるとする (図7.9(a))。1本のしきい値では、この並びを2つに分けられない。赤い四角が、青い丸をはさんで左右に散っているからである。ところが縦軸に x^2 を足して平面に持ち上げると、横一直線で分けられるようになる。

図7.9でやったのは、 x という1列から (x, x^2) という2列を作る操作である。実際のカーネルはこれをずっと高い次元で行う。高次元に写すほど分けやすくなる理屈は、付録BのCoverの定理にある。

肝心なのは、高次元に写した座標を実際には計算しないことである。SVMの計算に出てくるのは2




図 7.9 次元を上げると直線で分けられるようになる例。(a) の 1 次元では赤い四角が両端に分かれているので、どこにしきい値を置いても片方が残る。(b) のように x^2 を 2 本目の軸として足すと、遠い点ほど高く持ち上がるので、水平な直線 1 本で分かれる。この直線を (a) に戻すと $|x| = \text{一定}$ 、つまり **2 つのしきい値** という曲がった境界になる。

点の内積だけなので、「写した先での内積の値」を別の式で直接求めてしまえば足りる。その式をカーネルと呼ぶ。本書で使う RBF カーネル (radial basis function、動径基底関数) は $\exp(-\gamma\|x - x'\|^2)$ という形で、2 点のユークリッド距離を直接使う。 γ はどれくらい近い点だけを近いとみなすかを決める値で、大きくすると境界が個々の点のまわりに細かく巻きつき、小さくすると直線に近づく。

SVM には、もう 1 つ C という設定値がある。これは**訓練データの誤分類をどれだけ許すか**を決める。 C を大きくすると誤りを許さなくなり、境界が訓練データに合わせて無理な形をとる。 γ と C はどちらも複雑さを決めるパラメータで、2 つとも大きくするほど過学習 (訓練データに合わせすぎる) こと。第 7.8 節) しやすくなる。本書ではどちらも既定値のまま使っている (第 7.10.1 項)。scikit-learn の SVC の既定は $C = 1$ 、 γ は「列の数 $\times$ 全要素の分散」の逆数 (`gamma="scale"`) である。 γ を変えたときの境界の形は、第 7.10.2 項の図 7.22 で見る。

SVM はもともと 2 クラスを分ける手法である。本書のように 8 クラスある場合、scikit-learn の SVC は著者の組 $\binom{8}{2} = 28$ 通りのそれぞれに境界を引き、28 回の判定の多数決で答える (one-vs-one)。

補足 距離や正則化を使うモデルには標準化が要る

線形モデルはどちらも、複数の列を足し合わせて 1 つのスコアを作る (式 (7.1))。しかも正則化項や距離が入るので、列の単位がそろっていないと特定の列だけで結果が決まってしまう。第 4.4.2 項の表 4.2 は、74 作品の著者を層別 5 分割の交差検証で判別したときの正解率を、標準化の有無で並べたものである。標準化しない SVM(RBF カーネル) の正解率は、最頻クラスを答え続ける基準線 0.284 と同じ 0.284 にとどまった。既定の γ は、上で見たとおり全要素の分散で決まる。標準化していないと、この分散 (0.234) は、ほかの列より桁違いに大きい文長 μ (値は 3 から 4 程度) でほぼ決まり、 γ は 0.082 になる。一方、作品どうしの距離は小さいので、どの 2 作品を比べてもカーネルの値が 0.73 から 1 の間に収まり、中央値は 0.989 になる。すべての作品がほとんど同じに見えるので、区別の手がかりがなく、最も多い著者を答えるしかなくなる。単位のそろわない列を 1 つの距離に足し合わせたことが、この結果を生んでいる。

同じことが **k 近傍法** にも当てはまる。こちらは足し算ではなく距離を測るが、単位のそろわない列を混ぜれば距離が 1 列に支配されるという事情は同じである。同じ表の k 近傍法 ($k = 5$) では、正解率が標準化なしの 0.664 から標準化ありの 0.877 へ上がる。本書が以降で報告する kNN の数字は、すべて

補足（続き）

標準化してから測ったものである。

木のモデルは1列ずつ大小を見るだけなので、標準化しても結果が変わらない。列を足すか、距離を測るモデルには標準化が要ると覚えておけばよい。

7.5 決定木 — 質問を繰り返す

決定木 (decision tree) は、「この特徴がこの値より大きいか」という質問を繰り返してクラスを絞り込む。




図 7.10 74 作品すべてで作った深さ 2 の決定木。質問に「はい」なら左、「いいえ」なら右へ進む。各質問の下
の数字は、その節に届いた作品数とエントロピー H (本文で説明する乱雑さの量)。葉 (緑の箱) には多数を占め
る著者を太字で、その下に中身の内訳を書いた。分割の基準はエントロピー (criterion="entropy") である。

図 7.10 は、本書のデータで実際に作った深さ 2 の木である。最初の質問は「『は、』の割合が 0.132 以下か」で、「いいえ」の側（「は、」を多く打つ側）には太宰治と柳田国男の全作品と、吉川英治のほとんどが入る。もう 1 回質問すると、吉川英治は 1 つの葉にほぼまとまる。ほかの 3 つの葉には 3 人から 5 人が混ざったままで、深さ 2 ではここまでしか分けられない。

木を作るには「どの特徴のどの値で分けるか」を決めなければならない。基準として情報利得 (information gain) がよく使われる。

まず、集合の乱雑さを情報エントロピー (entropy) で測る。クラス i の割合を p_i として

$$H = - \sum_i p_i \log_2 p_i \quad (7.8)$$

すべて同じクラスなら $H = 0$ 、均等に混ざっているほど大きくなる。

特徴 A で分割したときの情報利得は

$$\text{IG}(A) = H(\text{分割前}) - \sum_v \frac{|S_v|}{|S|} H(S_v) \quad (7.9)$$

分割によってどれだけ乱雑さが減ったかを表す。これが最大になる特徴を選んで分割する。それを繰り返す*3。

*3 この量は、情報理論でいう相互情報量 (mutual information) にほかならない。第 2 項は「どの枝に落ちたかを知った

図 7.10 の最初の質問で確かめる。8 人が混ざった 74 作品全体のエントロピーは 2.845 ビットである。「『は、』の割合が 0.132 以下か」で分けると、「はい」の側の 40 作品は 2.416 ビット、「いいえ」の側の 34 作品 (吉川 20・太宰 7・柳田 5・漱石 1・藤村 1) は 1.626 ビットになる。作品数で重み付けて平均すると 2.053 ビットなので、この質問の情報利得は $2.845 - 2.053 = 0.792$ ビットである。木を作るときは、全 52 列のあらゆる切れ目についてこの値を計算し、最も大きいものを選ぶ。

scikit-learn の決定木とランダムフォレストは、既定ではエントロピーの代わりにジニ不純度 $G = 1 - \sum_i p_i^2$ を使う (criterion="gini")。すべて同じクラスなら 0、混ざるほど大きくなる点はエントロピーと同じで、選ばれる分割も多くの場合同じになる。本書の実験で使う決定木とランダムフォレストは、図 7.10 を除いてこの既定値のままである。後で出てくる「不純度」は、このジニ不純度を指す。

補足 エントロピーの直感

コインを投げて表裏を伝えるのに必要な情報は 1 ビットである。 $H = -0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1$ 。
いかさまコインで表が 90% 出るなら、 $H = -0.9 \log_2 0.9 - 0.1 \log_2 0.1 \approx 0.47$ ビットで済む。ほとんど表だと分かっているのだから、伝える情報が少なくて済む。
エントロピーは「平均して何ビット必要か」を表している。

決定木の利点は、**できた木を人が読めること**である。図 7.10 のような木なら、なぜその著者と判定したかを説明できる。これは後で見るランダムフォレストにはない性質である。

7.6 ランダムフォレスト — 木をたくさん作る

決定木は 1 本だと不安定である。データが少し変わると、まったく違う木ができることがある。

ランダムフォレスト (random forest) はこの弱点を、数を増やすことで解決する [80]。

1. 訓練データから重複を許して同じ件数を引き直す (**ブートストラップ**)。木ごとに見ているデータが違うものになる
2. 各分割では、全特徴のうち一部だけをランダムに候補にする
3. これを数百回繰り返して木を作り、多数決で決める

手順 1 で、なぜ木ごとにデータが変わるのかを確かめておく。74 件から 74 回引くとき、ある 1 件が 1 回の抽選で選ばれない確率は $1 - 1/74$ である。74 回とも選ばれない確率はそれを 74 乗した値で、 $(1 - 1/74)^{74} \approx 0.37$ になる^{*4}。つまり平均して 3 分の 1 強の作品が、その木の訓練から漏れる。漏れる顔ぶれは木ごとに違うので、育つ木も違うものになる。

2 つのランダム性がここで働く。1 本の木が 3 割間違えるとしても、**どこで間違えるかが木ごとにばらばら**なら、ある 1 作品について間違える木は全体の一部にとどまる。多数決を取れば、正しく答えた多数のほうを通る。逆に木どうしが似ていれば、同じ作品でそろって間違えるので、何本集めても多数決の意味がない。だから手順 1 と 2 で、わざと木を違うものになっている。

あとに残る乱雑さ、すなわち条件付きエントロピー $H(Y | A)$ なので、 $IG(A) = H(Y) - H(Y | A) = I(A; Y)$ が成り立つ。決定木は、分割のたびに「クラスとの相互情報量が最大になる質問」を選んでいくことになる。

^{*4} 一般に $(1 - 1/n)^n$ は n を大きくすると $1/e = 0.368$ に近づく。

量で書くと、1本の木の予測のばらつき (分散) を σ^2 、2本の木の予測の相関を ρ としたとき、 B 本の平均のばらつきは $\rho\sigma^2 + (1 - \rho)\sigma^2/B$ である [82]。本数 B を増やせば第2項は0に近づくが、第1項 $\rho\sigma^2$ は残る。手順2で候補の列を毎回絞るのは、この ρ を下げるためである。scikit-learn の既定では、候補にする列の数は全列数の平方根 (52列なら7列) である。

なお scikit-learn の実装は、票を数える代わりに各木が出すクラス確率を平均し、平均が最大のクラスを答える。深さを制限しない木は葉に1クラスしか残らないので、各木の確率は0か1になり、多数決と同じ答えになる。




図 7.11 ランダムフォレスト。似ていない木を多数作って多数決する。

代償として、なぜその判定になったかが説明しにくくなる。300本の木の多数決を人間が追うことはできない。精度と説明可能性のトレードオフは、機械学習のあちこちに現れる。

7.7 勾配ブースティング — 間違いを順に埋める

ランダムフォレストは木を並列に作って多数決を取った。これをバギング (bagging) という。

もう一つの方向がある。木を逐次的に作り、前の木が間違えた分だけを次の木に学ばせる。これがブースティング (boosting) である。

7.7.1 残差を埋める過程を見る

分類より回帰のほうが直感的なので、1次元のデータでブースティングの動きを見る。

真の関数は $f(x) = \sin x + 0.3x$ で、そこにノイズを加えたものが観測値である。弱い学習器として深さ1の決定木 (決定株) だけを使う。1本では「ある値を境に2つの水準に分ける」ことしかできない。出発点 (木0本) の予測は、すべての x で観測値の平均とする。そこに決定株を1本ずつ、0.4倍に縮めて足していく (この0.4を学習率と呼ぶ。第7.7.3項)。

木1本のときは、ある点を境に高さが2段に分かれるだけの階段である。2本、5本と足していくと段差が増え、30本では曲線をよく追っている。

7.7.2 各木が学ぶのは直前までの残差

m 本目の木が学ぶのは、それまでの予測の残差である。出発点は $F_0(x) = \bar{y}$ (観測値の平均) で、 F_{m-1} は $m-1$ 本の木を足し終えた予測を表す。




図 7.12 バギングとブースティングの違い。前者は並列、後者は逐次。




図 7.13 勾配ブースティングの過程。灰色は観測値、赤破線が真の関数、青が予測。決定株を学習率 0.4 で足していくと階段が細くなり、曲線に近づく。各パネルは、表題の本数の決定株を足し終えた後の予測である。

$$r_i^{(m)} = y_i - F_{m-1}(x_i) \quad (7.10)$$

新しい木 h_m を残差に当てはめ、学習率 η を掛けて足し込む (図 7.13 では $\eta = 0.4$)。

$$F_m(x) = F_{m-1}(x) + \eta h_m(x) \quad (7.11)$$

図 7.14 に、残差そのものと、それに当てはめた木を示す。

2 本目のときはまだ大きな構造が残っている。30 本目では残差がほぼ平らになり、木が拾えるもの




図 7.14 残差 (灰色の点) と、それに当てはめた決定株に学習率 0.4 を掛けたもの (赤)。回を追うごとに残差が小さくなり、木の刻み幅も細くなる。

が少なくなっている。

補足 残差は損失関数の負の勾配である — 「勾配」の由来

2 乗誤差 $L = \frac{1}{2} \sum_i (y_i - F(x_i))^2$ を考える。 $F(x_i)$ で微分すると

$$-\frac{\partial L}{\partial F(x_i)} = y_i - F(x_i) = r_i \quad (7.12)$$

残差はちょうど損失関数の負の勾配である。式 (7.11) は、関数の空間での勾配降下法になっている。

損失関数を変えれば、残差の代わりに別の量を当てはめることになる。分類問題ではロジスティック損失を使い、「確率のずれ」に相当する量を学ぶ。これが勾配ブースティング (gradient boosting) という名前の由来である。

7.7.3 学習率と木の本数

式 (7.11) の η は学習率 (learning rate) である。1 に近いと一気に残差を消し、小さいとゆっくり進む。




図 7.15 図 7.13 と同じデータに、深さ 2 の木を学習率 0.4 で足していったときの平均 2 乗誤差。木を足すほど観測値との誤差は下がり続けるが、真の関数との誤差は $m = 16$ で最小になり、その先はむしろ悪化していく。

図 7.15 が重要である。縦軸は、この 1 次元の人工データに深さ 2 の木を学習率 0.4 で足していったときの平均 2 乗誤差である。決定株より 1 本ごとの刻みが細かいので、過学習が早く現れる。観測

値との平均 2 乗誤差 (赤) は木を足すほど下がり続け、200 本で 0.0003 とほぼゼロになる。だが真の関数との平均 2 乗誤差 (青) は $m = 16$ のときの 0.017 が最小で、その先は木を足すほど悪化し、200 本では 0.047 になる。最小のときより 0.030 大きい。

底を過ぎてから起きているのは**ノイズの学習**、つまり過学習である。観測値にどこまでも近づくとすることは、観測値に混ざったノイズにもどこまでも近づくとことだからである。

同じデータに、深さを制限しない回帰木を平均するランダムフォレストを当てると、木の本数と誤差の関係はまったく違う形になる (図 7.16)。ランダムフォレストの誤差は数本で下がりきり、そのあとは 200 本まで平らなままで、200 本で 0.026 である。勾配ブースティングは $m = 16$ の底を過ぎると上がり続け、やがてランダムフォレストより悪くなる。




図 7.16 木の本数を増やしたときの、真の関数との平均 2 乗誤差 (図 7.13 と同じ 1 次元のデータ)。ランダムフォレストは本数を増やしても悪化しない。勾配ブースティングは $m = 16$ を底に、本数を増やすほど悪化する。

× アンチパターン 7.3 — ブースティングの木をランダムフォレストと同じつもりで増やす

ランダムフォレストは木を独立に作って多数決するので、本数を増やしても害はなく、増えるのは計算時間だけである。ブースティングは違う。前の木の誤りを次の木が引き受ける仕組みなので、足せば訓練誤差をいくらでも下げられ、**本数を増やすほど過学習する**。同じ「木をたくさん作る手法」でも、本数の意味が正反対である。

η と本数はトレードオフの関係にある。 η を小さくすると 1 本あたりの寄与が減るので、同じ性能に達するのに多くの木が要る。一般に「 η を小さく、本数を多く」のほうがテスト誤差は小さくなるが、計算時間は増える。

本数を止める位置をどう決めるかも問題になる。図 7.15 のように真の関数が分かっていたら底が見えるが、実際のデータでは見えない。そこで訓練データの一部を取り分けて成績を測り、**それが悪化し始めたところで打ち切る**。これを早期打ち切り (early stopping) といい、LightGBM にも XGBoost にも仕組みが用意されている。第 10.2.2 項で見る深層モデルの止め方と同じ考え方である。

本書は本数を 300 本に固定して使った。打ち切りのために訓練データをさらに削ると、74 点では学習側が痩せすぎるためである。

7.7.4 LightGBM

勾配ブースティングの実装として広く使われているのが **LightGBM**(Microsoft, 2017)[84] と **XGBoost**(2016)[83] である。Kaggle^{*5} などの競技では、表形式データにおける定番になっている。LightGBM の工夫はいくつかある。

- **ヒストグラム化** — 連続値を最大 255 個のビンに離散化し、分割点の探索を速くする。今では XGBoost や scikit-learn の実装も同じ方法をとる
- **Leaf-wise 成長** — 木を深さごとに揃えて成長させるのではなく、損失が最も減る葉から伸ばす。同じ葉数でより深い木になる
- **GOSS**(gradient-based one-side sampling) — 勾配の大きい行 (まだ誤差の大きいもの) を優先して使い、小さい行は間引いて学習を速くする。LightGBM 4 の既定では使われず、指定したときだけ使われる
- **EFB**(exclusive feature bundling) — 同時に 0 以外の値を取ることがほとんどない列どうしを 1 列に束ね、列の数を減らす

LightGBM の主な既定値は、学習率 0.1、木 100 本、葉 31 枚で、葉に残す最小データ数 (`min_child_samples`) は 20 である。




図 7.17 木の成長のさせ方。Leaf-wise は損失が最も減る葉だけを伸ばす。

7.7.5 本書のデータでは、調整が要る設定は 2 つだった

勾配ブースティングは調整できる値が多い。LightGBM の一覧には 100 を超える項目が並ぶ。だが役割は 3 つに分けられる。

- **どれだけの刻みで、何歩進むか** — 学習率と木の木数。この 2 つは対で決まる (第 7.7.3 項)。
- **1 本の木をどこまで細かくするか** — 葉の数 (または深さ) と、葉に残す最小データ数。細かくするほど 1 本が強くなり、過学習しやすくなる。
- **どれだけ手加減させるか** — 正則化の強さ、1 本の木に使う行や列の割合。わざと情報を減らして過学習を抑える。

どれをどれだけ触ると成績が変わるのかを、本書のデータで測った。使ったのは LightGBM では

^{*5} **Kaggle** は機械学習の競技会を運営するプラットフォーム (2010 年開始、2017 年に Google が買収)。主催者がデータと評価指標を公開し、参加者が予測を提出して順位を競う。勾配ブースティングがどれほど勝ってきたかは、本節末のコラムで触れる。

なく、scikit-learn の `HistGradientBoostingClassifier` である。LightGBM と同じく、連続値をビンに分けてから分割点を探す勾配ブースティングの実装で、既定値も学習率 0.1、木 100 本、葉 31 枚、葉の最小データ数 20 と LightGBM に近い。既定値から 1 つのパラメータだけを変え、他は既定値のままにしてある。

表 7.2 scikit-learn の `HistGradientBoostingClassifier` で、既定値から 1 つだけ設定を変えたとき、74 作品の著者を層別 5 分割の交差検証で判別した正解率が動いた幅 (試した値の中での最大と最小の差)。正解率そのものではない。右の 2 列は、正解率が最も高くなったパラメータの値と、そのときの正解率である。いずれも分割の乱数 3 通りで平均した。すべて既定値のままの正解率は、乱数 5 通りの平均で 0.943 である。

パラメータ	正解率の幅	最良の値	そのときの正解率
葉の最小データ数	0.134	10	0.950
学習率	0.117	0.3	0.937
ℓ_2 正則化の強さ	0.032	0.0	0.933
木の本数	0.009	200	0.937
分割ごとに候補にする列の割合	0.004	0.5	0.937
1 本の木の葉の数	0.000	4	0.933

上の 2 つと下の 4 つで、幅の桁が違う。**葉の最小データ数**を 1 から 20 まで動かしたときの正解率の幅は 0.134、**学習率**を 0.01 から 0.3 まで動かしたときの幅は 0.117 ある。残りの 4 つは、 ℓ_2 正則化の強さが 0.032、木の本数が 0.009、分割ごとに候補にする列の割合が 0.004、1 本の木の葉の数が 0.000 で、ほとんど変わらない (列の割合は、LightGBM の `colsample_bytree` のように木ごとに選ぶのではなく、分割のたびに選び直す割合である)。

葉の数の幅が 0.000なのは、葉の最小データ数 (既定値 20) が先に木の大きさを決めてしまうためである。5 分割の訓練側は 59 か 60 作品しかないので、20 作品以上を含む葉は 2 枚 (60 作品のときだけ 3 枚) しか作れない。上限を 4 枚にしても 31 枚にしても、育つ木は同じになる。既定値のままでは、1 本の木は実質的に 1 回しか分かれなない。

葉の最小データ数は、その上限そのものを動かす。値ごとの正解率を図 7.18 に示す。既定値の 20 では 0.933、10 に下げると 0.950 で、試した中で最もよかった。葉を 5 枚ほど作れるようになり、1 本の木が拾える区別が増えるためである。一方で 1、2、5 に下げると、それぞれ 0.843、0.816、0.824 に落ちる。数作品しか入らない葉ができて、木が訓練データを覚えてしまう。scikit-learn の説明書も、数百件に満たないデータではこの値を下げるよう勧めているが、下げすぎれば逆効果になる。**標本が少ないときは、既定値のままにせず、この値をいくつか試すほうがよい。**

学習率と木の本数は、片方を下げたらもう片方を上げる関係にある。

正解率は、学習率 0.02・木 25 本では 0.680 しかない。同じ学習率のまま木を 400 本に増やすと 0.937 になる。0.257 の差である。学習率 0.3 なら、木 25 本の時点ですでに 0.937 である。行き着く先は同じで、**そこに何本で着くかが違う**。一般には学習率を小さく、本数を多くしたほうがわずかに良くなるとされるが、その差は計算時間の増加に見合わないことも多い。




図 7.18 葉の最小データ数を変えたときの正解率 (scikit-learn の `HistGradientBoostingClassifier`、ほかは既定値、74 作品、層別 5 分割の交差検証、分割の乱数 3 通りの平均)。点の下の灰色の数字は、59 作品の訓練側で作れる葉の枚数の上限 (既定の上限 31 枚を超える場合は 31 枚) である。

表 7.3 学習率と木の本数の組み合わせごとの正解率 (74 作品、層別 5 分割の交差検証、分割の乱数 3 通りで平均)。学習率を下げたぶんだけ本数を増やせば同じところに行き着く。

学習率	25 本	50 本	100 本	200 本	400 本	800 本
0.3	0.937	0.937	0.937	0.937	0.937	0.937
0.1	0.923	0.928	0.933	0.937	0.937	0.937
0.05	0.855	0.914	0.932	0.933	0.937	0.937
0.02	0.680	0.820	0.901	0.919	0.937	0.937

○ 定石 7.1 — ブースティングのパラメータは 3 手に分けて触る

やみくもに全部を同時に振らない。順序を決めておくと探索が短くて済む。

1. 学習率を 0.05 から 0.1 に固定し、木の本数は早期打ち切りで決める。ここで大枠の成績が決まる。
2. 1 本の木の粗さを決める。葉の最小データ数から先に触る。既定値が標本数に対して大きすぎないかを確認する (74 点では 20 だと、木がほぼ 1 回しか分かれられない)。
3. 過学習が残っていれば正則化と列のサンプリングを足す。時間が許せば最後に学習率を下げ、本数を増やす。

木の深さや葉の数は、標本が多いときにだけ意味を持つ。74 点のような規模では、そこを刻んでも結果は変わらない。

探索して出た数字を成績として報告しない 74 作品の層別 5 分割の交差検証で、15 通りの設定をランダムに試して最も正解率の高いものを選ぶ。選ばれた設定の正解率は 0.973 で、すべて既定値のままの 0.943 との差は +0.030 である。だがこの 0.973 は、設定を選ぶのに使ったのと同じ分割で測った値である。探索そのものを内側に入れた入れ子交差検証で測り直すと正解率は 0.959 になり、既定値との差は +0.016 まで縮む。見えていた上積みのは半分は、選び方が分割に合わせただけの分であった。この測り方の詳細は第 9.7 節で扱う。

7.7.6 本書のデータでは

木を使う 4 つの手法を同じ枠組みで比べる。左の列は、章の初めに説明した層別 5 分割の交差検証 (層別 CV) の正解率である。

右側の「シリーズを分けた CV」は、『三国志』のように同じ長編から作った作品を訓練とテストに分けずにまとめて片側へ置いた場合の成績である (分け方が要る理由は本章の最後で述べる)。

表 7.4 木ベースの手法の比較。74 作品の著者を判別したときの正解率で、左は層別、中央は『三国志』のようなシリーズを 1 つの群として訓練とテストに分けない、いずれも 5 分割の交差検証である。右はその落差 (層別 − シリーズ) である。いずれも分割の乱数は 1 通りである。

モデル	通常の層別 CV	シリーズを分けた CV	落差
決定木 (1 本)	0.688	0.711	−0.023
ランダムフォレスト	0.987	0.975	+0.011
勾配ブースティング (sklearn)	0.812	0.772	+0.041
LightGBM	0.839	0.913	−0.074

ランダムフォレストが最も強い。層別 CV の正解率は 0.987 で、LightGBM の 0.839 を 0.148、勾配ブースティング (sklearn) の 0.812 を 0.175 上回る。ブースティングは Kaggle の定番だが、ここでは負けている。

ただし 0.148 の差のすべてを手法の差と読むことはできない。表の 0.839 は LightGBM で、葉 7 枚・学習率 0.05 に加えて、葉の最小データ数を 3 まで下げた設定での値である。図 7.18 で見たとおり、この値を小さくしすぎると正解率は下がる。scikit-learn の `HistGradientBoostingClassifier` を既定値のまま使えば、正解率は 0.943 (分割の乱数 5 通りの平均) になる (乱数の数が違うので、図 7.18 の既定値の点 0.933 とは少し違う)。勾配ブースティング (sklearn) の行は `GradientBoostingClassifier` の既定値 (深さ 3 の木を学習率 0.1 で 100 本。葉の最小データ数は 1) である。どの設定でも 0.987 には及ばなかった。手元には 74 点しかなく、ブースティングは逐次的に誤差を詰めていく手法なので、データが少ないとノイズを追いかけやすい。少数データでは、ランダムフォレストのほうが安定しやすい。

最右列は、層別 CV の正解率からシリーズを分けた CV の正解率を引いた落差である。52 列では、落差が正になった 2 つのうち大きいほうが勾配ブースティング (sklearn) の +0.041 で、ランダムフォレストは +0.011 にとどまる。決定木の −0.023 と LightGBM の −0.074 は負で、分け方を厳しくしたほうがかえって正解率が高い。落差は実装や設定でも大きく変わる。`HistGradientBoostingClassifier` を既定値のまま、表と同じ分割の乱数 1 通りで測ると、層別 CV で 0.946、シリーズを分けた CV で 0.825 で、落差は +0.121 になった。乱数 1 通りの 1 回の比較なので、この列で優劣までは論じられない。なぜ落差が小さいのか、そして特徴を変えると何が起きるのかは、第 9 章で扱う。

○ 定石 7.2 — 分類手法はデータの規模と目的で選ぶ —

- 標本数が数千以下 — ランダムフォレストから試す
- 標本数が数万以上、表形式 — LightGBM や XGBoost
- 説明が必要 — 決定木 1 本、線形モデル
- とにかく速く試したい — ロジスティック回帰

「最新の手法が常に最良」ということはない。データの規模と性質で決まる。

コラム Kaggle で勝ってきた勾配ブースティング

XGBoost の原論文 [83] には、競技会での実績が数字で書かれている。2015 年に Kaggle のブログで紹介された優勝解法 29 件のうち、17 件が XGBoost を使っていた。そのうち 8 件は XGBoost だけでモデルを作り、残りの多くはニューラルネットワークと組み合わせていた。2 番目に多かった深層ニューラルネットワークは 11 件である。同じ年のデータ分析の競技会 KDD Cup 2015 では、上位 10 チームのすべてが XGBoost を使っていた。「表形式のデータならまず勾配ブースティング」という通念は、こうした実績から広まった。

ただし、これらの競技のデータは数万行から数百万行あることが多い。行が多ければ、逐次的に誤差を詰めていくブースティングもノイズではなく規則のほうを追いかけられる。本書の 74 作品では、表 7.4 のとおりランダムフォレストが LightGBM も scikit-learn の勾配ブースティングも上回った。

7.8 訓練データで測った正解率は当てにならない

ここまでの数字はすべて交差検証で測ってきた。訓練データでの成績を使うとどれだけ話が変わるかを、本章の最も重要な実験として確かめる。

決定木を全データで学習し、**同じデータで正解率を測ってみる**。

```
tree = DecisionTreeClassifier(random_state=0).fit(X, y)
print(tree.score(X, y))    # 1.000
```

正解率 1.000。完璧である。

だがこれは何も意味しない。決定木は、必要なだけ深くすれば訓練データを丸暗記できる。答えを見ながら答え合わせをしているのと同じである。

データを 7:3 に分けてやり直す (著者の比率がどちらにも保たれるように分ける。やり方は第 7.9 節で見る)。テスト側は 23 作品である。

表 7.5 同じ決定木の正解率を、測り方を変えて出したもの。上は 74 作品すべてで学習して同じ 74 作品で測った値、下は 7:3 に分けて訓練側で学習しテスト側で測った値

測り方	正解率
学習に使ったデータで測る	1.000
学習に使っていないデータで測る	0.783

同じモデル、同じデータなのに、測り方を変えただけで正解率に 0.217 の差がついた。この差が過

学習 (overfitting) である。

差の中身は、モデルが覚え込んだ**その 74 作品に固有のこと**である。「吉川英治は『っ、』を打つ」なら未知の作品にも通じるが (吉川の 21 作品のうち 20 作品に現れる)、『斜陽』は『や、』の割合がちょうど 0.00075 である」は、その作品にしか通じない。訓練データで測れば後者も正解を生むので、成績が 1.000 まで上がる。別のデータに当てれば、後者は何の役にも立たない。

分類ではなく、点に線を当てはめる問題で描くと形が見える。




図 7.19 同じ 7 点に 3 通りの当てはめ方をした。灰色の破線が真の関係、黒い点が観測されたデータである。左は直線しか引けないので、どう頑張っても点の傾向を追えない。右は 7 点すべてをぴったり通るが、点と点のあいだで大きく暴れており、真の関係から離れている。訓練データでの誤差は右がいちばん小さい。それでも別のデータで測れば右がいちばん外す。

図 7.19 の右が、いま決定木で起きていることである。「訓練データでの誤差が最も小さいモデル」を選ぶと、このいちばん暴れた曲線が選ばれてしまう。

補足 「過学習」という訳語は誤解を招きやすい

overfit の over は「学びすぎ」ではなく「**訓練データに合わせすぎ**」を指す。過剰適合という訳のほうが原語に忠実だ、という指摘がある。実際、起きているのは適合のしすぎであって、学習の回数や時間が多すぎたわけではない。

本書は慣用に従って過学習と呼ぶが、言葉に引きずられて「学習を減らせばよい」と読むと的を外す。減らすのはモデルが持つ自由さのほうである。

× アンチパターン 7.4 — 訓練データで性能を報告する

気づきにくく、発表まで残りやすい間違いである。

1.000 に近い正解率を見たら、まず**評価に使ったデータが学習と分かれているか**を確認する。課題が易しければ高い正解率は正当に出るので、問題は数字の高さそのものではなく、どのデータで測ったかにある。

7.9 分割のときの注意 — 層別化

データを分けるとき、単純にランダムに切ると壊れる場合がある。

柳田国男の作品は 5 点しかない。ランダムに 7:3 で分けると、テスト側に 1 点も入らないことがある。あるいは訓練側に 1 点しか入らないこともある。

層別化 (stratification) は、分割後もクラスの比率が元と同じになるように分ける。

```
X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.3, stratify=y, random_state=0
)
```

`stratify=y` を書くかどうかだけの違いだが、クラスが偏っているデータでは必須である。

7.10 モデルを比べる

代表的な分類器を同じ条件で比べたのが表 7.6 である。測り方は章の初めに述べた層別 5 分割の交差検証で、詳しくは次章で扱う。

表 7.6 分類器の比較。74 作品の著者を 5 分割の層別交差検証で判別したときの正解率で、平均と標準偏差は 5 つのフォールドにわたるもの (標準偏差は 5 で割って計算した)

モデル	平均正解率	標準偏差
最頻クラス (基準線)	0.284	0.026
k 近傍法 ($k = 1$)	0.973	0.033
k 近傍法 ($k = 5$)	0.877	0.055
決定木	0.688	0.106
ロジスティック回帰	0.986	0.029
ランダムフォレスト	0.987	0.027

ランダムフォレストの平均正解率が 0.987 である。これは分割の乱数を 1 通りに固定したときの値で、乱数を 50 通りに変えると 0.932 から 0.987 まで振れ、平均は 0.966 になる (第 8 章の図 8.3)。本書の乱数での 0.987 は、この 50 通りの中で最も高い値にあたる。以下でもこの乱数の値を使い続ける。最頻クラスを答え続ける基準線 0.284 を 0.703 上回る。文字の使い方だけで著者がほぼ完全に判別できていることになる。




図 7.20 表 7.6 を横棒にしたもの。横向き細い線は標準偏差、破線は基準線 (最頻クラス) の高さ。上位 3 つは棒の長さも標準偏差もほぼ同じで、決定木だけ標準偏差が 3 倍以上ある

図 7.20 を見ると、上位 3 つ (k 近傍法 $k = 1$ 、ロジスティック回帰、ランダムフォレスト) は棒の長さがほとんど変わらない。太字にした 0.987 を「1 位」として読みたくなるが、標準偏差の細い線が互いに深く重なっている。この重なるの読み方は次章で扱う。

補足 交差検証は標準偏差も見る

平均だけでは比べたことにならない。5 つのフォールドにわたる正解率の標準偏差を見ると、決定木の 0.106 は、上位 3 つのモデル (0.027 から 0.033) の 3 倍以上あり、2 番目に不安定な k 近傍法 ($k = 5$) の 0.055 と比べても 2 倍近い。

これは「分割の仕方によって成績が大きく変わる」という意味で、モデルが不安定であることの兆候になる。ただし、5 つの値から出した標準偏差はそれ自体ぶれの大きい推定値である (第 8 章)。順位を決める根拠にはせず、不安定さの兆候として読む。

7.10.1 設定値はほとんど探索していない

表 7.6 には、書かれていない選択がいくつも隠れている。 k NN の k をいくつにするか、木をどこまで深く育てるか、森を何本にするか。これらは学習で決まらず、人が外から与える値である (第 8 章でハイパーパラメータとして扱う)。

その前に、本章の手法が何を学び、何を最小にし、何を既定値としているかを表 7.7 にまとめておく。既定値は scikit-learn 1.5 以降と LightGBM 4 のものである。

表 7.7 本章の分類器の一覧。「学ぶもの」は訓練で決まる中身、「最小にする量」は訓練で小さくしようとする量 (木では分割を選ぶ基準) である。

手法	学ぶもの	最小にする量	主な既定値	標準化
k 近傍法	なし (訓練データを覚えるだけ)	なし	$k = 5$	要る
ロジスティック回帰	係数と切片	交差エントロピー + L2 の罰	$C = 1$ (罰の弱さ)、多クラスは多項 (式 (7.3))	要る
SVM(RBF)	各訓練点の重み (0 でない点がサポートベクトル)	ヒンジ損失 ^{*6} + 係数の大きさの罰	$C = 1$ 、 γ は列数と分散から決める、多クラスは one-vs-one	要る
決定木	分割の質問と葉の答え	ジニ不純度の減少	深さ制限なし、葉の最小データ数 1	不要
ランダムフォレスト	木ごとの分割	ジニ不純度の減少 (木ごと)	木 100 本、分割ごとの候補は $\sqrt{\text{列数}}$ 列、木の確率を平均	不要
勾配ブースティング (sklearn)	足し合わせる木の列	交差エントロピー (勾配を木で近似)	木 100 本、学習率 0.1、深さ 3	不要
HistGradient-Boosting	同上	同上	木 100 本、学習率 0.1、葉 31 枚、葉の最小データ数 20、ビン 255	不要
LightGBM	同上	同上	木 100 本、学習率 0.1、葉 31 枚、葉の最小データ数 20、ビン 255、leaf-wise	不要

本書がどうしたかを表 7.8 に示す。

表 7.8 本書が使った主な設定値。特記のないものはライブラリの既定値

手法	設定	備考
k 近傍法	$k = 1, k = 5, k = 15$	k を変えたときの挙動そのものを見たいので、複数を併記する
決定木	深さ制限なし、図では深さ 2 と 4	制限なしだと訓練データを丸暗記する (第 7.8 節)
ランダムフォレスト	木 300 本、他は既定値	本数を増やしても悪化しない (図 7.16)
ロジスティック回帰	既定の正則化のまま	標準化してから使う
SVM	RBF カーネル、既定値	C と γ は探索していない
LightGBM	木 300 本、学習率 0.05、葉 7 枚、葉の最小データ数 3	葉の数を絞り、葉の最小データ数を下げた (表 7.4)
勾配ブースティング (sklearn)	既定値	GradientBoostingClassifier (表 7.4)
HistGradientBoosting	既定値から 1 つずつ変える	HistGradientBoostingClassifier (表 7.2、表 7.3)
MLP (第 10.2 節)	幅 を 4 通 り、 <code>max_iter=3000</code> 、他は既定値	止め方は既定 (訓練損失の停滞。検証データは使わない)

つまりほとんど探索していない。これは手抜きでもあり、意図でもある。

意図の側から言うと、探索を入れると比較の意味が変わる。「よく調整された手法 A」と「既定値の手法 B」を比べても、分かるのは調整の手間の差でしかない。本書が見たいのは手法の性格の違いなので、どれも同じだけ手をかけない、という揃え方を選んだ。

手抜きの側も認めておく。表 7.6 の順位は、探索すれば入れ替わりうる。とくに SVM は C と γ で境界の複雑さが決まる手法なので、第 4.4.2 項の表 4.2 に出した既定値のままの成績 (標準化ありで 0.959) を「SVM の実力」と読むわけにはいかない。勾配ブースティングも同じで、表 7.2 のとおり、葉の最小データ数 1 つで正解率が 0.134 変わる。

○ 定石 7.3 — 設定値を探索したかどうかをはっきり書く —

探索していないなら「既定値のまま」と書く。探索したなら、何を、どの範囲で、どう選んだかを書く。

書いていない報告を読むときは、探索したものとして扱うほうが安全である。そして探索し

*6 正しい側に一定の余裕 (マージン) を持って分類できた点は 0、余裕が足りないか反対側にある点は、足りない分に比例した罰を受ける損失。境界から遠い点が境界を動かさないのはこのためである。

たなら、その探索も評価の内側に入れる。選ぶために使ったデータで成績も測ると、数字が甘くなる。正しい手順は入れ子の交差検証で、第 9 章で実際に測る。

7.10.2 境界の形を見る

表 7.6 の数字は、どの手法も似た成績に見せてしまう。だが**同じ成績でも、引いている境界の形は違う**。

52 次元の境界は描けないので、2 列に絞る。吉川英治・夏目漱石・泉鏡花の 40 作品を、読点前の「は」と「ら」の 2 列だけで分ける (全 52 列から 2 列を選べば、3 著者はほぼ分かれる)。両方とも標準化してあるので、目盛りは標準偏差を単位とする。




図 7.21 同じ 40 点に 6 つの手法で境界を引いた。背景の色が、その位置に来た作品をどの著者と答えるかを表す (黄が吉川英治、青が夏目漱石、赤が泉鏡花の領域)。この 2 列だけを使った層別 5 分割 CV の正解率はどれも 0.900 から 0.975 の間で大差ないが、境界の形はまるで違う。

図 7.21 を見比べてほしい。

- $k = 1$ の **k 近傍法**は、点のまわりを囲むように境界が入り組む。1 点でも飛び地があれば、そこに小さな島ができる
- $k = 15$ にすると島が消え、なめらかな 3 分割になる。 k は境界の細かさを決めるパラメータである
- **決定木**の境界は必ず**軸に平行**である。「『は、』の割合 (標準化後) > 0.3 か」という質問しかできない

いので、斜めの境界を階段で近似するしかない

- ランダムフォレストも階段だが、300 本の木の数決なので刻みが細くなり、角が丸く見える
- ロジスティック回帰は直線だけで区切る。3 クラスなので、1 点から出る 3 本の半直線で平面を 3 つに区切る形になる
- SVM(RBF) はなめらかな曲線で囲む。カーネルが曲がった境界を許すためである

この 40 作品を 2 列だけで判別したときの層別 5 分割 CV の正解率は、 $k = 1$ の k 近傍法で 0.950、 $k = 15$ で 0.900、決定木で 0.925、ランダムフォレスト、ロジスティック回帰、SVM はいずれも 0.975 である。直線でしか区切れないロジスティック回帰が、最も成績のよい側に並んでいる。数字は近いのに、モデルが世界をどう切っているかは違う。未知の点がどこに来るかによって、どの手法が当てるかも変わる。

SVM の境界の形は、RBF カーネルの γ でも大きく変わる。同じ 40 作品で γ だけを変えたのが図 7.22 である。既定値はこの 2 列では $\gamma = 0.5$ で、図 7.21 の SVM はこれにあたる。 $\gamma = 0.05$ ではほぼ直線の境界になり、 $\gamma = 50$ では 1 点ずつを小さな島で囲む。島で囲むと訓練データには合うが、層別 CV の正解率は 0.575 まで落ちる。




図 7.22 RBF カーネルの SVM で γ だけを変えた境界 (図 7.21 と同じ 40 作品・2 列、 $C = 1$)。各パネルの表題の下に数字は、この 2 列だけを使った層別 5 分割 CV の正解率。 γ が小さいと直線に近く、大きいと点のまわりに細かく巻きつく。

○ 定石 7.4 — 成績が並んだときは境界の形か誤りの型で選ぶ —

交差検証の平均が 0.01 しか変わらない 2 つの手法は、その差では選べない (第 8 章)。決め手になるのは次のような性質である。

- 境界の形が、その領域で期待される形に近い (軸に平行な境界が自然な問題もあれば、なめらかな境界が自然な問題もある)
- 誤りの型が許せるか (混同行列を見る。第 8 章)
- 説明できるか、速いか、新しいデータに追従できるか

図 7.21 のような図は、2 列に絞らないと描けない。それでも、手法の癖を一度目で見ておくと、数字だけを見ていたときより判断が速くなる。

コラム 同じくらい当たるモデルはいくつもある —— 羅生門効果

ランダムフォレストを考案した Leo Breiman は、同じ 2001 年に「統計モデリングの 2 つの文化」という論文を書いている [81]。その中で彼は、予測の誤差がほぼ同じ最小値になる式が、同じ種類のモデルの中にたくさん見つかることを指摘し、これを**羅生門効果** (Rashomon effect) と呼んだ。名前は、1 つの出来事を 4 人の登場人物がまったく違うように語る黒澤明の映画『羅生門』から取られている。

本章にもその例がいくつも出てきた。図 7.21 の 6 つの手法は、正解率が 0.900 から 0.975 に並んだが、引いた境界の形はまるで違った。多重共線性の節では、平仮名と漢字の係数の組を谷に沿って動かしても予測の誤差はほとんど変わらなかった (図 7.6)。どちらの場合も、データは「どれか 1 つが正しい」とは教えてくれない。

Breiman がこの現象を重く見たのは、モデルから説明を読み取るときである。誤差が同じなら、どのモデルの係数や重要度を信じるかはデータからは決まらない。1 つのモデルだけを見て「この列が判別を支えている」と読むと、同じくらいよい別のモデルでは違う話になりうる。

7.11 判別を支えている特徴を突き止める

ここまでで正解率は出た。次に問うべきは、何を根拠に当てているのかである。確かめ方を 2 つ見る。特徴を群ごと抜き差しする方法と、1 列ずつ壊してみる方法である。

7.11.1 特徴群の抜き差し (アブレーション)

第 3 章で作った 3 種類の特徴を、単独あるいは組み合わせでランダムフォレストに与え、74 作品の著者を層別 5 分割の交差検証で判別したときの正解率を測る。

表 7.9 特徴群ごとの正解率 (74 作品、ランダムフォレスト、層別 5 分割の交差検証、分割の乱数は 1 通り)

使った列	列数	正解率
字種の比率だけ	3	0.419
文長 μ, σ だけ	2	0.569
字種 + 文長	5	0.635
読点前平仮名だけ	47	0.917
すべて	52	0.987

基準線 (最頻クラスを答え続ける) は 0.284 である。表 7.9 を順に読み取っていく。

- **読点前平仮名の 47 列だけで正解率 0.917 に達する。**第 3 章で「本書で最も判別力の高い特徴」と予告したことの実証である。読点をどこで打つかという癖だけで、8 人の著者はほぼ判別できてしまう
- 字種 3 列だけでも正解率 0.419 ある。基準線 0.284 を 0.135 上回るので、無力ではない。図 3.7 で見た著者ごとのまとまりが、そのまま成績になっている
- 52 列を全部合わせた正解率 0.987 は、読点単独の 0.917 を 0.070 上回る。弱い特徴群も、強い特徴群が間違える作品を拾う形で寄与している。第 8 章の混同行列 (図 8.5) で見る「漱石と藤村を分けるのは読点の癖」という逆算と、表裏の関係にある

7.11.2 置換重要度 — 1列ずつ壊す

群ではなく個々の列の寄与を見るには、**置換重要度** (permutation importance) を使う。テストデータの**1列だけをシャッフル**して正解率がどれだけ落ちるかを測る。その列が使われていなければ、壊しても成績は落ちないはずである。




図 7.23 置換重要度の上位 10 列。値は、その列をシャッフルしたときにテスト側の正解率が下がった量である。ランダムフォレストを 74 作品の層別 5 分割の交差検証で学習し、各フォールドのテスト側で 20 回置換した平均を、さらに 5 つのフォールドで平均した。1 位は「の、」の 0.0537、2 位は「っ、」の 0.0423 である。

図 7.23 で目を引くのは、上位に入っていない文字のほうである。頻度最大の「て、」は全読点の 17.5%(作品ごとの割合の平均) を占めるのに、置換重要度の順位は 52 列中 26 位である。一方、2 位の「っ、」は第 3 章のゼロの話で出てきた、74 作品中 42 作品では**一度も現れない列**である。

理由を考えれば説明がつく。「て、」は**誰もが打つ**ので、差がつきにくい。「っ、」は「あっ、と叫んだ」のような書き方を**する作家としない作家に割れる**ので、出現の有無そのものが署名になる。よく出るものより、**人によって使い方が割れるもの**が判別の決め手になる。第 2 章で「ポアソン分布に従う機能語を選べ」と言ったのは題材への依存を避けるためだったが、その中でどれが寄与するかは、著者間のばらつきで決まる。

1 位の「の、」は、その中間にあたる。「て、」ほど誰もが打つわけではなく、「っ、」ほど使う人と使わない人に割れるわけでもない。2 つの中間で、そこそこ出るうえに作家ごとに割合が違う。判別に最も寄与するのは、**頻度と個人差が両方そろった列**である。

× アンチパターン 7.5 — 不純度重要度だけを見る —

ランダムフォレストが標準で出す重要度 (feature_importances_) は、訓練中の分割でどれだけ不純度を下げたかの集計であり、**訓練データで測った量**である。実際、本書のデータで比べると (図 7.24)、不純度重要度の 1 位は「っ、」、2 位は「は、」で、「は、」は置換重要度では 7 位である。上位 10 列のうち両方に入るのは 6 列にとどまり、不純度重要度だけで上位 10 列に入った列には、置換重要度では 44 位まで下がるものもある。過学習した木が訓練データの中でだけ役立てた特徴も、高く出てしまう。重要度は**テストデータ側で測る**。置換重要度をテスト

側で計算すれば避けられる。




図 7.24 不純度重要度と置換重要度の順位の比較 (74 作品、ランダムフォレスト、層別 5 分割の交差検証)。不純度重要度は各フォールドの訓練側で学習した森の `feature_importances_` の平均、置換重要度は図 7.23 と同じもの。両方の上位 10 列に入る列を青の実線で、片方だけに入る列を灰色の破線で結んだ。

× アンチパターン 7.6 — 特徴重要度を因果や本質と読む

置換重要度が示すのは「このモデルが、このデータでその列に頼っている度合い」である。「著者性の本質は特定の 1 文字の前の読点にある」という主張ではない。

相関の強い特徴どうしても、重要度が分け合われることにも注意がいる。片方をシャッフルしても、もう片方が肩代わりするので、どちらの重要度も実際の寄与より低く出る。似た列をまとめてから測る (本節のアブレーションはその一形態である) か、相関構造と合わせて読む。

同じ現象が、本章で見た 3 つの道具すべてに現れる。線形モデルの係数では符号ごと入れ替わり (第 7.4 節)、L1 正則化では片方だけが残る (すぐ後で見る)、置換重要度では両方が低く出る。道具を変えても、**相関した列のどちらが寄与しているかは分からない**。分からないものを分けようとせず、グループとして扱うほうが筋が通っている。

L1 が 0 を作るのは係数の動ける範囲が角を持つからである 罰の大きさを入で調整するかわりに、**罰の値をある大きさ以下に抑える**という言い方に置き換えると見通しがよい。両者は同じことを別の側から書いたものである。すると係数の動ける範囲が、L1 では**ひし形**、L2 では**円**になる。

図 7.25 のとおり、違いは**角があるかどうか**だけである。ひし形の頂点は軸の上にあるので、そこで触れれば片方の係数が 0 になる。列が増えれば頂点も辺も増えるが、尖っている場所ほど触れやすいという性質は変わらない。L1 がいくつもの係数を同時に 0 にするのは、そのためである。




図 7.25 L1 と L2 で解の形が変わる理由。青い領域は、罰の値が上限以下に収まる係数の範囲である。灰色と赤の円は予測誤差の等高線で、中心が罰を課さないときの解である。解は等高線が青い領域に最初に触れる点(赤い円の接点)になる。ひし形には尖った頂点があり、そこは軸の上なので係数の1つが厳密に0になる。円には尖った点がないので、触れる場所は軸から外れる。

× アンチパターン 7.7 — L1 が残した列を「重要な列」と読む

変数選択の道具として使えることと、残った列だけが判別に寄与しているということは別である。

強く相関した列が複数あるとき、L1 はそのうち 1 本だけを残して他を 0 にする性質を持つ。どれが残るかは、標本のわずかな違いで入れ替わる。平仮名と漢字のように連動する 2 列があれば、ある分割では平仮名が残り、別の分割では漢字が残る、ということが起きる。

残らなかったほうが無関係なのではない。残ったほうと同じ情報を持っていたから消された。それを「漢字は判別の役に立たない」と読むと、逆の結論になりかねない。

相関した列をまとめて扱いたいときは、罰し方を変える。どれを使うかは、グループの境目を人が知っているかどうかで決まる。

- **Elastic Net** — L1 と L2 を混ぜる。グループの指定は要らない。L2 の項が相関した列の係数を一緒に縮めるので、1 本だけ残して他を切る挙動がやわらぐ
- **Group Lasso** — 列をあらかじめグループに分けておき、グループ単位で丸ごと残すか落とすかを選ぶ。本書の 52 列なら、字種 3 列・文長 2 列・読点前 47 列という 3 つのグループが自然に決まる。カテゴリ変数をダミー展開した列も、1 つの変数から出たものなのでまとめて扱いたい
- **Sparse Group Lasso** — グループを選んだうえで、グループの中でも列を絞る

グループの境目が分からないなら Elastic Net、分かっているなら Group Lasso、と考えればよい。


同じ理由で、L1 が選んだ列の数も鵜呑みにできない。第 4.4.2 項の正則化パスで最後まで残った 3 列という数字は、図に描いた α の範囲の右端 ($\alpha = 7.9$) で残った列の数である。 α をもっと大きくすれば減り、小さくすれば増える。「判別に必要な情報が 3 列ぶんある」という意味にはならない。読点前の 47 列は互いに相関しているので、残った列は、落とされた列が持っていた情報も肩代わりしている。

発展 SHAP — 貢献度を公平に配る

置換重要度は「モデルが全体としてどの列に頼っているか」を教えるが、「この作品が太宰治と判定されたのは、どの列のおかげか」には答えない。1件ごとの判定を特徴に分解する道具が **SHAP** (SHapley Additive exPlanations) である。

原理は協力ゲーム理論の **Shapley 値** (1953 年)[85] である。素朴に言えば次の考え方になる。特徴たちを、共同で予測値を作るプレイヤーとみなす。ある特徴の貢献は「その特徴が加わった瞬間に予測がどれだけ動いたか」。ただしその量は先に誰が入っていたかに依存するので、**参加順のすべての並べ方について平均する**。これが Shapley 値である。Shapley 値の配り方は、「全員の取り分を足すと、予測値と基準値 (平均的な予測) の差に一致する」「同じ働きをする 2 人の取り分は等しい」「何もしない人の取り分は 0」という公平性の要請を (技術的な条件とあわせて) 満たす**唯一**の配り方であることが証明されている。

実例を 1 つ。74 作品すべてで学習したランダムフォレストが『斜陽』を太宰治と判定する確率は 0.823 である。この確率を TreeSHAP で分解すると、基準値 0.094 (モデルの平均予測。ここではほぼ太宰治の事前の割合 7/74 に一致する) の上に、「は、」の SHAP 値 +0.082、「と、」の +0.052、「ら、」の +0.043、……と 52 列分の寄与が積み上がり、**足すとちょうど 0.823 に一致する**。足し算が必ず合うこと (加法性) が SHAP の利点で、「どの癖がどれだけ寄与したか」を 1 作品単位で示せる。審査や診断のように、個々の判定に説明責任がある場面で使われる理由である。



上の図が『斜陽』の分解である。いちばん上の基準値から始めて、各列の取り分を 1 行ずつ右 (正の寄与) か左 (負の寄与) へ積んでいく。最後の行まで積むと、予測確率 0.823 にぴったり一致する。

問題は計算量で、「参加順のすべての並べ方」は $52! \approx 8 \times 10^{67}$ 通り、連合 (特徴の部分集合) の数でも $2^{52} \approx 4.5 \times 10^{15}$ 通りあって、定義どおりには計算できない。実用になっているのは近似と特化のおかげである。モデルを問わない **KernelSHAP** は、連合をサンプリングして重み付き回帰で Shapley 値を推定する。木のモデルに限れば、木構造を利用して厳密値を多項式時間で計算する **TreeSHAP** がある [86, 87]。上の数字も TreeSHAP による。

注意は置換重要度のときと同じである。SHAP が配っているのは「このモデルがこの予測を作った内訳」であって、著者性の因果ではない。関連した特徴の間でどう配るかにも流儀があり、実装の設定しただけで値は変わる。数字の細部より、「基準値からの差を、公平の公理に従って特徴に配る」という枠組みごと覚えておくのがよい。

なお、ここまでの数字はすべて交差検証で測っている (SHAP の例だけは、判定の説明が目的なの

で学習済みモデルをそのまま使った)。

手で組み立てた 52 列の代わりに、大規模言語モデルの埋め込みや深層学習のモデルを使うとどうなるか。その比較は、評価の作法と漏れの避け方がそろってからのほうが読みやすいので、第 10 章に置いた。

7.12 同じ長編の巻が訓練とテストに分かれている

74 作品を層別 5 分割の交差検証で判別したときの、ランダムフォレストの正解率が 0.987 である。8 名の著者を、52 個の数値でほぼ完璧に当てている。

だが、素直に喜ぶ前に確かめたいことがある。

第 6 章の図 6.8 では、吉川英治の作品は右寄りに並び、なかでも『三国志』の各巻は小さく固まっていた。第 1 章の表 1.2 によれば、吉川英治の 21 作品のうち 17 は『三国志』と『宮本武蔵』を巻ごとに分けたもので、もう 1 点は『三国志』の篇外余録である。

層別の交差検証は、著者の比率だけをそろえて作品を分ける。つまり『三国志』の第 3 巻で訓練し、第 4 巻でテストすることが起きている。

同じ長編の別の巻。登場人物も舞台も語彙もほぼ同じである。モデルは「吉川英治の文体」を学ばなくても、「この長編に固有の癖」を覚えれば当てられてしまう。表 7.4 の「シリーズを分けた CV」は、この心配を確かめるために同じ長編の巻をまとめて片側へ置いた測り方だった。ランダムフォレストでは落差が +0.011 と小さかったが、それは 52 列の特徴で、乱数 1 通りの分割で測った場合の話である。

これはデータ漏洩 (data leakage) の一種である。第 9 章で、正しく測り直すと数字がどれだけ変わるかを見る。

その前に、次章で「正しく測る」とはどういうことかを整理しておく。

7.13 章末の課題

1. 決定木の深さを 1 に制限して学習し、木を描け。モデルは何を根拠に判定しているか。
2. 図 7.3 では、 $k = 1$ の k 近傍法の訓練データでの正解率が 1.000 になった。この値が 1.000 にならない例外 (どんなデータのときか) を説明せよ。
3. 表 7.6 でロジスティック回帰とランダムフォレストがほぼ同じ成績である。どちらを選ぶべきか、判断材料を 3 つ挙げよ。
4. `stratify=y` を外して 7:3 分割を 20 回繰り返し、テストデータに含まれる柳田国男の作品数を記録せよ。0 になったのは何回か。
5. 置換重要度を k 近傍法 ($k = 5$ 、標準化つき) で計算し直し、図 7.23(ランダムフォレスト) と上位の順位を比べよ。(ヒント: 重要度は「そのモデルが」使った度合いであり、モデルを替えれば順位も変わりうる。大きく変わる列と変わらない列のどちらが信頼できるかも考えよ。)

第8章

正しく測る

8.1 1回の分割では足りない

前章で、74 作品を 7:3 に分けて決定木を学習させ、テストデータでの正解率 0.783 を得た。データの 7 割で学習し、残りの 3 割で成績を測る、というやり方である (74 作品なら訓練 51 作品、テスト 23 作品になる^{*1})。このように一度だけ分けて測ることを**ホールドアウト** (hold-out) という。

分け方は乱数で決めた。乱数の引き方が違えば、この 0.783 という正解率も変わりうる。どれだけ変わるのかを確かめる方法がある。**分割の乱数だけを変えて**、同じことを 50 回繰り返す。データもモデルも設定も変えない。変えるのは分け方だけである。




図 8.1 同じ 74 作品・同じ決定木で、7:3 の分割の乱数だけを変えて 50 回測った、テストデータでの正解率の分布。

50 回のテストデータでの正解率は、最小 0.478、最大 0.870、平均 0.690、標準偏差 0.084 であった。

最大と最小の差が 0.39 ある。最悪の引きでは正解率が 0.478 で半分も当たらず、最良の引きでは 0.870 で 9 割近く当たる。どちらも同じモデルを同じデータで測った結果である。

前章の正解率 0.783 が、この 50 回の中でどのあたりに位置するかも確かめておく。50 回の平均 0.690 を 0.093、つまり標準偏差 0.084 の 1 つぶん以上、上回っている。あの数字は、平均よりかなり高めの引きだったことになる。

論文に書かれた「正解率 0.870」が、実は何回も引いた中の当たりくじだったということは起こりうる。そして書いた本人にその自覚がないことも多い。乱数の種を変えて何度か走らせ、いちばん良い数字を残す。悪気なくそうしてしまう。データが小さいほど振れ幅は大きく、本書のデータでは 1 作品の当たり外れで正解率が 0.043 も上下する。「乱数の種を変えたら数字が変わった」という経験がないうちは、1 回の分割を信じてしまいがちである。一度自分で確かめておくとよい。

^{*1} `train_test_split` は、テスト側の件数を $0.3 \times 74 = 22.2$ の端数を切り上げて決める。

8.2 交差検証

振れ幅の原因は、テストに回る作品が 23 点しかないことにある。たまたま易しい 23 点を引けば高く、難しい 23 点を引けば低く出る。

かといってテストを増やせば、訓練に回る作品が減る。どちらを増やしても、もう一方が減る。

k 分割交差検証 (k -fold cross-validation) は、この板挟みを**全部の作品に 1 回ずつテストを担当させる**ことで抜ける。データを k 個の塊に分け、1 つをテスト、残りを訓練にして測る。これをテスト役を入れ替えながら k 回繰り返す。 k 回終われば、どの作品もちょうど 1 回テストに使われたことになる。第 7.2 節では、分けた 1 つ 1 つの塊を**フォールド** (fold) と呼んだ。本章では、その塊をテストに回して測る 1 回ぶんもフォールドと呼ぶ。




図 8.2 5 分割交差検証。全データが 1 度ずつテストに使われる。

5 回の正解率の平均を報告する。5 回のあいだで数字がどれだけ振れたかも意味を持つので、標準偏差も一緒に出す。

○ 定石 8.1 — 分割数は 5 か 10 から始めてデータが少ないときだけ増やす —

$k = 5$ か $k = 10$ が標準的な選び方である。

データが少ないときは k を大きくする。 k を大きくするほど 1 回あたりの訓練データが増えるからである。その代わり学習を k 回やり直すので、計算時間も k に比例して伸びる。

どちらを選んでも、報告するのは平均だけではない。ばらつきの添え方は第 8.4.2 項で扱う。

k を大きくする方向の極端は、データ件数に等しく取ることである。1 件だけをテストにして残り全部で訓練する形になり、これを**1 つ抜き交差検証** (leave-one-out cross-validation、LOOCV) という。訓練データを最大限に使えるので偏りは小さくなるが、学習を件数ぶん繰り返すので計算が重い。それに、 k 個の結果は訓練データをほとんど共有しているので互いに強く相関し、そこから計算したばらつきは信用しにくい。本書は 5 分割を使っている。

8.2.1 層別交差検証

分けるときには、もう一つ気をつけることがある。柳田国男は 5 作品しかないのに、何も考えずに 5 分割すると、柳田の作品が 1 つも入らない回や、逆に 2 つ入る回ができる。前者の回では柳田を当てる機会がなく、後者では 1 件の外れが大きく響く。

そこで分割のあとも**各著者の比率が元の表にできるだけ近くなるように**分ける。柳田国男の 5 作品

なら各回に 1 作品ずつ、吉川英治の 21 作品なら各回に 4 か 5 作品ずつ入る。これを**層別化**という。**StratifiedKFold** を使えば自動でそうなる。表 8.1 は、本書で使う乱数で 5 分割したとき、各回のテストに 3 人の著者の作品がいくつ入ったかを数えたものである。

表 8.1 5 分割の各回のテストに入った作品数 (74 作品、分割の乱数は本書の他の箇所と同じ)。括弧内は全体の作品数

分け方	著者	1 回目	2 回目	3 回目	4 回目	5 回目
層別なし KFold	吉川英治 (21 作品)	1	4	4	9	3
	谷崎潤一郎 (6 作品)	0	2	1	2	1
	柳田国男 (5 作品)	2	2	0	0	1
層別あり StratifiedKFold	吉川英治 (21 作品)	5	4	4	4	4
	谷崎潤一郎 (6 作品)	1	1	1	2	1
	柳田国男 (5 作品)	1	1	1	1	1

層別なしでは、柳田国男の作品が 2 つ入る回と 1 つも入らない回があり、吉川英治は 1 作品しか入らない回と 9 作品が入る回がある。層別ありでは、どの著者も各回にほぼ同じ数ずつ入る。

74 作品をランダムフォレストで判別し、5 分割交差検証の正解率を層別化ありとなしで比べたのが表 8.2 である。

表 8.2 層別化の有無で 5 分割交差検証の正解率がどう変わるか (74 作品、52 列、ランダムフォレスト)

分割	正解率の平均	最小の回	最大の回
層別なし KFold	0.933	0.867	1.000
層別あり StratifiedKFold	0.987	0.933	1.000

平均の差より、**最小の回**に注目してほしい。層別なしでは 5 回のうち最も悪い回の正解率が 0.867 で、層別ありの最も悪い回の 0.933 を 0.066 下回っている。層別なしの最も悪い回は 2 つあり、一方はテスト 15 作品のうち 9 作品が吉川英治、もう一方は谷崎潤一郎と柳田国男が 2 作品ずつ入った回だった。

ただし、表 8.2 は分割の乱数を 1 通りだけ使った値である。前節のホールドアウトと同じく、乱数を変えれば交差検証の平均も動く。乱数だけを 50 通り変えて、層別あり・なしの 5 分割交差検証を繰り返した結果が図 8.3 である。

層別ありの平均正解率は 0.932 から 0.987 に散らばり、平均は 0.966 だった。層別なしは 0.878 から 0.973 で、平均は 0.935 である。最も悪い回の正解率を 50 通りで平均すると、層別ありが 0.902、層別なしが 0.849 で、層別化の利点は乱数を変えても残る。一方、本書が第 7 章からランダムフォレストの成績として使ってきた 0.987 は、層別ありの分布の上端にあたる。50 通りの中で最も高い値で、同じ 0.987 が出たのは本書の乱数を含めて 5 通りだった。乱数の違いだけで平均が標準偏差 0.013 ほど動くので、他の手法との差がこの程度に収まるときは、どちらが良いとは言えない。本書




図 8.3 分割の乱数だけを 50 通り変えて 5 分割交差検証を繰り返したときの、ランダムフォレストの平均正解率 (74 作品、52 列)。1 つの点が 1 回の交差検証の平均である。点が重ならないよう縦に少しずらしてある。赤い縦線は表 8.2 の値 (本書が使う乱数)。

では比較の条件をそろえるため、以後もこの乱数の値を使う。

8.3 正解率だけでは足りない

正解率だけを見ることには限界がある。

吉川英治は全体の 28% を占めるのだった。正解率が高くても、柳田国男の 5 作品を 1 つも当てられていないかもしれない。5 作品を全部落としても、正解率は $5/74 = 0.07$ しか下がらないからである。全体の数字 1 つでは、少数の著者が丸ごと捨てられていても気づけない。

そこで、著者ごとに成績を出す。

ここで見方を 1 つ変える。「8 名の誰か」を当てる問題として見るのをやめ、「太宰治か、そうでないか」という 2 択の問題を、著者ごとに 8 つ立てる。太宰治についての 2 択、夏目漱石についての 2 択、というふうに 8 回考える。1 つの 2 択に注目すれば、予測と正解の関係は 4 通りしかない。

	その著者と予測	違うと予測
実際に その著者	真陽性 TP	偽陰性 FN (見逃し)
実際は 違う著者	偽陽性 FP (誤検出)	真陰性 TN

図 8.4 ある著者 1 名に注目したときの、予測と正解の 4 通り。著者ごとにこの表を 1 枚ずつ作る。

太宰治を例にとる。太宰治の作品を太宰治と当てたものが真陽性 (TP)、太宰治なのに他の著者と答えたものが偽陰性 (FN)、他の著者なのに太宰治と答えたものが偽陽性 (FP)、他の著者を他の著者と答えたものが真陰性 (TN) である。「陽性」はいま注目している著者だと判定したという意味で、病気の検査の言い方をそのまま借りている。

この 4 つの数から、3 つの指標を作る。

$$\text{適合率 (precision)} = \frac{TP}{TP + FP} \quad (8.1)$$

$$\text{再現率 (recall)} = \frac{TP}{TP + FN} \quad (8.2)$$

$$F_1 = \frac{2 \cdot \text{適合率} \cdot \text{再現率}}{\text{適合率} + \text{再現率}} \quad (8.3)$$

言葉にすると、

- **適合率 (precision)** — そう予測したもののうち、実際に当たっていた割合。誤検出の代償が大きいときに重視する
- **再現率 (recall)** — 実際にそうだったもののうち、当てられた割合。見逃しの代償が大きいときに重視する
- F_1 — 両者の調和平均。バランスを見る^{*2}

適合率と再現率のどちらを重く見るかを変えたいときは、一般形

$$F_\beta = \frac{(1 + \beta^2) \cdot \text{適合率} \cdot \text{再現率}}{\beta^2 \cdot \text{適合率} + \text{再現率}} \quad (8.4)$$

を使う。 β は再現率を適合率の何倍重く見るかを表し、 $\beta = 1$ が F_1 である。添字の 1 はこの β の値を指す。文字 F 自体に意味はない。van Rijsbergen の教科書 *Information Retrieval*(1979) の有効性指標 E に由来する量が、評価会議 MUC-4(1992) で採用された際に、同書の別の関数の記号 F で呼ばれてしまい、そのまま定着したとされる [88, 89]。

8.3.1 マクロ平均とマイクロ平均

著者ごとに F_1 が 8 個出たので、これを 1 つの数にまとめたい。まとめ方が 2 通りある。

- **マクロ平均 (macro-average)** — 著者ごとの F_1 を 8 個そのまま平均する。21 作品の吉川英治も 5 作品の柳田国男も同じ 1 票になる
- **マイクロ平均 (micro-average)** — 著者ごとに分けて、8 名分の TP・FP・FN を全部足してから 1 回だけ計算する。作品数の多い著者の影響が大きい

多クラスでは、マイクロ平均は必ず正解率と一致する。1 件間違えると、間違えた先の著者では偽陽性が 1 つ、本当の著者では偽陰性が 1 つ増える。8 名分を足し合わせると分子は正解した件数、分母は全件数になり、正解率の式と同じものになるからである。

偏りのあるデータでは、2 つの差そのものが情報になる。マクロ平均だけが低ければ、少数の著者を取りこぼしている。

74 作品を 52 列すべてでランダムフォレストに判別させ、層別 5 分割交差検証で著者ごとの適合率・再現率・ F_1 を測った。結果を表 8.3 に示す。

^{*2} 算術平均でなく**調和平均**を使う理由は 2 つある。一つは、調和平均が小さいほうに強く引きずられること。適合率 1.0 でも再現率 0.1 なら $F_1 = 0.18$ にしかならず、片方を犠牲にした「見かけの高得点」を許さない (算術平均なら 0.55 になってしまう)。もう一つは、適合率と再現率が**同じ分子 TP を持つ割合**であること。分子が同じ割合どうしは、調和平均を取ると分母のほうに平均されて $F_1 = 2TP / (2TP + FP + FN)$ というきれいな形にまとまる。誤りの総量 $FP + FN$ を 1 つの分母に束ねた指標、と読める。

表 8.3 著者ごとの適合率・再現率・ F_1 (74 作品、52 列、ランダムフォレスト、層別 5 分割交差検証)

著者	適合率	再現率	F_1	作品数
吉川英治	1.000	1.000	1.000	21
夏目漱石	1.000	1.000	1.000	10
島崎藤村	1.000	1.000	1.000	9
泉鏡花	1.000	1.000	1.000	9
太宰治	1.000	1.000	1.000	7
夢野久作	1.000	1.000	1.000	7
谷崎潤一郎	1.000	0.833	0.909	6
柳田国男	0.833	1.000	0.909	5
マクロ平均			0.977	
正解率 (マイクロ)			0.986	

誤りは 74 作品中 1 件だけである。谷崎潤一郎の随筆『陰翳礼讃』を、柳田国男と誤判定している。その 1 件が、谷崎の再現率を $5/6 = 0.833$ に、柳田の適合率を $5/6 = 0.833$ に下げている*³。本書の谷崎の作品のうち、『陰翳礼讃』以外は小説である。柳田の作品は民俗学の文章なので、字種や読点の特徴は、書き手だけでなく文章の種類も拾っていることがうかがえる。

作品数の多い 6 名の F_1 が 1.000 なので正解率は 0.986 と高いが、マクロ平均 F_1 は 0.977 にとどまる。少数の著者での取りこぼしは、正解率にはほとんど現れず、マクロ平均 F_1 には現れる。

8.3.2 混同行列 — 誤りの型から足りない特徴が分かる

平均された数値だけでは、どの著者とどの著者を取り違えたかが分からない。混同行列 (confusion matrix) は行が正解、列が予測である。

ただし、そのまま描いても読むものが出てこない。8 名を当てる問題を 52 列すべてでランダムフォレストに解かせると、層別 5 分割交差検証の正解率が 0.9 を超え、行列はほぼ対角線だけになるからである。そこでわざと難しくした設定を右に並べる。特徴を字種 3 列と文長 2 列の計 5 列に間引き、読点の癖という強力な手がかりを封じた状態である。

(b) には模様がある。夏目漱石と島崎藤村が相互に混ざる (漱石 10 作品中 2 作品が藤村に、藤村 9 作品中 3 作品が漱石に化ける)。泉鏡花は 9 作品中 5 作品が吉川英治と誤判定される。字種の比率と文の長さだけで見ると、鏡花の文語調と吉川の講談調は似た位置に来てしまう。全列に戻すとこれらの誤りは消える。つまり漱石と藤村、鏡花と吉川を分けているのは読点の癖だと、誤りの型から逆算できる。

数値の要約より先に混同行列を見る習慣をつけるとよい。「A を B と間違える誤りが多い」というパターンが見えれば、その 2 クラスを分ける特徴が足りないと分かる。これは平均された F_1 からは読み取れない。逆に (a) のような対角行列しか出ないなら、その課題はもう評価の役に立たない

*³ $73/74 = 0.986$ である。表 8.2 など他の箇所でも 0.987 と書いているのは、5 回の分割それぞれで正解率を出してから平均した値である。全体をまとめて数えるか、分割ごとに出してから平均するかで、小数第 3 位が食い違う。




図 8.5 混同行列。行が実際の著者、列が予測した著者で、色は行内の割合。対角線が正解、それ以外が取り違えである。どちらも 74 作品をランダムフォレストで判別した層別 5 分割交差検証の結果で、括弧内は 74 作品全体をまとめて数えた正解率。マスの数字は作品数 (0 のマスは省いた)。(a) はほぼ対角線だけで読むものがない。(b) のように課題を難しくすると、誤りの型が現れる。

ほど簡単だということである。

8.4 成績の不確かさを添える

8.4.1 小数第 3 位は偶然の範囲に収まる

ここまで正解率を小数第 3 位まで書いてきた。だがその桁に意味があるかどうかは、別に考えなければならない。

正解率は「74 作品のうち何作品を当てたか」という割合である。割合には、標本の大きさから来る不確かさがつきまとう。コインを 10 回投げて 7 回表が出ても、そのコインの表の出やすさが 0.7 だとは言えないのと同じである。

74 件中 73 件を当てたときの 95% 信頼区間を計算すると*4、

$$\text{正解率 } 0.986 \quad (95\% \text{ 信頼区間 } [0.927, 1.000])$$

となる。下端は 0.927 である。つまりこのデータから言えるのは「真の正解率が 0.927 を下回るとは考えにくい」までであって、0.986 という数字そのものではない。

*4 二項比率の信頼区間で、Clopper-Pearson の方法による。`scipy.stats.beta.ppf` で計算できる。なお二項比率の区間は各件の当たり外れが独立であることを仮定するが、交差検証の予測は訓練データを共有していて独立ではない。ここでの区間は目安として読む。

補足 「95%」が何にかかっているか

信頼区間の 95% は、**確率**である。ただし、**何の確率か**に注意が要る。

データを取る前の段階を考える。これから取るデータに同じ手続きを当てはめて区間を作ったとき、その区間が真の値を含む確率が 0.95 になるように、区間の作り方が決めている。Neyman はこの確率を**信頼係数** (confidence coefficient) と呼んだ。今日では**被覆確率** (coverage probability) と呼ぶことが多い。確率が付いているのは**区間を作る手続きのほう**である。真の値は決まってい動かぬ。動くのは、データとそこから作られる区間である。

同じことは、繰り返しの割合としても書ける。同じ手続きでデータを取り直して区間を作る操作を何度も繰り返せば、そのうち 95% が真の値を含む。「100 回やれば 95 回」という説明はこれを指しており、被覆確率と別のことを言っているわけではない。

一方、いま手元にある**この 1 本の区間**は、すでに 2 つの数値として確定している。真の値を含んでいるか、いないかのどちらかである。「この区間に真の値がある確率は 95%」と言いたければ、真の値の大きさについての**事前分布**をもう一つ仮定する必要がある、そうして得られる区間は**信用区間** (credible interval) と呼んで区別する [77]。どちらの立場を取るべきかは長く議論されてきたところで、本書はその判定に立ち入らない。本書が区間を使う目的、つまり「小数第 3 位を真に受けない」「差を見るときは差の区間を計算する」は、どちらの立場でも変わらないからである。

そして、どちらの読み方をするにせよ、95% という数字は**計算に使った仮定がすべて正しいとき**の話である。正規分布を仮定したなら、その仮定が現実と合っているかどうかで実際の被覆確率は変わる。実務では、この仮定のほうが解釈の議論よりはるかに大きく結果を左右する。

日常的には「だいたいこのへんらしい」で構わない。気をつけたいのは、**区間の幅を、細かく読んでよい桁数の目安として使う**ことだけである。区間の全幅が 0.07 あれば、小数第 2 位を比べる意味はない。

もう 1 件間違えて 74 件中 72 件だったとすると、正解率は $72/74 = 0.973$ 、その 95% 信頼区間は $[0.906, 0.997]$ になる。73 件のときの区間 $[0.927, 1.000]$ と大きく重なる。1 件の当たり外れで小数第 3 位は変わるが、その動きは**偶然の範囲に収まっている**。

だから**小さなテストデータの成績を小数第 3 位まで比べても意味がない**。「手法 A は正解率 0.986、手法 B は 0.973。A の勝ち」と書きたくなるが、74 件で測った正解率なら、0.986 と 0.973 の差 0.014 は、たった 1 件の当たり外れでしかない。件数が少ないほど、1 件の重みが大きくなる。差が「1 件か 2 件ぶん」に収まっているなら、**どちらが良いとは言えない**と書くのが正しい。第 9.8 節で見ると、たくさんの手法を試して最良を報告すれば、この程度の差は簡単に作り出せる。

○ 定石 8.2 — 成績を報告するときはばらつきの幅を添える —

添え方は 2 通りある。

- **交差検証の標準偏差** — 1 回の交差検証の中で、どのフォールドをテストに回したかで正解率がどれだけ違ったかを表す (第 8.2 節)。1 フォールドの件数が少ないことから来る揺れも含む
- **二項比率の信頼区間** — 件数の少なさから来る不確かさを表す

2 つは別のものを測っている。前者は 1 回の交差検証の中のフォールドどうしの違い、後者は同じ件数のデータを集め直したときの違いである。分割の乱数を変えたときに平均正解率がどれだけ動くかは、どちらとも別の量で、図 8.3 のように乱数を変えて交差検証を繰り返せば測れる (本書のデータでは標準偏差 0.013 で、フォールド間の標準偏差 0.030 とは大きさも違

う)。どちらか一方でも添えてあれば、読み手は小数第 3 位を真に受けずに済む。

8.4.2 エラーバーは 3 通りある

「±」を添えると書いたが、何を添えたのかを書かないと、読み手には伝わらない。グラフに立てるエラーバーにも、よく使われるものが 3 種類ある。どれも見た目は同じ縦棒なので、図だけを見て区別することはできない。

74 作品を 52 列すべてでランダムフォレストに判別させ、層別 5 分割交差検証で正解率を測った結果 (5 回の平均は 0.987) で、3 つを並べてみる。

- 標準偏差 (SD) = 0.030 — 5 回の正解率が、互いにどれだけばらついたか。個々の測定の散らばりである*⁵
- 標準誤差 (SEM) = 0.013 — SD を $\sqrt{5}$ で割った値。5 個の値が互いに独立に得られたと仮定したときの、平均の揺れの目安である (交差検証ではこの仮定が成り立たない。後述)
- 95% 信頼区間 = ± 0.037 — SEM に t 分布の係数 2.78 を掛けたもの*⁶




図 8.6 同じ結果から作った 3 種類のエラーバー。左端の白丸は、もともなった 5 回の正解率である (4 回が 1.000 に並ぶ)。中心はどれも 5 回の平均正解率 0.987 で、長さだけが違う。図の見た目では区別できない。平均 $\pm$ SD の棒は 1.000 を超えて伸びるが、正解率そのものが 1.000 を超えることはない。

図 8.6 のとおり、同じ結果から長さの違う 3 本が作れてしまう。SEM は SD の $1/\sqrt{5}$ 、つまり 2.24 分の 1 である。独立に測った値の個数 n を増やせば、SEM はその平方根に反比例して短くなる。 $n = 100$ なら 10 分の 1 である。ただし交差検証の分割数を増やしても、そうはならない。分割を細かくすると 1 回あたりのテスト作品が減り、各回の正解率の SD のほうが広がるからである。本書のデータで分割数を変えた結果が表 8.4 で、SEM は短くならなかった。エラーバーが短いことは、それだけでは推定が確かなことを意味しない。

平均正解率の列も見えておくとよい。5 分割の値は、3 分割・10 分割・1 つ抜きのどれよりも高い。分割数を増やすほど訓練データが増えて平均正解率が上がる、という傾向は、乱数 1 通りのこの表からは読み取れない。図 8.3 で見たとおり、5 分割の 0.987 はこの乱数での当たりの値だからである。

なお、交差検証の SEM には追加の注意が要る。 $1/\sqrt{n}$ という式は n 個の値が互いに独立であることを前提にしているが、 k 分割の各回は訓練データの大部分を共有しているので独立ではない。その

*⁵ $n - 1$ で割る標本標準偏差である。第 7 章の表 7.6 は n で割っているので、同じ 5 つの値から 0.027 になる。

*⁶ 5 回しか測っていないので、正規分布の 1.96 ではなく、自由度 $5 - 1$ の t 分布の値を使う。

表 8.4 分割数を変えたときの、フォールド間の標準偏差 (SD) と SEM (74 作品、52 列、ランダムフォレスト。1 つ抜きは各回の正解率が 0 か 1 になる)

分割	平均正解率	SD	SEM = $SD/\sqrt{k}$
層別 3 分割	0.946	0.025	0.014
層別 5 分割	0.987	0.030	0.013
層別 10 分割	0.957	0.069	0.022
1 つ抜き ($k = 74$)	0.959	0.199	0.023

ため $SD/\sqrt{k}$ は標準誤差の過小評価になりやすい。交差検証の分散には、どんなデータの分布にも通用する不偏推定量が存在しないことが知られており [124]、ここでの SEM はあくまで目安として読む。

× アンチパターン 8.1 — エラーバーが何かを書かずに図を出す —

「±」の中身を書かなければ、読み手は判断できない。SEM を SD だと思って読めば、散らばりを $\sqrt{n}$ 分の 1 に見誤る。

図のキャプションか凡例に、必ず次の 2 つを書く。

- エラーバーが SD か SEM か信頼区間か
- n がいくつ (平均を何個から計算したか)

読むときも同じで、書いていない図の棒の長さは信じない。

使い分けは、何を伝えたいかで決まる。

- 個体がどれだけばらついているかを見せたい → SD。「作品ごとに成績が違う」ことを伝えたいならこちら
- 平均をどれだけ正確に測れたかを見せたい → SEM か信頼区間
- 2 つの条件の差を論じたい → 信頼区間。ただし次の項の注意が要る

8.4.3 区間が重なっていても差はあるかもしれない

2 つのモデルの成績を並べ、それぞれの 95% 信頼区間が少し重なっているのを見て「差はない」と結論するのをよく見かける。これは正しくない。信頼区間について広く知られた誤読の一つで、統計の誤用を整理した文献にも項目として挙がっている [77]。

作例で確かめる。2 つのモデルを同じ手続きで何度も測り、次の結果を得たとする。

	平均正解率	SEM	95% 信頼区間
モデル A	0.900	0.020	[0.861, 0.939]
モデル B	0.835	0.020	[0.796, 0.874]

0.861 から 0.874 のあいだで、2 つの区間は重なっている。ここで手が止まる人が多い。

実際にすることは 1 つで、**差そのものの信頼区間**を計算する。差の標準誤差は、2 つの標準誤差か




図 8.7 同じ結果を 2 通りに描いた。(a) ではモデル A とモデル B の区間が赤い帯の部分で重なっており、「差はない」と読みたくなる。(b) は差そのものの区間で、こちらは 0(差なし) を含まない。判定に使うのは (b) であって (a) ではない。

ら次のように求める。

$$SE_{\text{差}} = \sqrt{SEM_A^2 + SEM_B^2} \quad (8.5)$$

これは 2 つの測定が互いに独立な場合の式である。同じ分割で 2 つのモデルを測ったのなら、フォールドごとに差を取る対応ありの方式 (第 8.4.5 項) を使う。

足し算ではなく二乗和の平方根なので、2 つを単純に足すよりも短くなる。この差が、次に見る「区間は重なるのに差はある」領域を生む。

作例に当てはめる。差は $0.900 - 0.835 = 0.065$ 、その標準誤差は $\sqrt{0.020^2 + 0.020^2} = 0.028$ である。測った回数が十分多いとして、 t 分布の係数を 1.96 で近似すれば、95% 信頼区間は $0.065 \pm 1.96 \times 0.028 = [0.010, 0.120]$ となり、0 を含まない。区間が重なっていたにもかかわらず、差はあると言ってよい。

図 8.7 が同じことを 2 通りに描いたものである。(a) だけを見て判断すると結論を取り違える。

理由は 2 つの幅を比べれば分かる。2 群の SEM がどちらも s のとき、2 つの区間の端がちょうど接するのは平均の差が $2 \times 1.96s = 3.92s$ のときである。一方、差の区間が 0 を含まなくなるのは $1.96 \times \sqrt{2}s = 2.77s$ を超えたときである。2.77s から 3.92s のあいだが、区間は重なっているのに差はあるという領域になる。作例の $s = 0.020$ なら 0.055 から 0.078 で、差の 0.065 はここに入っている。

片側の結論を出すだけなら、目で見えて使える判定もある。

- 2 つの区間がまったく重ならない → 差はあると言ってよい。 $s_A + s_B \geq \sqrt{s_A^2 + s_B^2}$ が常に成り立つので、重ならない時点で必要な幅を超えている
- 一方の区間がもう一方の平均を含んでいる → 差があるとは言えない。重なりがここまで深ければ、差の区間は必ず 0 を含む
- それ以外、つまり重なってはいるが相手の平均は含まない → 何も分からない。差があるかもし

れないし、ないかもしれない。作例がちょうどこの場合に当たる

要するに、2つの区間を並べて重なりを目で測るのはやめ、式(8.5)で差の標準誤差を出して差の区間を作る。判断することは「区間が0を含むか」の1つだけになる。3つ以上を並べるときは、図の描き方まで変える必要がある。第8.4.5項で扱う。

図の描き方といえば、平均を棒の高さで表し、その上にエラーバーを1本立てた図もよく見る。簡潔だが、**隠すものが多すぎる**。データが何件あるのか、分布が1つの山か2つの山か、外れ値が1点あるだけなのか全体がばらけているのか。どれもこの図からは読み取れず、まったく違う形のデータが、同じ棒と同じ長さの棒になりうる。第4.8.2項の Anscombe の四重奏と同じ話である。件数が数十以下なら、**生のデータ点をそのまま重ねて描く**のがよい。本書の5分割交差検証なら、点は5個しかないのだから、平均と棒を描くより、5個をそのまま並べたほうが情報量が多い。図8.8は、第7章の表7.6の6手法について、5回の正解率をそのまま描いたものである。同じフォールドの点は細い線で結んである。




図8.8 6手法の層別5分割交差検証の、フォールドごとの正解率(74作品、52列)。1つの記号が1回ぶんで、同じフォールドの点を線で結んだ。重ならないよう、フォールドごとに横に少しずらしてある。

ロジスティック回帰とランダムフォレストは、5回のうち4回で満点を取り、誤りのある回はそれぞれ別のフォールドである。決定木だけは回によって0.571から0.867まで大きく動く。平均と棒だけの図からは、こうした違いは読み取れない。件数が多いなら、箱ひげ図やバイオリンプロットで分布の形を見せる。棒とエラーバーだけで済ませるのは、分布の形が明らかに問題にならない場合に限る。

8.4.4 たくさん並べて比べる — フォレストプロット

手法が2つなら差の区間を1本計算すればよい。だが実際には、5つも10も並べて比べるのほうが多い。そのとき定番になっているのが、1行に1手法、点で平均、横棒で区間を描いた図である。医学の分野で複数の研究をまとめるときに使われてきた形で、**フォレストプロット** (forest plot、森林図) という。横棒がずらりと並ぶ様子が林に見えることから、この名前がついた。

第7章の表7.6にある6手法の正解率(74作品、52列、層別5分割交差検証)を、この形で描く。読み方の順序を決めておくと迷わない。

1. **基準線がどこにあるか**を最初に見る。最頻クラスを答え続ける戦略の正解率の95%信頼区間は




図 8.9 6 手法のフォレストプロット。点が層別 5 分割交差検証の平均正解率、濃い細い棒がその手法だけを見たときの 95% 信頼区間、薄い太い棒が 6 手法をまとめて 95% にした区間である。表を眺めるより、どの差が読み取れてどの差が読み取れないかが早く分かる。区間はいずれもフォールド間の $SD/\sqrt{5}$ を標準誤差とした t 区間で、フォールドが独立でないため (第 8.4.2 項)、正式に 95% の被覆を保証する区間ではない。描き方の説明用と考えてほしい。この作り方では、区間の上端が正解率の上限 1 を超えることがある。

[0.25, 0.32] で、他のどれとも重なっていない。並べた手法はすべて基準線を超えている。なお、この区間が狭いのは、層別化によってどのフォールドでも吉川英治の割合がほぼ同じになるため、測り方が確かだからではない

- 棒の長さを見る。決定木の棒がいちばん長い。平均正解率が 0.688 と低だけでなく、測れていないのである
- 最後に順位を見る。上位 3 つは棒が大きく重なっている。順位はついてはいるが、読み取れる差ではない

棒を 2 種類描く理由 — 並べた本数だけ外れやすくなる 区間を 1 本だけ描くときには起きず、たくさん並べたときにだけ起きる問題がある。

1 本ずつは 95% で正しくても、6 本並べれば少なくとも 1 本が外れる確率はおおよそ 26% になる。第 9.8 節の多重テストと同じ構造で、計算もそちらで扱う。なお 6 本の区間は同じデータから作られていて独立ではないので、この 26% という値は独立を仮定した近似である。

図全体を「95% の信頼度で読みたい」なら、1 本あたりの信頼度を上げて棒を伸ばす必要がある。最も素朴なやり方はボンフェローニ補正 (Bonferroni correction) で、5% を手法の数で割り、1 本あたり $5/6 = 0.83\%$ の水準にする。本書の場合、掛ける t 分布の係数が 2.78 から 4.85 へ、つまり棒が 1.75 倍に伸びる。これが薄い太いほうの棒である。

伸ばすと読み方が変わる。決定木とランダムフォレストは、個別の区間では、決定木の上端 0.834 とランダムフォレストの下端 0.950 のあいだに隙間があり、分かれて見える。同時区間になると、決定木の区間は [0.431, 0.944] まで広がり、ランダムフォレストの下端 0.922 を超えて重なってしまう。個別の区間では分かれて見えた 2 つが、6 手法をまとめて主張しようとする分けられなくなる。

ただし、ボンフェローニ補正が直すのは本数の問題だけである。もとの 1 本 1 本の区間が、独立でないフォールドから $SD/\sqrt{5}$ で作った目安の区間であることは変わらない。棒を伸ばしても、その被

覆が 95% になるわけではない。

× アンチパターン 8.2 — 並べた区間の重なりを見て手法に順位をつける —

フォレストプロットは順位表ではない。

第 8.4.3 項で見たとおり、2 本の区間が重なっているかどうかから差の有無は判定できない。本数が増えれば、その判定をたくさん繰り返すことになる。6 手法なら組み合わせは $\binom{6}{2} = 15$ 通りある。15 回も目で判定すれば、そのうちいくつかは間違える。

フォレストプロットに向いているのは次の使い方である。

- どれが基準線を超えたかを見る (1 本ずつの判定で足りる)
- どの手法が測れていないかを見る (棒が異様に長いもの)
- 全体としてどのくらいの幅に収まっているかをつかむ

「A と B のどちらが強いかな」を決めたいなら、図を眺めるのではなく、A と B の差の区間を計算する。比べたい相手が最初から決まっているなら、そもそも 6 本並べる必要がない。

コラム フォレストプロットの「森」は誰か

複数の研究の結果を 1 行に 1 本の横棒で並べる図は、1970 年代の終わりに医学で使われ始めた。1978 年に Freiman らがいくつかの研究の信頼区間を横線で並べ、1982 年には Lewis と Ellis が、メタアナリシスで全体をまとめた効果を最下段に置く形にした。ところが「forest plot」という名前が印刷物に現れるのはかなり後で、この図の歴史を調べた Lewis と Clarke が最も早い候補に挙げたのは、1996 年の看護研究の総説だった [106]。

名前の由来には逸話が残っている。1990 年 9 月、乳がんの治療研究をまとめる共同解析の会合で、統計学者の Richard Peto が「この図は乳がん研究者の Pat Forrest にちなんで名づけた」と冗談を言ったという。Lewis と Clarke 自身は、線がたくさん並んで林のように見えることから来た名前だ、としている。本文で「横棒がずらりと並ぶ様子が林に見える」と書いたのは、この説明による。

彼らの記事の副題は「trying to see the wood and the trees」で、英語の慣用句「木を見て森を見ず」をもじっている。1 本ずつの区間 (木) と、並べた全体 (森) の両方を読む図だという意味である。本文で見た、1 本ずつなら 95% でも並べると外れやすくなるという問題は、木と森を取り違えないための注意にあたる。

8.4.5 差だけを描く

前項の図には根本的な弱点がある。見せたいものが描かれていない。知りたいのは差なのに、図に描いてあるのは各手法の区間である。だから読み手は重なりを目で測るしかなくなり、第 8.4.3 項で見た誤りに落ちる。

直し方は単純である。差そのものを横軸にする。

手順は 3 段である。

1. 基準にする手法を 1 つ決める。本書では平均正解率が最も高かったランダムフォレストにした。ただし同じ結果を見てから基準を選んでいるので、基準を事前に決めた場合 (例えば「いま使っている手法」を基準にする) より差が大きくなりやすい。本来は基準を先に決めておく
2. 残りの 5 手法それぞれについて、基準との正解率の差を計算する

3. 差の点推定と信頼区間を並べ、0 のところに縦線を引く




図 8.10 ランダムフォレストを基準にした、層別 5 分割交差検証の平均正解率の差の区間。薄い太い棒は**対応を取らずに**計算した差の区間、濃い細い棒は**同じ分割のフォールドごとに差を取って**計算した区間である。赤い縦線が「差なし」で、区間がこの線をまたいでいれば差があるとは言えない。重なりを目で測る余地がない。区間は図 8.9 と同じくフォールド間の $SD/\sqrt{5}$ から作った目安で、正式な 95% の被覆は保証しない。

読み方は 1 つに減る。区間が 0 の線をまたいでいるかだけである。

- またいでいない → 基準との差を示唆する
- またいでいる → 差があるとは言えない

図 8.10 では、5 手法のうち 3 つで、正解率の差の区間が 0 を含まない。残る 2 つは 0 をまたいでおり、ランダムフォレストとの正解率の差があるとは言えない。前項のフォレストプロットで「上位 3 つは棒が重なっている」と読んだのと同じ結論だが、こちらは**目で測っていない**。

「0 を含まない」を「差がある」と断定しないのは、区間の作り方による。フォールドごとに差を取ると、モデル間で共通する上下は消えるが、**フォールドどうしが訓練データを共有していることは消えない** (第 8.4.2 項)。 $SD/\sqrt{5}$ はやはり標準誤差の過小評価になりやすく、区間は短めに出る。性能差を正式に推論したいなら、目的と分割の単位を先に決め、分割を繰り返したときの補正付きの t 検定 [101] などで測り直す。本項の図は、**差を軸にすると読み方がどう変わるか**を示すためのものである。

棒を 2 種類描く理由 — 差を取ると共通の上下が消える 薄いほうと濃いほうで長さが違う。濃いほうは**フォールドごとに差を取ってから区間を作っている**。

交差検証では、どのモデルも**同じ分割**で測っている。だから「たまたま難しい作品ばかりがテストに集まったフォールド」では、どのモデルも一緒に成績が下がる。この共通の上下は、モデルどうしの差を取れば引き算で消え、そのぶん区間が短くなる。

ただし、本書のデータでは区間はほとんど短くならなかった。対応を取らずに作った区間と比べた長さの比は、平均 1.01 倍である。k 近傍法 ($k=1$) とロジスティック回帰では、フォールドごとに差を取った区間のほうがかえって長い。図 8.8 のとおり、基準のランダムフォレストは 5 回のうち 4 回で満点を取っており、差し引く共通の上下がそもそも小さいからである。対応を取ると区間が短くなるのは、フォールドの難しさがどのモデルの成績にも同じ向きに現れるときである。

比べたいのが差なら、最初から差を測る設計にする。同じ分割で全部のモデルを回しておけば、あとからフォールドごとの差が取れる。モデルごとに別々の分割で測ってしまうと、共通の上下を差し

引くことはできない。

ただし、差を軸にしても**本数の問題は消えない**。5本の95%区間を並べれば、少なくとも1本が外れる確率はやはり23%ある(これも独立を仮定した近似の値である)。基準を決めて15通りから5通りに減らしたぶん、前項より軽くなっているが、ゼロにはならない。図全体を95%で読みたいなら、前項と同じくボンフェローニ補正で棒を伸ばす。本数を減らすことと、補正することは、別々の対処である。

○ 定石 8.3 — 比べたいものが差なら差を軸にした図を描く —

区間を並べた図は、読み手に重なりを測らせてしまう。差を軸にすれば、読むのは「0をまたぐか」だけになる。


- **基準を1つ決める**。全ペアを描くと15通りになるが、基準を決めれば5通りで済む
- **0の線を必ず引く**。これがないと差の図の意味がない
- **同じ分割で全モデルを回す**。フォールドごとの差が取れる。フォールドの難しさがモデルに共通していれば、区間が短くなる

生のデータ点も一緒に見せたいなら、**推定プロット** (estimation plot) という描き方がある。左側に各群の生の点を並べ、右側に**別の軸**を立てて差の分布と区間を描く。提案者の名前から Gardner–Altman プロットとも呼ばれ、医学や心理学の分野で「 p 値の代わりにこれを載せよ」という提案とともに広まった [69]。DABEST などの実装がある。

発展 複数のデータセットで手法を比べる — CD ダイアグラム

機械学習の論文では、手法を複数のデータセットで走らせて比べることが多い。このとき正解率をそのまま平均するのは筋が悪い。データセットによって正解率の水準も幅も違うからである。どの手法でも正解率が0.99を超えるデータセットと、どれも0.6前後にとどまるデータセットとを平均すれば、手法間の差が大きく出るのは後者のほうである。平均は、差の出やすいデータセットの結果に引きずられる。

そこで**データセットごとに順位をつけ、順位の平均で比べる方法**がある。これを図にしたのが **CD ダイアグラム** (critical difference diagram) で、Demšar が提案した比較の手順 [70] とともに広まった。日本語では**臨界差図**と訳されることもあるが、論文や実装では CD diagram、CD plot と書かれることが多い。本書は CD ダイアグラムと呼ぶ。



横軸が平均順位で、左ほど成績が良い。赤い横棒でつないだ手法どうしは**差があるとは言えないこと**を表す。つなぐかどうかの境目になる順位差が**臨界差** (critical difference、CD) で、手法の数を k 、デー

発展（続き）

タセットの数を N として

$$CD = q_{\alpha} \sqrt{\frac{k(k+1)}{6N}} \quad (8.6)$$

で決まる。 q_{α} は Nemenyi 検定の表から引く値である。Demšar の手順では、先に Friedman 検定で「どの手法も平均順位が同じ」かどうかを調べ、そこで差が見つかったときだけ、この臨界差で手法の組を比べる。図の名前の CD はこの臨界差のことである。図の A と B、C と D は順位差が臨界差より小さいのでつながれ、B と C は臨界差より大きいのでつながれていない。

読み方は 1 つだけ覚えればよい。同じ棒につながれていれば、順位が違っていても差があるとは言えない。順位の数字そのものを比べることはできない。

本書はデータセットが 1 つしかないので、CD ダイアグラムは描けない。描くには「手法 × データセット」の表が要る。論文でこの図を見たら、いくつかのデータセットで測ったかを先に確かめるとよい。数が少なければ臨界差は大きくなり、ほとんどの手法が 1 本の棒でつながってしまう。

8.5 指標は「どの誤りが高くつくか」で選ぶ

指標が増えてきたので、選び方を整理しておく。出発点はどの誤りが高くつくかであって、指標の名前ではない。がん検診なら再現率を重視する。見逃せば命に関わるが、誤検出は追加検査で解消できる。迷惑メールのフィルタなら適合率を重視する。迷惑メールが 1 通届くより、大事なメールが 1 通消えるほうが困る。「 F_1 を最大化する」は思考停止になりうる。自分の問題ではどちらの誤りが高くつくかを先に決める。

表 8.5 指標の選び方

状況	見るもの
クラスの大きさがそろっていて、どの誤りも同じ重さ	正解率。ただし最頻クラスの割合と必ず並べる
クラスが偏っていて、少数クラスも同じくらい大事	マクロ F_1 。正解率は多数クラスに引きずられる
誤検出と見逃しで代償が違う	適合率と再現率を別々に見る。 F_1 にまとめると差が消える
しきい値をまだ決めていない、順位付けの良し悪しを見たい	ROC 曲線と AUC。陽性がごく少ないときは PR 曲線
多クラスで「どこを取り違えたか」を知りたい 数値を当てる（回帰）	混同行列。数字 1 つに要約する前に必ず一度見る 決定係数 R^2 か平均絶対誤差。 $R^2 = 0$ が「つねに平均を答える」

表 8.5 の 1 行目と 2 行目は、本書のデータでは食い違わなかった。表 8.3 のとおり、正解率 0.986、マクロ F_1 0.977 で、どちらで見ても同じ結論になる。食い違うのは、多数クラスだけを当てて少数クラスを捨てているときである。その場合、正解率の高いままマクロ F_1 だけが落ちる。

補足 指標を目標にすると指標だけが上がる

指標を選ぶことには、もう1つの意味がある。**選んだ指標が、そのまま最適化の目標になることである。**

そして目標にされた指標は、たいてい抜け道を持っている。本書の言葉でいえば、「正解率を上げよ」と命じられたモデルが最初に見つけるのは、最頻クラスを答え続ける戦略である。文体を学ばずに正解率 0.284 を得る道が、そこにあるからである。

同じことが人にも起きる。コールセンターの評価を「平均処理時間」で測れば、時間は短くなる。用件が済んでいなくても電話を切ることで達成できるからである。強化学習でボートレースのゲームを走らせた実験では、エージェントがゴールせずに、ボーナスアイテムの湧く場所を延々と周回してスコアを稼いだ [123]。

測るために選んだ量が、目標そのものにすり替わる。これはグッドハートの法則と呼ばれている。指標は目的の代理でしかないので、代理が取りこぼしている部分を別の指標で見張っておく必要がある。正解率を報告するときにマクロ F_1 を並べるのは、その一例である。

8.5.1 基準線は指標ごとに作る

第7.2節で「基準線を置く」と書いたが、**基準線は指標ごとに違う**。当てずっぽうにも何通りかあり、どれが強いかは指標で入れ替わる。

74 作品・8 名のデータで、3 つの当てずっぽうの正解率とマクロ F_1 を実際に測った (ランダムなものは 2000 回の平均)。

当てずっぽうの戦略	正解率	マクロ F_1
一様ランダム (8 名から等確率)	0.126	0.117
クラス比に比例して選ぶ	0.157	0.122
つねに最頻クラス (吉川英治)	0.284	0.055

表の太字は、その指標でいちばん強かった戦略である。2 つの列では、別の戦略が太字になっている。

正解率でいちばん強い「つねに最頻クラス」(正解率 0.284) が、マクロ F_1 では 0.055 でいちばん弱い。吉川英治だけを当てて残り 7 名を全部捨てるので、7 名分の F_1 がゼロになり、8 個の平均が押し下げられるからである。逆に一様ランダムは、正解率では 3 つのうち最低の 0.126 だが、どのクラスも同じように当てにいくぶん、マクロ F_1 では 0.117 と、最頻クラス戦略の 0.055 の 2 倍になる。

つまり「当てずっぽうの成績」は 1 つに決まらない。どの当てずっぽうを相手にするかで、自分のモデルがどれだけ上回ったかの見え方が変わる。

○ 定石 8.4 — 報告する指標と同じ指標で基準線を測る

「正解率 0.90 を達成」と書くなら、最頻クラス戦略の**正解率**を並べる。「マクロ F_1 0.62 を達成」と書くなら、同じ当てずっぽうの**マクロ F_1** を並べる。指標を混ぜると、基準線が不当に低く見えたり高く見えたりする。

当てずっぽうの候補は次の 3 つで足りることが多い。

- **一様ランダム** — クラス数の逆数。理論値がすぐ出る

- **クラス比に比例** — 正解率の期待値は $\sum_i p_i^2$
- **つねに最頻クラス** — 正解率の期待値は $\max_i p_i$

2 値分類で AUC を報告するなら、基準線は 0.5 である (当てずっぽうの順位付け)。回帰なら $R^2 = 0$ 、すなわち「つねに平均を答える」が基準線になる。

8.5.2 決定係数は誤差の大きさではなく基準線からの改善

表 8.5 の最終行に決定係数を挙げたが、 R^2 については「使うべきでない」という批判が長く続いている。何が問題で、代わりに何を見ればよいかを整理しておく。

定義から始める。 n 個の正解 y_i と予測 $\hat{y}_i$ に対し、

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} \quad (8.7)$$

分子は予測の二乗誤差、分母は「つねに平均 $\bar{y}$ を答える」ときの二乗誤差である。つまり R^2 は誤差そのものではなく、**基準線に対して誤差が何割減ったか**を表す。第 7.2 節の考え方が式に埋め込まれていると見ればよい。

分母は評価データの散らばりで決まる 問題は、その分母が測る相手によって変わることにある。

第 9.9.2 項「時系列の漏れ」で使う連載小説のデータで確かめる。Web 上で 677 話にわたって連載された作品について、各話の文体から**その話がいつ公開されたか**を当てる問題である。正解も予測も「連載開始から何日目か」という日数で、誤差の単位は日になる。

677 話すべてをリッジ回帰で予測し、5 分割交差検証で測ると、 $R^2 = 0.77$ 、平均絶対誤差は 133 日、つまり平均して 4 か月ほどずれる。なお、この 5 分割は各話をランダムに分けており、第 9.9.2 項で扱う時系列の漏れを含む。ここでは、同じ予測を測る範囲だけ変えたときに R^2 がどう動くかを見るために、この予測を使う。

ここで、**予測はそのままにして測る範囲だけを変える**。連載中盤の 226 話を取り出し、その範囲だけで測り直す。すると平均絶対誤差は 133 日から 118 日へ 15 日下がるのに、 R^2 のほうは 0.77 から -0.94 になった。誤差が小さくなったのに、 R^2 は 0 を割り込み、「つねに平均を答える」という基準線に負けた。

R^2 が下がったのは、比較の相手が変わったためである。全期間では正解 (公開日) の標準偏差が 362 日あるが、中盤だけなら 107 日しかない。狭い範囲では「つねに平均」が強い相手になるので、同じ大きさの誤差でも R^2 は落ちる。図 8.11 で塗った帯の中だけを見ると、予測の縦の散らばりのほうが、帯の幅 (正解の散らばり) より大きい。帯の中の正解の平均を一律に答えるほうが誤差が小さくなるので、 R^2 は負になる。

R^2 が測っているのは予測の質だけでなく、**評価データの散らばり**でもある。

× アンチパターン 8.3 — 別々のデータで測った決定係数を並べて優劣を論じる

「先行研究は $R^2 = 0.6$ 、本手法は $R^2 = 0.8$ 」は、両者が同じ評価データを使っていない限り比較になっていない。均質な集団に当てれば R^2 は下がり、散らばりの大きい集団に当てれば




図 8.11 677 話の公開日をリッジ回帰で予測した結果 (5 分割交差検証)。破線は予測と正解が一致する線。全期間では $R^2 = 0.77$ 、塗った中盤の 226 話だけで測ると $R^2 = -0.94$ になる。予測は同じで、測る範囲だけが違う。

上がる。比べてよいのは、**同じ正解の並び**に対する R^2 どうしだけである。

列を足せば増える 第二の批判は、説明変数を増やしても訓練データの R^2 が決して減らないことである。役に立たない列を足しても、モデルはその列の係数を 0 にすればよいので、少なくとも元と同じ値は保たれる。実際には 0 でない係数がわずかに当てはまるので、値は上がる。同じデータに、情報をまったく含まない乱数列を足していった (図 8.12)。




図 8.12 677 話の公開日を線形回帰で当てる問題に、情報ゼロの乱数列を足したときの R^2 。訓練データで測れば増え続ける

同じ 677 話を線形回帰で予測するとき、乱数を 200 列足すと、訓練データで測った R^2 は 0.81 から 0.88 に上がる。同じモデルを 5 分割交差検証で測れば R^2 は 0.63 まで落ちるので、予測が悪化したことは正しく分かる。自由度調整済み R^2 ^{*7} は 0.80 でほとんど変わらない。無情報の列がもたらす見かけの増分を罰で打ち消して横ばいに保つのが調整の役目なので、これは設計どおりの挙動である。ただし、交差検証で見た予測の悪化までは検出できない。

これは R^2 固有の欠点というより、本章で繰り返してきた「訓練データで測るな」の一例である。ただし R^2 は列を足しても減らないことが数学的に保証されているぶん、「 R^2 が上がったから良くなった」という誤読を招きやすい。

発展 R^2 への批判とそれへの反論

R^2 への批判は古い。Kvålseth は 1985 年の論文で、 R^2 と呼ばれる式が少なくとも 8 通り流通していること、それらが一致するのは切片付きの線形回帰という限られた場合だけであることを指摘した [115]。切片を置かない回帰では $\sum (y_i - \bar{y})^2$ を残差と回帰に分解する等式が成り立たなくなり、定義によっては 1 を超える値さえ出る。

非線形回帰ではさらに悪い。Spiess と Neumeyer は薬理学の用量反応曲線を題材に、数千回のシミュレーションで R^2 が良いモデルにも悪いモデルにも一様に高い値を返すこと、自由度調整済み R^2 を基準にモデルを選んでも、正しいモデルを選べたのは 4 割ほどで、同じ条件で情報量規準の AICc は 8 割を超えたことを示した [116]。彼らの結論は、非線形では R^2 を捨てて AIC などの情報量規準を使え、というものである。

いっぽう擁護もある。Chicco らは、MSE・RMSE・MAE・MAPE には上限がないため値を 1 つ示されても良し悪しが判断できない、と論じた [117]。「平均絶対誤差 133」と言われても、正解の分布を知らなければ優れた予測なのか無意味な予測なのか分からない。 R^2 には 1 という上限と、0 という意味のある基準点がある。彼らはこれを理由に、回帰の標準指標として R^2 を推奨している。

ただし彼ら自身が認めるとおり、 $R^2 = 1 - \text{MSE}/\text{MST}$ で分母は評価データごとに固定されるから、同じデータの上でモデルを順位づけるかぎり、 R^2 による順序と RMSE による順序は完全に一致する。 R^2 の利点は順位付けの精度ではなく、1 つの値の読みやすさにある。また彼らは、 R^2 が負のときは下限が $-\infty$ なので -0.5 と -50 の差を解釈できない、という限界も挙げている。

批判が当てはまる場面と、当てはまらない場面 批判をまとめると、 R^2 が壊れるのは (1) 別のデータで測った値と比べたとき、(2) 訓練データで測ったとき、(3) 切片なしや非線形の回帰に当てはめたとき、である。逆にいえば、同じ評価データの上で、交差検証で測り、切片付きの回帰に使うかぎり、 R^2 は「基準線からどれだけ改善したか」を素直に表す。

○ 定石 8.5 — 回帰は誤差と基準線を組にして報告する —

数値を当てる問題では、次の 3 つを並べる。

- **単位の残る誤差** — 平均絶対誤差や RMSE。「何日ずれるか」が読み手に伝わる
- **基準線** — 「つねに平均を答える」ときの同じ誤差。 R^2 はこの 2 つの比を 1 つの数にしたものである
- **残差の図** — 予測値を横軸、 $y_i - \hat{y}_i$ を縦軸に取る。誤差が特定の範囲に偏っていないかは、

^{*7} 列数 p による罰を入れた $1 - (1 - R^2) \frac{n-1}{n-p-1}$ 。「調整済み」と呼ばれる。

数値 1 つでは分からない

R^2 を報告してもよいが、そのときは評価データが何かを必ず書く。非線形回帰や切片なしの回帰では R^2 を使わず、予測誤差そのものの情報量規準で比べる。

第 9.9.2 項の時系列の漏れでは、同じ連載小説の公開日を時間順に分けて予測したときの R^2 が -4.41 になる。負の値が出ることも自体が、 R^2 を「説明できた分散の割合」とは読めない証拠である。割合なら負にならない。 R^2 は割合ではなく、基準線との比較である。

8.6 しきい値を動かす — ROC 曲線と AUC

ここまでは「モデルが出した予測クラス」だけを見てきた。だが多くのモデルは、実際には**確率**を出している。

```
proba = model.predict_proba(X) # 各クラスの確率 (列の順は model.classes_)
pred = model.classes_[proba.argmax(axis=1)] # 確率が最大のクラス名を選ぶ
```

2 値分類なら「陽性の確率が 0.5 を超えたら陽性」と判定するのが既定である。だが 0.5 というしきい値は、単なる慣習にすぎない。

しきい値を下げれば、陽性と判定する数が増える。見逃し (偽陰性) は減り、誤検出 (偽陽性) は増える。上げれば逆になる。




図 8.13 しきい値を左右に動かすと、見逃しと誤検出のバランスが変わる。

しきい値を 0 から 1 まで動かしながら、次の 2 つを記録する。

$$\text{真陽性率 (TPR)} = \frac{TP}{TP + FN} \quad (= \text{再現率}) \quad (8.8)$$

$$\text{偽陽性率 (FPR)} = \frac{FP}{FP + TN} \quad (8.9)$$

しきい値を 1 つ決めると、図 8.4 の 4 つの数が 1 組決まり、そこから真陽性率と偽陽性率が 1 組決まる。これが平面上の 1 点になる。しきい値を 1 から 0 へ下げていくと、点は (0, 0) から (1, 1) へ動いていく。横軸を FPR、縦軸を TPR として、この点の動きを描いた曲線が **ROC 曲線** である。Receiver Operating Characteristic の略で、第二次大戦中のレーダー信号の判別研究に由来する。

一つ工夫をする。ここから測るのは「太宰治か、そうでないか」という 2 択で、74 作品を層別 5 分割交差検証にかけ、そこで出た確率から AUC を計算する。52 列すべてを使うと、この 2 択は簡単すぎて 3 つの手法の AUC がどれも 0.98 を超え、曲線が左上の角で重なってしまう (ランダムフォレストが 0.983、k 近傍法 ($k=5$) が 0.997、ロジスティック回帰が 0.996)。差が見えないので、混同行列 (第 8.3.2 項) と同じ工夫をする。特徴を字種 3 列と文長 2 列の計 5 列に間引いた、読点の癖を封じた状態で描く。




図 8.14 「太宰治かどうか」を判定する ROC 曲線 (字種 3 列と文長 2 列の計 5 列に間引いた設定、74 作品、層別 5 分割交差検証)。左上に近いほど良い。黒丸は、ロジスティック回帰でしきい値を 0.1、0.5、0.8 にしたときの点 (表 8.6)。

こうすると 3 本の曲線がはっきり分かれる。5 列に間引いた設定での AUC は、ロジスティック回帰が 0.968 で最も高く、ランダムフォレストが 0.934、k 近傍法が 0.883 と続く。52 列すべてを使った場合の順位はこれと違い、k 近傍法が 0.997 で最上位、ロジスティック回帰が 0.996、ランダムフォレストが 0.983 で最下位になる。手法の優劣は特徴集合しだいで入れ替わる。

曲線上の 1 点が 1 枚の混同行列にあたることを、ロジスティック回帰で確かめておく。表 8.6 は、しきい値を 3 通りに変えたときの 4 つの数である。太宰治は 7 作品、それ以外は 67 作品ある。しきい値を下げるほど TP が増えて FN が減り、その代わり FP が増える。図 8.14 の黒丸は、この 3 行を点にしたものである。

表 8.6 しきい値を変えたときの「太宰治かどうか」の判定 (ロジスティック回帰、5 列に間引いた設定、層別 5 分割交差検証で出した確率)

しきい値	TP	FN	FP	TN	真陽性率	偽陽性率
0.1	7	0	8	59	1.000	0.119
0.5	5	2	1	66	0.714	0.015
0.8	1	6	1	66	0.143	0.015

× アンチパターン 8.4 — 全員が満点近くなる課題で手法の優劣を論じる

どの手法でも成績がほぼ満点に張りつくことを**天井効果** (ceiling effect) という。天井に張りついた数値どうしの差は、ほとんど乱数である。「AUC0.997 の手法が 0.996 の手法に勝った」と書いても、乱数の種を変えれば順位は入れ替わる。

比べたいものがあるなら、課題のほうを難しくする。特徴を間引く、クラスを増やす、訓練データを減らす。本節で 52 列から 5 列に絞ったのはそのためである。逆に、難しくしても差が出ないなら、**その比較には差がない**と報告すればよい。無理に順位を付ける必要はない。

曲線上の目印をいくつか押さえる。

- **左上の角** (0, 1) — 完璧。誤検出ゼロで全部当てる
- **対角線** — 当てずっぽうと同じ
- **対角線より下** — 予測を反転させたほうがまし

曲線の下面積が **AUC (Area Under the Curve)** である。1 に近いほど良く、0.5 が当てずっぽうに相当する。

この面積には、分かりやすい解釈がある。

陽性のサンプルを 1 つ、陰性のサンプルを 1 つランダムに選んだとき、モデルが陽性のほうに高いスコアを与える確率。

図 8.14 のランダムフォレストの $AUC = 0.934$ なら、無作為に選んだ太宰治の作品と他の作家の作品を 1 つずつ比べて、93% の確率で太宰治のほうに高いスコアがつくという意味である。しきい値をどこに置くかとは無関係に、**順位付けの良さ**だけを測っている。

8.6.1 AUC の落とし穴

AUC は便利だが、万能ではない。

× アンチパターン 8.5 — 不均衡データで AUC だけを見る

陽性が 1% しかないデータを考える。陰性が 99% あるので、偽陽性率 $FP/(FP + TN)$ の分母が非常に大きい。偽陽性が多少増えても FPR はほとんど変わらない。

結果として、実用に耐えないモデルでも AUC が 0.9 を超えることがある。「陽性と判定したもののうち 9 割が誤り」でも、AUC は高く出る。

不均衡なデータでは **PR 曲線** (適合率-再現率曲線) を使う。横軸に再現率、縦軸に適合率を取る。不均衡があるほど、AUC と PR 曲線の下面積の差が開く。

PR 曲線の当てずっぽうの線は、AUC の 0.5 と違って、陽性の割合の高さの水平線になる。でたために陽性と判定すれば、判定したもののうち陽性の割合どおりしか当たらないからである。図 8.15 は、図 8.14 と同じ 3 手法・同じ設定の PR 曲線である。太宰治は 74 作品中 7 作品なので、当てずっぽうの線は 0.095 の高さにある。曲線の下面積に相当する量 (平均適合率、average precision) は、ロジスティック回帰が 0.670、ランダムフォレストが 0.787、k 近傍法が 0.452 で、3 つとも AUC より低い。AUC ではロジスティック回帰が最も高かったが、平均適合率ではランダムフォレストのほ

うが上になる。順位付けの良さを全体で見るか、上位に並べたものの当たり方で見ると、手法の順位は入れ替わりうる。ROC 曲線では左上に寄って見えた曲線も、適合率で見ると、再現率を上げるにつれて誤検出が混ざって下がっていく。




図 8.15 「太宰治かどうか」を判定する PR 曲線 (図 8.14 と同じ設定)。括弧内は平均適合率。右上に近いほど良い。

○ 定石 8.6 — しきい値は誤りのコストで決める

ROC 曲線は「どのしきい値がありうるか」を見せてくれるが、どれを選ぶべきかは教えてくれない。決めるのは、第 8.5 節で指標を選んだときと同じ誤りのコストである。見逃しと誤検出のコストの比が決まれば、最適なしきい値も決まる。

見逃し 1 件のコストを C_{FN} 、誤検出 1 件のコストを C_{FP} とする。陽性の確率が p の文書を陽性と判定したときの期待コストは $(1-p)C_{FP}$ 、陰性と判定したときは pC_{FN} なので、 $p > C_{FP}/(C_{FP} + C_{FN})$ なら陽性と判定するほうが損が小さい。見逃しが誤検出の 9 倍高くなれば、しきい値は 0.1 になる。この計算は、モデルの出す p が額面どおりの確率であることを前提にしている。それを確かめるのが次節の較正である。

コラム AUC は 469 回の対戦の勝率

図 8.14 の「太宰治かどうか」の問題には、太宰治の作品が 7 つ、それ以外が 67 ある。太宰治の作品と他の作品を 1 つずつ組にすると、 $7 \times 67 = 469$ 組できる。各組で、モデルが太宰治のほうに高いスコアをつけていれば 1 勝、同じスコアなら 0.5 勝と数える。ランダムフォレスト (5 列に間引いた設定) の勝ち数は 438 で、勝率 $438/469$ は AUC の 0.934 に一致する。本文で「陽性のほうに高いスコアを与える確率」と書いたのは、この勝率のことである。

この勝ち数は、2 つの群の値の大小を全部の組で比べる Mann-Whitney の U 統計量そのものである (Wilcoxon の順位と検定と同じ検定の別の書き方)。ROC 曲線は第二次大戦中のレーダーの信号検出から生まれ、心理学の信号検出理論を経て、放射線医学で画像診断の評価に使われるようになった。曲線の下の面積を 1 つの数として使い、それが U 統計量と同じものであることを画像診断の研究者向けに示し

コラム (続き)

たのが、Hanley と McNeil の 1982 年の論文である [105]。そこから、AUC の標準誤差を件数から計算する方法も広まった。

組の数が 469 しかないことは、AUC の小数第 3 位を読みすぎない理由にもなる。1 組の勝ち負けが入れ替わるだけで、AUC は $1/469$ だけ動く。

8.7 較正 — 出力された確率が当たっているかを測る

AUC は順位だけを見ていた。モデルが出した確率の 0.9 と 0.6 のどちらが大きいかが分かればよく、その 0.9 という数値自体には踏み込まない。

だが実務では、確率の値そのものを使う場面がある。「この文書が太宰治である確率は 0.9」と表示する、確率で期待損失を計算して判断を決める、複数のモデルの確率を平均する。どれも **0.9** と言われたら、そう判定された文書の 9 割が本当に太宰治であることを前提にしている。

これが成り立っているかどうかを**較正** (calibration) という。2 値化の対象は、ROC 曲線の太宰治から替えて、ここからは吉川英治にする。太宰治は 7 作品しかなく、確率の帯に分けると、ほとんどの帯で陽性が 0 か 1 作品になってしまうからである。吉川英治なら 21 作品ある。測り方は素朴で、モデルが「吉川英治である確率は 0.9 前後」と答えた文書だけを集め、その中で実際に吉川英治だった割合を数えればよい。確率の帯ごとにこれを繰り返して、横軸に予測確率、縦軸に実際の割合を取った図が**信頼度曲線** (reliability diagram) である。対角線の上に乗っていれば、確率は額面どおりということになる。




図 8.16 信頼度曲線。「吉川英治かどうか」を字種 3 列と文長 2 列で当てた場合 (図 8.14 と同じ難しくした設定、74 作品、層別 5 分割交差検証)。横軸はモデルが答えた「吉川英治である確率」、縦軸はその帯で実際に吉川英治だった割合である。点が対角線より下にあれば確率を大きく言いすぎており、上にあれば小さく言いすぎている。確率の高い側で下に、低い側で上に外れていれば、確率を 0 や 1 に寄せすぎた自信過剰である。

8.7.1 ずれを 1 つの数で測る — Brier スコア

図を見るだけでなく、数値でも比べたい。確率と実際 (吉川英治なら 1、そうでなければ 0) の **2 乗誤差の平均**を **Brier スコア**という。

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (p_i - y_i)^2 \quad (8.10)$$

小さいほどよい。確率と正解の 2 乗誤差なので、較正のずれだけでなく、陽性と陰性をどれだけ分離できているかも一緒に反映する。**確率予測の総合的な誤差**であって、較正専用の指標ではない。較正そのものは、信頼度曲線対角線からのずれで見る。「吉川英治か、そうでないか」を字種 3 列と文長 2 列の計 5 列で判定し、層別 5 分割交差検証で出した確率の Brier スコアを測ると、ランダムフォレストが 0.0958、SVM が 0.1084、ロジスティック回帰が 0.1495 である。参考までに、**全員に同じ確率 (陽性の割合) を答える**という何も学ばないモデルでは 0.2033 になり、3 つともこの基準線を下回っている。基準線を置くのは、正解率のときと同じである (第 7.2 節)。

木のアンサンブルは多数決の平均なので確率が 0 や 1 に振り切りにくく、較正が悪くなりやすい、とよく言われる。本節の実測では、Brier スコアが最も小さいのはランダムフォレストだった。ただし Brier スコアは分離の良さも含むので、これだけで較正が良いとは言えない。図 8.16(a) の信頼度曲線では、ランダムフォレストの点は確率の高い帯で対角線より上にあり、確率を控えめに出すという通説どおりの傾向も見える。一方で最も低い帯では、0.02 前後と答えた作品のうち 2 作品が吉川英治で、対角線より上に外れている。表 8.7 のとおり 1 つの帯に 10 作品ほどしかないのも、どちらも決めきれない。較正の良し悪しは、手法の名前ではなく、手元のデータで測って確かめる。

表 8.7 図 8.16(a) のランダムフォレストの帯ごとの作品数。帯は予測確率の小さい順に 74 作品をほぼ 7 等分したもの

帯	予測確率の平均	作品数	うち吉川英治	吉川英治の割合
1	0.019	11	2	0.18
2	0.061	10	0	0.00
3	0.108	11	0	0.00
4	0.157	10	0	0.00
5	0.317	11	2	0.18
6	0.665	10	7	0.70
7	0.842	11	10	0.91

コラム 降水確率はどう採点されるか

Brier スコアは、米国気象局の研究部門にいた Glenn W. Brier が 1950 年に *Monthly Weather Review* に書いた 3 ページの論文で提案したものである [102]。「明日雨が降る確率は 70%」のように確率で出した天気予報を、外れたかどうかだけでなく、確率の値まで含めて採点する方法を考えた。

Brier の元の定義は、「降る」「降らない」の両方のカテゴリについて 2 乗誤差を足すので、値の範囲は

コラム (続き)

0 から 2 になる。本文の式は、2 値の場合によく使う、その半分の形である。

気象の分野では、予報の確率が額面どおりかどうか、つまり較正が早くから調べられてきた。Murphy と Winkler は 1977 年に、米国の予報官が出した降水確率の予報を調べ、予報官が確率を信頼できる形で出せることを示した [104]。降水確率 30% は、30% と予報された日を集めると 3 割ほどの日に雨が降る、という意味で採点されている。


Brier スコアは、較正のずれ (reliability)、分離の良さ (resolution)、事象そのものの不確かさ (uncertainty) の 3 つの項に分けられる [103]。本文で「較正のずれだけでなく、陽性と陰性をどれだけ分離できているかも一緒に反映する」と書いたことを、式の上で分けたものである。

発展 Brier スコアと交差エントロピー — 罰の重さが違う

確率を測る基準は Brier スコアだけではない。第 7 章の発展で見た**交差エントロピー** (1 件あたり $-\ln p$ 。 p は正解のほうに与えた確率) も同じ用途に使う。

2 つは大事な性質を共有している。真の確率が q である事象に対してモデルが p と答えたときの期待値は、どちらも $p = q$ でちょうど最小になり、そこからずらせば必ず増える。この性質を持つ基準を**厳密に固有なスコアリングルール** (strictly proper scoring rule) という。自信を水増ししても、逆に安全側へ丸めても、期待値では損をする。この性質を持たない量 (たとえば正解率) だけを見ていると、しきい値の周りで確率を歪めたほうが得になる余地が残る。

違うのは**言い切ったときの罰の重さ**である。1 件ぶんの罰を、正解のほうに与えた確率 p の関数として並べる。



Brier スコア $(p - y)^2$ の罰は最大でも 1 で、正解に 0.5、0.1、0.01 しか与えなかったときの値は 0.25、0.81、0.98 にとどまる。交差エントロピーは同じ場面でも 0.69、2.30、4.61 と立ち上がり、 $p \rightarrow 0$ で正解が 1 だったときには $-\ln p \rightarrow \infty$ となる。「ありえない」と言い切った側が起きたときの罰に上限がない。

どちらを使うかは、外れの重さをどう見るかで決まる。確率そのものが判断に使われる場面 (検査の陽性確率、与信の債務不履行確率) なら、罰に上限のない交差エントロピーが向いている。半面、ラベルが 1 件間違っているだけで値が跳ね上がるので、実装では p を $[\varepsilon, 1 - \varepsilon]$ に丸めてから計算する。本節で Brier スコアを使うのは、値が暴れず、較正のずれと分離の良し悪しをまとめて 1 つの数で見られるからである。

8.7.2 ずれていたら直せる

較正がずれていても、順位付けさえ良ければ後から直せる。やり方は、**予測確率を入力として、正解を当てる 1 変数のモデルを重ねること**である。

- **Platt scaling** — シグモイド関数を当てはめる。パラメータが 2 つだけなので、データが少な

くても安定する

- **等調回帰 (isotonic regression)** — 単調増加という条件だけを課して、自由な形の対応表を作る。柔軟だがデータが要る

図 8.16(b) がランダムフォレストに Platt scaling をかけた結果である。Brier スコアは較正前の 0.0958 から較正後の 0.1110 へ上がり、**かえって悪くなった**。何も学ばないモデルの 0.2033 よりは小さいものの、較正しないほうがよかったことになる。

較正には、森の学習に使わなかった作品が要る。ここで使った `CalibratedClassifierCV(cv=3)` は、交差検証の訓練側をさらに 3 つに分け、森を 3 分の 2 だけで学習させて、残りの 3 分の 1 でシグモイドを当てはめる。これを 3 通り行って平均する。較正をせずに、森を 3 分の 2 で学習させて平均しただけでも、Brier スコアは 0.1073 に上がった。悪化の大半は、較正用に作品を取り分けて森の訓練作品が減ったことによる。74 点しかないデータでは、この取り分けが高くつく。

データが小さいことは、図の読み方にも関わる。**小さいデータでは信頼度曲線を読み込みすぎない**。本節の図は、74 点を 7 つの帯に分けて描いている。1 つの帯に 10 点ほどで (表 8.7)、そのうち何点が吉川英治だったかを割合にしているので、1 点ずれば割合は 0.1 変わる。信頼度曲線がぎざぎざしていても、それがモデルの性質なのか、点が少ないだけなのかは区別できない。較正を論じるには**帯ごとに数十点は必要**だと考えておくとうまく、足りないなら、曲線の形ではなく Brier スコアのような 1 つの数だけを見るほうが安全である。

○ 定石 8.7 — 確率の値を使うなら較正まで確かめる

順位だけを使う場面 (上位 10 件を人が確認する、AUC で比べる) では、較正がずれていても困らない。

確率の値そのものを使う場面では確かめる。

- 確率を表示して、人がそれを見て判断する
- 期待損失 (確率 $\times$ コスト) を計算してしきい値を決める
- 複数モデルの確率を平均する、確率を別のモデルの入力にする

正解率や AUC が高いことと、確率が信用できることは別の性質である。

× アンチパターン 8.6 — 不均衡を「補正」して確率を壊す

クラスの偏りが気になると、少数クラスを水増ししたり (オーバーサンプリング、SMOTE)、多数クラスを間引いたり (アンダーサンプリング) したくなる。

補正すると、モデルが学ぶ**事前の割合**が変わる。本来 100 件に 1 件しか起きないことを、半々のデータで学ばせれば、出てくる確率は系統的に大きくなる。較正が壊れる。

医療の予測モデルで検証した研究では、3 つの補正手法のいずれもが少数クラスの確率を強く過大推定し、それでいて AUC は補正なしのモデルと変わらなかった [100]。**順位付けの力是不変で、確率だけがずれる**という結果である。

感度と特異度のバランスを取りたいだけなら、データをいじらずに**しきい値を動かせば**同じことができる (第 8.6 節)。そのほうが確率を壊さずに済む。

補正が必要になるのは、少数クラスの件数が絶対的に足りず、モデルがその存在をほとんど学べないような場合に限られる。

8.8 過学習を目で見る

決定木の最大の深さを1から20まで変えながら、74作品を52列で判別したときの、訓練データでの正解率と層別5分割交差検証での正解率を並べる。




図 8.17 決定木の最大の深さと正解率。2本の線が開いていく部分が過学習。

訓練データでの正解率は深くするほど上がり、1.000に張り付く。交差検証での正解率は途中で頭打ちになる。**2本の差**が過学習である。訓練データの正解率が上がり続けるのは良いことではなく、モデルが暗記を始めた合図である。見るべきは差であって、上の線ではない。

k近傍法でも、横軸を近傍数 k に取り替えて同じ2本の線を描く。




図 8.18 k 近傍法の近傍数 k と正解率 (74作品、52列、層別5分割交差検証)。 k が小さいほど複雑なモデルになる。

$k = 1$ が最も複雑で、 k を大きくするほど単純になる。決定木の深さとは向きが逆である。

ただし、この図は決定木の図と同じ読み方ができない。訓練データでの正解率は、各作品が自分自身を近傍に数えるので、 $k = 1$ では必ず 1.000 になる。本書のデータでは、交差検証の正解率も $k = 1$ で最も高く (0.973)、 k を大きくするほど下がって $k = 25$ では 0.379 になる。作品数の少ない著者が、近傍の多数決で作品数の多い著者に負けるようになるからである。 k を大きくすると2本

とも下がっていく。これは過学習ではなく、単純すぎて外す側の誤り (未学習) である。2 本の差は $k = 11$ のあたりで最も大きく (0.24)、右端の $k = 25$ では縮んでいる。訓練の線が交差検証の線より上にあるのは、各作品が自分自身にも 1 票を入れるからで、この差を決定木の図と同じように過学習の目安として読むことはできない。このデータでは作品どうしの近さがそのまま著者を表しているので、 $k = 1$ でも暗記の害が小さい。

木の深さや近傍数 k のように、モデルが学習で決めるのではなく人が外から与える設定値をハイパーパラメータ (hyperparameter) という。学習率、正則化の強さ、クラスタ数 k 、t-SNE の perplexity も同類である。モデルの複雑さは、たいていハイパーパラメータで決まる。

× アンチパターン 8.7 — 「パラメータを大きくすると複雑になる」と覚える

そう覚えていると、 k 近傍法で向きを取り違える。

決定木では分岐の数、 k 近傍法では近傍の狭さ、正則化つき回帰では正則化の弱さが複雑さを増やす。ハイパーパラメータの値と複雑さの向きは、手法ごとに確かめるしかない。

害は、過学習を直そうとしてかえって複雑にしまうことである。過学習が起きているときに「単純にしよう」と k を小さくすれば、境界はさらに細くなり、過学習は強まる。単純にしたいなら k を大きくする。値を変える前に、それを増やすと複雑さが増すのか減るのかを確かめる。

8.9 学習曲線 — 作品を増やせばまだ伸びる

「正解率が足りない。データを増やすべきか、特徴を見直すべきか」という判断に使うのが学習曲線 (learning curve) である。

訓練に使う作品数を変えながら、ランダムフォレストの正解率の推移を見る。各フォールドの訓練側から、指定した数の作品を無作為に選んで学習させ、テスト側で測る。作品の選び方の乱数を 5 通り変えて平均した。




図 8.19 学習曲線 (74 作品、52 列、ランダムフォレスト、層別 5 分割交差検証。訓練作品の選び方の乱数 5 通りの平均)。訓練作品数が少ないところでは、訓練側に入らない著者が出ることがある。検証データでの正解率の線は、伸び方が小さくなりながらもまだ上を向いている。

見るのは検証の線の向きである。

- 検証の線がまだ上を向いている — データを増やす価値がある

- 検証の線が**水平になった** — 増やしても頭打ち。特徴やモデルを見直すべき
- 2本の線が**大きく開いたまま** — 過学習。正則化を強める
- 2本とも**低い位置で重なる** — 未学習。モデルが単純すぎる

ただし、ランダムフォレストのように訓練データをほぼ丸暗記する手法では、訓練の線はどのデータ量でも 1.000 に張りつく。図 8.19 の 2 本が開いているのはそのため、この場合に見るのは検証の線の向きだけである。

図 8.19 では、訓練に使った作品数が 45 から最大の 59 が増えるあいだに、検証データでの正解率は 0.932 から 0.951 へ上がっている。伸びは小さくなってきているが、まだ止まってはいない。作品数を増やせば正解率はもう少し上がる、と読める。

図の右端の 0.951 は、表 8.2 の 0.987 より低い。訓練作品数の最大 59 は、各フォールドの訓練側のほぼ全部にあたるので、設定だけを見れば同じ量を測っている。違いは乱数にある。訓練作品を選ぶ乱数を変えると、森の中で使われる乱数の引き方も変わり、右端の値は 5 通りで 0.931 から 0.973 まで振れた。図 8.3 で見たとおり、0.987 は当たりの引きである。学習曲線は線の向きを読む図で、右端の値を他の表の値と比べるものではない。

○ 定石 8.8 — モデルをいじる前に学習曲線を描く

モデルを取り替えたりパラメータを調整したりする前に、学習曲線を描く。描けば「データが足りないのか、モデルが合っていないのか」が分かる。

データ不足が原因なのにモデルをいじり続けて時間を失う、というのはよくある失敗である。逆に、線が頭打ちになっているのにデータを集めに行くのも同じ失敗である。

2 本の線をどう読むかは、第 9.12 節で偏りとばらつきの言葉に置き直す。

8.10 評価の手順をまとめる

図 8.20 に、ここまでの手順をまとめる。




図 8.20 評価の手順。どれも省略しない。

残っているのは、次章で扱う問いである。層別 5 分割交差検証で測ったランダムフォレストの正解率 0.987 が**正しく測られたものかどうか**を、そこで確かめる。

8.11 章末の課題

1. 表 8.4 を、分割の乱数を 10 通り変えて作り直せ。5 分割の平均が他より高かったのは乱数のせいかどうかを確かめ、分割数を増やすと平均正解率と分割間の標準偏差がそれぞれどちらへ動くかを調べよ。

2. 表 8.3 で誤判定された『陰翳礼讃』が、層別化しない 5 分割 (表 8.2) や分割の乱数を変えた場合にも誤判定されるかを確かめよ。
3. 適合率を重視すべき場面、再現率を重視すべき場面を、著者判別の文脈でそれぞれ考えよ。
4. 図 8.19 の検証曲線を延長すると、どこで頭打ちになると予想するか。その予想を確かめる方法はあるか。
5. クラスごとの F_1 を $F_2(\beta = 2, \text{再現率重視})$ で計算し直し、順位の変わる著者を探せ。(ヒント: 適合率と再現率の開きが大きい著者ほど大きく変わる。 F_β の式は式 (8.4) である。)

罣を避ける

9.1 出来すぎた結果を疑う

前章までで、ランダムフォレストが74作品の著者を層別5分割交差検証で0.987の正解率で当てるところまで来た。8名の著者を、たった52個の数値ではほぼ完璧に言い当てている。

こんなときは、まず疑う。

機械学習の失敗の多くは、モデルが弱すぎるのではなく**評価が甘すぎる**ことから来る。本番に出して初めて、交差検証で見た成績が出ないと気づく。そのときには手遅れである。

とてもいい性能が出たときは、
過学習かデータ漏洩を疑う。

本章では、甘い評価を生む漏れを一つずつ実際に測る。そのあとで、漏洩とは限らない落とし穴に移る。訓練で見た範囲の外に出られないモデルがあること(第9.10節)、漏洩と交絡と評価設計の不備が1つの事例の中で重なった例(第9.11節)、予測誤差が3つの部分に分かれること(第9.12節)、次元が上がると距離が使いものにならなくなること(第9.13節)、そして生成AIに分析を任せたときに固有の罣があること(第9.14節)である。

9.2 データ漏洩 — 本番では手に入らない情報が訓練に混ざる

訓練の時点で使えるはずのない情報が、モデルに入り込むことをデータ漏洩(data leakage)という。

漏れているかどうかの判断基準は一つである。

本番でこのモデルに新しいデータが来たとき、訓練時に使ったのと同じ情報が手に入るか。

答えが「いいえ」なら漏れている。テストデータの平均値も、テストデータの正解ラベルも、本番の時点では存在しない。

9.2.1 漏洩の分類

Kapoor と Narayanan は漏洩を8つの型に整理した[92]。表9.1は、その整理のうち本書で扱うものを土台に、彼らの分類にはない**多重テストの漏れ**を本書が加えたものである。

表 9.1 データ漏洩の型

型	内容
前処理の漏れ	標準化・欠損補完などを分割前に行う
特徴選択の漏れ	全データを見て特徴を選んでから分割する
グループの漏れ	同じ元から来たデータが訓練とテストに分かれる
多重テストの漏れ	同じデータで何度も試し、最良の結果を報告する
ターゲットの漏れ	目的変数から派生した変数、予測時には手に入らない変数を使う
時系列の漏れ	未来のデータで訓練し、過去を予測する

補足 漏洩は珍しい事故ではない

Kapoor と Narayanan の調査では、**17 分野・294 本の論文**に何らかの漏洩が見つかった。医療、政治学、分子生物学など、分野を問わず起きている。

多くは悪意ではなく、手順の順番を一つ間違えただけである。




図 9.1 本章で測る漏れのうち代表的な 4 つ。多くの場合は数字を良い方向に歪めるが、向きが逆になることもある (第 9.3 節、第 9.5 節)。

9.3 前処理の漏れ

標準化は平均と標準偏差を使う。2 つの値を**全データ**から計算すると、テストデータの分布が訓練に混ざる。

```

# 悪い例: 全データで fit してから交差検証
X_scaled = StandardScaler().fit_transform(X)
score = cross_val_score(KNeighborsClassifier(5), X_scaled, y, cv=cv)

# 正しい: Pipeline に入れると fold ごとに訓練データだけで fit される
pipe = make_pipeline(StandardScaler(), KNeighborsClassifier(5))
score = cross_val_score(pipe, X, y, cv=cv)

```

どれだけ漏れるのかを測る。k 近傍法 ($k = 5$) で 74 作品の著者を判別し、分割の乱数を 50 通り変えて、5 分割交差検証の正解率を求めた。漏れた手順の正解率から正しい手順の正解率を引いた差を、




図 9.2 標準化と分割の順序。一つ入れ替えるだけで漏洩になる。

以下**水増し**と呼ぶ。正なら漏れたほうが良く見えたことになる。

表 9.2 前処理の漏れ (k 近傍法 $k = 5$ 、分割の乱数 50 通りの平均)

手順	正解率の平均	標準偏差
漏れている (分割の外で標準化)	0.923	0.014
正しい (分割の内側で標準化)	0.921	0.022
見かけ上の水増し	+0.002	0.021

水増しの平均は正解率にして +0.002 である。50 通りの水増しの標準偏差は 0.021 なので、平均の標準誤差は $0.021/\sqrt{50} \approx 0.003$ になり、平均 +0.002 は 0 と区別できない。50 通りのうち、漏れた側の正解率が高かったのは 48%、両者が一致したのが 20%、そして**正しく測ったほうが高かった**のが 32% である。水増しは -0.053 から +0.056 までの幅で散らばる (図 9.3)。




図 9.3 標準化の漏れによる水増しを、5 分割の乱数を 50 通り変えて測った分布 (k 近傍法 $k = 5$)。幅 0.01 の階級で数えた。0 の破線をはさんで両側に散らばる。1 作品の当たり外れは正解率にしておよそ 0.014 にあたる。

つまりこの規模のデータでは、標準化だけの漏れは分割の揺らぎに埋もれる。乱数の種を 1 つだけ選べば水増し +0.029 という値も出るが、それは 50 通りの分布の中の 1 点にすぎない。この数字は、本章の主題である漏洩の代表値にはならない。

補足 今回の作品データで標準化の漏れが小さい理由

標準化が使うのは列の平均と標準偏差である。これはラベルをまったく見ていない。テストデータが訓練に持ち込むのは「その列の値がどのあたりに散っているか」という情報だけで、答えそのものではない。

5 分割なら、テスト側の作品は平均と標準偏差の計算の 5 分の 1 を占める。それでも、テスト側が訓練側と同じ分布から来ていれば、入れても入れなくても平均と標準偏差はほとんど変わらない。変わり方は、標本が少ないほど大きくなる。

そこで、標本を減らしたときの差も測った。著者ごとに同じ数の作品を無作為に選び (24 作品なら著者あたり 3 作品)、どの著者も各分割に 1 作品以上入るように 3 分割の交差検証にした。モデルは、標本が少なくても学習が安定するロジスティック回帰に替えてある。部分標本の選び方 20 通りと分割の乱数 5 通りの平均である。モデルと分割数が違うので、74 作品の行は表 9.2 の値とは一致しない。

標本数	分割の外で	内側で	差
74	0.989	0.989	0.000
40	0.967	0.959	+0.008
24	0.954	0.935	+0.020

74 作品では正解率に差が出ないが、24 作品まで減らすと水増しは正解率にして +0.020 になる。小さなデータでこそ、順序を守る意味がある。

9.3.1 標準化だけでも大差が出る場合

作品データでは、標準化にテストデータを含めても正解率の差は小さかった。次に、訓練データとテストデータで値の分布が異なる場合を調べる。

2 クラスの人工データを、訓練用とテスト用に 40 点ずつ作る。各クラスは 20 点ずつである。横軸 x_1 は、どちらの集合でも青が -1 、橙が $+1$ の付近にある。縦軸 x_2 は、訓練側では青が $+1$ 、橙が -1 の付近にあるが、テスト側では関係を逆転させ、青を -10 、橙を $+10$ の付近に置く。測定環境の変化によって、 x_2 の値が大きくなり、二つのクラスの大小関係も逆転した状況を想定している。各点には小さな乱数のずれを加えた。

二つの手順で、同じ訓練 40 点を使って k 近傍法 ($k = 5$) を学習させる。標準化に使う平均と標準偏差を訓練 40 点から計算した場合、テスト正解率は 0% だった。訓練とテストを合わせた 80 点から計算した場合は 100% になった。テストの正解ラベルはどちらの学習にも渡していない。違いは、標準化にテストの値を含めたかどうかだけである。

近い点が入れ替わるのは、距離の測り方そのものが変わるからである。標準化後のユークリッド距離の 2 乗は、各列の標準偏差を s_1, s_2 とすれば

$$d^2(\mathbf{x}, \mathbf{z}) = \frac{(x_1 - z_1)^2}{s_1^2} + \frac{(x_2 - z_2)^2}{s_2^2}$$

となる。同じ平均を引いた 2 点の差を取るので、平均は消える。訓練側だけでは $(s_1, s_2) = (1.013, 1.022)$ だが、テストを含めると $(1.016, 6.979)$ になる。横軸の標準偏差はほぼ変わらず、縦軸の差の 2 乗に掛かる重みが約 0.021 倍に小さくなる。

図の星から伸びる線を追う。中央では、縦方向で近い橙の訓練点を選んでしまう。右では、縦方向の差が距離に及ぼす影響が小さくなり、横方向で近い青の点が選ばれる。テストデータを使って標準




図 9.4 標準化の漏れを調べる人工データの散布図。左は変換前、中央と右はそれぞれの手順で標準化した後の値を描いた。3 図の軸範囲はそろえてある。右では縦方向のばらつきが縮む。青と橙は正解クラス、丸は訓練点、菱形はテスト点。中央と右では、星で示した同じテスト点から近い訓練 5 点へ線を引いた。縦横の 1 単位の長さは異なるため、紙面上の線の長さが計算上の距離を表すわけではない。

偏差を計算したために近傍が変わり、正解率が上がった。

この人工例では、標準化の手順による違いを示すため、訓練データとテストデータの分布を意図的に変えた。同じ分布から無作為に分けたデータでも、常にこれほどの差が出るとは限らない。

学習に使っていないデータをどれだけ正しく分類できるかを評価するには、標準化に使う平均と標準偏差を訓練データだけから計算し、テストデータにもその値を使う。テストデータを含めて計算すると、評価対象のデータに合わせて距離の測り方を変えることになる。この例で得られた 100% という正解率は、訓練データだけから学習した分類器の性能を表していない。

授業用デモでは、テストデータの x_2 の値を何倍にするかを換え、標準偏差と近傍の変化を確認できる。

9.3.2 分割の前に済ませると漏れる処理

標準化だけではない。「データから何かを学ぶ」処理はすべて危ない。

表の SMOTE は scikit-learn ではなく imbalanced-learn のクラスである。標本を増やす処理は scikit-learn の Pipeline には入らないので、imbalanced-learn の Pipeline を使う。そうすれば、訓練側でだけ標本が増える。

○ 定石 9.1 — 前処理は Pipeline に入れて分割の内側で fit する

Pipeline は書き方の好みではない。事故を構造的に防ぐための道具である。

前処理をパイプラインに入れておけば、交差検証は各分割で自動的に訓練データだけを使って fit してくれる。自分で順序を管理する必要がなくなる。

使う理由は、漏れが大きいためではない。作品データでは二つの手順による正解率の差は小

表 9.3 分割の内側に入れるべき処理 (scikit-learn と周辺ライブラリの例)

クラス	何を学ぶか
StandardScaler	平均と標準偏差
MinMaxScaler	最小値と最大値
SimpleImputer	欠損を埋める値 (平均・中央値)
SelectKBest	どの特徴を残すか
PCA	主成分の方向
SMOTE(imbalanced-learn)	少数クラスの合成サンプル
TargetEncoder	カテゴリごとの目的変数の平均

さかったが、人工例では標準化に使うデータの範囲を変えるだけで 0% から 100% に変わった。それでも全部を内側に入れておくのは、**どれが危ないかを毎回判断しなくて済むから**である。上の表の StandardScaler を SelectKBest に書き換えただけで、正解率の水増しは +0.002 から +0.4 以上に変わる (次節で測る)。その判断を書くたびに繰り返すより、順序のほうを固定しておくほうが安全である。

9.4 特徴選択の漏れ

次は、クラスの情報を持たない乱数だけで高い正解率が出る例を見る。

中身がすべて乱数の特徴量を 2000 列用意する。著者とは何の関係もない。ここから「著者との関連が強い 30 列」を選び、その 30 列で交差検証する。

```
X_noise = rng.normal(size=(74, 2000))      # 情報量ゼロ

# 悪い例: 全データを見て30列選んでから交差検証
selected = SelectKBest(f_classif, k=30).fit(X_noise, y).transform(X_noise)
knn = make_pipeline(StandardScaler(), KNeighborsClassifier(5))
score = cross_val_score(knn, selected, y, cv=cv)

# 正しい: 選択もパイプラインに入れ、fold ごとにやり直す
pipe = make_pipeline(SelectKBest(f_classif, k=30),
                     StandardScaler(), KNeighborsClassifier(5))
score = cross_val_score(pipe, X_noise, y, cv=cv)
```

標準化はどちらも訓練側だけで行っている。違うのは**特徴選択を分割の外でやるか中でやるか**の 1 点だけである。

情報が一切ない乱数から、5 分割交差検証の正解率が **0.570** になった。最頻クラスの吉川英治と答え続けるだけで得られる 0.284 の 2 倍である。

正しい手順に直すと、同じ乱数から得られる正解率は 0.161 まで下がる。8 名から等確率に選んだときの 0.125 をわずかに上回るだけで、最頻クラスを答え続ける 0.284 にも及ばない。情報が無いの

表 9.4 情報がゼロの乱数から得た正解率

手順	正解率
全データで特徴選択 → 交差検証 (漏れている)	0.570
交差検証の中で特徴選択 (正しい)	0.161
参考: 最頻クラスを答え続ける	0.284

だから、これが正しい姿である。

9.4.1 漏れた側の正解率が 0.570 になる理由

2000 列も乱数を用意すれば、その中にはたまたま著者と相関する列が必ず紛れ込む。実際、2000 列それぞれについて著者との関連を検定すると、5% 水準で「有意」になる列が 117 本あった。その中から上位 30 本を選ぶのが、漏れた手順である。

全データを見て選ぶと、テストデータでもたまたま合う列を選んでしまう。そしてその列でテストすれば、当然よく当たる。




図 9.5 乱数を大量に用意すれば、偶然に相関の高い列が必ず出る。

正しい手順の正解率が 0.161 にとどまるのにも理由がある。選ばれた 30 列は、訓練データの中でだけ著者と相関していた列である。テストデータに当てれば、その相関は消えて無関係な乱数に戻る。手がかりのない 30 列で距離を測ることになるので、当てずっぽうと変わらない成績になる。

× アンチパターン 9.1 — 特徴選択を前処理として分割の前で済ませる —

そう考えると罣にはまる。基準は「前処理かどうか」ではない。

正解ラベル y を見る操作は、すべて分割の内側でなければならない。特徴選択、外れ値除去、しきい値の決定、クラスの再定義。どれも y を見た瞬間に漏洩の候補になる。

9.5 グループの漏れ

漏洩の中で最も見つけにくいのがこれである。

第 1 章の表 1.2 で見たとおり、吉川英治の 21 作品のうち 11 は『三国志』の各巻と篇外余録、7 は『宮本武蔵』の各巻だった。

74 作品と言っているが、独立した作品は 58 点しかない。『三国志』の 11 点 (10 巻と篇外余録) を 1 点、『宮本武蔵』の 7 巻を 1 点と数え直すと、吉川英治の 21 作品は 5 点になる。 $74 - 21 + 5 = 58$ という計算である。

交差検証は作品をランダムに分けるので、『三国志』の第3巻が訓練データに、第4巻がテストデータに入る。




図 9.6 シリーズをまたぐ分割と、またがない分割。

第7章の末尾で予告したとおり、これでは「吉川英治の文体」ではなく「この長編に固有の癖」を覚えるだけで当たってしまう。ここでは、それが数字にしてどれだけの水増しになるかを測る。結果は予想と違う方向に出るので、先に測ってから読み方を考える。

StratifiedGroupKFold は、同じグループのデータが訓練とテストにまたがらないように分割する。表 9.5 の**落差**は、通常の層別 CV の正解率からシリーズを分けた CV の正解率を引いた差である。正なら、シリーズをまたいで分割したぶんだけ成績が良く見えていたことになる。

表 9.5 グループの漏れ (52 列を使った場合)

モデル	通常の層別 CV	シリーズを分けた CV	落差
k 近傍法 ($k = 5$)	0.877	0.900	-0.023
ランダムフォレスト	0.987	0.975	+0.011

正解率の落差は**拍子抜けするほど小さい**。ランダムフォレストは通常の層別 CV の 0.987 からシリーズを分けた CV の 0.975 へ、0.011 下がっただけである^{*1}。k 近傍法にいたっては落差が負で、シリーズを分けたほうの正解率が 0.877 から 0.900 へ**むしろ高い**。

これは失敗ではない。第3章の特徴設計が狙いどおりに働いた結果である。52 列は読点の前の文字と字種の比率と文長しか見ていない。そこには『三国志』という物語も、登場人物の名前も入っていない。覚え込むべき「その長編に固有のこと」が、そもそも特徴に含まれていない。

k 近傍法の落差 -0.023 のほうは、意味を読まないほうがよい。74 作品を判別しているので、1 作品の当たり外れが正解率 0.014 に相当する。落差の 0.023 は 2 作品ぶん満たない。落差が小さいときは**符号が反転することもある**という、測り方のばらつきの範囲である。

^{*1} 落差は丸める前の正解率どうしの差である。表示した小数第3位の値で引き算すると 0.012 になるが、丸めの影響にすぎない。

× アンチパターン 9.2 — 落差が小さいことを「漏れがない」の証明として使う

表 9.5 を見て「本書のデータにグループの漏れはない」と結論するのは飛躍である。言えるのはこの特徴の組み合わせでは目立たなかったことだけである。

同じデータでも、特徴を変えれば落差は大きくなる。次節で文字 n -gram に取り替えると、4-gram では落差が正解率にして 0.036 と 3 倍以上に開く。第 11 章でライトノベルを足すと、落差は 0.43 に達する。

漏れの有無を決めるのはデータの集められ方と特徴の作り方であって、モデルでも手法でもない。一度測って小さかったからといって、特徴を変えたあとも小さいままだとは限らない。

9.5.1 文字認識の教科書的な例

グループの漏れを最も明快に示すのが、次の設定である。

100 人に、数字を 0 から 9 まで各 100 回ずつ書いてもらう。データ数は $100 \times 10 \times 100 = 100,000$ 枚。これを訓練用とテスト用にランダムに分割する。

一見なんの問題もない。だが同じ人が書いた文字が訓練とテストの両方に入る。




図 9.7 文字認識でのグループ漏れ。人の筆跡の癖を覚えれば当たってしまう。

モデルは「数字の形」を学ばなくても、「この人の筆跡の癖」を覚えれば当てられる。だが本番で使うときには、訓練に参加していない人が書く。

分割は要求仕様に沿って設計する。「未知の人が書いた文字を読みたい」なら、人で分けなければならない。

9.5.2 Kaggle での実例 — 岩塩層の識別

TGS Salt Identification Challenge[91](2018) は、音波探査の画像から岩塩層を識別する競技だった。訓練画像 4,000 枚、テスト画像 18,000 枚、それぞれ 101×101 ピクセル。

参加者が気づいたのは、これらの画像がもっと大きな画像を切り分けたタイルだということだった。隣り合うタイルは地質構造が連続しているので、片方を見ればもう片方もほぼ分かる。上位陣はタイルをパズルのように組み直し、隣接の情報を利用した。

競技としては巧妙な戦略だが、実務なら評価設計の失敗である。

補足（続き）

きで得ることになる。件数が多いぶん、誤った答えが確かなものに見えてしまう。

2021年に報告された例がある。週に25万件を超える回答を集めた大規模なオンライン調査が、米国のワクチン接種率を公式統計より17ポイントも高く見積もった。同じ時期、無作為抽出で募った約1,000人のパネルに毎回回答を依頼する調査は、誤差5ポイント以内に収まっていた[96]。250倍の回答数が、精度では負けた。

差を生んだのは、**誰が回答したか**である。広告などを見て自分から回答する人と、無作為に選ばれて依頼される人とは、集団の性質が違う。その違いは件数では埋まらない。

本書のコーパスも同じ性質を持つ。青空文庫から作品をもう100点足しても、第1章で見た2つの選抜（著作権と電子化）は残ったままである。

9.6 特徴の作り方が漏れを招く — n-gram の罣

ここまでは分割の仕方の問題だった。だが**特徴の設計そのものが漏れを引き起こすこともある**。

第3章で、内容語を避けて文字ベースの特徴を作った。もし手軽に精度を上げようとして、第2.5.1項の文字 n-gram を使ったらどうなるか。

```
pipe = make_pipeline(
    CountVectorizer(analyzer="char", ngram_range=(3, 3), max_features=500),
    Normalizer(norm="l1"),
    RandomForestClassifier(n_estimators=300, random_state=0))
score = cross_val_score(pipe, texts, y, cv=cv)
```

頻度上位の3文字の並びを500種類選び、作品ごとの頻度を行和1に正規化して森に渡す。**500種類を選ぶ操作もパイプラインの中に入れてある**。どの並びを語彙にするかは訓練側の頻度で決まるので、検証側の作品を見ずに語彙を作ることになる（この理由は本節の終わりで扱う）。

表 9.7 n-gram 特徴の成績（ランダムフォレスト）。語彙の選択は交差検証の各分割で訓練側だけから行った

特徴	通常の層別 CV	シリーズを分けた CV	落差
文字 2-gram (上位 500)	0.973	0.983	-0.010
文字 3-gram (上位 500)	0.987	0.969	+0.018
文字 4-gram (上位 500)	0.960	0.924	+0.036
本書の 52 列	0.987	0.975	+0.011

3-gram の正解率は通常の層別 CV で 0.987 と、本書の 52 列と並んでいる。シリーズを分けた CV では 0.969 で、落差 0.018 は 52 列の 0.011 より大きい、1 作品ぶん (0.014) と変わらない程度である。4-gram になると落差は 0.036 に開く。並びが長いほど、特定の作品にしか出ない文字列が語彙に入りやすくなるためと考えられる。

正解率だけ見れば、n-gram は本書の 52 列と同程度に使いそうに見える。そこで、モデルが何を見ているかを調べる。表 9.8 は、全作品で語彙と森を作り直し、ランダムフォレストの重要度が高い順に 3-gram を 12 個並べたものである。それぞれの並びについて、作品ごとの出現割合（行和 1 に

正規化した値) を著者ごとに平均し、最も多く使う著者と 2 番目の著者、最も多い著者の値が残り 7 名の平均の何倍かを添えた。

表 9.8 ランダムフォレストの重要度が高い 3-gram(全 74 作品で語彙と森を作った)。**[改行]** は改行 1 文字を表す。倍率は、最も多く使う著者の平均出現割合を、残り 7 名の平均出現割合で割った値

順位	3-gram	最も多く使う著者	2 番目	倍率
1	また、	太宰治	吉川英治	4.9
2	が」[改行]	吉川英治	夏目漱石	15.0
3	か」[改行]	吉川英治	夏目漱石	6.4
4	れども	谷崎潤一郎	太宰治	3.7
5	[改行] と、	吉川英治	谷崎潤一郎	10.1
6	る」[改行]	吉川英治	夏目漱石	7.4
7	の方へ	島崎藤村	谷崎潤一郎	7.9
8	て、[改行]	吉川英治	泉鏡花	4.9
9	ども、	谷崎潤一郎	太宰治	4.8
10	、彼の	吉川英治	谷崎潤一郎	9.7
11	い。[改行]	泉鏡花	吉川英治	4.9
12	それか	太宰治	島崎藤村	2.1

上位には、「また、」「れども」のような接続の言い回しと並んで、会話文の閉じかぎ括弧のあとに改行が続く並び(「が」)と改行、「か」)と改行) がある。12 個のうち 6 個は吉川英治が最も多く使う並びで、「が」)と改行の並びは、吉川英治では残り 7 名の平均の 15 倍出てくる。漢字 3 文字の並びは、重要度の上位 20 個に 1 つもない。『三四郎』の「三四郎」や『宮本武蔵』の「小次郎」は、全作品での頻度がそれぞれ 582 位と 916 位にとどまり、上位 500 種類の語彙にそもそも入らない。

このモデルが文体を学んだとは、まだ言いきれない。会話文のあとで改行する組み方は、書き手の癖であると同時に、底本の組み方や入力 of 約束にも左右される。モデルが見分けているのが吉川英治の文章なのか、吉川英治の作品が収められた本の体裁なのかは、この表だけでは区別できない。シリーズを分けた CV で落差が小さかったのは、『三国志』や『宮本武蔵』以外の吉川作品にも同じ並びが出てくるからだと考えられる。ただし、同じ体裁で入力されていれば、吉川英治以外の作品でも同じ並びが出る。

× アンチパターン 9.4 — 何を当てたいかを考えずに n-gram を入れる

n-gram は強力で、実装も簡単である。だからよく使われる。

問題は n-gram そのものではなく、**当てたいものと、n-gram が拾うものが食い違いうること**にある。文字 n-gram は文字列なら何でも拾う。語彙を広げれば、人名や地名のような作品固有の並びも候補に入ってくる。表 9.8 のように、文体と区別しにくい表記の約束が上位に来ることもある。人名を覚えたモデルはその作品を覚えてだけで、未知の作品には別の登場人物が出てくる。

当てたいものが変われば、判定も変わる。

- 話題やジャンルを当てるなら、固有名詞は邪魔者ではなく主戦力である (第 11 章)。時代物

に多い人名の並びは、区分の手がかりとしては正しく働く

- 言語判定、文字コードの推定、スパム判定でも n-gram は素直に使える。拾ってほしいものと拾ってくるものが一致しているからである
- 著者判別で n-gram を使うなら、機能語だけの n-gram、品詞の n-gram、漢字列や改行・かぎ括弧を除いた文字 n-gram のように、内容語や表記の約束が入らない**制限つきの形**にする

どの場合でも、特徴を作ったら**モデルが何を見ているか**を確認する。特徴重要度を上位 20 個ほど眺めるだけで、多くのことが分かる。表 9.8 の会話文の並びも、それをやったから気づけたものである。

補足 語彙を全作品で選ぶのも漏れである

表 9.7 では、上位 500 種類の選択を交差検証の内側に入れた。`CountVectorizer(max_features=500)` を全作品に `fit` してから交差検証に渡すと、どの並びを語彙にするかに検証側の作品の頻度が入る。特徴選択を分割の前で済ませると同じ形の漏れである (第 9.4 節)。

本書の初期の版では、この語彙選択を全作品で行っていた。そのときの 3-gram のシリーズを分けた CV は 0.938 で、訓練側だけで語彙を選ぶ現在の手順では 0.969 である。**漏れを直したら正解率が上がった**。検証側の作品に多い並びが語彙に混じると、その作品に固有の文字列が列を占め、訓練側の作品には役立たない列になる。漏れの向きは常に楽観側とは限らない (第 9.3 節の標準化と同じである)。だから、正解率が上がったか下がったかでは漏れの有無を判定できない。判定の根拠は数字ではなく**手順**にある。

9.6.1 ライトノベルではもっと極端になる

同じことをライトノベル 60 区間 (6 シリーズ) で試すと、事態はさらに悪化する。

表 9.9 3-gram 特徴、ライトノベルでの著者判別 (通常の CV は 5 分割、シリーズを分けた CV は 4 分割)

対象	通常の CV	シリーズを分けた CV
ライトノベル 6 名	1.000	0.000
近代文学 + ラノベ 14 名	0.985	0.560

通常の CV で 1.000 だった正解率が、**シリーズを分けると 0.000 になった**。

理由は、ライトノベルは長期シリーズが中心で、6 名がそれぞれ 1 つのシリーズしか書いていないことがある。つまり**著者とシリーズが 1 対 1 に対応している**。シリーズで分割すると、テストに現れる著者の作品が訓練データに 1 つも存在しない。訓練にない著者名は予測の候補にすら入らないので、どんな特徴を使っても正解率は 0 になる。

反対に、通常の CV で 1.000 になるのは、同じシリーズの別の区間が訓練側にあるからである。ここでは、登場人物の名前のようなシリーズ固有の並びでも当てられてしまう。実際、ライトノベル 60 区間だけで語彙 (上位 500) と森を作り、重要度の上位 30 個を書き出すと、出現の 99% 以上が 1 つのシリーズに集まる並びが 6 個あり (6、12、18、22、24、28 位)、どれも登場人物の名前の一部だっ

た。『葉屋のひとりごと』の主人公の名「猫猫」が、空行の直後と読点の直後の2つの形で入り、ほかに『サイレント・ウィッチ』の「フェリクス」「モニカ」、『Re: ゼロから始める異世界生活』の「スバル」、『片田舎のおっさん、剣聖になる』の「アリュースシア」の一部がある。残りの並びのうち13個は改行か空行を含み、段落や会話文の区切り方の癖を拾っている。

補足 著者ごとにシリーズが1つしかないとき正解率は0.000になる

「正解率ゼロ」は失敗した実験ではない。このデータでは著者判別を学習できないという事実の発見である。

著者ごとに1シリーズしかないなら、「著者の文体」と「シリーズの世界観」を切り分ける手立てがない。必要なのはより良いモデルではなく、より良いデータである。

第11章では、ライトノベルで何なら学習できるかを考える。

9.7 ハイパーパラメータ選択の漏れ

もう一つ、見落とされやすい漏れがある。

第8章で、 k 近傍法のハイパーパラメータ k を1から25まで変えて交差検証した(図8.18)。最も良かったのは $k=1$ で、そのときの正解率は0.973だった。

0.973を「このモデルの性能」として報告することはできない。 k を選ぶのに、評価と同じデータを使っているからである。




図 9.9 k を変えたときの交差検証スコア。最大値を性能として報告するのは漏洩である。

25通り試して最も良いものを選んだのだから、その値は偶然の上振れを含んでいる。

正しい手順は入れ子交差検証 (nested cross-validation) である。




図 9.10 入れ子交差検証。外側で性能を測り、内側でハイパーパラメータを選ぶ。

内側: k を選ぶ

```
grid = GridSearchCV(
```

```

make_pipeline(StandardScaler(), KNeighborsClassifier()),
{"kneighborsclassifier__n_neighbors": range(1, 26)},
cv=StratifiedKFold(5, shuffle=True, random_state=1),
)
# 外側：性能を測る。grid 自体をモデルとして渡す
score = cross_val_score(grid, X, y, cv=StratifiedKFold(5, shuffle=True, random_state=0))

```

作品数が5の柳田国男は、外側の訓練側では4作品になる。内側の5分割では、柳田国男の作品が入らない分割ができるので、このコードを実行すると scikit-learn が警告を出す。計算は進むが、気になるなら内側を4分割にすれば警告は出ない。

表 9.10 ハイパーパラメータ選択と評価の分離

手順	正解率
同じ CV で k を選び、最良値を報告 (漏れている)	0.973
入れ子交差検証 (正しい)	0.973
入れ子 + シリーズを分ける (さらに正しい)	0.911

本書のデータでは、入れ子にしても正解率が変わらなかった。表 9.12 の上半分のとおり、外側のどの分割でも内側では $k = 1$ が選ばれ、内側で選び直しても同じモデルに行き着くためである。差が出ないこともあるということも大事な観察である。

入れ子交差検証の外側の平均は、特定の k を持つ1つのモデルの性能ではない。「内側の交差検証で k を選び、そのモデルで予測する」という手順全体の性能である。外側の分割ごとに選ばれる k が違って、測っているものは変わらない。実際に使うモデルは、同じ手順を全データに当てて作る (`grid.fit(X, y)` のあと `grid.best_estimator_` を使う)。その性能の見積もりとして報告するのが、入れ子で測った値である。

ただし、差が出なかったのは本書のデータが素直だからで、手順が問題ないことの証明ではない。差が出る状況は人工的に作れる。特徴を**情報ゼロの乱数 60 列**に差し替えて、 $k \cdot$ 距離・重み付けの 48 通りの組を同じ手順で選んでみる (次節でも同じ 48 通りを使うが、乱数の列は次節とは別に引いた)。

表 9.11 情報ゼロの乱数 60 列での比較。漏れた手順だけが基準線を超える

手順	正解率
同じ CV で設定を選び、最良値を報告 (漏れている)	0.310
入れ子交差検証 (正しい)	0.243
参考: 基準線 (最頻クラス)	0.284

正解率の差は 0.310 対 0.243 で、0.067 しかない。だがこの 0.067 が**基準線 0.284** をまたいでいる。漏れた手順は「乱数に予測力がある」と報告し、入れ子は「情報はない」と正しく報告する。結

論の向きが逆になる。

表 9.12 の下半分を見ると、外側の分割ごとに選ばれる設定がばらばらで、内側の最良値は 5 回のうち 4 回で外側の正解率を上回る。内側の最良値は、48 通りの中から最も良いものを選んだ値なので、偶然の上振れを含む。外側の正解率は、選んだ設定を選択に使っていない作品で測り直した値である。

表 9.12 入れ子交差検証の外側の分割ごとの結果。内側の最良値は内側の 5 分割交差検証で最も良かった設定の値、外側の正解率はその設定で外側の評価用の作品を判別した値

外側の分割	内側で選んだ設定	内側の最良値	外側の正解率
本書の 52 列			
1	$k = 1$	0.932	1.000
2	$k = 1$	0.983	0.933
3	$k = 1$	0.983	0.933
4	$k = 1$	0.950	1.000
5	$k = 1$	0.950	1.000
平均			0.973
情報ゼロの乱数 60 列			
1	$k = 7$ 、ユークリッド、一様	0.289	0.267
2	$k = 21$ 、ユークリッド、一様	0.306	0.333
3	$k = 21$ 、チェビシェフ、一様	0.358	0.267
4	$k = 5$ 、ユークリッド、一様	0.323	0.133
5	$k = 11$ 、チェビシェフ、一様	0.317	0.214
平均			0.243

だが差が出るかどうかを事前に知ることはできない。入れ子にして初めて分かる。

コラム 取り分けたデータも、何度も見れば漏れる

入れ子交差検証と並ぶもう一つの守り方は、最終確認用のデータを最後まで取り分けておくことである。ただし、この守りは「一度しか見ない」ことで成り立っている。

機械学習の競技会では、参加者がモデルを提出するたびに、主催者が手元に取り分けたデータでの得点を公開の順位表に出すことが多い。参加者はその得点を見てモデルを直し、また提出する。Dwork らは 2015 年、取り分けたデータの得点を見てモデルを変えた時点で、モデルとそのデータのあいだに依存が生じ、取り分けたデータで測った値が「未知のデータでの成績」を表さなくなることを定式化した [99]。何度も見るうちに、そのデータにたまたま合う方向へモデルが寄っていくからで、本章の多重テストの漏れと同じことが、取り分けたデータの側で起きる。

彼らは、取り分けたデータへの問い合わせに答えるとき、訓練データでの得点との差が小さいうちは訓練データでの得点を返し、差が大きいときだけ取り分けたデータでの得点に小さな乱数を加えて返すようにすれば、同じデータを何度も使っても評価が崩れにくいことを示した。問い合わせのたびに返す情報を絞るという考え方である。

手元の分析でも、同じことが起きる。「最終確認用」のデータで一度測り、結果を見て手を入れ、もう一度測れば、そのデータはもう最終確認用ではない。手を入れたなら、その回数を報告に書く。

9.8 多重テストの漏れ

前節の前半では、本物の特徴で k を 25 通り試した。試す設定を増やし、特徴を乱数に替えると、何が起きるかを 1 つずつ見ていく。

k だけでなく、距離の種類 (ユークリッド・マンハッタン・チェビシェフ)、重み付け (一様・距離の逆数) も変えてみる。 k を 8 通り取れば $8 \times 3 \times 2 = 48$ 通りである。ただし特徴量は情報ゼロの乱数 60 列にする。




図 9.11 情報ゼロの乱数 60 列で 48 通りの設定を試したときの、5 分割交差検証の正解率の分布。

48 通りの設定それぞれについて、74 作品の著者を 5 分割交差検証で判別したときの正解率を測った。48 通りの平均は 0.242 で、最頻クラスを答え続ける基準線 0.284 を下回っている。乱数の列には著者を見分ける情報がないのだから、これは当然の結果である。

ところが 48 通りのうち最も良かった設定では、正解率が 0.324 になった。基準線を 0.040 上回っている。

「マンハッタン距離を使い、 $k = 21$ 、一様な重みという設定で正解率 0.324 が得られました」と報告すれば、それらしく聞こえてしまう。48 通り試したうちの 1 つだと書かなければ、読み手には見分けようがない。

どれくらい起きやすいかは計算できる。1 回の試行が偶然に「当たり」になる確率、つまり本当は何の関係もないのに基準を超えてしまう確率を 5% とすると、 n 回試して 1 回も当たらない確率は 0.95^n である。少なくとも 1 回当たってしまう確率は $1 - 0.95^n$ になる。なお 48 通りの試行は同じデータを使い回していて独立ではないので、この値は厳密には成り立たないが、試すほど当たりやすくなるという方向は変わらない。

上で試した 48 通りは、この図の右端に近い。最良の設定が最頻クラスを超えたのは、たまたまではなくそうなるまで試したからである。

× アンチパターン 9.5 — 試行回数を報告しない —

何通り試したかを書かずに最良の結果だけを報告するのは、統計でいう多重比較の問題である。

同じデータに何度も問いを投げれば、そのうち偶然に良い答えが返ってくる。

対策は次のとおりである。





図 9.12 1 回あたり 5% の確率で偶然に当たる試行を、 n 回繰り返したとき、少なくとも 1 回当たってしまう確率。14 回でもう五分五分になり、50 回では 0.92 に達する。「いろいろ試したら 1 つうまくいった」は、試した回数を知らなければ評価のしようがない。

- 入れ子交差検証で、選択と評価を分ける
- 試行回数を明記する
- 最終確認用のデータを完全に取り分けておき、一度だけ使う

発展 多重比較の補正と、その限界

統計の検定では、試す回数 m に応じて判定の基準を厳しくする。最も単純なのはボンフェローニ補正で、1 回ごとの有意水準を $0.05/m$ にする。48 回なら 1 回あたり約 0.001 で、試行が独立なら、少なくとも 1 回偶然に当たる確率は $1 - (1 - 0.05/48)^{48} \approx 0.049$ に抑えられる。小さい p 値から順に基準をゆるめていくホルムの方法は、同じ保証のまま取りこぼしが少ない。多数の特徴を一度に調べるときは、「当たり」と判定したもののうち偶然による割合の期待値を 5% に抑える偽発見率 (false discovery rate, FDR) の考え方 (ベンジャミーニとホッホベルクの方法) がよく使われる。

第 9.4 節の乱数 2000 列で、列ごとに著者との関連を F 検定にかけると、 $p < 0.05$ になる列は 117 本ある (図 9.13)。ボンフェローニ補正で残るのは 0 本、ベンジャミーニとホッホベルクの方法で残るのも 0 本である。本書の 52 列では、ボンフェローニ補正のあとも 46 列が残る。



発展（続き）

図 9.13 列ごとの F 検定の p 値を小さい順に並べた。ボンフェローニ補正は赤の破線より下にある p 値を「当たり」とする。ベンジャミーニとホッホベルクの方法は、緑の線より下にある p 値のうち最も右のものを探し、そこまでの p 値をすべて「当たり」とする。乱数 2000 列では両方とも 1 本も残らない。

ただし、交差検証で設定を選ぶ場面には、この補正はそのままは使えない。48 通りの試行は同じ作品を使い回して強く依存しているうえ、知りたいのは「どれかが偶然でないか」ではなく「選んだ設定の本当の性能」だからである。そのためモデル選択では、補正ではなく、選択に使っていないデータで測り直す（入れ子交差検証、最後まで取り分けたデータ）。

補足 多重テストの漏れは AI との対話でも起きる

「もう少し精度を上げて」と AI に繰り返し依頼して調整を続けると、テストデータが実質的に選択基準になっていく。

これも多重テストの漏れである。人間が手で調整しても、AI に任せても、同じデータを何度も見た事実は変わらない。

コラム 死んだサケの脳が「反応」した

2009 年、Bennett らは学会で、1 匹の大西洋サケを fMRI(磁気共鳴で脳の活動を測る装置)に入れた実験を報告した。人が写った社会的な場面の写真を次々に見せ、写真の人物がどんな気持ちかを判断させる、という体裁の実験である。サケは撮影の時点ですでに死んでいた [97]。

脳の画像は、ボクセルと呼ぶ小さな立方体に区切って、ボクセルごとに「写真を見ているときと見ていないときで信号が違うか」を検定する。1 回の撮影で調べるボクセルは数万から十数万にのぼる。補正をしないで解析すると、サケの脳と脊髄に「有意な活動」を示すボクセルのかたまりが見つかった。偽発見率を抑える補正や、全体で 1 回でも誤る確率を抑える補正をかけると、活動は 1 つも残らなかった。

論文の副題は「適切な多重比較補正を支持する議論」である。当時、fMRI の論文には補正をしない解析がまだ少なからずあった。この研究は 2012 年にイグノーベル賞 (神経科学賞) を受けている。

本章の乱数 2000 列と同じ形の問題である。ボクセルが列に、写真の種類が著者にあたる。

9.9 そのほかの漏れ — ターゲットと時系列

9.9.1 ターゲットの漏れ

目的変数から派生した変数、あるいは予測の時点ではまだ存在しない変数を使ってしまう型である。

- クレジットカードの不正検出で「返金の有無」を特徴にする。返金は不正と判定された後で発生する
- 病気の予測に「その病気の治療薬の処方歴」を使う
- 退職予測に「引き継ぎ資料の作成有無」を使う

補足 KDD Cup 2008 の患者 ID

マンモグラフィ画像から乳がんを予測する競技で、**患者 ID** に予想外の強い予測力があった。データは複数の臨床研究・機関・装置から集められ、ID はその出所ごとに連番で振られていた。出所によってがん患者の割合が違ったので、ID の値から出所がわかり、出所から答えの見当がついた。ID という、本来なんの意味も持たないはずの数字に、答えが埋め込まれていた [90]。

9.9.2 時系列の漏れ

時間の順序があるデータをランダムに分割すると、**未来のデータで訓練して過去を予測することになる**。




図 9.14 時系列データの分割。過去で訓練し、未来を予測する。

本書のデータで確かめられる。『本好きの下剋上』は 677 話が 3.5 年かけて投稿された。各話の文体特徴 (字種・文長・読点) から、**その話がいつ投稿されたか**を Ridge 回帰 (第 4.4.2 項で触れた、正規化つきの線形回帰) で当ててみる。目的変数は連載開始からの経過日数である。列ごとの標準化は Ridge 回帰と 1 つの Pipeline にまとめ、分割ごとに訓練側の話だけで平均と標準偏差を求める (第 9.3 節)。

普通に 5 分割交差検証 (ランダム分割) をすると、決定係数 (第 8.5.2 項) は $R^2 = 0.77$ 。「文体から執筆時期が当てられる」ように見える。ところが**先の 451 話で訓練し、残りの 226 話を予測する** (時間順の分割) と、 $R^2 = -4.41$ 。テスト期間の 226 話の実際の経過日数の平均を答え続けるより悪い。その平均は予測の時点では知りえない値なので、この基準線は予測の側に厳しい比べ方ではある。モデルの予測は訓練期間の終わり付近に張りついたままで、その先の伸びをまったく追えていない (図 9.15)。

からくりは**ドリフト** (drift) である。シリーズの文体は連載が進むにつれて少しずつ変わる。実際、列ごとに標準化した特徴ベクトルどうしのユークリッド距離は、隣り合う話では平均 9.0 なのに、掲載順で全話数の 3 分の 1 (225 話) 以上離れた話の組では平均 10.7 になる。全 677 話からとれるすべての組の平均は 10.0 なので*2、隣の話はそれより近く、遠く離れた話はそれより遠い。掲載順の差ごとに組の距離を平均すると、隣の話がいちばん近く、差が開くにつれて距離も少しずつ大きくなる (図 9.16)。この距離は予測に使うものではなく、データの様子を調べるための集計なので、標準化には全 677 話の平均と標準偏差を使った。

*2 標準化した 52 列では、どんなデータでも、すべての組の距離の 2 乗の平均がほぼ 2×52 になる (各列の分散が 1 なので)。そのため全組の平均距離は $\sqrt{2 \times 52} \approx 10.2$ を少し下回る値になる。距離の大小は、この全組の平均と比べて読む。




図 9.15 『本好きの下剋上』各話の投稿時期を文体から予測する。ランダム分割では対角線に沿うが、未来を知らずに予測した 226 話 (赤) は訓練期間の終わり付近に張りつく。




図 9.16 『本好きの下剋上』の 677 話から 2 話を選ぶすべての組について、掲載順の差ごとに文体の距離を平均したもの (全話で標準化した 52 列のユークリッド距離)。差が開くほど距離は大きくなる。差が 600 話を超える組は 76 組以下と少ないので描いていない。

ランダム分割では、テストの話の直前と直後の話が訓練に入るので、モデルは両側からの内挿で答えを写せる。どのフォールドでも、テストの話より未来の話が訓練側に入っている。時間順に分けると、この写しができなくなる。

× アンチパターン 9.6 — 未来で訓練して過去を予測する —

時間の順序があるデータ (売上、センサ、経過観察、連載作品) をシャッフルして交差検証すると、検証成績は「未来を知っている場合」の成績になる。運用時のモデルは未来を知らないのだから、数字は再現されない。

さらに、ドリフトが強いデータほどランダム分割の成績は良く出る。隣接時点からの内挿で補ってしまうからである。「時系列なのに交差検証の成績が妙に良い」は、喜ぶところではなく疑うところである。

TimeSeriesSplit を使えば、常に過去で訓練し未来で検証できる。時間の順序を無視した分割は、

Kapoor と Narayanan が整理した 8 つの型のうちの 1 つに数えられている [92]。売上予測、災害予測、疫学のモデルなど、時間とともに性質が変わるデータを扱う分野では繰り返し起きている。

コラム Google のインフルエンザ予測はなぜ外れたか

Google は 2008 年、検索語の頻度からインフルエンザのような症状での受診率を推定する Google Flu Trends を公開した。米国疾病予防管理センター (CDC) の集計は 1~2 週間遅れて出るが、検索の数はその日のうちにわかる。検索から受診率をいち早く推定できれば役に立つ、という発想である。

作り方は、約 5000 万の検索語の中から、CDC の受診率の時系列 1152 点に最もよく合うものを選ぶというものだった [98]。候補が観測点よりはるかに多いところから最良のものを選んでいたので、本章の特徴選択の漏れや多重テストの漏れと同じ形をしている。冬に増える検索語であれば、インフルエンザと関係がなくても季節の波には合ってしまう。

この予測は、2009 年の新型インフルエンザ (A/H1N1) の流行を捉えられなかった。作り直したあとも、2011 年 8 月からの 108 週のうち 100 週で高すぎる値を出し、2013 年 2 月には CDC の受診率の 2 倍を超える値を予測した。Lazer らは原因として、多数の候補から選んだことによる過学習に加え、検索エンジン側の仕様の変更などで、検索のされ方そのものが時間とともに変わったことを挙げている。本章の言葉でいえば、ドリフトである。

『本好きの下剋上』の実験で、ランダム分割では当たり、時間順に分けると外れたのと同じことが、膨大な数の検索を使った予測でも起きた。

9.10 訓練で見た範囲の外に出られないモデルがある

ここからは漏洩を離れる。分割を正しく設計しても残る落とし穴である。前節で時間順に分けたついでに、もう 1 つ確かめておきたいことがある。**モデルによっては、そもそも未来の値を出せない。**

同じ連載データで、先の 451 話で訓練して残りを予測する。使うモデルを Ridge 回帰・ランダムフォレスト・k 近傍法の 3 つにして比べた (図 9.17)。




図 9.17 訓練期間より先の話を予測させた結果。ランダムフォレスト (緑) と k 近傍法 (赤) の予測は、訓練で見た最大値のあたりで頭打ちになる。

訓練に使ったのは 675 日目までで、テストは最大 1265 日目までである。3 つの予測の最大値を並べる。

ランダムフォレスト 605 日 k 近傍法 617 日 Ridge 回帰 954 日

前の2つは**訓練で見た範囲を1日も超えていない**。

これは実装の都合ではなく、予測値の作り方から来る性質である。2つとも、予測値を**訓練データのラベルの平均**として作っている。

- **決定木**の予測値は、その葉に落ちた訓練データのラベルの平均である。森はその平均をさらに平均する
- **k 近傍法**の予測値は、最も近い k 件のラベルの平均である

平均は、元の値の最大値を超えない。どんな入力を与えても、訓練ラベルの最大値より大きな値は出てこない。入力が訓練データからどれだけ離れていても、返ってくるのは「いちばん端の訓練データの値」で頭打ちになる。

Ridge 回帰の予測は文体特徴の一次式なので、特徴が訓練で見た範囲の外に出れば、予測も範囲の外に出られる。図でも訓練期間より先まで予測が伸びている。ただし 954 日どまりで、テストの最大 1265 日に及ばない。**外に出られることと、外で当たることは別**である。

× アンチパターン 9.7 — 訓練データの範囲の外を平均を返すモデルに予測させる

売上、株価、利用者数、累積の何か。上がり続けるデータを、木ベースのモデルや k 近傍法で予測すると、未来の予測は必ず**頭打ち**になる。モデルが慎重なのではなく、その値を出す能力がない。

見分け方は「予測値が訓練データのラベルの平均で作られているか」である。木、森、k 近傍法、近傍の重み付き平均を返すカーネル回帰 (ナダラヤ-ワトソン推定) はこの側にある^a。

対処を挙げる。

- **トレンド**を先に取り除く (差分を取る、時間で割る)。残った変動だけを学ばせる
- **線形の項**を持つモデルと組み合わせる
- **そもそも外挿しない**。訓練で見た範囲の中だけで使う

^a 勾配ブースティングは、初期値に木の出力を足し込んでいく形なので、原理上は訓練ラベルの範囲を超えられる。ただし範囲外の入力に対しては各木が端の葉を返すので、実際には同じように頭打ちになりやすい。

補足 予測が当たることと効果が測れることは違う

本書が扱ってきたのは、一貫して**予測**である。文体から著者を当てる、文体から時期を当てる。どれも「入力から出力を言い当てる」問題だった。

実務では、似て非なる問いが出てくる。**介入の効果を知りたい**という問いである。「この施策を打ったから売上が伸びたのか」「この機能を足したから利用者が増えたのか」。

2つは別の問題である。右肩上がりのデータで施策の前後を比べて「伸びた」と言っても、何もしなくても伸びていた分が混ざっている。本書の言葉でいえば、**時間そのものが交絡**している。

取り出すには、同じ時期に施策を受けなかった集団を用意して、**両者の変化の差**を取る。共通して起きた伸びが打ち消されて、施策を受けた側にだけ起きた分が残る。差の差 (difference-in-differences) と呼ばれる考え方である。

本書はここから先に踏み込まないが、**予測の精度をいくら上げても、効果の推定にはならない**。必要な道具立てがまったく違う。

9.11 COVID-19 診断モデルの教訓

ここまで個別に見てきた落とし穴は、実際の研究では1つの事例の中で重なる。漏洩・交絡・評価設計の不備が同時に起きた例を見ておく。

2020年から2021年にかけて、胸部X線やCTからCOVID-19を診断するモデルの論文が大量に発表された。

Roberts ら [93] は 2,212 本の論文から候補を絞り込み、最後に残った 62 本を精査したうえで、**臨床利用に耐えるものは一つもなかった**と結論している。

原因は漏洩に限らない。型の違う3つに整理できる。

- **Frankenstein データセット** (グループの漏れ) — 公開データが統合・再配布される過程で、同じ患者の画像が訓練と評価の両方に入った
- **子供の画像の混入** (交絡) — 精査した 62 本のうち 16 本が、陰性の対照群に、1~5 歳の小児の肺炎画像を集めた公開データを使っていた。COVID-19 の画像は成人から集めているので、陰性か陽性かが、子供か大人かと重なる。モデルが学んだのは「子供と大人の見分け方」だった。第 11 章の時代とジャンルの交絡と同じ形である
- **外部検証の欠如** (評価設計の不備) — 外部のデータで確かめた研究は、62 本のうち 13 本だった。1 つの病院のデータだけで訓練と評価を済ませると、撮影装置や患者層の癖まで込みで学んでしまう

3 つとも、モデルや手法の問題ではない。**データがどう集められたかを確認しなかったこと**から来ている。

補足 手元のデータで測れることには限りがある

外部検証がなぜ要するのかは、本書のデータで考えると分かりやすい。

本書は青空文庫の 74 作品で訓練し、同じ 74 作品を分けて評価している。どれだけ分割を厳しくしても、測れるのは「青空文庫のこのコーパスの中での成績」までである。

たとえば底本の入力者による表記の癖が全作品に共通していれば、モデルはそれも込みで学ぶが、同じコーパスで評価するかぎり、それは誤りとして現れない。別の出典から集めたテキストで試して、はじめて分かる。

第 11 章でライトノベルを足すのは、話を広げるためだけでなく、**別の出所のデータに当てるとどうなるかを見るためでもある**。

9.12 誤差を 3 つに分ける — 偏りとばらつき

ここから 2 節も、漏洩とは別の落とし穴を扱う。まず、これまで別々に出てきた「深さ」「 k 」「正則化の強さ」「木の本数」を、1 つの軸の上に並べ直す。

モデルの予測誤差は、3 つの部分に分けられる。

- **偏り** (bias) — モデルの形が単純すぎて、真の関係を表せないぶん。データを取り直しても**同じ向きに外れる**
- **ばらつき** (variance) — 訓練データが変わると答えが変わってしまうぶん。平均すれば合っている、1 回ごとには外れる

- 雑音 — データそのものに乗っている、どうやっても説明できないぶん

言葉だけでは掴みにくいので、的当てにたとえる。的の中心が**真の値**、1発の矢が**1回ぶんの訓練データで作ったモデルの予測**である。訓練データを取り直すたびに矢を1本射ると思えばよい。




図 9.18 偏りとばらつきを的当てで見る。中心が真の値、点1つが1回ぶんの訓練データから得た予測である。偏りは点の集まりが中心からどれだけずれているか、ばらつきは点どうしがどれだけ散らばっているかにあたる。右上は毎回同じ答えを出すのが的を外し、左下は平均すれば中心に来るが1回ごとには大きく外れる。

図 9.18 の右上と左下に注目してほしい。どちらも当たっていないが、外し方が違う。右上は**何度やっても同じ場所に外れる**ので、データを増やしても直らない。モデルの形を変えるしかない。左下は**平均を取れば中心**なので、データを増やすか、複数のモデルを平均すれば近づく。ランダムフォレストが多数の木を平均するのは、深い木を左下から左上へ寄せる操作にあたる。

2乗誤差で測るとき、3つはちょうど足し算になる。ある入力 x で、訓練データ D から作ったモデルの予測を $\hat{f}_D(x)$ 、真の値を $f(x)$ 、新しく観測した値を $y = f(x) + \varepsilon$ (雑音 ε は平均 0・分散 σ^2) とする。訓練データの取り直しと雑音の両方について平均を取ると

$$E[(y - \hat{f}_D(x))^2] = \underbrace{(E_D[\hat{f}_D(x)] - f(x))^2}_{(\text{偏り})^2} + \underbrace{E_D[(\hat{f}_D(x) - E_D[\hat{f}_D(x)])^2]}_{\text{ばらつき}} + \underbrace{\sigma^2}_{\text{雑音}} \quad (9.1)$$

が成り立つ。 E_D は訓練データの取り直しについての平均を表す。ばらつきは分散なので、はじめから2乗の単位である。偏りは差そのものなので、2乗して単位をそろえる。式は1つの x ごとに成り立つので、後の図 9.20 では各項を x について平均した。

発展 3つに分かれる理由

$\bar{f}(x) = E_D[\hat{f}_D(x)]$ と書き、 $y - \hat{f}_D(x) = \varepsilon + (f(x) - \bar{f}(x)) + (\bar{f}(x) - \hat{f}_D(x))$ と3つに分けて2乗する。2乗の展開に出てくる交差項は、3つとも平均すると0になる。 ε は訓練データと関係がなく平均

発展 (続き)

0であり、 $E_D[\bar{f}(x) - \hat{f}_D(x)] = 0$ だからである。残るのは σ^2 、 $(f(x) - \bar{f}(x))^2$ 、 $E_D[(\bar{f}(x) - \hat{f}_D(x))^2]$ の3項である。

式 (9.1) の3つが実際にどう振る舞うかを、人工のデータで測ってみる。本物のデータでは真の関数が分からないため、偏りとばらつきを別々に取り出せない。そこで真の関数をこちらで決めてしまう。 $f(x) = \sin x + 0.3x$ と定め、そこに標準偏差 0.35 の雑音を乗せた点を 60 個作る。これを訓練データとして決定木で当てはめ、**データを作り直して 400 回繰り返す**。各点における予測の平均が真の値からどれだけずれているかが偏り、400 回の予測の**散らばり**がばらつきである。図 9.19 は、そのうち 20 回分の当てはめを重ねて描いたものである。




図 9.19 データを作り直すたびに決定木を当てはめ、20 回分を重ねた (細い青線)。太い黒線が真の関数 $f(x) = \sin x + 0.3x$ 、赤の破線が 400 回の予測の平均である。深さ 1 では平均が真の関数から外れ (偏り)、深さ 12 では 1 回ごとの線が大きく揺れる (ばらつき)。




図 9.20 木の深さを変えたときの誤差の分解 (60 点のデータを 400 回作り直した)。偏りは深くするほど減り、ばらつきは増える。合計が最小になるのは、その途中である。

図 9.20 が式 (9.1) の 3 項である。

以下の値はすべて式 (9.1) の各項、つまり 2 乗誤差の単位である。

深さ 1 の木は、 x をある値で 2 つに割って、それぞれの平均を答えるだけである。 $\sin$ の曲線を 2

段の階段で近似することになるので、偏りの2乗が0.1272と大きい。一方で、データを取り直しても答えはあまり変わらないので、ばらつきは0.0674にとどまる。これが**未学習** (underfitting) の状態である。

深さ12まで伸ばすと、偏りの2乗は0.0004とほぼ消える。真の曲線を細かく追えるようになったからである。ところがばらつきが0.1278まで増える。訓練データに乗った雑音まで木が拾うので、データを取り直すたびに違う形になる。これが**過学習**である。

合計が最小になるのは深さ4、つまり両端ではなく途中である。そして雑音そのものが持つ2乗誤差0.122は、どこまで行っても引けない。**誤差をゼロにはできない**という下限がここにある。

9.12.1 これまで調整してきた値はすべて同じ軸の上にある

本書でこれまで調整してきた値を並べると、どれも図9.20の横軸にあたる。

表 9.13 偏りとばらつきの兼ね合い。左に行くほど偏りが大きく、右に行くほどばらつきが大きい

調整する値	偏りが大きくなる側	ばらつきが大きくなる側
木の深さ (第8章 図8.17)	浅い	深い
k 近傍法の k (第8章 図8.18)	k が大きい	$k = 1$
正則化の強さ (第4章 図4.9)	α が大きい	α が小さい
特徴の数 (第9.13節)	少なすぎる	多すぎる
$n - 1$ か n か (第3章)	n で割る	$n - 1$ で割る

第3章で「 $n - 1$ で割ると偏りは消えるが二乗誤差は最も大きい」と書いたのも、同じ兼ね合いの一例である (偏りをゼロにする代償として、ばらつきを引き受けている)。

アンサンブルの2つの流儀も、同じ軸で説明がつく。

- **ランダムフォレスト**は、似ていない木を並列に作って平均する。平均を取るとばらつきが減る。偏りはほとんど変わらないので、**ばらつきだけを削る**手法である。木を増やしても害がないのは、平均を取る操作だからである (第7章)
- **ブースティング**は、前の木の誤りを次の木が引き受ける。こちらは**偏りを削っていく**。削りすぎると今度はばらつきが増えるので、本数を増やすほど過学習する (第7章の図7.15。ランダムフォレストとの比較は図7.16)

○ 定石 9.2 — 成績が悪いときは偏りとばらつきのどちらが原因かを先に見る —

訓練データでの成績と検証データでの成績を並べる (第8章の学習曲線)。

- **両方とも悪い** — 偏りが大きい。モデルを複雑にする、特徴を足す、正則化を弱める
- **訓練だけ良い** — ばらつきが大きい。モデルを単純にする、正則化を強める、データを増やす、アンサンブルで平均する

判定を飛ばして手当てをすると、逆向きの対処をしてしまう。「精度が出ないからモデルを大きくする」は、ばらつきが原因のときには事態を悪くする。

発展 偏りとばらつきにきれいに分かれるのは2乗誤差のときだけ

式 (9.1) のきれいな足し算が成り立つのは、2乗誤差で測る回帰の場合である。分類の正解率 (0-1 損失) では、偏りとばらつきを一意に分ける方法が知られていない。分解の定義自体がいくつも提案されていて、どれを使うかで結論が変わる。

それでも「単純すぎて外す」と「訓練データに振り回される」という2つの向きの誤りがあるという見方は、分類でも有効である。本書が図 8.17 で訓練と検証の2本の線を並べているのは、分解の代わりに**2本の線の差**でばらつきの大きさを読むためである。ただし、この読み方は訓練側の線がモデルの当てはまりを表しているときに限る。k 近傍法の図 8.18 では、各作品が自分自身を近傍に数えるので $k = 1$ の訓練正解率は必ず 1.000 になり、2本の差は過学習の大きさを表さない (k を大きくしたときの成績の低下は未学習の側の誤りだった。第 8 章)。

9.12.2 U 字の右にもう一度谷がある — 二重降下*

図 9.20 の U 字は、長いあいだ機械学習の基本図だった。ところが深層学習で巨大なモデルが使われるようになってから、**U 字の右側にもう一度谷がある**ことが分かってきた。




図 9.21 二重降下の模式図。訓練データでの誤差は単調に下がり続け、訓練データをちょうど暗記できる点 (補間しきい値) で 0 に達して、それより右では 0 のまま動かない。未知データでの誤差はこの点で最悪になり、そこからさらにモデルを大きくすると再び下がっていく。軸の目盛りは省いてある。実際の位置と山の高さは、データと学習の設定で変わる。

図 9.21 のこの形を**二重降下** (double descent) という [67]。谷が 2 つあるので二重である。

真ん中で最悪になる理由は、解の選び方にある。線形モデルなら、補間しきい値はパラメータの数が訓練データの件数と等しくなる点にある。未知数と式の数が同じになり、訓練データをぴったり通す解がちょうど 1 つに決まる。この解は**ようやく 1 つ見つかる**ものなので選択の余地がなく、データに乗った雑音まで律儀に通す形になる。さらにパラメータを増やすと、訓練データを通す解が**無数**にできる。そうなると学習の手続き (勾配降下法) が、その中から係数の小さい、なめらかな解を選ぶ余地が生まれる。**選べるようになったことが**、2 つ目の谷が生じる理由だと考えられている。

この形は人工データで確かめられる。特徴が 400 個ある線形のデータ (係数は先頭の特徴ほど大きい) から 60 件を取り、先頭の p 個の特徴だけを使って最小二乗で当てはめる。 p が 60 を超えて訓練データを通す解が無数にあるときは、係数の 2 乗和が最小の解を使う。勾配降下法を係数 0 から始めると行き着く解である。図 9.22 は、データの取り直し 300 回の中央値である。未知データでの誤差は $p = 15$ で 0.32 と 1 つ目の谷になり、 $p = 60$ で 22.2 まで跳ね上がり、 $p = 100$ で 0.76 と 2 つ目

の谷をつくる。この例では、2つ目の谷は1つ目より浅い。




図 9.22 二重降下を人工データで計算した (訓練データ 60 件、特徴は全部で 400 個)。縦軸は対数目盛りである。訓練データでの誤差は $p = 60$ で 0 になり、それより右は描いていない。未知データでの誤差は $p = 60$ で山になり、その右で再び下がる。雑音の分散 0.1225 は、どこまで行っても引けない。

同じ形は、パラメータ数だけでなく**エポック数**を増やしたときにも、**訓練データの件数**を増やしたときにも現れることが報告されている [68]。最後のものはとくに直観に反する。データを増やしたのに未知データでの成績が下がる領域が、しきい値の近くに存在する。

× アンチパターン 9.8 — 二重降下を「モデルは大きいほどよい」の根拠にする —

二重降下は**必ず起きる法則**ではない。正則化の強さを適切に選ぶと山は低くなり、消えてしまうこともある [71]。条件が揃ったときに現れる現象であって、大きくすれば必ずテスト誤差が下がるという保証ではない。

そして**自分が U 字のどのあたりにいるかは、測らないと分からない**。本書の実験 (図 9.20) では、合計の 2 乗誤差は深さ 4 の 0.2020 から深さ 12 の 0.2507 へ増え、深さ 8 より先はほとんど変わらなかった。60 点のデータでは、深さ 10 から 12 のあたりで木は訓練データをほぼ完全に通すようになり、それより深くしても同じ木しかできない。図の右端が補間しきい値あたり、1 本の木ではその右側へ進めない。Belkin らは、訓練データを通す木を多数平均する (ランダムフォレスト) ことでしきい値の右側を作り、そこで誤差が再び下がることを示している [67]。

新しい現象を知ったからといって、測り方の話は変わらない。交差検証で確かめる手順は、どちらの領域にいても同じである。

9.13 次元の呪い

漏洩とは別の落とし穴を見る。「特徴量が多いほどよい」という素朴な想定が崩れる場面である。

第 4 章で、高次元では最も近い点と最も遠い点の差が相対的に消えることを見た。ここでは、それが実際の分類精度にどれだけ影響するかを測る。

52 列に、情報を持たない乱数の列を足していく。足した列には何の情報もないので、理想的なモデルなら著者判別の正解率は変わらないはずである。以下の正解率はすべて、シリーズを分けた CV で測っている。




図 9.23 情報のない列を足していくと何が起きるか (シリーズを分けた CV)。赤の破線はデータ全体に占める最頻クラスの割合で、目安として引いてある。

k 近傍法の正解率は乱数列を足すほど下がっていき、2052 次元では 0.269 になる。**最頻クラスを答え続ける 0.284 より低い**。52 個の意味ある列は消えていないのに、周りのノイズに埋もれて距離が意味をなさなくなったからである。

一直線に下がるわけではない点にも触れておく。k 近傍法の正解率は、62 次元の 0.868 から 102 次元の 0.876 へ、いったん上がっている。74 点しかないのに、乱数列の引き方しだいでこの程度は上下する。1 本の折れ線を細かく読まず、**全体として下がっている**とだけ読む。

ランダムフォレストの落ち方は緩い。各分岐では候補の列のうち不純度を最も下げるものを選ぶので、意味のある列が候補に入っていれば、乱数の列はほとんど選ばれない。ただし scikit-learn の既定では、各分岐の候補は全列のうち無作為に選んだ一部 (列数の平方根、2052 次元なら 45 列) である。乱数の列が増えると、意味のある列が候補に 1 つも入らない分岐が増え、2052 次元では分岐のおよそ 3 割 (0.31) がそうなる。正解率が 2052 次元で 0.544 まで下がるのはこのためで、無限に耐えるわけではない。各分岐で全列を候補にすると (`max_features=None`)、2052 次元でも正解率は 0.853 を保つ (図 9.23 の紫の三角)。意味のある列だけのときは既定の森のほうが正解率が高い。候補を絞る仕組みは木どうしを似せないための工夫だが、無関係な列が大半を占めるデータでは弱点にもなる。

数学的な背景は付録 B で扱う。高次元では球の体積が消え、点どうしの距離が一点に集中し、ランダムな 2 ベクトルがほぼ直交する。私たちの 3 次元的な直感は、そこでは通用しない。

× アンチパターン 9.9 — 距離を使う手法にとりあえず特徴を全部入れる

「情報は多いほうがよい」は、距離ベースの手法では成り立たない。役に立たない列は**害**になる。

特徴を増やすときは、その列が本当に情報を持っているかを確認してから足す。

○ 定石 9.3 — 列を足して成績が落ちたらまず列を減らす —

モデルを取り替える前に試す順で並べる。

- 次元削減 (PCA、UMAP など) を先に行う (これも分割の内側で)
- 特徴選択で無関係な列を落とす (ただし分割の内側で)
- 距離に依存しないモデル (木ベース) を選ぶ
- そもそも特徴を作る段階で吟味する

なぜこれで直るのかは第4章の定石「次元の呪いは解かずに、低次元の構造を探して避ける」に、高次元データ一般の点検項目は付録Bにある。

9.14 生成 AI に分析を手伝わせるときの罣

コードを書き、図を作り、結果の解釈まで、いまや**生成 AI**(大規模言語モデル) に任せられる。本書の分析程度なら、指示さえ与えれば一通り実行できるコードが返ってくる。だからこそ、漏洩の章の締めくくりに、生成 AI に特有の罣を挙げておく。

9.14.1 相手はすでに答えを読んでいる

本書の題材は青空文庫である。そして主要な言語モデルの訓練データには、青空文庫のテキストが含まれている可能性が高い。「この文章は誰の文体か」と AI に聞いて正解が返ってきても、それは文体の分析ではなく**記憶の引き出し**かもしれない。冒頭の一文から作品名ごと思い出せるのだから。

これは本章で扱ってきた漏洩の、最も大きなスケールの姿である。テストのつもりで与えた問題が、相手の訓練データに入っている。**ベンチマーク汚染** (benchmark contamination) と呼ばれ、AI 自身の性能評価でも深刻な問題になっている。

× アンチパターン 9.10 — AI が当てられたことを「この特徴で判別できる」証拠にする —

「AI に聞いたら著者を当てられた」は、「その特徴量で判別できる」ことも「その手法が優れている」ことも意味しない。モデルがその作品を記憶している可能性を排除できないからである。検証したければ、訓練データに含まれないテキスト (未公開の文章、その場で書いた文章) で試すしかない。

9.14.2 AI は「発見」に甘い

第3.7節の負の相関がよい例である。「作家は漢字を使うほど平仮名を控えることを発見した」と AI に見せれば、「興味深い発見です」と応じてくる可能性が高い。合計1の制約だけでも負の相関は生じるので、それだけでは発見とは言えない、と指摘してくれるとは限らない。

会話型の AI には、使い手の仮説に同調する方向へ応答が寄る傾向が知られている (**追従性**、sycophancy)。

しかも、同調だけが原因ではない。AI に研究を自律的に進めさせる試みでは、使い手が水を向けなくても、モデル自身が失敗した実験を「成功」と報告し、明らかに雑音でしかない数値から成果を宣言する行動が繰り返し観察されている。**ユーレカ本能** (eureka instinct) と名づけられた失敗の型

である [94]。追従性を使い手の仮説に寄る性質だとすれば、こちらは発見そのものを過大に評価する性質で、こちらから仮説を出さなくても起きる。

人間の側にも、ばらばらの点に意味を読み取ってしまう傾向がある。AI が使い手に同調し、発見を過大に評価し、人間の側も意味を読み取りたがると、誰も否定しないまま偽の発見が残る。

× アンチパターン 9.11 — AI の相づちを裏付けに数える —

「AI も面白い結果だと言っている」は、証拠として 0 件である。懷疑は自分の側から持ち込むしかない。「この結果を疑うとしたらどこか」「これが人工的な制約や漏洩から出る可能性はないか」と、**反対方向の質問**を明示的に投げる。同調を求める聞き方 (「この発見、すごくないですか」) をした時点で、返ってくる答えの価値は決まってしまう。

9.14.3 生成されたコードは教科書どおりに漏洩する

AI が生成する分析コードには、本章のアンチパターンがそのまま混入することがある。分割前の標準化も、全データでの特徴選択も、シャッフルされた時系列も、エラーを出さないまま交差検証の成績を高く見せることが多いので、気づきにくい。体裁が整っているぶん、人の書いたコードより読み飛ばしやすい。

漏洩については、本章のチェックリストがそのまま使える。前処理は交差検証の内側にあるか、分割はグループと時間の順序を尊重しているか、基準線と比べているか。書き手が人でも AI でも、疑うべき箇所は変わらない。変わるのは、読まずに信じてしまいやすさだけである。

そのうえで、相手が AI のときだけ足す手順が 2 つある。

○ 定石 9.4 — AI が出した数字は 1 つ選んで自分で再計算する —

コードと数値が同時に出てくるので、**そのコードがその数値を出したのか**を確かめる機会がない。人が書いた報告なら、計算とは別の人が集計するなど、どこかで独立した確認が入っていた。

主要な数字を 1 つ選び、手元で計算し直して一致するかを見る。1 つでよい。ずれたら全部を疑う。

もう 1 つ、**反証を AI 自身に挙げさせる**。「この結論が間違いだとしたら、原因として何が考えられるか」と聞く。同調しやすい相手なので、反対側を言わせる問いを明示的に投げないと出てこない。

9.14.4 再現できるように記録する

同じ指示でも、モデルが違えば、同じモデルでも時期が違えば、返ってくるコードも数値も変わってくる。乱数の種と同じ扱いで、使ったモデル名・日付・主要な指示文を記録しておく。「AI に聞いたらかうなった」を再現可能な報告にする方法は、いまのところそれしかない。

9.15 手順のまとめ

表 9.14 に、本章で測った漏れを並べた。同じ「漏れ」でも、差は 0 から 1 まで開き、符号が逆になるものもある。差の大きさからは漏れの有無を判定できないので、判定は手順で行う。

表 9.14 本章で測った漏れの一覧。「差」は漏れた手順の値から正しい手順の値を引いたもの。時系列の行だけは正解率ではなく決定係数 R^2 で、左がランダム分割、右が時間順の分割

型	実験	漏れた手順	正しい手順	差	節
前処理	標準化 (作品、k 近傍法、分割の乱数 50 通りの平均)	0.923	0.921	+0.002	9.3
前処理	標準化 (人工例、k 近傍法)	1.000	0.000	+1.000	9.3
特徴選択	乱数 2000 列から 30 列を選ぶ (k 近傍法)	0.570	0.161	+0.410	9.4
グループ	シリーズをまたぐ分割 (k 近傍法)	0.877	0.900	-0.023	9.5
グループ	シリーズをまたぐ分割 (ランダムフォレスト)	0.987	0.975	+0.011	9.5
グループ	同上、文字 3-gram (ランダムフォレスト)	0.987	0.969	+0.018	9.6
多重テスト	k を同じ CV で選ぶ (本物の 52 列)	0.973	0.973	0.000	9.7
多重テスト	設定 48 通りを同じ CV で選ぶ (乱数 60 列)	0.310	0.243	+0.067	9.7
時系列	投稿日の予測 (R^2 、Ridge 回帰)	0.77	-4.41		9.9

順番を守れば、本章で見た事故はほぼ防げる。

1. データを見る前に、評価の設計を決める。何を予測するのか、本番では何が手に入るのか (第 9.2 節)。
2. グループを特定する。同じ人・同じ機械・同じ作品から来た行があるなら GroupKFold 系を使う (第 9.5 節)。
3. データから値を学ぶ処理は、すべてパイプラインに入れて分割の内側で fit する。標準化も特徴選択も同じである。 y に触る操作はとくに漏れが大きい (第 9.3 節、第 9.4 節)。
4. ハイパーパラメータを選ぶなら入れ子の交差検証。試行回数も報告する (第 9.7 節、第 9.8 節)。
5. クラスの偏りを見る。最頻クラスの割合を併記し、マクロ F_1 と混同行列を見る (第 8 章)。
6. 特徴重要度を眺める。固有名詞や ID、表記の約束のような、当てたいものと関係の薄い手がかりが上位に来ていないか (第 9.6 節)。
7. 高い数字が出たら疑う (第 9.1 節)。

9.16 章末の課題

1. 標準化の代わりに、欠損値の平均補完を分割前に行う例を作り、水増し量を測れ。標準化より大きくなるか。
2. SelectKBest の k を 5、30、100、500 と変え、漏れありと漏れなしの差がどう変わるか調べよ。差が変わる向きを、選ばれる列の数と、各列がたまたま著者と相関する度合いの両方から説明せよ。
3. 3-gram 特徴について、語彙を上位 500 種類から 5000 種類に広げ、重要度の上位 20 個に何が入るかを表 9.8 と比べよ。次に、改行とかき括弧を含む並びをすべて除いてから成績を測れ。シリーズを分けた CV の正解率はどう変わるか。
4. 入れ子交差検証で、内側の分割数を 3、5、10 と変えたとき、外側の評価はどう変わるか。
5. 自分が最近読んだ論文か、自分の研究の一つを選び、表 9.1 の 6 つの型それぞれについて該当しないことを確認せよ。

6. 図 9.15 の実験で、訓練を先の 3 分の 2 から先の半分に減らすと、時間順分割の R^2 はどうなるか。予想してから実行して確かめよ。(ヒント: テスト側の話が訓練から時間的に遠くなる。外挿の距離とドリフトの関係で考える。)

第 10 章

学習された表現と比べる

第 3 章で 52 個の数を手で組み立て、第 7 章でそれを分類器にかけ、第 8 章で測り方を整え、第 9 章で測り方の壊れ方を見てきた。

ここで、同じ問い (著者を当てる) を別の入力で解かせてみる。手作りの 52 列を大規模言語モデルの埋め込みに置き換えた場合、入力はそのままモデルだけ深層学習に取り替えた場合、文章をそのままモデルに渡した場合の 3 つを、順に試す。3 つの方式で、何を人が決め、何を学習し、何を借りてきて固定するかを図 10.1 にまとめた。




図 10.1 本章で比べる 3 つの方式。(a) は第 10.1 節と第 10.2 節の比較の相手、(b) は第 10.1 節、(c) は第 10.2.4 項で扱う。括弧内は学習する (または借りてくる) 係数のおおよその数である。

比較の道具はもう手元にある。層別の交差検証とシリーズを分けた交差検証、標準偏差の読み方、そして「小さい差を順位に読まない」という作法である。それらを使って、手作業で作った特徴が学習された表現に対してどこまで通用するかを測る。

10.1 手作りの特徴を埋め込みに置き換える

第 3 章では、数える対象を選び、比率に直し、分布を要約して、52 個の数を手で組み立てた。いまなら、文章をそのまま大規模言語モデルに渡して埋め込み (embedding) を受け取るという手がある。あの手作業がそれに置き換えられるかどうかを、実際に測って確かめる。ここまで待ったのは、**当て**

てみないと優劣が決まらないからであり、その「当てて比べる」ための道具立て (交差検証、群を分けた分割、差の読み方) が前の 2 章でようやくそろったからである。

10.1.1 800 字の断片 12 か所を平均して 1 本のベクトルにする

使ったのは Qwen3-Embedding-8B である。文章を入れると 4096 次元のベクトルを返す。筆者の手元の PC で実行した (OpenAI 互換のサーバを立て、そこへ問い合わせる)。

作品 1 つを 1 本のベクトルにするまでに、3 つの判断がある。

1. **読ませる範囲と量を決める。** 各作品から 800 字の断片を 12 か所、本文全体に等間隔で取った。Qwen3-Embedding の文脈長は 32k トークンあるので、長さが足りなくて刻んでいるのではない。800 字あれば、人が読んで文体や話題の見当をつけるには足りると考えて、この長さにした。同じ総量なら、長い断片を少数取るより短い断片を全体に散らすほうが、冒頭や特定の場面に引きずられにくい
2. **指示を付けるかどうかを決める。** Qwen3-Embedding は指示を受け取れる (次項)
3. **断片のまとめ方を決める。** 断片ごとのベクトルを長さ 1 に揃えてから平均し、もう一度長さ 1 に揃えた。長さを揃えずに平均すると、たまたまノルムの大きい断片が平均を支配する

```
pieces = chunks_of(work.body, n_chunks=12, size=800)
if instruction:
    pieces = [f"Instruct: {instruction}\nQuery: {p}" for p in pieces]
E = embed(pieces) # (12, 4096)
E = E / np.linalg.norm(E, axis=1, keepdims=True)
v = E.mean(axis=0)
v = v / np.linalg.norm(v) # 作品1つにつき1本
```

10.1.2 指示を変えて作る

Qwen3-Embedding は指示を受け取れる。ただし書式に決まりがある。

```
Instruct: {タスクの説明}
Query: {本文}
```

ここに書くのはどんな課題に使うかの説明であって、「どんな埋め込みを作れ」という命令ではない。学習では、検索のほかに分類や文の類似度の課題も、同じ「指示 + 本文」の形で与えられている [73]。公式の説明には注意書きが 2 つある。検索ではクエリ側にだけ指示を付け、引かれる側の文書には付け不要と勧められている。また、多言語で使う場合も指示は英語で書くよう勧められている (学習時の指示がほとんど英語だったため)。

本節の使い方は検索ではなく分類なので、クエリと文書の区別がなく、どの文書にも同じ指示を付ける。言語のほうは勧められているとおり英語にする。そのうえで、何を頼むかを 3 通り変えた。指示を付けた 2 通りは、どちらも検索の形 (「しかじかの文章を引け」) で書いている。

- 指示なし — 既定のまま
- 同じ話題を引け — Given a passage from a Japanese novel, retrieve passages that

discuss the same subject matter.

- **同じ著者を引け** — Given a passage from a Japanese novel, retrieve passages written by the same author.

Focus on writing style rather than subject matter or named entities.

同じモデル、同じ本文、同じまとめ方で、頼む内容だけが違う 3 組ができる。

10.1.3 まず眺める

52 列と 3 通りの埋め込みを、それぞれ 2 次元に落として並べる (図 10.2)。1 つの手法だけで見ると「その手法が悪いのでは」と言えてしまうので、PCA・t-SNE・UMAP の 3 通りで写した。4 行 × 3 列で 12 枚あるが、見るべき違いは行のほうにある。

まず PCA の列 (左) を見ると、最上段では著者の塊がはっきりしない。52 次元を線形の 2 次元に潰しても、著者の塊は現れない。非線形の t-SNE と UMAP で写すと、最上段には著者ごとの塊が現れる。ところが埋め込みの 3 段には現れない。どの手法で写しても、離れて固まるのは吉川英治の『三国志』の各巻だけで、ほかの作品は著者ごとにまとまらない。指示を変えても同じで、とくに UMAP では『三国志』以外のほとんどの点が 1 つのかたまりに潰れてしまう。同じ吉川英治の『宮本武蔵』の各巻はこの塊に入らないので、埋め込みが寄せたのは、書き手よりも物語の近さだと考えられる。

ここで一つ確かめておくことがある。埋め込みが塊にならないのはたまたま乱数の当たりが悪かったせいではないかという疑いが残る。t-SNE と UMAP は計算の途中で乱数を使うので、これは正当な疑いである。そこで種を 5 通り変えて実行し、2 次元に落とした後の著者ごとのまとまりをシルエット係数^{*1}で測った。

表現	t-SNE	UMAP
本書の 52 列	0.570 ± 0.000	0.387 ± 0.020
埋め込み (指示なし)	0.116 ± 0.016	0.023 ± 0.028
埋め込み (同じ話題を引け)	0.127 ± 0.023	0.038 ± 0.035
埋め込み (同じ著者を引け)	0.171 ± 0.025	0.045 ± 0.023

表の値は、74 作品を 2 次元に落としたあとで著者ごとのまとまりを測ったシルエット係数の、種 5 通りの平均と標準偏差である。埋め込みは指示の 3 通りをすべて載せた。種を変えても平均はほとんど変わらず、標準偏差は最も大きいものでも 0.035 である。ただし本書の t-SNE は PCA の結果を初期値にしているので、種を変えても出発点はほぼ同じになる。本書の 52 列の t-SNE で標準偏差が 0.000なのはそのためで、t-SNE については、この表は初期値の当たり外れまでは確かめていない。乱数で初期値を決める設定 (`init="random"`) で同じ 52 列を写すと、シルエット係数は種によって 0.51 から 0.56 まで散らばる。一方、52 列と埋め込みの差は、埋め込みの 3 通りのうち最も高いものと比べても、t-SNE で 0.570 と 0.171 の 0.399、UMAP で 0.387 と 0.045 の 0.342 あって、種によるばらつきよりはるかに大きい。初期値の当たり外れではなく、埋め込みでは著者ごとのまとま

^{*1} 同じ著者の点どうしがどれだけ近く、他の著者の点からどれだけ離れているかを、-1 から 1 の値で表した指標である。1 に近いほどきれいにまとまっている。定義は第 5.5 節にある。




図 10.2 74 作品を 4 通りの表現 × 3 つの手法で 2 次元にしたもの。最上段だけが本書の 52 列、残りの 3 段は埋め込みで、指示だけが違う。非線形の 2 つで写すと、最上段では著者ごとの塊が現れる。埋め込みの 3 段では、離れて固まるのは『三国志』の各巻だけで、著者ごとの塊にはならない。t-SNE と UMAP の軸には意味がなく、PCA も軸の値そのものは比べないので、目盛りは省いた (第 6.5.7 項で扱った)。

りがそもそも弱いと読める。

見た目の印象は、著者判別に絞った 2 つの数字にしておく。同じ著者どうしの距離と、違う著者どうしの距離がどれだけ離れているかを表す**効果量** (第 4.6 節) と、クラスタのまとまりを表すシルエット係数である (いずれもコサイン距離で計算した)。どちらも 2 次元に落とす前の表現そのものについて、列を標準化したうえで 74 作品から計算している。

表現	効果量	シルエット係数
本書の 52 列	2.404	0.371
埋め込み (指示なし)	1.150	0.107
埋め込み (同じ話題を引け)	1.206	0.115
埋め込み (同じ著者を引け)	1.422	0.152

10.1.4 当ててみる

眺めるだけでは決まらないので、著者判別で比べる。対象は近代文学 74 作品である。どの表現も列を標準化してからロジスティック回帰に入れ、正解率を測った。分割は、層別 5 分割の交差検証と、『三国志』『宮本武蔵』の各巻を 1 つの群にまとめて訓練とテストに分けない 4 分割の交差検証の 2 通りである。後者を、第 9 章と同じく**シリーズを分けた CV** と呼ぶ。

群を分けた分割では、どのフォールド (第 7.2 節) にどの群が入るかで正解率が変わり、**分割の乱数を 1 つ選んだだけの値では比べられない**。そこで分割の乱数を 10 通り変えて実行し、平均と標準偏差を示す。この手当てが要る理由は、表を見た後で説明する。

表現	次元	層別 CV	シリーズを分けた CV
本書の 52 列	52	0.994 ± 0.007	0.984 ± 0.013
埋め込み (指示なし)	4096	0.793 ± 0.024	0.762 ± 0.028
埋め込み (同じ話題を引け)	4096	0.797 ± 0.017	0.771 ± 0.024
埋め込み (同じ著者を引け)	4096	0.834 ± 0.021	0.804 ± 0.028

表の各欄は、分割の乱数 10 通りにわたる正解率の平均と標準偏差である。

- **本書の 52 列が大きく上回った。**層別 CV では 52 列の 0.994 に対して埋め込みの最上位が 0.834、シリーズを分けた CV では 0.984 に対して 0.804 で、差は 0.160 と 0.180 ある。4096 次元の埋め込みより、手作りの 52 個の数のほうが著者をよく当てる。どちらの差も標準偏差の何倍もある
- **課題に合わせて頼むと上がる。**層別 CV の平均正解率は、指示なしの 0.793 に対し、「同じ著者の文章を引け」と頼むと 0.834 になる。差は 0.041 で、標準偏差 (0.024 と 0.021) 2 つ分ほどある
- **ただし何を頼んでもよいわけではない。**「同じ話題の文章を引け」の層別 CV は 0.797 で、指示なしの 0.793 との差は 0.004 しかない。課題 (著者を当てる) と食い違う頼み方をしても、成績は上がらない

× アンチパターン 10.1 — 分割の乱数を 1 つ選んで手法を比べる

シリーズを分けた CV は、分割の乱数を変えるだけでぶれる。上の表の「指示なし」のシリーズを分けた CV の正解率は、10 通りの乱数で 0.720 から 0.808 まで、0.088 の幅に散らばった。比べたい差、すなわちシリーズを分けた CV での指示なしの 0.762 と「同じ著者を引け」の 0.804 の差 0.042 の、**2.1 倍の幅**である。乱数ごとに 2 つを比べると、10 通りのうち 1 通りでは指示なしのほうが上になる。乱数を 1 つに固定した表からは、差の大きさも、どちらが上かも確かには読み取れない。

同じ乱数を指定すれば安心というものでもない。本書の前の版では、この表を scikit-learn 1.7 以前で計算していた。同じコードで同じ乱数 0 を指定しても、「指示なし」のシリーズを分けた CV の正解率は、1.7 では 0.677、いま使っている 1.9 では 0.755 になる。10 通りの平均も 0.660(標準偏差 0.086) から 0.762(標準偏差 0.028) に変わった。1.8 で `StratifiedGroupKFold` の `shuffle=True` の扱いが直され、同じ乱数から作られる分割が変わったためである^a。1.7 以前の乱数 0 の分割では、4 つのテスト側の作品数が 13 から 27 までばらついていた (1.9 では 17 から 21)。分割を作る手続きはライブラリの版によって変わらう。

分割に乱数が入る評価では、**乱数を変えて繰り返し、平均と標準偏差の両方を報告する**。ライブラリの版も一緒に書き残す。標準偏差より小さい差を「勝った」と書かない。群を分ける分割、データが少ない場面、クラス数が多い場面では、ばらつきがとくに大きくなる (第 8 章)。

^a scikit-learn 1.8.0 の変更履歴 (https://scikit-learn.org/stable/whats_new/v1.8.html) の #32540。1.7 までは、群の並びを乱数で混ぜるときに群と行の対応がずれ、テスト側の著者の割合がそろわなかった。

52 列に埋め込みを継ぎ足しても、ほとんど変わらなかった。両方を並べた 4148 次元で分割の乱数 0 の層別 CV を行くと、74 作品のうち予測が埋め込み単独のときと違ったのは 0 件である。乱数 10 通りの平均でも、層別 CV の正解率は 0.846 で、埋め込み単独の 0.834 との差 0.012 は標準偏差 (0.021) より小さい。列を標準化すると、各列は同じ大きさの寄与を持つ。すると作品どうしの内積のうち、4096 列が占める分は 52 列の約 80 倍になる。L2 正則化のロジスティック回帰は、作品どうしの内積 (似ている度合い) を通してしかデータを見ない。そのため 52 列ぶんの情報は、足しても予測にほとんど表れない。

埋め込みがこの課題で振るわない理由の候補は、学習の目的にある。Qwen3-Embedding は、検索や分類の課題で、**何が書かれているか**が近い文章どうしを近くに置くよう対照学習で訓練されている [73]。読点をどこで打つかのように、書き手が意識せず、内容とも無関係に出る癖は、その学習で拾われにくい情報である。指示で向きを多少変えられることは表から読めるが、この説明そのものは、ここでは測っていない。

10.1.5 ライトノベルを足して問いを変える

ここまでは近代文学 74 作品だけの話だった。第 11 章で使うライトノベル 60 区間を足し、134 点・14 名にして同じことをする。あわせて、近代文学からライトノベルかを当てる **ジャンル判別**も測る。分類器も分割も前項と同じで、ロジスティック回帰、層別 5 分割の交差検証とシリーズを 4 分割した交差検証、分割の乱数は 10 通りである。

表現	著者判別 (14 名)		ジャンル判別	
	層別 CV	シリーズを分けた CV	層別 CV	シリーズを分けた CV
本書の特徴量	0.998	0.573 ± 0.004	0.993	0.995 ± 0.004
埋め込み (指示なし)	0.886	0.449 ± 0.017	1.000	0.934 ± 0.000
埋め込み (同じ話題を引け)	0.888	0.449 ± 0.009	1.000	0.938 ± 0.004
埋め込み (同じ著者を引け)	0.911	0.469 ± 0.009	1.000	0.944 ± 0.006

表の数字はいずれも 134 点での正解率で、どれも分割の乱数 10 通りの平均である。シリーズを分けた CV の欄だけ、標準偏差を併記した。

数字が 8 つ並ぶと読みにくいので、同じ内容を図にする。左の点が層別 CV、右の点がシリーズを分けた CV で、線の傾きが分割を厳しくしたときの落ち方を表す。




図 10.3 分割を厳しくしたときの落ち方。縦軸は 134 点での正解率である。(a) の著者判別では 4 つとも急落し、とくに埋め込み 3 種はシリーズを分けた CV の正解率が 0.449 から 0.469 になる。破線はシリーズを分けたときの上限 74/134 で、ライトノベルの 60 区間はどの表現でも必ず外れる。(b) のジャンル判別では、本書の特徴量の線はほぼ水平だが、埋め込みの 3 本はシリーズを分けた CV で下がる (下がり幅は 0.056 から 0.066)。右端の誤差棒は分割の乱数を 10 通り変えたときの標準偏差である。

図 10.3(a) のシリーズを分けた CV の値は、読み方に注意が要る。ライトノベルは著者ごとにシリーズが 1 つなので、シリーズを分けるとテストに出るライトノベルの著者は訓練に 1 件も現れず、60 区間はどの表現でも必ず外れる (第 11 章)。全体の正解率は、近代文学 74 作品を全部当てても $74/134 = 0.552$ にしかならない (表の値がこれを少し超えるのは、フォールドごとの正解率を平均しているためである。フォールドの大きさがそろわないと、平均は全体をまとめた値とずれる)。この欄で比べているのは、実質的には近代文学の側の成績である。本書の特徴量の 0.573 と埋め込みの 0.449 から 0.469 の差は、第 10.1 節前半の表のシリーズを分けた CV の差 (0.984 と 0.762 から 0.804) を、ほぼそのまま縮めて写している。

ジャンル判別の結果は、分割の仕方での読み方が変わる。層別 CV では、埋め込み 3 種がいずれも正解率 1.000 になり、本書の特徴量の 0.993 をわずかに上回る。差は 134 点のうち 1 点ほどである。ところがシリーズを分けた CV にすると、埋め込みは 0.934 から 0.944 に下がり、本書の特徴量 (0.995)

を 0.051 以上下回る (図 10.3(b))。埋め込み側の標準偏差は 0.000 から 0.006 で、この差よりずっと小さい。埋め込みがジャンルを当てるときには、シリーズごとの内容も手がかりにしていた、という読みと矛盾しない。図 10.4 は、同じ 134 点を主成分分析で 2 次元にしたものである。




図 10.4 134 点を主成分分析で 2 次元にしたもの。著者では混ざっていた埋め込みも、ジャンルではおおむね分かれる。本書の特徴量の (a) では、ライトノベルの一部が近代文学と重なる (第 11 章の図 11.10 と同じ現象)。

同じ表現、同じデータでも、何を当てさせるかと、どう分けて測るかで優劣の読み方が変わる。表現の良し悪しは課題と測り方から切り離して決められない。

この結果には実利の面もある。手作りの特徴は速く、説明でき、配布もできる (第 11 章)。埋め込みや事前学習モデルを持ち出す前に、領域の知識で作った素朴な特徴でどこまで解けるかを測っておくという順序は、第 10.2 節で改めて定石として書く。

10.1.6 埋め込みとの比較でそろえきれなかった条件

この比較には、条件がそろっていない点があるいくつかある。

- 埋め込みは 12 断片 (各 800 文字) の平均で、本書の 52 列は全文から作っている。全文を渡せば埋め込み側の数字は上がりうる
- 埋め込みモデルは 1 つしか試していない。日本語の文体に特化した学習をしたモデルなら結果は変わりうる
- 分類器はロジスティック回帰に固定した。4096 次元では、正則化 (第 4.4.2 項) の強さで正解率が変わる

- 埋め込みモデルは、公開元の配布形式ではなく、手元の実行環境 (LM Studio) 向けに変換された版を使った。変換や量子化の違いで、埋め込みの値は公開元のモデルと少し変わりうる

再現するには手で 8B のモデルを実行できる環境が要る。付属の `mkembed.py` は OpenAI 互換のエンドポイントを叩くだけなので、サーバを用意できれば同じことができる。

つまり本節が示したのは「埋め込みは著者判別に使えない」ではなく、**ここで扱った課題と分量と条件では、手作りの特徴が勝った**ということである。比較の条件を書き残しておくのは、結論を使い回されないためでもある。実際、同じ事前学習済みモデルでも係数を動かして学習し直すと結果が変わる。第 10.2.4 項で確かめる。

10.2 入力を変えずにモデルだけ深層学習に取り替える

前節では、大規模言語モデルが作った**表現**を借りてきた。分類器のほうはロジスティック回帰に固定したままである。本節では逆に、**入力**は変えずに**モデル**のほうを深層学習に取り替える。

本書がここまで使ってきたのは、木・線形・近傍・カーネルの 4 系統である。勾配ブースティングの実装は新しいが、考え方の骨格はどれも深層学習が広まる前に固まったものである。

10.2.1 多層パーセプトロンを走らせる

最も素直な深層モデルは**多層パーセプトロン** (multilayer perceptron, MLP) である。第 7.4 節の線形スコアを何段も重ね、段のあいだに非線形な関数を挟む。

$$x \rightarrow \underbrace{\sigma(W_1x + b_1)}_{1 \text{ 層目}} \rightarrow \underbrace{\sigma(W_2h_1 + b_2)}_{2 \text{ 層目}} \rightarrow \dots \rightarrow \text{各著者のスコア} \quad (10.1)$$

$h_1 = \sigma(W_1x + b_1)$ は 1 層目の出力で、次の層の入力になる。 σ は各成分に別々にかかる非線形な関数 (活性化関数) で、本章の実験では負の値を 0 にするだけの $\text{ReLU}(\max(0, z))$ を使っている。ここでの σ は標準偏差でもシグモイド関数でもない。

各層の幅と段数を決めれば、あとは誤差を減らす向きに係数 (W と b) を少しずつ動かしていく。層を深くするほど複雑な関数を表せる。

その「少しずつ動かす」の中身を、次項で開ける。決定木やランダムフォレストは当てはめの手順が 1 回で終わるが、深層モデルは同じ計算を何百回、何千回と繰り返す。何を何回繰り返し、いつ止めるのかを決めるのは人であり、その決め方しだいで結果が変わる。

10.2.2 損失・勾配・バッチ・止め方の 4 つを決める

深層モデルの学習は、次の 4 つを決めれば始められる。

1. 最小にする量 (損失関数) モデルは著者ごとにスコアを出す。このスコアの組を確率に直し^{*2}、正解の著者に与えた確率が高いほど小さくなる量を作る。第 7.4 節の発展で見た交差エントロピー損失を、著者 8 名にそのまま当てはめればよい。

^{*2} 著者 k のスコアを s_k とすると、 $p_k = e^{s_k} / \sum_j e^{s_j}$ とする。どの p_k も正で、合計は 1 になる。第 7.4 節の式 (7.3) のソフトマックス関数である。

$$L = -\frac{1}{N} \sum_{i=1}^N \ln p_i(\text{正解の著者}) \quad (10.2)$$

正解に確率 1.0 を与えれば $-\ln 1 = 0$ 、0.1 しか与えなければ $-\ln 0.1 = 2.3$ が積み上がる。学習とは、この L を小さくする係数を探す作業のことである。

図 10.5 に、著者 3 名の小さな例を描いた。スコアを確率に直し、正解の著者に与えた確率から $-\ln p$ を取る。正解の著者のスコアがほかの著者より高いほど、損失が小さい。




図 10.5 スコアから損失まで。(a) のスコアを式 (7.3) で (b) の確率に直すと、正解の著者 A の確率は 0.79 になり、損失 $-\ln 0.79 = 0.24$ が 1 件ぶん積み上がる。(c) は正解に与えた確率が 0.30、0.05 のときの損失 (1.20、3.00) と並べたもので、正解の確率が低いほど損失が急に大きくなる。

2. 係数の動かし方 (勾配降下法) L を各係数で微分すると、「その係数を増やせば L がどれだけ増えるか」が分かる。増える向きの逆に、少しだけ動かす。

$$w \leftarrow w - \eta \frac{\partial L}{\partial w} \quad (10.3)$$

η が学習率で、1 回の歩幅である。勾配ブースティングの η (第 7.7.3 項) と同じ役目だが、向こうは木を 1 本足す量、こちらは係数を動かす量である。これを勾配降下法 (gradient descent) という。

霧の中で谷底を探すのに似ている。足元の傾きだけは分かるので、下っている向きに 1 歩踏み出す。それを繰り返す。歩幅の決め方で結果が変わる。




図 10.6 学習率 (1 歩の歩幅) で学習の進み方が変わる。点は 1 歩ごとの位置で、曲線は係数を動かしたときの損失である。小さすぎるといつまでも谷底に着かず、大きすぎると谷を飛び越えて反対側の斜面を登り、往復しながら遠ざかる。

図 10.6 の右が**発散**である。損失が下がらずに増えていくときは、まず学習率を 10 分の 1 にして試すとよい。

3. 一度に見る件数 (バッチとエポック) 1 歩進むのに、訓練データを何件使うかを決めなければならない。

全件を使って微分すれば、いちばん正確な向きが分かる。だが 1 歩ごとに全件を計算し直すのは重い。かといって 1 件だけで微分すると、その 1 件の癖に振り回されて向きが定まらない。

そこで折衷する。訓練データを**数十件ずつの束**に切り、1 つの束で微分して 1 歩進む、を束の数だけ繰り返す。この束を**バッチ (batch)** という。

束を使い切って訓練データを 1 周し終えた時点を、**1 エポック (epoch)** と数える。1 周で終わりにせず、束を作り直して何周もする。図 10.7 に、12 件の訓練データを 4 件ずつの束で 2 周する様子を描いた。




図 10.7 12 件の訓練データを、4 件ずつのバッチで 2 周する。1 つの束につき係数の更新が 1 回起きる。全部の束を使い切ると 1 エポックである。

図では小さく 12 件にしたが、第 10.2.4 項の実験では断片が全部で 8233 件、バッチが 64 件である。ただし 1 回の学習に使うのはこのうち訓練側だけで、5 分割の交差検証なので 5 分の 4、およそ 6600 件である。1 エポックは $6600 \div 64 \approx 103$ 個の束からなり、更新も 103 回起きる。これを 8 エポック繰り返したので、1 回の学習で係数を約 800 回動かしたことになる。

バッチを大きくすると、1 歩の向きは正確になるが歩数が減る。小さくすると、向きは荒れるが歩数を稼げて、荒れること自体が細かい谷から抜け出す助けにもなる。どちらが良いかはデータとモデルによる。

4. 学習の止め方 損失は最初のうち大きく下がり、やがて下げ止まる。どこで止めるかには 2 つの流儀がある。

- **エポック数を先に決めて、そこまで回す。** 単純で、実行時間が読める
- **検証データでの損失を毎エポック測り、下がらなくなったら止める** (早期打ち切り、early stopping)。過学習に入る手前で止められる

本書は前者を採った。74 作品から取った断片しかないので、早期打ち切りのために検証データを切り出すと訓練が痩せるからである。そのかわり、エポック数そのものが**人が決めたハイパーパラメータ**になる。少なすぎれば学習しきらず、多すぎれば訓練データを覚え込む。

図 10.8 は、後で表 10.1 に出てくる MLP (64,64) を 52 列で 1 エポックずつ学習し、訓練データでの損失と、学習に使っていないフォールドでの損失 (検証損失) を測ったものである。5 つのフォールドで平均した。訓練損失は 300 エポックで 0.0011 まで下がり、ほぼ 0 になる。検証損失も 300 エポックまで上がり始めることはなく、ゆっくり下がり続けて 0.129 になった。表 10.1 の MLP は、訓練損失の改善が止まった 136~140 エポックで打ち切られていて、そのあたりの検証損失は 0.158 である。訓練損失がほぼ 0 になっても、検証損失はその 100 倍以上の値に残る。訓練損失が 0 に近いことは、未知の作品でもよく当たることを意味しない。




図 10.8 MLP (64,64) の学習曲線 (52 列、5 分割層別 CV の各フォールドで測って平均)。訓練損失はほぼ 0 まで下がるが、検証損失は 300 エポックでも 0.129 にとどまる (ゆっくり下がり続けている)。設定は表 10.1 の MLP と同じで、訓練データ全件を 1 つの束にしている。

× アンチパターン 10.2 — 「収束するまで回した」とだけ書く

何をもって収束と判断したのかが伝わらない。損失が下げ止まったのか、エポック数を決め打ちしたのか、検証データを見て止めたのかで、意味がまるで違う。

報告には**バッチの大きさ**、**エポック数**、**学習率**、**止め方**を書く。この 4 つがないと、他人は同じ実験を再現できない。止め方の既定は実装ごとに違う。scikit-learn の `MLPClassifier` は、既定では訓練損失の改善が止まった時点で打ち切り、検証データを使う早期打ち切りは `early_stopping=True` を指定したときだけ働く。だから「既定値のまま」と書くだけでも情報になる。

補足 学習率は一定でなくてよい

歩幅 η を最後まで同じにする必要はない。はじめは大きく歩いて谷のある方向へ向かい、終盤は小さく歩いて底に落ち着く、という進め方がよく使われる。歩幅を時間とともに変える仕組みを**スケジューラ**という。

第 10.2.4 項の実験では、歩幅を最初に上げてから終盤にかけて下げる方式を使い、最大の歩幅を 3×10^{-4} に置いた。最適化の道具にも **Adam** 系と呼ばれる、係数ごとに歩幅を自動調整する方式を使っている。

こうした選択はどれも結果を変えるが、本書ではどれも既定的な設定のまま固定し、探索していない。

本書の 52 列に 4 つのモデルを当てはめた (表 10.1 の左端の列)。うち 2 つは幅と段数の違う MLP で、残る 2 つは比較のためのランダムフォレストとロジスティック回帰である。

表 10.1 入力を変えたときの正解率 (74 作品、層別 5 分割 CV、分割の乱数は 1 通り)。「生のカウント」は正規化も対数変換もしていない数、「生 + 総量」はそこに総文字数の列を足したもの。MLP は scikit-learn の `MLPClassifier`(ReLU、Adam、学習率 10^{-3} 、L2 正則化 10^{-4} 、いずれも既定値) で、訓練データ全件を 1 つの束にし、訓練損失の改善が止まるか 3000 エポックに達したところで打ち切った。どのモデルも、入力の列は分類器の手前で標準化している (ランダムフォレストを除く)

モデル	本書の 52 列	生のカウント	生 + 総量
ランダムフォレスト	0.987	0.880	0.892
ロジスティック回帰	0.986	0.893	0.893
MLP (64,64)	0.986	0.947	0.947
MLP (256,128,64)	0.959	0.933	0.947

まず左端の列を見る。本書の 52 列を入力にしたときの、層別 CV の正解率である。深くしても上がない。MLP (64,64) は 0.986 で、ランダムフォレストの 0.987、ロジスティック回帰の 0.986 と並ぶ。層を 3 段にした MLP (256,128,64) に 55,240 個の係数を持たせると、むしろ 0.959 へ 0.027 下がる。入力の表は 74 行 $\times$ 52 列、数にして 3,848 個の値しかない。覚えるべき係数のほうが 14 倍多い状態で、新しい情報が出てくるはずもない。

10.2.3 人が 2 行で書いた正規化に、MLP は追いつかない

もう一つ、深層学習に期待されがちなことがある。前処理を自分で学んでくれるのではないかという期待である。第 3 章で人手でやった作業、つまり文字数を作品の長さで割り、文長は対数を取って平均と標準偏差にまとめる操作は、言ってしまうえば四則演算である。非線形な層を重ねたモデルなら、生の数から同じ変換を学んでもよさそうに思える。

表 10.1 の中央の列が実験の結果である。正規化も対数変換もしない「生のカウント」を入力にした。長い作品ほど値が大きい表である。

結果は半分だけ期待どおりだった。層別 CV の正解率は、ランダムフォレストで 0.880、ロジスティック回帰で 0.893 まで落ちる。52 列を渡したときの 0.987 と 0.986 から、0.107 と 0.093 の低下である。これに対して MLP (64,64) は 0.947 で踏みとどまる。非線形の層は、割り算に近い変換をある程度は代わりにやってくれる。深層学習の強みが出た場面といえる。

だが、同じ MLP に 52 列を渡したときの 0.986 より 0.039 低い。「総文字数の列を足せば、モデルが自分で割り算を組み立てられるはずだ」と考えて列を足しても (右端の列)、MLP (64,64) の正解率は 0.947 のままで変わらなかった。総文字数は字種 3 列の和なので、線形の 1 段目にとっては新しい情報ではない。モデルに欠けていたのは材料ではなく、割り算という形である。人が 2 行で書いた正規化に、数千個の係数を持つモデルが負けている。

図 10.9 に同じ数字を横棒で並べた。モデルごとに 3 本並ぶ棒の長さの差が、入力の作り方によって成績がどれだけ変わるかを表す。下 2 組 (MLP) では 3 本の長さがそろっているのに対し、上 2 組では各組のいちばん下の棒 (本書の 52 列) だけが長い。




図 10.9 表 10.1 を横棒にしたもの。入力を生のカウントに変えたとき、木と線形モデル (上 2 組) は大きく落ちるのに、MLP (下 2 組) の落ち幅は小さい。ただしどの MLP も、52 列を渡したときの正解率は超えない

表 10.2 シリーズを分けた CV (第 9 章) での正解率。入力 は 本書の 52 列、74 作品を 5 分割、分割の乱数は 1 通り

モデル	シリーズを分けた CV
ランダムフォレスト	0.975
ロジスティック回帰	0.973
MLP (64,64)	0.946

分割を厳しくすると、全体が下がる (表 10.2)。同じ長編の巻をまとめて片側に置くと、層別 CV の正解率が 0.986 から 0.987 だった 3 つのモデルは、ランダムフォレストが 0.975、ロジスティック回帰が 0.973、MLP (64,64) が 0.946 になる。落ち幅が最も大きいのは MLP で、表現力の高いモデルほど「その長編に固有の癖」を覚え込みやすい、という見方に合う。

ただし上位 2 つの差は 0.002 しかなく、分割の乱数を引き直せば入れ替わる程度なので、同じくらいと読む。最上位はランダムフォレストの 0.975 だが、以下でこれを比較の相手にするときも、「52 列でここまでは行ける」という目安である以上の意味は持たせない。

図 10.10 のように左右 2 点を線で結ぶと、表を読むだけでは目立たない下がり方の違いが傾きとして見える。3 本の線は左端ではほぼ重なっているのに、右端では開いている。

補足 表形式データで木が強いのは本書だけの話ではない

「表の形をしたデータでは、深層学習より勾配ブースティングやランダムフォレストのほうが強いことが多い」というのは、機械学習の分野で繰り返し確かめられてきた経験則である。45 個のデータセットで体系的に比較した研究では、中規模 (1 万行程度) の表形式データにおいて木のアンサンブルが深層モデルを上回り続けることが報告されている [72]。理由として挙げられているのは、表の列には意味のある向きや単位があり、座標を回転させると失われること、無関係な列が混ざっていても木は無視できること、そして表形式データで当てたい関数は滑らかでないことが多く、木はそうした不規則な関数を表しや




図 10.10 表 10.2 を線で結んだもの。分割を層別から群に変えたときの下がり方が、線の傾きに当たる。最も急なのが MLP である

補足（続き）

すいこと、である。

画像や音声や文章の生の系列では話が逆になる。そこでは隣り合う画素や単語のあいだに強い構造があり、その構造を学ぶこと自体が難しい問題だからである。

10.2.4 文章をそのまま渡す

ここまでの MLP は、52 列の表を入力にしていた。表に直した時点で「何を数えるか」の設計は済んでいる。深層学習が強いのは生の系列だという先の話に従うなら、文章そのものを渡さないかぎり、条件を与えたことにならない。

そこで、本文を 256 文字ずつの断片に切り (1 作品から最大 120 断片、全体で 8233 件)、2 つのモデルに直接与えた。

- **文字レベル Transformer** — 文字を語彙とする 4 層のモデルを、この 74 作品だけで 1 から学習する。事前学習はしていない
- **日本語 BERT** — 大量の日本語で事前学習された公開モデル (`tohoku-nlp/bert-base-japanese-v3`) に分類の層を足し、この課題に合わせて全体を微調整する^{*3}。このモデルは、ウェブから集めた日本語 (CC-100) と日本語版ウィキペディアで事前学習されている [74]。文章はまず形態素解析で語に分け、さらに頻度の低い語を細かい単位 (サブワード) に分けて、約 3 万 3 千種類の記号の並びとして読む。現代の文章で学んだモデルを、旧字の多い近代文学に使うことになる

入力に 2 通り用意した。本文そのままの**生テキスト**と、漢字をすべて「漢」1 文字に置き換えた**漢字マスク**である。後者では文の長さも読点の位置も仮名の並びも残るが、話題を運ぶ語は消える。語彙は 3533 文字から 225 文字に減る。

教師あり学習の問題としての組み立て 文章を渡すといっても、そのままでは学習の形にならない。次のように組み立てた。

^{*3} **微調整 (fine-tuning)** は、事前学習済みのモデルの係数を初期値として、手元の課題のデータで学習を続けることをいう。第 10.1 節の埋め込みは係数を変えずに出力を借りるだけだったが、微調整では事前学習で得た係数そのものが更新される。

- **1 件の入力** — 256 文字の断片 1 つ。作品まるごとではない。BERT が一度に読めるトークン数に上限があり、文字レベルのモデルも系列が長いほど計算が重くなるためである
- **1 件の正解** — その断片が取られた作品の著者。断片自体に著者名が書いてあるわけではないので、作品の著者をそのまま断片に配る
- **出力** — 8 名それぞれのスコア。前項と同じく確率に直し、交差エントロピー損失 (式 (10.2)) で測る
- **最終的な判定** — 断片ごとの確率を**作品単位で平均**してから、最大の著者を答える。当てたいのは断片ではなく作品だからである

文字レベルのモデルは、語彙を作るところから始める。本文に出てくる文字を数え、5 回以上現れたものだけを覚える対象にした。残りは「未知の文字」という 1 種類にまとめる。語彙は分割の前に全 74 作品から作った。テスト側にしか現れない文字も語彙に入るので、厳密には訓練側だけで作り直すところである。ただし、テスト側にしか現れない文字の埋め込みは、訓練中に勾配を 1 度も受けないので、学習では何も覚ええない。また出現 5 回未満で語彙から外れる文字は全体の 0.1% なので、影響は小さいと見ている。BERT のほうは語彙が学習済みで固定されているので、こちらで作る必要はない。

分割 分割は作品単位で行う。断片をランダムに分けると、同じ作品の断片が訓練とテストにまたがり、それは漏れになる (第 9 章)。

学習の設定 第 10.2.2 項の 4 つを、表 10.3 のとおりに決めた。どれも探索していない。既定的な値を置いて固定してある。

表 10.3 生の文章を渡した実験の学習設定

	文字レベル Transformer	日本語 BERT
係数の初期値	乱数	事前学習済み
係数の数	約 128 万 (漢字マスクは約 86 万)	約 1.1 億
構成	4 層、幅 128、注意ヘッド 4	12 層、幅 768、注意ヘッド 12
断片の長さ	256 文字	256 文字 (最大 256 トークン)
バッチ	64 件	16 件
束の順序	周ごとに混ぜ直す	周ごとに混ぜ直す
エポック	8	3
学習率 (最大)	3×10^{-4}	2×10^{-5}
学習率の変え方	上げてから下げる	上げてから下げる
最適化	AdamW (重み減衰 0.01)	AdamW (重み減衰 0.01)
その他	勾配の大きさを 1 で切る、 ラベル平滑化 0.05	勾配の大きさを 1 で切る
止め方	エポック数を固定	エポック数を固定

BERT の学習率が 15 分の 1 と小さいのは、事前学習で得た係数を壊さないためである。すでに日本語について学んだ状態から出発するので、大きく動かすとその知識が失われてしまう。エポックが 3 回と少ないのも同じ理由による。

表 10.4 文字レベル Transformer(この 74 作品だけで学習)。数字は断片ごとの確率を作品単位で平均してから判定した正解率で、平均と標準偏差は 5 つのフォールドにわたるもの

入力	層別 CV		シリーズを分けた CV	
	平均	標準偏差	平均	標準偏差
生テキスト	0.973	0.053	0.967	0.041
漢字をマスク	0.933	0.042	0.913	0.041

表 10.5 日本語 BERT の微調整。数字は断片ごとの確率を作品単位で平均してから判定した正解率で、平均と標準偏差は 5 つのフォールドにわたるもの

入力	層別 CV		シリーズを分けた CV	
	平均	標準偏差	平均	標準偏差
生テキスト	0.973	0.033	0.922	0.092
漢字をマスク	0.987	0.027	1.000	0.000




図 10.11 表 10.4 と表 10.5 をまとめたもの。縦軸は作品単位の正解率、縦線は 5 つのフォールドにわたる標準偏差である。破線は比較の相手にする 52 列の最上位で、層別 CV では 0.987、シリーズを分けた CV では 0.975 である。4 条件は縦線が重ならないよう左右に少しずらしてある。縦線の上端まで破線より下にあるのは、層別 CV とシリーズを分けた CV のどちらでも、文字レベル (漢字マスク) だけである

図 10.11 に 2 つの表を重ねた。標準偏差を縦線で描くと、シリーズを分けた CV では、4 条件のうち 2 つ (文字レベルの生テキストと BERT の生テキスト) が破線 (52 列の最上位) と縦線で重なる。縦線まで破線より下にあるのは文字レベル (漢字マスク) で、正解率 0.913 に標準偏差 0.041 を足した上端が破線の 0.975 を 0.021 下回る。逆に BERT(漢字マスク) は、5 つのフォールドすべてで全作

品を当てて 1.000 になり、縦線の幅がなく破線の上にある。ただしこの条件でも、破線との差は 74 作品に直して 2 作品ほどで、分割の乱数は 1 通りしか試していない。縦線が重なる 2 つについて、この図から読み取るべきは順位ではなく、**破線と区別がついていない**という一点である*4。

比べる相手を先に決めておく。表 10.2 のとおり、52 列でシリーズを分けた CV の最上位はランダムフォレストの 0.975 である。以下、層別 CV では 52 列の最上位 0.987、シリーズを分けた CV では 0.975 を相手にする。最も弱かった MLP の 0.946 と比べれば話は簡単になるが、それでは比較にならない。**比べる相手は、素朴なモデルの中で最も強かったものにする。**

なお第 10.1 節の表では、同じ 52 列・同じロジスティック回帰の正解率が、層別 CV で 0.994、シリーズを分けた CV で 0.984 になっている。測り方が違うためである。あちらは層別 CV を 5 分割、シリーズを分けた CV を 4 分割にし、どちらも分割の乱数を 10 通り変えて平均したもの、こちらは深層モデルと同じ 5 分割・1 通りの分割で測ったものである。比べるときは**同じ手続きで測った数どうし**を並べる。数字が独り歩きしやすいのはここで、表をまたいで最も都合のよい値を拾ってくると比較が壊れる。

以下、正解率と断らずに書いたものは作品単位である。断片ごとの確率を作品でまとめてから判定した値で、断片単位の場合はそう明記する。

読む前に、**標準偏差を見る癖**をつけておきたい。シリーズを分けた CV の、5 つのフォールドにわたる標準偏差は、条件によって 0.000 から 0.092 まで開いている。層別 CV では 1 回のテストはおよそ 15 作品で、1 作品の当たり外れが 0.067 にあたる。シリーズを分けた CV では『三国志』の 11 点 (10 巻と篇外余録) が 1 つのフォールドにまとまるので、フォールドの大きさはもっとばらつく。0.01 や 0.02 の差を順位として読むことはできない。

そのうえで、表から読み取れるものを順に挙げる。

1 から学習しても、52 列とほぼ同じ成績になる 文字レベル Transformer に生テキストを渡したときの正解率は、層別 CV で 0.973、シリーズを分けた CV で 0.967 である。比べる相手である 52 列の 0.987 と 0.975 に対して、差は 0.014 と 0.008 しかない。どちらもこのモデルの標準偏差 (0.053 と 0.041) の中に収まっている。

8233 件の断片、文字の並びだけ、事前学習なし。それでも人が設計した 52 列と同じ水準の成績が出た。「深層学習には大量のデータが要る」という一般論は、少なくともこの課題では当てはまらなかった。

ただし**同じ水準**までである。上回ってはいない。そして手間は 1 条件あたり GPU で 90 秒、相手は CPU で数秒である。

事前学習は、生の文章では活きなかった BERT に生テキストを渡したときの正解率は、層別 CV で 0.973、シリーズを分けた CV で 0.922 である。層別 CV は文字レベルと同じ値だが、シリーズを分けた CV は文字レベルの 0.967 を 0.045 下回る。**74 作品だけで学習したモデルのほうが高い。**

もっと目を引くのは標準偏差である。シリーズを分けた CV で 0.092 あり、4 条件の中で最も大きい。分割の引き当てかたに、このモデルが最も振り回されている。

理由の候補は挙げられる。BERT は文字ではなく語 (サブワード) を見るので、「玄德」や「孔明」

*4 縦線が重なっていても差がないとは限らない。その扱いは第 8 章第 8.4.3 項で述べる。

といった固有名詞をそのまま 1 つの単位として拾える。その巻が訓練側に残る分割では当たり、残らない分割では外す。平均が中くらいで標準偏差が大きいのは、この形の誤りと矛盾しない。文字レベルのモデルは固有名詞を語として掴みにくいぶん、文体寄りの手がかりに寄った、というのが対になる候補である。

ただし、ここにあるのは平均とフォールド間の標準偏差だけで、乱数の系列も 1 本である。この数字だけでは、上の説明を他の候補 (入力長さ、語彙と未知語の扱い、学習の不安定さ) から区別できない。確かめるなら、作品ごとの誤分類、入力長さ、語彙の重なり、複数の乱数系列の結果をそろえて見る必要がある。本節では仮説として記すにとどめる。

事前学習済みだから強いとは限らない。何で学習されたモデルが、いま当てたいものと合っているかによる。

漢字を消す効果は、モデルによって逆になる 本節の 3 点のうち、事前の予想から最も外れたのがこの結果である。

BERT に漢字マスクを渡すと、シリーズを分けた CV の正解率が 0.922 から 1.000 へ 0.078 上がった。標準偏差も 0.092 から 0.000 へ縮み、5 つのフォールドすべてで全作品を当てた。**情報を減らしたのに成績が上がった。**

ところが文字レベル Transformer では**逆になる**。同じシリーズを分けた CV で、作品単位の正解率が 0.967 から 0.913 へ 0.054 下がった。断片単位の正解率も 0.738 から 0.706 へ 0.032 下がる。

同じ前処理が、モデルによって逆に働いている。「漢字を消すと良くなる」という規則ではない。

分かれ目は**そのモデルが漢字から何を読んでいたか**にある。

- BERT は漢字を含む語を**語**として持っている。漢字を潰すと、話題を運ぶ語がまとめて消える。残るのは仮名の並びと文の切り方で、これはどの著者にも同じ条件で当てはまるから、分割の運に左右されなくなる
- 文字レベル Transformer は**文字**を語彙とする。漢字を潰すと語彙が 3533 文字から 225 文字へ、約 16 分の 1 に減る。消えるのは話題だけではない。どの漢字を選ぶか、旧字を使うか、熟語をどれだけ重ねるかという**文字の使い分けそのもの**も一緒に捨てている

前処理は、モデルと組にして考えるものである。

最も高かった条件と、その差の大きさ BERT に漢字マスクを渡した条件が最も高い。層別 CV の正解率 0.987 は 52 列の 0.987 と同じ値で、シリーズを分けた CV の 1.000 はランダムフォレストの 0.975 を 0.025 上回る。

ただし **0.025** である。74 作品に直すと 2 作品ほどの差で、しかも 1.000 はこれ以上は上がりようのない値である。分割の乱数は 1 通りしか試していないので、別の乱数では順位が入れ替わりうる。GPU で 1011 秒かけて学習した 1 億パラメータのモデルと、52 個の数から作った素朴なモデルの差は、条件を厳しくしてもこの程度にとどまる。

上がった理由を測る BERT で上がったことについて、もっともらしい説明が 2 つ思いつく。

1 つは**未知語が減ったから**という説明である。青空文庫の底本には旧字や稀用漢字が多いから、生テキストでは相当数の字が「未知語」という同じ記号に潰れていて、それが成績を下げていたのでは

ないか。

もう1つは**話題が消えたから**という説明である。漢字は話題を運ぶ。『三国志』を訓練で見たモデルは「玄德」や「孔明」で吉川英治を当てられるが、それは文体ではない。その手がかりが使える分割では高得点が出て、使えない分割では落ちる。だから平均が上下し、標準偏差が膨らむ。

前者は測れる。測ってみると、支持されなかった。生テキストで語彙から漏れる文字は全体の0.1%、BERTのトークナイザが未知語として扱うトークンは0.01%しかない。0.922と1.000の差を生む量ではない。

ついでに、断片の長さがそろっているかも確かめた。断片は256文字にそろえてあるが、BERTが読むのは文字ではなくトークンなので、条件によってトークン数が変わり、上限で切られる恐れがある。

測ってみると、心配した向きとは逆だった。1断片あたりの平均トークン数は生テキストが202(標準偏差12)、漢字マスクが223(標準偏差11)で、**漢字を消したほうが増えている**。「漢」の連なりが細かく分割されるためである。それでも上限を超えて切り捨てられた断片は、生テキストで0.1%、漢字マスクで0.6%と、どちらも1%に満たない。2つの条件で、モデルが読んでいる範囲は実質的に変わっていない。

消去法で残るのは話題の除去である。積極的な手がかりもある。話題説が正しければ、成績は**分割の引き当てかた**に左右されるはずで、『三国志』の巻が訓練側に残る分割では高く、残らない分割では低くなる。実際、シリーズを分けたCVの標準偏差は生テキストで0.092と大きく、漢字を消すと0.000に落ちた。分割ごとの当たり外れが消えたことになる。

文字レベルで逆に下がったことも、この説明と矛盾しない。文字レベルのモデルはもともと固有名詞を語として使えていないので、消して得るものが少なく、失うもの(文字の使い分け)のほうが大きかった、という読みになる。

× アンチパターン 10.3 — 測れば確かめられる原因の説明を測らずに書く —

「漢字を消したら上がった」に対して、未知語が減ったからだ、という説明は自然に思いつく。語彙は3533文字から225文字に減っているのだから、何割かは未知語だったに違いないと考えたくなる。

実際に語彙から漏れていた文字は、全体の0.1%だった。思いついた時点で書いていたら、そのまま間違いが残っていた。**説明のほうも仮説である**。測れる形に言い直せるなら、測ってから書く。

もう一つ、この節には**反証**が転がっていた。同じ前処理で文字レベルは下がっている。「語彙が減ると良くなる」が一般の規則なら、こちらも上がるはずである。自分の説明に合わない条件が手元にないかを、先に探す。

特徴設計というと「何を数えるか」を考えることだと思いがちだが、生の入力を受け取るモデルに対しては**何を見せないか**も同じくらい成績を左右する。本節では漢字を1文字に潰しただけで、BERTのシリーズを分けたCVの正解率が0.922から1.000に上がり、フォールド間のばらつき(標準偏差)は0.092から0.000に縮んだ。

ただしこれを一般の規則にはできない。同じ操作で文字レベルTransformerは下がっている。

○ 定石 10.1 — 前処理を 1 つ足したらモデルごとに測り直す

前処理の良し悪しは、そのモデルが何を手がかりにしていたかで決まる。落とすものが「関係のない手がかり」なのか「そのモデルが頼っていた手がかり」なのかは、モデルによって違う。

本節の漢字マスクがそうだった。BERT では話題を運ぶ語だけが消えたので成績が上がり、文字レベル Transformer では文字の使い分けまで消えたので下がった。同じデータ、同じ前処理、逆の結果である。

前処理を 1 つ足したら、使うモデルすべてで測り直す。1 つのモデルで良かったから他でも良い、とは言えない。

計算の手間には大きな差がある。文字レベル Transformer は 1 条件あたり 90 秒、BERT は 956 秒で、どちらも GPU を使った値である。52 列のランダムフォレストとロジスティック回帰は、CPU で数秒しかかからない。最も高かった BERT は、GPU を使ってなお 2 桁以上の差がある。その差を払って得られたのは、シリーズを分けた CV の正解率で 0.025 (74 作品に直すと 2 作品ほど) という、分割の乱数しだいで入れ替わりうる程度の上積みだった。

図 10.12 に、係数の数とシリーズを分けた CV の正解率を並べた。係数の数は横軸の対数目盛で 5 桁あまり開いているが、縦軸の正解率は、漢字マスクの文字レベルと BERT の生テキストを除いて、破線 (52 列のランダムフォレスト) の近くに集まる。




図 10.12 係数の数 (対数目盛) と、シリーズを分けた CV での作品単位の正解率。縦線は 5 つのフォールドにわたる標準偏差で、scikit-learn のモデルは分割の乱数 1 通りの値である。BERT の 2 条件は係数の数が同じなので、重ならないよう左右に少しずらした。ランダムフォレストは係数の数で比べられないので破線で示した。係数の数は、文字レベル Transformer が 1,279,368 個 (漢字マスクは 855,944 個)、BERT が 111,213,320 個、MLP (64,64) が 8,072 個、ロジスティック回帰が 424 個である。

補足 漢字マスクは話題だけを消したわけではない

漢字マスクは話題を消すと同時に、**漢字の位置と連続する長さ**という情報を残している。「漠漠漠」と「漠」では見え方が違うから、語の切れ目や熟語の長さは伝わっている。これは第3章の字種比率を、系列の形にしたものと見ることもできる。話題だけをきれいに取り除いたわけではない。

また、試したのは事前学習済みモデル1つ、断片の長さ1通り、学習の設定1組である。モデルを変えれば序列は変わりうる。

10.2.5 設計の仕事は「何を数えるか」から「何を見せないか」へ移る

深層学習が向くのは、おおむね次の場合である。

- **データが桁違いに多い**。数万から数百万件あれば、係数の多さが表現力として働く
- **生の入力に構造がある**。画像の画素配置、音声の波形、文章の語順。構造を捉える層 (畳み込み、注意機構) が用意されている
- **良い特徴の作り方が分からない**。何を数えればよいか見当がつかない領域では、表現を学ばせるほうが速い
- **学習済みモデルを借りられる**。自分で1から学習する必要がなく、大量のデータで得た知識をそのまま持ち込める

本書の題材を、4つに照らしてみる。

1つ目の**データの量**は足りない。点は74個しかない。2つ目の**生の入力の構造**はある。文章には語順があり、第10.2.4項ではそれをそのまま渡した。3つ目の**良い特徴の作り方が分からない**は当てはまらない。何を数えればよいかは、読点と字種という領域の知識から決められた。4つ目の**学習済みモデルを借りられる**は当てはまる。

条件が半分しか揃っていないのに、結果は「深層学習の出番はない」とは言えないものだった。

74作品だけで1から学習した文字レベルTransformerが、シリーズを分けたCVの正解率0.967に達している。ランダムフォレストの0.975との差は0.008で、標準偏差の中である。1つ目の条件(データの量)が満たされていなくても、ここまでは来た。

最も高かったのは、事前学習済みのBERTに漢字を消した入力を渡した条件である。作品単位の正解率は、層別CVで0.987、シリーズを分けたCVで1.000である。どちらも52列と同等か、わずかに上である。

ただし、そこまで来るのに2つのものが要った。1つは公開された学習済みモデルで、これは借り物である。もう1つは**漢字を消すという前処理**で、これは人が決めた。生の文章をそのまま渡した場合、シリーズを分けたCVの正解率は0.922にとどまり、自前の文字レベルモデルの0.967にすら負けている。設計の仕事が消えたのではなく、**何を数えるかから何を見せないか**に移っただけである。

そして、ランダムフォレストとほぼ同じ成績だった52列のロジスティック回帰(シリーズを分けたCVで0.973)は、CPUで数秒、係数は著者1人あたり53個(52列ぶんと切片1つ)で、8人ぶん並べても424個にすぎない。どの列が判別をどちらへ動かしたかを人が読める。差が標準偏差に埋もれる程度なら、そちらを選ぶ理由は十分にある。

○ 定石 10.2 — 深層学習を使う前に素朴なモデルの成績を出す

モデルを取り替える前に、ランダムフォレストやロジスティック回帰の成績を測る。どちらも設定するものがほとんどなく、数秒で終わる。

上回れなかったときに、それが分かる。上回れたときも、**どれだけ上回ったか**を言えるのは比べる相手があるからである。

比べる相手は**素朴なモデルの中で最も強かったもの**にする。本節の実験でも、シリーズを分けた CV の相手を最上位の正解率 0.975 にするか、最下位の MLP の 0.946 にするかで、「ようやく並んだ」とも「大きく上回った」とも書いてしまう。相手を選んだ時点で結論はほとんど決まる。第 7.2 節で見た**基準線を先に置く**という手順そのものである。

× アンチパターン 10.4 — 前処理を省いてモデルに任せる

「深層学習なら前処理を自分で学んでくれる」は、半分は正しいが、そのぶんの負担をモデルとデータが払うことになる。表 10.1 では、正規化を省いた入力で MLP が木や線形モデルより粘ったものの、先に見たとおり正規化した入力に 0.039 負けている。表 10.5 では、事前学習済みの BERT ですら、漢字を消しておいたほうが成績が上がった。

領域の知識で 1 行書けば済むことを、モデルに推測させる理由はない。**知っていることは前処理で渡し、知らないことだけをモデルに学ばせるのが順序である。**

コラム 計算量で押し切る方法は、いつも勝つか

強化学習の研究者リチャード・サットンは、2019 年 3 月 13 日に「The Bitter Lesson(苦い教訓)」という短い文章を公開した [75]。要旨は「計算を活用する汎用の方法が、最終的には大差で最も有効である」という一文にまとめられている。

例として挙げられているのは、チェス、囲碁、音声認識、画像認識である。チェスで 1997 年に世界王者カスパロフを破ったのは、人の知識を組み込む方式ではなく、深い探索を大量の計算で回す方式だった。囲碁でも、探索と自己対戦による学習を大規模に回すと、人の知識を組み込む工夫は要らなくなった。音声認識では隠れマルコフモデルなどの統計的な方法が、音素や声道についての人の知識を組み込んだ方法を上回った。画像認識では、エッジや SIFT などの人が設計した特徴が、深層学習に置き換えられた。サットンは、人の知識を組み込むと短期的には成績が上がるが、やがて伸びが止まり、計算を増やせる方法に追い越される、と書いている。

本章の結果は、この教訓と逆向きに見える。手作りの 52 列は、80 億個の係数を持つモデルの埋め込みを上回り、1 億個の係数を持つモデルとは標準偏差の中で並んだ。ただし前提が違う。サットンの例は、データと計算がいくらでも増やせる課題である。本書のデータは 74 作品で、著者を当てるための手がかりが何かも、第 3 章でかなり分かっていた。本節で挙げた「深層学習が向く 4 つの場合」のうち、データの量と「良い特徴の作り方が分からない」の 2 つが、本書では満たされていない。

10.3 手作りの特徴が残った理由

52 列は、4096 次元の埋め込みを上回り、GPU で学習した 1 億パラメータのモデルとは、標準偏差の中で並んだ。その理由の候補は、モデルの優劣ではなく**課題と特徴の噛み合い**にある。埋め込みは「何が書かれているか」に近い文書を近くに置くよう学習されており、読点をどこで打つかのような、書き手が意識せず内容とも無関係に出る癖は、その学習で拾われにくい情報だと考えられる。

裏を返せば、問いが変われば結論も変わりうる。ライトノベルを足してジャンルを当てさせると、層別 CV では埋め込みが本書の特徴量をわずかに上回った (シリーズを分けた CV では逆になる)。第 11 章では、その「問いを変えると何が起きるか」を正面から扱う。

第 11 章

ジャンルを分ける

11.1 問いを変えてみる

ここまで、近代文学 74 作品で著者を当ててきた。最後に、別のデータを足して別の問いを立てる。ライトノベル 60 区間 (6 シリーズ) を加える。『本好きの下剋上』『薬屋のひとりごと』『Re: ゼロから始める異世界生活』『無職転生』『片田舎のおっさん、剣聖になる』『サイレント・ウィッチ』を、それぞれ 10 区間に区切ったものである (第 1.6.1 項)。

合わせて 134 点、14 名になった。

ここで立てる問いは次の 1 つである。

作品が近代文学かライトノベルかを、文体だけで判別できるか。

補足 テキストは配れないが特徴量なら配れる

第 1 章でも触れたとおり、近代文学は著作権が切れているのでテキストそのものを配布でき、ライトノベルは著作権が生きているので**特徴量** (feature)、つまり第 3 章と同じ作り方で作った数値しか配れない。ここでは著作権の側の詳細を補っておく。本書の 8 名で最も没年が遅いのは谷崎潤一郎 (1965 年) で、旧法の保護期間 (没後 50 年) を 2015 年末に満了している。2018 年の保護期間延長 (50 年から 70 年) は、その時点で既に消滅していた著作権を復活させないので、8 名全員がパブリックドメインである。なお青空文庫の「収録ファイルの取り扱い規準」は、著作権切れ作品の複製・再配布を有償無償を問わず認めたうえで、底本・入力者・校正者などの記載を残すことと、改変した場合は作業履歴を明記することを希望している。本書の配布物もこれに従っている [129]。

特徴量なら配ってよいのは、「平仮名の比率が 0.633」「読点の前に『て』が来る割合が 0.198」といった数値からは**もとの文章を復元できない**からである。

これは実務でもよく使う考え方である。個人情報を含むデータを共有できないとき、集約統計量や埋め込み表現だけを渡す。ただし「復元できない」の保証は自明ではなく、特徴量が細かすぎると復元されうる。モデルや特徴量から入力を推定する攻撃はモデル反転攻撃 (model inversion attack) と呼ばれ、研究が続いている。

コラム 埋め込みから元の文章は戻せるか

上の補足では、個人情報を含むデータを共有できないときに「集約統計量や埋め込み表現だけを渡す」ことを挙げた。埋め込みについては、この前提を揺るがす研究がある。

2023 年、モリスらは、文章の埋め込みから元の文章を推定する方法を発表した [109]。まず埋め込みから文章を 1 つ推定し、それを埋め込み直して元の埋め込みとの差を測り、差が小さくなるよう文章を直す。これを繰り返すと、32 トークンの文章の 92% を、一字一句そのまま復元できた。臨床記録のデータでは、埋め込みから患者の氏名を取り出せることも示している。

コラム (続き)

第 10 章で使った埋め込みは、1 本が 4096 個の数である。本書の 52 列は、1 作品を 52 個の比率に要約したもので、持っている情報の量がまるで違う。「平仮名の比率が 0.633」からは文章を戻せない。一方、研究で戻せたのは 768 次元や 1536 次元の埋め込みで、元の文章は 32 トークンほどと短い。本書の埋め込みは 800 字の断片 12 個を平均したものなので同じようには戻せないだろうが、文章 1 本ごとの埋め込みを配る場合には、この種の復元を考えに入れておく必要がある。特徴量なら配ってよいかどうかは、「特徴量かどうか」ではなく、その特徴量が元のデータをどれだけ細かく写しているかで決まる。

11.2 まず眺める

字種の比率を見る。第 3 章の図 3.3 と同じ特徴だが、今度は横軸を片仮名にする。




図 11.1 片仮名と漢字の比率。6 シリーズのうち 1 つ (『薬屋のひとりごと』) を除けば、重なりは小さい。

ライトノベルの多くは、片仮名の比率で近代文学の右側に離れている。ただし左端、片仮名がほぼ 0 のところにも、ライトノベルの点が 10 個ある。

1 点あたりの片仮名の比率を群ごとに平均すると、近代文学 74 作品では 0.0133、ライトノベル 60 区間では 0.0748 になる。ライトノベルのほうが高く、**5 倍以上の開き**がある。しかし平均は、群の中の違いを隠す。著者とシリーズごとに分けて並べると (図 11.3)、片仮名の比率が低いのは『薬屋のひとりごと』の 10 区間で、平均 0.0003、最も多い区間でも 0.0028 と、近代文学の平均 0.0133 より低い。1 区間 (8 万～16 万字) あたり、片仮名は多くても数百字である。

理由は次のようなことだろう。ライトノベルの多くには「スキル」「ステータス」「ダンジョン」といった片仮名語が多く、登場人物の名前も片仮名であることが多い。一方、近代文学では片仮名の出る場面が外来語や擬音や強調などに限られがちことが一因だろう。『薬屋のひとりごと』は例外で、中国風の宮廷が舞台であり、人名も漢字で書かれる。外来語も「意匠《デザイン》」のように漢字で書き、片仮名はルビに回している。本書はルビを除いて数えるので、その片仮名は数に入らない (第 3 章)。生のテキストで確かめると、10 区間のルビの中にある片仮名は 8,315 字、ルビの外は 340 字だった。片仮名が少ないのは、舞台と書き方の選び方に、ルビを除く前処理が重なった結果である。




図 11.2 片仮名比率の分布。縦軸は近代文学では作品数、ライトノベルでは区間数である。0 付近のライトノベル 10 区間は、1 つのシリーズ (『薬屋のひとりごと』) である。




図 11.3 著者・シリーズごとの片仮名の比率。左の 8 組が近代文学の著者 (1 点が 1 作品)、右の 6 組がライトノベルのシリーズ (1 点が 1 区間) で、それぞれ平均の小さい順に並べた。破線は、片仮名の比率 1 列で全 134 点に当てはめた決定株のしきい値である。

11.3 分類してみる

全 134 点それぞれが近代文学かライトノベルかを、第 3 章と同じ作り方で作った特徴量だけを使って 3 つのモデルで判別する。測るのは 5 分割交差検証での正解率である。作品と区間をばらばらに分ける通常の層別 CV と、同じシリーズをまとめて片側に置く CV の 2 通りで測る。基準線は、最頻クラス (近代文学) を答え続けたときの正解率 0.552 である。

ランダムフォレストは、通常の層別 CV で正解率 1.000 である。134 点すべてのジャンルを正しく当てた。基準線 0.552 を 0.448 上回っている。

11.4 喜ぶ前に

正解率 1.000 という数字が出たら、第 9 章の作法どおり、まず疑ってかかる。

11.4.1 疑い 1 — 片仮名 1 列だけで 9 割近く当たる

たった 1 つの特徴で解けるのではないかを確認める。

表 11.1 134 点のジャンル判別の正解率

モデル	通常の層別 CV	シリーズを分けた CV
決定株 (深さ 1 の木)	0.941	0.815
k 近傍法 ($k = 5$)	0.993	0.982
ランダムフォレスト	1.000	0.978
基準線 (最頻クラス)	0.552	

深さ 1 の決定木 (決定株) は、「ある特徴がある値を超えるか」という 1 回の質問しかできない。これで何割当たるかを見る。

表 11.1 の決定株は、通常の層別 CV でジャンル判別の正解率が 0.941 だった。これに対し、表 11.2 に並ぶ正解率はどれもそれより低い。前者はすべての列の中から不純度をいちばん下げる 1 列を毎回選べるのに対し、後者は使う列を 1 つに固定して測っているからである。

表 11.2 字種と文長の 5 列から列を 1 つに固定したときのジャンル判別の正解率 (134 点、決定株、5 分割の層別 CV)。読点前の平仮名の列は試していない。文長の 2 列は対数を取った値である

特徴	正解率	近代文学の平均	ラノベの平均
片仮名の比率	0.888	0.0133	0.0748
漢字の比率	0.806	0.3262	0.2840
文長 μ (対数)	0.718	3.3975	3.1258
文長 σ (対数)	0.612	0.7723	0.7240
平仮名の比率	0.590	0.6605	0.6412

5 列の中でいちばん高いのは片仮名の比率で、この 1 列だけで正解率 **0.888** である。基準線 0.552 を 0.336 上回っている。「片仮名が 5.4% を超えたらライトノベル」という 1 行のルールで、134 点のうち 9 割近くを正しく分類できている。全点に当てはめたこのルールが取り違えるのは、近代文学 3 点とライトノベル 11 点で、ライトノベルの誤りのうち 10 点は片仮名がほぼ 0 の『薬屋のひとりごと』である (図 11.3)。




図 11.4 ジャンル判別の正解率が 0.888 になるモデルの全体像。図の木は説明用に全 134 点で学習したもので、しきい値の 5.4% はそのときの値である。0.888 は交差検証の各分割でしきい値を学び直したときの平均正解率で、この一つの木に対する値ではない。

× アンチパターン 11.1 — 最も単純なルールを試さずに高い精度を誇る

ジャンル判別の正解率 1.000 という数字だけを見ると、55 次元のランダムフォレストの働きに見える (134 点では、読点前の平仮名を 134 点の頻度で選び直すので、第 3 章の 52 列より多い)。だが片仮名の比率 1 列に固定した決定株で正解率 0.888、55 列から 1 列を選んで 1 回だけ質問する決定株で 0.941 になる。ランダムフォレストが上積みしたのは、0.941 から 1.000 までの 0.059 にすぎない。

「機械学習で 99% の精度を達成」と報告する前に、**最も単純なルールで何割当たるかを測る**。決定株、線形しきい値、多数決。これらを基準線に置く。

差がわずかなら、複雑なモデルを使う理由は**精度以外のところ**になければならない。

11.4.2 疑い 2 — ジャンルと時代が交絡している

モデルが学んだのは「ジャンルの違い」だと思いたくなるが、このデータではもう 1 つの候補がある。**時代の違い**である。

両側の作品が世に出た年を、1 本の年表に並べた (図 11.5)。近代文学 74 作品の初出年は 1896 年から 1955 年のあいだにあり (中央値 1931 年)、新聞や雑誌の連載の終わり、論集に収めた文の初出まで含めても 1961 年までである。ライトノベル 60 区間は 2011 年から 2026 年に掲載された (区間の最初の話の掲載年の中央値 2014 年)。1962 年から 2010 年までは、どちらの側の作品も 1 つもない。中央値どうしでおよそ 83 年離れていて、その間に日本語の表記習慣が変わった。

- 片仮名語 (外来語) の増加
- 漢字使用の減少 (当用漢字・常用漢字の制定)
- 文の短文化
- 会話文の比率の増加

交絡しているのは時代だけではない。題材や舞台も違う。異世界を舞台にしたライトノベルには外来語が多く、中国風の宮廷を舞台にした『葉屋のひとりごと』は、片仮名を本文にほとんど書かない。図 11.6 に、ジャンル・時代・題材と、測った特徴の関係を描いた。

片仮名の比率は、そのまま表記習慣の変化を映す列でもある。つまりこのモデルの成績は、ジャンルの違いによるものか時代の違いによるものか、**このデータでは切り分けられない**。

切り分けるには、同じ時代の作品を両側に用意するしかない。本書のコーパスにはそれがないので、「1960 年代以前の文章か、2010 年以降の文章か」を見分けている可能性を排除できないままである。このモデルを「文体判別器」と呼んで配るのは、その意味で危うい。

補足 同じ時代どうしを比べれば交絡は消える

同じ時代の作品どうしを比べれば、時代の効果は消える。

たとえば「2010 年代のライトノベルと、2010 年代の一般文芸を判別する」なら、本当にジャンルの違いを見ていることになる。

問いを立てるときは、**比較したいものの以外の差**が入り込んでいないかを確認する。実験計画でいう**交絡 (confounding)**の問題である。




図 11.5 近代文学 74 作品の初出年と、ライトノベル 60 区間の掲載時期。近代文学は著者ごとの行に、1 作品を 1 つの点 (連載や論集は初出から終わりまでの線) で置いた。同じ年の作品はまとめて「× 作品数」を添えた。吉川英治の『宮本武蔵』と『三国志』の各巻 (破線) は、巻ごとの掲載期間を確かめられなかったので、連載全体の期間 (1935～1939 年、1939～1943 年) を示している。ライトノベルはシリーズごとの行に、各区間の最初の話から最後の話までの掲載日を濃淡を交互にした帯で置いた。初出年は、青空文庫のファイル末尾の初出の記載と図書カード、Wikipedia、国立国会図書館のレファレンス協同データベースなどで調べた。作品ごとの値と出典は `book/data/novels_first_published.csv` にある。




図 11.6 ジャンルと時代、ジャンルと題材は、本書のデータでは一緒に変わる (破線)。どれも片仮名の比率や文の長さに影響するので (実線)、特徴から当てられたものがどれに由来するかは切り分けられない。

11.4.3 疑い 3 — シリーズを分けてもほとんど落ちない

ランダムフォレストのまま、同じシリーズをまとめて片側に置く CV にすると、ジャンル判別の正解率は 1.000 から 0.978 に落ちた。差は 0.022 である。

落ちること自体は当然である。ライトノベル側は 6 シリーズしかないので、6 シリーズを 5 つに分ければ、1 回のテストにシリーズ 1 つか 2 つが丸ごと入る。そのシリーズの文章は訓練で一度も見えない。

それでもシリーズを分けた CV で正解率 0.978 であり、基準線 0.552 を 0.426 上回っている。ジャンル判別に関しては、シリーズ固有の癖に頼らずとも判別できているということである。近代文学とライトノベルを分ける手がかり (片仮名の多さ、文の長さ) はシリーズをまたいで共通しているからである。

次節で見る著者判別は、これとまったく対照的になる。

11.5 著者判別に戻ると

同じ 134 点、同じ特徴量のまま、ジャンルではなく 14 名の著者を当てる問題に切り替えると、事態は一変する。

表 11.3 134 点・14 名の著者判別の正解率と落差

モデル	通常の層別 CV	シリーズを分けた CV	落差
k 近傍法 ($k = 5$)	0.985	0.555	+0.430
ランダムフォレスト	0.970	0.533	+0.438

落差は、通常の層別 CV の正解率からシリーズを分けた CV の正解率を引いた差である。近代文学 74 作品だけで著者を判別したときは、ランダムフォレストの落差が 0.011 だった (第 9 章の表 9.5)。それが 134 点・14 名では、k 近傍法でもランダムフォレストでも **0.43 以上になった**。40 倍近い。

ただし、この落差の中身は第 9 章の落差とは違う。ライトノベルの 60 区間は、シリーズを分けるなどのモデルでも必ず外れる (理由は次に述べる)。それだけで正解率は最大 $60/134 = 0.448$ 下がる。落差の 0.43 は、ほぼこの量にあたる。近代文学の作品の当たり外れは、ほとんど変わっていない。

跳ね上がったのは、ライトノベルには**著者ごとに 1 シリーズしかない**ためである。



図 11.7 同じ「作品数」でも中身が違う。ライトノベルは著者とシリーズが一对一。

シリーズを分割の単位にすると、テストに現れる著者の作品が訓練データに 1 つも残らない。未知の著者を当てることはできないので、正解率は落ちる。

第9章で見たとおり、ライトノベル 60 区間だけで 6 名の著者を文字 3-gram で判別すると、通常の CV で正解率 1.000 だったものが、シリーズを分けた CV では 0.000 になった。極端な形で同じことが起きている。

— ○ 定石 11.1 — 独立した単位がいくつあるかを先に数える —

「134 作品ある」という数字だけでは、何も分らない。

- 独立した単位はいくつあるか
- 各クラスに独立単位はいくつあるか
- 予測したい対象は、訓練データに現れるものか、現れないものか

本書のライトノベルは、**著者判別の教材としては使えない**。だがジャンル判別や、シリーズ内での区間の判別には使える。データが悪いのではなく、問いとの相性の問題である。

11.6 候補の外にいる著者を棄却する

もう一つ、問いの立て方に隠れている前提がある。

本書のモデルは、どの作品を入れても**必ず 8 名の誰かだと答える**。確率が最も高い著者を選ぶ仕組みなので、「この 8 名の誰もいない」という選択肢がそもそも用意されていない。これを**閉集合の仮定** (closed-set assumption) という。データベース分野の閉世界仮定 (closed-world assumption) から借りた呼び方をされることもある。

現実の著者判別で困るのは、たいていここである。匿名の文書が来たとき、それが手元の候補者の誰かとは限らない。筆跡鑑定、話者認識、不正検知も同じ形をしている。候補者リストの外にいる人物を、リストの中の誰かに割り当ててしまう。

11.6.1 未知の著者を入れてみる

実験してみる。近代文学 74 作品に戻り、夢野久作を訓練データから外して、残り 67 作品・7 名で学習する。モデルはランダムフォレスト、特徴は第3章の 52 列である。そのうえで、夢野久作の 7 作品を投入する。

モデルは当然、全部を 7 名の誰かだと答える。正解は 1 つもない。だが**答え方**に手がかりが残っている。ランダムフォレストが返す 7 名ぶんの確率のうちの最大値 (以下**確信度**と呼ぶ) を見ると、夢野久作の 7 作品では確信度の中央値が 0.23、最大値でも 0.36 である。学習した 7 名の作品では、確信度がこれよりずっと高い。7 名に確率を配るので、確信度はどれだけ票が割れても $1/7 \approx 0.14$ より下にはならない。夢野久作の作品の確信度は、この下限に近い。

図 11.8 に、2 つの確信度の分布を並べた。既知 7 名の確信度は、5 分割交差検証で各作品をテスト側に回したときの値、夢野久作の確信度は、既知 7 名の 67 作品すべてで学習したモデルに入れたときの値である。

当たっているかどうかは分からなくても、自信がないことはモデル自身が知っている。ここを使う。

図 11.9 が、しきい値を動かしたときの 2 本の線である。確信度がしきい値未満なら「該当なし」と答えることにする。

2 本の線は別々の量である。**既知側の正解率**は、既知 7 名の 67 作品を 5 分割交差検証で判別した




図 11.8 確信度の分布 (0.05 刻み、積み上げ)。夢野久作の 7 作品は 0.2 から 0.4 のあいだに集まり、既知 7 名の作品の多くはそれより右にある。破線は本文で取り上げるしきい値である。




図 11.9 棄却のしきい値を動かしたときの 2 つの割合。上げるほど未知の著者を弾けるが、既知の著者も弾いてしまう。

とき、正しい著者名を答えられた作品の割合である (「該当なし」と答えたものは不正解として数える)。未知側の棄却率は、夢野久作の 7 作品を「該当なし」に落とした割合である。

しきい値を 0 にすれば、これまでどおり必ず誰かだと答える。このとき既知側の正解率は 0.9701、未知側の棄却率は 0 である。しきい値を 0.3 まで上げると、未知側の棄却率が 0.8571 まで上がり、既知側の正解率はそこから 0.9552 に下がるだけである。未知側は 7 作品しかないの、棄却率は $1/7 \approx 0.14$ 刻みでしか変わらない。0.4 まで上げれば未知側の棄却率が 1 になり、夢野久作の 7 作品をすべて弾ける。その代わり、既知側の正解率は 0.7910 まで下がる。

第 8 章の ROC 曲線と同じ構造である。未知側の棄却率を上げれば、既知側の正解率が下がる。どこに置くかは、どちらの誤りが高くつくかで決める。未知の人物を既知の誰かだと誤って名指しする害が大きいなら、しきい値は高めに置く。

補足 未知の書き手が既知の誰かに似ているとこの方法は通じない

しきい値で夢野久作を弾けたのには理由がある。訓練から外した夢野久作の文体が、残り 7 名のどれとも似ていなかったからである。どの著者にも当てはまらない作品を渡されたモデルは、7 名のどこにも票を集められない。その結果として確信度が下がり、しきい値で拾えた。

逆の場合を考えてみる。未知の書き手が、たまたま既知の 7 名のうち誰かと似た書き方をしていたとする。モデルはその 1 名に票を集める。そのときの確信度は 0.9 にも 0.95 にもなりうる。訓練で見た著者の作品を当てたとき、数字の上で区別がつかない。しきい値をどこに置いても弾けない。

しかも、候補として並べる著者を増やすほど、「たまたま似ている誰か」が混じる見込みは高くなる。候補を網羅するほど正解を含む見込みは上がるが、「該当なし」と答えさせる目的からは逆に働く。

確信度のしきい値のほかにも方法はある。既知の著者たちの分布からどれだけ離れているかを測る外れ値検知や、「その他」というクラスを作って明示的に学習させるやり方があり、まとめてオープンセット認識 (open-set recognition) と呼ばれている。ただしどの方法を使っても、未知がどれくらい既知に似ているかという難しさの根は変わらない。

× アンチパターン 11.2 — 答えの候補が出そろっている前提に気づかない

分類器は、訓練で見たクラスの中からしか答えを選べない。「どれでもない」と答えさせたいなら、その仕組みを自分で足す必要がある。

見分け方は、次の問いを自分に投げることである。本番で来るデータは、必ず訓練で見たクラスのどれかに入るか。入らないものが来るなら、確信度のしきい値なり外れ値検知なりを設計に組み込む。

そして棄却を入れたら、評価指標も変える。正解率だけでは「該当なしと答えた分」を数えられないので、既知側の正解率と未知側の棄却率を並べて報告する (図 11.9)。

コラム ロバート・ガルブレイスは誰か

2013 年、ロンドンを舞台にした推理小説『カッコウの呼び声』(The Cuckoo's Calling) が、新人作家ロバート・ガルブレイスの名で出版された。その後、これは『ハリー・ポッター』の J・K・ローリングの筆名ではないか、という匿名の情報が、ツイッター経由で英国の新聞社に届いた。

その新聞社の記者から相談を受けたデューク大学のパトリック・ジュオラは、計量的な著者判別で確かめた [108]。比べた相手は、ローリングが本名で書いた一般小説『カジュアル・ベイカンシー』と、英国の女性推理作家 3 人 (ルース・レンデル、P・D・ジェイムズ、ヴァル・マクダーミド) の作品である。使った特徴は、語の長さの分布、よく使われる 100 語の頻度、4 文字の並び (文字 4-gram)、隣り合う語の組の 4 通りである。本書の字種の比率、読点前の平仮名、第 9 章の文字 3-gram と、同じ発想の特徴である。4 つの方法のどれでも、ローリングがいちばん近い 2 番目に近かった。新聞社がこの結果をもとに問い合わせると、1 日足らずで、ローリングは代理人を通じて自分が書いたと認めた。

ジュオラ自身は、結果の読み方を慎重に書いている。これはローリングが書いたことの証明ではなく、「調べた 4 人の中では、最も可能性が高いのはローリング」ということしか示していない、と。候補の外にいる書き手は比べておらず、本章でいう閉集合の仮定をそのまま置いている。候補を 4 人に絞った時点で、答えは 4 人の中からしか出てこない。この件で結論が支持されたのは、候補の中に本当の著者がいたからである。

11.7 2次元で眺める

最後に、134 点を PCA で 2 次元に落とす。




図 11.10 134 点の PCA。ライトノベルは第 1 主成分の正の側に寄るが、1 つのシリーズ (『本好きの下剋上』) は近代文学の中に入り込み、ほかのシリーズの一部も境目で重なる。

第 1 主成分の正の側にライトノベルが寄るが、きれいには分かれていない。第 1 主成分に 1 本のしきい値を置いて分けても、正解率は 0.903 にとどまる。『本好きの下剋上』の 10 区間は、第 1 主成分の値が近代文学の範囲に入っている。寄与率は第 1 主成分が 0.181、第 2 主成分が 0.140 で、2 つ合わせても 3 割程度である。

第 6 章では、寄与率が低い図で距離を読むことはできないと書いた。射影は群どうしを重ねて見せることはあっても、偽の分離を作ることはない。したがって、この図で重なっていることは、元の空間で重なっていることを意味しない。実際、同じ 134 点をランダムフォレストにかけると、層別 CV でジャンルをすべて当てている (表 11.1)。逆に、この図で分かれて見える点どうしは、元の空間でも分かれている。図から読み取れるのは「分かれているかどうか」の手がかりで、「どれだけ離れているか」ではない。その区別は保っておきたい。

11.8 当てているものと、当てたいものは違うことがある

本章で見たのは、当てられてはいるが、当てているものが問いとずれている、という事態だった。最後にこれを一般の形に広げておく。

本書は「著者を当てる」という問いを立てて、それに対応するラベル (作品に付いた著者名) を持っていた。問いとラベルが一致している、恵まれた設定である。

実務ではそうならないことのほうが多い。本当に知りたい量が測れないので、測れる別の量で代用する。これを代理変数という。

米国の医療機関で広く使われていた、患者をリスクで振り分けるアルゴリズムは、「翌年の医療費」を予測していた [107]。医療の必要度そのものは測れないので、費用で代用した。ところが同じ費用でも、医療への接し方の違いから、黒人患者のほうが実際には重症だった。代用したことで、必要な

人ほど追加ケアの対象から外れる仕組みができていた。予測する対象を「総医療費」から「活動中の慢性疾患の数」に変えて学習し直すと、リスク上位 3% に入る患者に占める黒人患者の割合は 14.1% から 26.7% に増えた。

モデルの精度をいくら上げて、**代理変数と本来の目的のずれは消えない**。むしろ精度が上がるほど、ずれた目標に忠実になる。

ジャンル判別が時代判別でもありえたのと同じで、**当てているものが、当てたいものと同じかどうか**は、成績を見ても分からない。ラベルがどう作られたかを遡って確かめるしかない。

11.9 この本のまとめ

第 1 章の図 1.1 に、第 9 章から第 3 章へ戻る点線を描いた。本章では、戻る先がさらに手前の、問いの立て方にまで及んだ。

本書で通ったのは、次の道である。

1. テキストの性質を調べ (第 2 章)
2. 内容に依存しない特徴を設計し (第 3 章)
3. 距離を定義し (第 4 章)
4. まとまりを見つけ (第 5 章)
5. 次元を落として眺め (第 6 章)
6. 著者を当てるモデルを作り (第 7 章)
7. 正しく測る方法を整え (第 8 章)
8. 測り方が間違っていたことに気づき (第 9 章)
9. 学習された表現と比べ (第 10 章)
10. そして問いそのものを立て直した (第 11 章)

最後の 2 つが本書の主題である。

分類器を作るだけなら、scikit-learn で 3 行書けば済む。

手間がかかるのは、**出てきた数字が何を意味するかを判断すること**のほうである。近代文学 74 作品の著者判別で得た正解率 0.987 という数字が「文体を学んだ」ものなのか「長編の癖を覚えた」ものなのかは、数字を見ても分からない。データがどう作られたかを知り、評価を設計し、モデルが何を見ているかを確かめて、初めて分かる。

良い交差検証ができれば、半分は勝ったようなものだ。

モデルをきちんと評価する方法が見つからないうちは、次の工程に進まない。

— Shubin Dai (2018 年、Kaggle 世界ランキング 1 位当時のインタビューより。

原文 “A good CV is half of success.”[95])

11.10 章末の課題

1. 片仮名の比率を特徴から除いて、ジャンル判別をやり直せ。正解率はどこまで落ちるか。次に決め手となる特徴は何か。

2. 「2010 年代のライトノベルと 2010 年代の一般文芸」を判別する実験を設計せよ。どんなデータが必要か。
3. ライトノベル 6 名について、「同じシリーズの中で、前半の区間と後半の区間を判別する」問題を作れ。作家の文体は連載を追って変化するか。
4. 134 点でクラスタリングを行い ($k = 2$)、ジャンルとの一致度 (ARI) を測れ。教師なしでもジャンルは見つかるか。
5. 本書で扱わなかった特徴を 1 つ設計し、第 3 章の 3 条件を満たすかを検討したうえで、ジャンル判別と著者判別の両方で効果を測れ。

marimo 教材の使い方

授業や自習で使うために、5 本の marimo ノートブックを用意した。スライダーや選択欄を操作すると計算と図が更新される。例えば、標準化に使うデータを変えたときに k 近傍法の予測がどう変わるかを、点の配置と近傍への線で確認できる。

A.1 教材の構成

配布されたフォルダには、次のファイルが入っている。public フォルダは、ノートブックと同じ場所に置く。

```
00_from_text_to_authors.py
01_style_map.py
04_clustering.py
05_classification.py
06_leakage_and_pitfalls.py
public/
  features.csv
  features_all.csv
  samples/
```

features.csv は近代文学 74 作品の特徴量で、01~06 が読み込む。features_all.csv は近代文学にライトノベルの区間を足した 134 点の特徴量で、第 11 章と同じ表である。samples には青空文庫の数作品などの本文が入っている。この 2 つは 00 が読み込む。これらのファイルを移動したり名前を変えたりすると、ノートブックから読み込めなくなる。

00 は通し教材で、本文を数えるところからジャンル判別まで、本書の順に追う。まず 00 を通して読み、個別の実験は 01~06 で条件を変えて試すとよい (図 A.1)。




図 A.1 教材の読み順。00 で全体を通し、気になった実験を 01~06 で条件を変えて試す。

表 A.1 各ノートブックで試せる操作。ファイル名の番号は本書の章番号とは異なる

ファイル	内容
00_from_text_to_authors.py	通し教材。本文を数えるところから、特徴の設計、距離、クラスタリング、主成分分析、交差検証、ジャンル判別まで、本書の順に追う (第 2～9・11 章)
01_style_map.py	次元削減による文体の地図、元の特徴空間との近傍の比較、入力文の表示 (第 3・4・6 章)
04_clustering.py	k-means の反復、初期値による違い、デンドログラムの切断 (第 5・6 章)
05_classification.py	分類器の予測確率と、判定のしきい値による誤分類の変化 (第 7・8 章)
06_leakage_and_pitfalls.py	特徴選択と標準化による漏洩、長編単位の分割、次元数による近傍の変化 (第 9 章)

A.2 自分のパソコンで実行する

実行には、Python の環境を管理する `uv` を使う。`uv` の導入方法は公式の案内を参照する。

<https://docs.astral.sh/uv/getting-started/installation/>

ターミナルで配布フォルダへ移動し、次のコマンドを実行する。

```
uvx marimo run --sandbox 04_clustering.py
```

初回は、必要な Python とライブラリをダウンロードするため、インターネット接続が必要になる。起動するとブラウザに教材が表示される。他の教材を開くには、末尾のファイル名を変更する。`run` で開くと、コードは送られず画面にも出ない。コードも見ながら読むには `--include-code` を付ける。00 はこの形で開くとよい。

```
uvx marimo run --sandbox --include-code 00_from_text_to_authors.py
```

教材を終了するときは、起動に使ったターミナルで `Ctrl+C` を押す。

Python のコードも編集したい場合は、`run` を `edit` に変える。

```
uvx marimo edit --sandbox 04_clustering.py
```

marimo では、あるセルの値が変わると、その値を使うセルが自動で再計算される。コードを編集しなくても、画面のスライダーや選択欄だけで各実験を操作できる。

A.3 操作するときの注意

一度に変える条件は一つにすると、結果が変わった理由を調べやすい。例えば分類のしきい値を変えるときは、作家、特徴量、分類器を固定する。誤分類の件数が変わっても予測確率そのものは変わらないことを確かめる。

乱数を使う実験では、乱数の番号も変えて比較する。1 回だけ得られた高い正解率を、その手法の一般的な性能と考えない。

A.4 困ったときは

データファイルが見つからない

ノートブックと同じ場所に `public` フォルダがあり、その中に `features.csv` が入っているか確認する。00 では `features_all.csv` と `samples` も要る。

初回の起動が途中で止まる

インターネット接続と、ターミナルに表示されたエラーを確認する。大学などのネットワークでダウンロードが制限されている場合は、管理者に相談する。

図の日本語が四角で表示される

ブラウザが日本語フォントを使えるか確認する。

本書と異なる数値が出る

選んだ特徴量、分類器、分割方法、乱数の番号を確認する。教材では条件を操作できるため、設定によって結果は変わる。

高次元空間の幾何

第4章と第9章で「次元の呪い」に触れた。これは、高次元空間の幾何が私たちの直感と大きく違うことから来ている。

付録では、いくつかの事実を数式で確かめる。2次元や3次元で成り立つ感覚が、なぜ通用しなくなるのかが分かる。

B.1 球の体積は消える

半径 r の d 次元球の体積は次の式で与えられる。

$$V_d(r) = \frac{\pi^{d/2}}{\Gamma(\frac{d}{2} + 1)} r^d \quad (\text{B.1})$$

Γ はガンマ関数で、 $\Gamma(n+1) = n!$ を実数に拡張したものである。

$r = 1$ として d を増やしていくと、意外なことが起きる。




図 B.1 単位球の体積。 $d = 5$ で最大になり、その後ゼロに向かう。

半径 1 の単位球の体積 $V_d(1)$ は、 $d = 5$ のあたりで最大 (≈ 5.26) になり、そこからは急速に減っていく。 $d = 20$ では 0.026 、 $d = 50$ では 1.7×10^{-13} である。

補足 なぜ次元を上げると球の体積が減るのか

式 (B.1) の分子 $\pi^{d/2}$ も、 d とともに指数的に増える。それでも体積が減るのは、分母の $\Gamma(d/2+1)$ が**階乗の速さで増える**からである。 $d = 20$ なら分子は $\pi^{10} \approx 9.3 \times 10^4$ だが、分母は $\Gamma(11) = 10! \approx 3.6 \times 10^6$ で、すでに約 40 倍離れている。 d を大きくするほど差は開く一方なので、比は 0 へ向かう。

図形として見る。半径 1 の球は、一辺 2 の立方体 $[-1, 1]^d$ にすっぽり入っている。立方体の体積は 2^d で、これも指数的に増える。球の体積は減るのだから、**立方体の体積のほとんどは、球の外側の「隅」に**

補足（続き）

あることになる。

隅がどれだけ遠いかも見ておく。立方体の中心から面までの距離は、次元がいくつでも 1 である。一方、中心から頂点までの距離は $\sqrt{d}$ で、次元とともに伸びていく。 $d = 100$ なら、中心から面までの距離は 1、中心から頂点までの距離は 10 である。球が占めるのは中心から半径 1 までなので、頂点までの残り 9 のぶんは全部、球に入らない隅ということになる。次元が上がるほど、立方体は「トゲトゲのウニ」のような形になる。

もっと直接的な比較をする。一辺 1 の立方体に内接する球 (半径 1/2) の体積比は

$$\frac{V_d(1/2)}{1^d} = \frac{\pi^{d/2}}{2^d \Gamma(d/2 + 1)} \quad (\text{B.2})$$

表 B.1 一辺 1 の立方体に対する内接球の体積比

次元 d	体積比
2	0.785
3	0.524
5	0.164
10	0.0025
20	2.5×10^{-8}
50	1.5×10^{-28}

$d = 10$ では、内接球の体積は立方体の体積の 0.25% でしかない。立方体の中に一様に点を撒いても、球の中にはほぼ入らない。

立方体の中に一様に点を撒いたなら、「中心付近にデータが集まっている」という直感は通用しない。ほぼすべての点が「隅のほう」にいることになる。

実データが一様に散らばっていることはまずないので、この結論をそのまま持ち込むことはできない。ただし、次元が上がるほど中心付近が空になるという圧力は働く。どれくらい働くかは、データがどんな形に散らばっているかによる。

B.2 体積は薄い殻に集中する

もう一つの奇妙な性質がある。半径 1 の球のうち、半径 $1 - \varepsilon$ の内側が占める体積の割合は

$$\frac{V_d(1 - \varepsilon)}{V_d(1)} = (1 - \varepsilon)^d \quad (\text{B.3})$$

である。式 (B.1) で体積が r^d に比例することから直ちに従う。

$d = 100$ では、半径 1 の球の体積の 99.4% が、表面から厚み 5% の殻 (半径 0.95 から 1 までの部分) に入っている。 $d = 500$ では、厚み 1% の殻に体積の 99.3% が入っている。どちらも表 B.2 の内側の割合を 1 から引いた値である。

表 B.2 半径 1 の球の体積のうち、半径 $1 - \varepsilon$ の内側が占める割合

d	$\varepsilon = 0.01$	0.05	0.1	0.2
1	0.990	0.950	0.900	0.800
10	0.904	0.599	0.349	0.107
100	0.366	0.0059	2.7×10^{-5}	2.0×10^{-10}
500	0.0066	7.3×10^{-12}	1.3×10^{-23}	3.5×10^{-49}

高次元の球は、中身のないシャボン玉のようなものである。




図 B.2 高次元の球では、体積のほとんどが表面近くの薄い殻にある。

B.3 距離の集中

第 4 章の図 4.22 と図 4.23 で見た現象を、式で確かめる。

d 次元の単位立方体 $[0, 1]^d$ に一様に点を撒く。2 点 X, Y の距離の 2 乗は

$$\|X - Y\|^2 = \sum_{j=1}^d (X_j - Y_j)^2 \quad (\text{B.4})$$

各項 $(X_j - Y_j)^2$ は独立同分布である。 $X_j, Y_j \sim U(0, 1)$ のとき

$$E[(X_j - Y_j)^2] = \frac{1}{6} \quad (\text{B.5})$$

$$\text{Var}[(X_j - Y_j)^2] = \frac{7}{180} \quad (\text{B.6})$$

したがって

$$E[\|X - Y\|^2] = \frac{d}{6}, \quad \text{Var}[\|X - Y\|^2] = \frac{7d}{180} \quad (\text{B.7})$$

距離そのものについては、大数の法則から、 $\|X - Y\|^2/d$ が $1/6$ に近づく。つまり距離を $\sqrt{d}$ で割ったものが $1/\sqrt{6}$ に近づき、

$$\|X - Y\| \approx \sqrt{\frac{d}{6}} \quad (d \rightarrow \infty) \quad (\text{B.8})$$

と書ける。両辺とも d とともに大きくなるので、ここでの「 $\approx$ 」は、両辺の比が 1 に近づくという意味である。

ここで平均と散らばりの伸び方を比べる。平均距離は $\sqrt{d/6}$ で、 $\sqrt{d}$ に比例して伸びる。一方、距離の標準偏差は次元を上げてほとんど増えず、一定の値に近づく^{*1}。分子が一定で分母だけ伸びるので、変動係数 (標準偏差 ÷ 平均) は

$$CV = \frac{\sigma}{\mu} = O\left(\frac{1}{\sqrt{d}}\right) \rightarrow 0 \quad (\text{B.9})$$

注意すべきは、距離そのものが同じ値になるわけではないことである。最も遠い点と最も近い点の差は縮まらない [36]。縮むのは、その差を平均距離で割った比のほうである。1 万円の買い物での 100 円の差は大きいですが、1 億円の買い物での 100 円の差は誤差に見える。高次元で起きているのは後者である。




図 B.3 一様分布の点对距離。上の 2 本は距離 (単位あり)、下の 1 本は距離を平均で割った比 (単位なし) である。平均は理論値 $\sqrt{d/6}$ に一致し、変動係数は $1/\sqrt{d}$ で減る。

図 B.3 の青い線が、単位立方体に一様に撒いた点の対距離を実測した平均、赤の破線が理論値 $\sqrt{d/6}$ である。次元が上がるほど両者は重なっていく。緑の線は、距離の標準偏差を平均距離で割った変動係数で、単位のない量である。同じ図に描いてはあるが、青や赤との高さの比較に意味はない。

発展 Beyer らの定理 — 最も近い点と最も遠い点の比が 1 に近づく

Beyer ら (1999) は、より一般的な条件でこの現象を定式化した [35]。

定理 B.1 点の数 n を固定したまま、次元 d を大きくしていく。データ点 X_d と、基準にした 1 点 Q_d (クエリ点) との距離が

$$\lim_{d \rightarrow \infty} \text{Var} \left[\frac{\|X_d - Q_d\|}{E[\|X_d - Q_d\|]} \right] = 0 \quad (\text{B.10})$$

を満たすとする。このとき、任意の $\varepsilon > 0$ に対して

$$\lim_{d \rightarrow \infty} P[D_{\max} \leq (1 + \varepsilon)D_{\min}] = 1 \quad (\text{B.11})$$

^{*1} 2 乗距離の分散 $7d/180$ から距離そのものの標準偏差を求めると $\sqrt{7d/180} / (2\sqrt{d/6})$ となり、 d が約分されて定数になる。

発展 (続き)

ここで $D_{\max}, D_{\min}$ は、クエリ点から見て最も遠い点・最も近い点までの距離である。「この作品に似た作品を探す」というとき、探す起点になる作品がクエリ点にあたる。

日本語にすると「最も遠い点までの距離と最も近い点までの距離の比が、1 にいくらでも近づく」となる。距離そのものが同じ値になるわけではない。だが比が 1 に近づけば、「いちばん近い」という言葉が意味を持たなくなる。どれも同じくらい遠いだから、最近傍探索という操作自体が意味を持たなくなる。

前提条件は、たとえば各次元が独立に同じ分布に従い、4 次のモーメントが有限なら満たされる。距離の 2 乗が d 個の同じ分布の項の和になり、大数の法則が使えるからである。独立でも、次元ごとの尺度が急に小さくなっていく場合 (第 j 次元の分散が 2^{-j} など) は、距離が最初の数次元でほぼ決まってしまう、条件は満たされない。また、次元間に強い相関があるデータでは満たされないことがある。列どうしが連動していれば、見かけの列数ほどには自由に散らばっていないからである。このとき、データが実際に広がっている向きの数を**実効次元**という。実効次元が低ければ定理は適用されず、高次元でも近傍探索が働くことがある。本書の 52 列がそうであるように、実データの列はたいてい互いに相関している。

図 B.4 は、200 点とクエリ点 1 点で $D_{\max}/D_{\min}$ を測ったものである。各次元が独立な一様分布では、 $d = 1000$ で比が 1.10 まで下がる。2 次元の一様分布を d 次元へ線形に写したデータ (実効次元 2) では、列の数をいくら増やしても比はおよそ 35 から 60 のあいだにとどまり、 $d = 1000$ でも 42 である。




図 B.4 クエリ点から見た最遠点と最近点の距離の比 (200 点。データとクエリ点を取り直して 20 回の平均)。定理の条件を満たす独立な次元では比が 1 へ近づき、実効次元が低いデータでは次元を増やしても比が下がらない。

B.4 高次元ではベクトルがほぼ直交する

もう一つ、直感に反する事実がある。

d 次元空間で、各成分を標準正規分布から取って 2 つのベクトルを作る。そのなす角は、どんな角度も同じくらい起こりそうに思える。2 次元で試せば実際にそうなる。

ところが次元を上げると、そうならない。

$d = 100$ では、標準正規分布から取った 2 ベクトルの組のうち 9 割以上が、なす角 $90^\circ \pm 10^\circ$ の範囲に入る (角度の分布を厳密に積分すると 91.8%)。高次元では、無関係な 2 つのベクトルはほぼ直交する。

理由は計算で分かる。 X, Y を標準正規分布から取ると




図 B.5 ランダムな 2 ベクトルのなす角の分布。次元が上がるほど 90° に集中する。

$$\cos \theta = \frac{X \cdot Y}{\|X\| \|Y\|} \quad (\text{B.12})$$

分子 $X \cdot Y = \sum_j X_j Y_j$ は平均 0、分散 d である。分母は $\|X\| \|Y\| \approx d$ (それぞれ $\approx \sqrt{d}$)。したがって

$$\text{Var}[\cos \theta] \approx \frac{d}{d^2} = \frac{1}{d} \implies \cos \theta = O\left(\frac{1}{\sqrt{d}}\right) \quad (\text{B.13})$$

$\cos \theta \rightarrow 0$ 、すなわち $\theta \rightarrow 90^\circ$ である。

補足 直交性がもたらす良いこと

ほぼ直交するという性質は、悪いことばかりではない。

d 次元空間には、互いにほぼ直交するベクトルを d 個よりずっと多く詰め込める。互いのなす角の余弦の絶対値が ε 以下でよいとすれば、入る本数は $e^{c\varepsilon^2 d}$ 本 (c は正の定数) にまで増やせる。

これがランダム射影 (Johnson–Lindenstrauss の補題) や、高次元の埋め込み表現が多数の語を互いに干渉させずに置ける理由である。「単語埋め込みが 300 次元で数十万語を表現できる」のは、高次元空間が思ったより広いからである。

B.5 呪いと祝福

高次元がもたらす困難と利点をまとめる。

発展 Cover の定理 — 次元を上げると線形分離しやすくなる

d 次元空間に n 個の点が一般の位置に置かれているとする^a。これらを 2 クラスに分ける方法は 2^n 通りあるが、そのうち 1 枚の超平面で分けられるものの割合は [128]

$$P(n, d) = \frac{1}{2^{n-1}} \sum_{k=0}^d \binom{n-1}{k} \quad (\text{B.14})$$

表 B.3 高次元の性質

呪い	祝福
距離が集中し、近傍探索が意味を失う	ランダム射影で低次元に落としても距離が保たれる
必要なサンプル数が指数的に増える	互いにほぼ直交するベクトルを大量に詰め込める
体積が殻に集中し、内挿で補えない	線形分離できる確率が上がる (Cover の定理)
無関係な特徴がノイズとして距離を歪める	多様体仮説により、実効次元は低いことが多い

発展 (続き)

$n \leq d + 1$ なら和が二項係数の全体になるので、 $P = 1$ になる。点の数が次元の数より 1 多い程度までなら、**どんなラベルの付き方でも線形分離できる**ということである。

n が $d + 1$ を超えても、 P はすぐには下らない。 $P(n, d)$ は、表が出る確率 $1/2$ の硬貨を $n - 1$ 回投げて表が d 回以下になる確率に等しいので、 n が $2(d + 1)$ に近づくあたりで $1/2$ になり、そこを過ぎると急に 0 へ向かう (図 B.6)。次元が高いほど、この落ち方は急になる。本書のデータは $n = 74$ 、 $d = 52$ で、 $n/(d + 1) = 1.40$ である。点が一般の位置にあれば、2 クラスへのラベルの付け方のうち、割合にして約 0.9999 が線形分離できる。

低次元では分離できないデータでも、高次元に写してしまえば分けられるようになる。この見通しがカーネル法の背景にある。第 7.4 節のサポートベクトルマシンがカーネルで曲がった境界を引けるのも、同じ考え方による^b。

ただし「分離できる」と「未知のデータで当たる」ことは別である。 $n \leq d + 1$ の状況は、訓練データをそっくり暗記できてしまう状況でもある。第 7 章で見た過学習そのものである。

^a どの $d + 1$ 個を取っても同じ超平面に乘らない、という条件である。点をでたらめに置けば、ほぼ確実に満たされる。

^b ただしカーネル法の要点は、高次元に写した座標を実際には計算せず、内積の値だけを別の式で求めてしまうところにある。Cover の定理はその動機を説明するが、手法そのものの中身ではない。

コラム 「次元の呪い」の名付け親と「次元の祝福」を広めた人

「次元の呪い」という言葉を作ったのは、動的計画法を考えた数学者 Richard Bellman である。1957 年の著書『Dynamic Programming』で、状態を格子に区切って最適な手を探すとき、変数が 1 つ増えるごとに調べる格子点の数が掛け算で増えていく困りごとを、こう呼んだ [125]。本付録の話よりも、計算の手間の話として生まれた言葉である。

分類の分野では、G. F. Hughes が 1968 年に示した結果がよく引かれる [126]。訓練データの数を固定したまま測る特徴を増やしていくと、予測の精度の平均はいったん上がり、ある数を境に下がり始める。ヒューズ現象、あるいはピーキング現象と呼ばれる。第 9 章で乱数列を足していった実験は、情報のない特徴だけを足したので、この現象のうち下がる側だけを見ていることになる。




図 B.6 Cover の定理の $P(n, d)$ 。横軸が 2 のところ ($n = 2(d + 1)$) で $1/2$ を通り、次元が高いほど 1 から 0 へ急に落ちる。破線は本書のデータの位置 ($n = 74$, $d = 52$)。

コラム (続き)

反対側の「次元の祝福」を広めたのは、統計学者 David Donoho の 2000 年の講演「High-Dimensional Data Analysis: The Curses and Blessings of Dimensionality」である [127]。講演の趣旨は、高次元で起きる測度の集中が、解析をかえって簡単にする場合もあるというものだった。本付録のランダムな 2 ベクトルがほぼ直交する話も、この集中の一例である。表 B.3 の右の列は、この「祝福」の側を並べたものにあたる。そのうちランダム射影やほぼ直交するベクトルの話は、距離の集中と同じ現象を別の側から見たものである。

B.6 実務での構え方

付録で見た性質は、実務では次の形で顔を出す。

- **特徴の数と標本数の比**。標本数 n が特徴の数 d を下回るなら、Cover の定理の範囲に入り、どんなラベルでも線形分離できてしまう。訓練データでの成績は当てにならない
- **距離を使う手法** (k 近傍法、k-means、コサイン類似度) は実効次元が高い場合、次元が上がるほど当てにならなくなる (発展で見たとおり、実効次元が低ければ距離は働きうる)。当てはまるなら、先に次元を落とすか、距離を使わない手法にする
- **木ベースの手法**は、無関係な次元が増えても成績の落ち方が緩い。分割のたびに情報利得の高い列だけが選ばれて使われる、埋め込み型の特徴選択が働くためである。ただしランダムフォレストのように分割ごとに候補の列を無作為に絞る手法では、乱数列が増えるほど、候補に情報のある列が 1 本も入らない分割が増える。候補を絞る仕組みは、乱数列が増えるとむしろ弱点になる (第 9 章)
- **実効次元**。列どうしが相関していれば、見かけの列数ほど自由には散らばっていない。PCA の寄与率や多様体学習で見当をつける

行動としてまとめると、第 9 章の定石と同じ 1 点に帰着する。**特徴を足したら必ず測り直す**。増やして悪化するのは普通のことである。

本書の近代文学のデータは、標本数が $n = 74$ (作品)、特徴の数が $d = 52$ (列) である。 n が d より少し大きい程度で、決して余裕のある状況ではない。第 9 章で乱数列を足したとき、k 近傍法の正解

率は 2052 次元で最頻クラスの割合を下回るまで下がった。

B.7 章末の課題

1. 式 (B.1) を使って、単位球の体積が最大になる次元を求めよ (d を実数として扱ってよい)。
2. d 次元立方体 $[-1, 1]^d$ の頂点は 2^d 個ある。中心から頂点までの距離と、中心から面までの距離の比を求め、 $d \rightarrow \infty$ での挙動を調べよ。
3. 一様分布ではなく標準正規分布から点を取ったとき、平均距離はどうなるか。 $\sqrt{2d}$ になることを確かめよ。
4. 図 B.5 を $d = 1000$ まで延長し、分布の幅が $1/\sqrt{d}$ で縮むことを数値的に確かめよ。
5. 本書の 52 次元データについて、点对距離の変動係数を計算せよ。一様分布の理論値 (図 B.3) と比べてどうか。違いがあるとすれば、それは何を意味するか。

付録 C

不偏性をめぐる補足

第3章の発展「 $n-1$ で割るべきか」で触れた2つの話を、式の導出まで含めてここに置く。本文の結論（本書のデータではどちらで割っても結論は変わらない）は、この付録の内容に依存しない。

C.1 二乗誤差を最小にする割る数は $n+1$ である

第3章の実験では、偏差平方和を $n-1$ 、 n 、 $n+1$ で割った3通りのうち、二乗誤差 $E[(\hat{\sigma}^2 - \sigma^2)^2]$ が最も小さかったのは $n+1$ で割ったものだった。ここで当然の疑問が出る。 $n+1$ が n より良いなら、 $n+10$ で割ればもっと良いはずである。だがそうはならない。割る数 c を動かして二乗誤差を測ると、 $c = n+1$ を底とする谷の形になる。




図 C.1 偏差平方和 S を c で割った推定量の二乗誤差 ($n=10$ 、 $\sigma=1$ の正規分布)。破線と点線は下の式による理論値で、2つの和が実線に一致する。 c を大きくするとばらつきは減り、偏りは $c = n-1$ を過ぎてから増えていく。

c を大きくするほど推定値のばらつきは減るが、そのぶん真の値より小さく答えるようになる。 $c = n+1$ より先では、偏りの増加がばらつきの減少を上回る。極端に大きい c は「いつもほぼ0と答える」推定量であり、二乗誤差は σ^4 に向かって戻っていく。谷の底が1か所しかないことは計算でも確かめられる。 $S = \sum (x_i - \bar{x})^2$ とおくと、 $E[S] = (n-1)\sigma^2$ で、データが正規分布に従うなら $\text{Var}[S] = 2(n-1)\sigma^4$ でもあるので

$$\text{MSE}(c) = \frac{\text{Var}[S]}{c^2} + \left(\frac{E[S]}{c} - \sigma^2 \right)^2 = \sigma^4 \left(\frac{n^2-1}{c^2} - \frac{2(n-1)}{c} + 1 \right) \quad (\text{C.1})$$

となり、 c で微分してゼロと置くと $c = n+1$ が唯一の解として出る。このとき $\text{MSE} = 2\sigma^4/(n+1)$ で、 $n-1$ で割る場合の $2\sigma^4/(n-1)$ より小さい。ただしこれは正規分布を仮定したうえで、この形

の推定量に限った話である。分布が違えば底の位置も変わるので、 $n+1$ を新しい既定にする話ではない。

C.2 標準偏差を不偏にする補正

第3章で見たとおり、 s^2 が不偏でも $s = \sqrt{s^2}$ は不偏にならない。どれだけずれるかを実測する。 $n-1$ で割って 40 万回繰り返し、 s^2 と s の平均を並べる。

n	$E[s^2]$	$E[\sqrt{S/(n-1)}]$	$E[\sqrt{S/(n-1.5)}]$
5	0.9995	0.9396	1.0045
10	1.0004	0.9728	1.0010
30	1.0005	0.9916	1.0003
100	1.0000	0.9975	1.0000

真の分散も真の標準偏差も 1 である。 s^2 の平均は 1 に一致しているのに、 s の平均は $n=5$ で 1 より 6%、 $n=10$ でも 2.7% 小さい。正規分布なら $E[s] = c_4(n)\sigma$ と書けることが知られていて、 $c_4(n) = \sqrt{2/(n-1)} \Gamma(n/2)/\Gamma((n-1)/2)$ である。 s を $c_4(n)$ で割れば標準偏差も不偏にできる。

ガンマ関数を持ち出さない近似もある。 $n-1$ ではなく $n-1.5$ で割ってから平方根を取るという手で、表の右端がそれである。この推定量の平均は、40 万回の実測で $n=10$ なら 1.0010、 $n=30$ なら 1.0003 で (正規分布での厳密値は 1.0009 と 1.0001)、真の標準偏差 1 からのずれは $n \geq 5$ なら 0.5% 以内に収まっている。種を明かすと、 c_4 で割った推定量の実効的な割る数は $(n-1)c_4(n)^2$ で、これが $n=10$ で 8.515、 $n=30$ で 28.504 と、 $n-1.5$ にほぼ一致する。

ただし、こうして偏りを消せば二乗誤差は大きくなる。前と同じ話である。

ずれの大きさは標本の数で決まる。文数が数百から数千ある本書の文長 σ では、 c_4 が 1 からほとんど離れないので、この補正は要らない。補正が意味を持つのは、数十点以下の標本で標準偏差そのものを報告するときである。

参考文献

- [1] F. Mosteller and D. L. Wallace: *Inference and Disputed Authorship: The Federalist*, Addison-Wesley (1964).
- [2] T. C. Mendenhall: The Characteristic Curves of Composition, *Science*, 9(214S), pp. 237–249 (1887).
- [3] 安本美典: 宇治十帖の作者 —— 文章心理学による作者推定, 文学・語学, 4, 全国大学国語国文学会 (1957).
- [4] 土山玄: 計量文献学による『源氏物語』の成立に関する研究, 博士論文, 同志社大学 (2015). 紹介は情報処理学会「博士論文速報」<https://www.ipsj.or.jp/magazine/hakase/2014/CH01.html>
- [5] 金明哲, 樺島忠夫, 村上征勝: 読点と書き手の個性, 計量国語学, 18(8), pp. 382–391 (1993).
- [6] Z. S. Harris: From Phoneme to Morpheme, *Language*, 31(2), pp. 190–222 (1955).
- [7] Z. Jin and K. Tanaka-Ishii: Unsupervised Segmentation of Chinese Text by Use of Branching Entropy, *Proc. COLING/ACL 2006 Main Conference Poster Sessions*, pp. 428–435 (2006).
- [8] 金明哲: テキストデータの統計科学入門, 岩波書店 (2009).
- [9] G. U. Yule: On Sentence-Length as a Statistical Characteristic of Style in Prose: With Application to Two Cases of Disputed Authorship, *Biometrika*, 30(3/4), pp. 363–390 (1939).
- [10] C. B. Williams: A Note on the Statistical Analysis of Sentence-Length as a Criterion of Literary Style, *Biometrika*, 31(3/4), pp. 356–361 (1940).
- [11] H. S. Sichel: On a Distribution Representing Sentence-Length in Written Prose, *Journal of the Royal Statistical Society, Series A*, 137(1), pp. 25–34 (1974).
- [12] G. K. Zipf: *Selected Studies of the Principle of Relative Frequency in Language*, Harvard University Press (1932).
- [13] D. François, V. Wertz and M. Verleysen: The concentration of fractional distances, *IEEE Transactions on Knowledge and Data Engineering*, 19(7), 873–886 (2007).
- [14] M. Radovanović, A. Nanopoulos and M. Ivanović: Hubs in space: Popular nearest neighbors in high-dimensional data, *Journal of Machine Learning Research*, 11, 2487–2531 (2010).
- [15] G. A. Miller: Some effects of intermittent silence, *The American Journal of Psychology*, 70(2), 311–314 (1957).
- [16] W. Li: Random texts exhibit Zipf’s-law-like word frequency distribution, *IEEE Transactions on Information Theory*, 38(6), 1842–1845 (1992).
- [17] K. W. Church and W. A. Gale: Inverse Document Frequency (IDF): A Measure of Deviations from Poisson, *Proc. Third Workshop on Very Large Corpora*, pp. 121–130 (1995).

- [18] E. G. Altmann, J. B. Pierrehumbert, and A. E. Motter: Beyond Word Frequency: Bursts, Lulls, and Scaling in the Temporal Distributions of Words, *PLoS ONE*, 4(11), e7678 (2009).
- [19] K.-I. Goh and A.-L. Barabási: Burstiness and Memory in Complex Systems, *EPL*, 81, 48002 (2008).
- [20] F. Mosteller and D. L. Wallace: *Applied Bayesian and Classical Inference: The Case of The Federalist Papers*, 2nd ed., Springer (1984).
- [21] J. Albert and J. Hu: *Probability and Bayesian Modeling*, CRC Press (2019). <https://bayesball.github.io/BOOK/>
- [22] J. VanderPlas: The Waiting Time Paradox, or, Why Is My Bus Always Late? (2018). <https://jakevdp.github.io/blog/2018/09/13/waiting-time-paradox/>
- [23] K. Pearson: Mathematical Contributions to the Theory of Evolution. On a Form of Spurious Correlation Which May Arise When Indices Are Used in the Measurement of Organs, *Proceedings of the Royal Society of London*, 60, pp. 489–498 (1897).
- [24] F. Chayes: On Correlation between Variables of Constant Sum, *Journal of Geophysical Research*, 65(12), pp. 4185–4193 (1960).
- [25] J. Aitchison: The Statistical Analysis of Compositional Data, *Journal of the Royal Statistical Society, Series B*, 44(2), pp. 139–177 (1982).
- [26] J. Aitchison: *The Statistical Analysis of Compositional Data*, Chapman and Hall (1986).
- [27] J. A. Martín-Fernández, C. Barceló-Vidal, and V. Pawłowsky-Glahn: Dealing with Zeros and Missing Values in Compositional Data Sets Using Nonparametric Imputation, *Mathematical Geology*, 35(3), 253–278 (2003).
- [28] J. A. Martín-Fernández, K. Hron, M. Templ, P. Filzmoser, and J. Palarea-Albaladejo: Bayesian-Multiplicative Treatment of Count Zeros in Compositional Data Sets, *Statistical Modelling*, 15(2), 134–158 (2015).
- [29] G. B. Gloor, J. M. Macklaim, V. Pawłowsky-Glahn, and J. J. Egozcue: Microbiome Datasets Are Compositional: And This Is Not Optional, *Frontiers in Microbiology*, 8, 2224 (2017).
- [30] A.-M. Legendre: *Nouvelles méthodes pour la détermination des orbites des comètes*, Paris (1805).
- [31] R. W. Farebrother: Rogerius Josephus Boscovich, in C. C. Heyde, E. Seneta, et al. (eds.), *Statisticians of the Centuries*, Springer, pp. 82–85 (2001).
- [32] G. Salton, A. Wong, and C. S. Yang: A Vector Space Model for Automatic Indexing, *Communications of the ACM*, 18(11), 613–620 (1975).
- [33] L. Lee: Measures of Distributional Similarity, *Proc. 37th Annual Meeting of the ACL*, pp. 25–32 (1999).
- [34] H. Steck, C. Ekanadham, and N. Kallus: Is Cosine-Similarity of Embeddings Really About Similarity?, *Companion Proc. ACM Web Conference 2024 (WWW '24)*, pp. 887–890 (2024).
- [35] K. Beyer, J. Goldstein, R. Ramakrishnan, and U. Shaft: When Is “Nearest Neighbor” Meaningful?, *Proc. ICDT 1999*, LNCS 1540, pp. 217–235 (1999).
- [36] C. C. Aggarwal, A. Hinneburg, and D. A. Keim: On the Surprising Behavior of Distance

- Metrics in High Dimensional Space, *Proc. ICDT 2001*, pp. 420–434 (2001).
- [37] R. A. Olshen and B. Rajaratnam: Successive Normalization of Rectangular Arrays, *Annals of Statistics*, 38(3), 1638–1664 (2010).
 - [38] R. A. Olshen and B. Rajaratnam: Correction: Successive Normalization of Rectangular Arrays, *Annals of Statistics*, 41(5) (2013).
 - [39] D. Schnitzer, A. Flexer, M. Schedl, and G. Widmer: Local and Global Scaling Reduce Hubs in Space, *Journal of Machine Learning Research*, 13, 2871–2902 (2012).
 - [40] J. Burrows: ‘Delta’: A Measure of Stylistic Difference and a Guide to Likely Authorship, *Literary and Linguistic Computing*, 17(3), 267–287 (2002).
 - [41] S. Evert, T. Proisl, F. Jannidis, I. Reger, S. Pielström, C. Schöch, and T. Vitt: Understanding and Explaining Delta Measures for Authorship Attribution, *Digital Scholarship in the Humanities*, 32(suppl. 2), ii4–ii16 (2017).
 - [42] C. Eckart and G. Young: The Approximation of One Matrix by Another of Lower Rank, *Psychometrika*, 1(3), 211–218 (1936).
 - [43] G. N. Lance and W. T. Williams: A General Theory of Classificatory Sorting Strategies: 1. Hierarchical Systems, *The Computer Journal*, 9(4), 373–380 (1967).
 - [44] D. Wishart: An Algorithm for Hierarchical Classifications, *Biometrics*, 25(1), 165–170 (1969).
 - [45] L. Hubert and P. Arabie: Comparing Partitions, *Journal of Classification*, 2(1), 193–218 (1985).
 - [46] P. J. Rousseeuw: Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis, *Journal of Computational and Applied Mathematics*, 20, 53–65 (1987).
 - [47] M. Eder: Visualization in Stylometry: Cluster Analysis Using Networks, *Digital Scholarship in the Humanities*, 32(1), 50–64 (2017).
 - [48] S. P. Lloyd: Least Squares Quantization in PCM, *IEEE Transactions on Information Theory*, 28(2), 129–137 (1982).
 - [49] H. Steinhaus: Sur la division des corps matériels en parties, *Bulletin de l’Académie Polonaise des Sciences, Classe III*, 4(12), 801–804 (1956).
 - [50] J. MacQueen: Some Methods for Classification and Analysis of Multivariate Observations, *Proc. 5th Berkeley Symposium on Mathematical Statistics and Probability*, Vol. 1, pp. 281–297 (1967).
 - [51] D. Arthur and S. Vassilvitskii: k-means++: The Advantages of Careful Seeding, *Proc. 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pp. 1027–1035 (2007).
 - [52] L. van der Maaten and G. Hinton: Visualizing Data using t-SNE, *Journal of Machine Learning Research*, 9, 2579–2605 (2008).
 - [53] L. McInnes, J. Healy, and J. Melville: UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction, arXiv:1802.03426 (2018).
 - [54] J. B. Tenenbaum, V. de Silva, and J. C. Langford: A Global Geometric Framework for Nonlinear Dimensionality Reduction, *Science*, 290, 2319–2323 (2000).

- [55] S. T. Roweis and L. K. Saul: Nonlinear Dimensionality Reduction by Locally Linear Embedding, *Science*, 290, 2323–2326 (2000).
- [56] A. Coenen and A. Pearce: Understanding UMAP, Google PAIR (2019). <https://pair-code.github.io/understanding-umap/>
- [57] D. Kobak and G. C. Linderman: Initialization is Critical for Preserving Global Data Structure in Both t-SNE and UMAP, *Nature Biotechnology*, 39(2), pp. 156–157 (2021).
- [58] M. Wattenberg, F. Viégas, and I. Johnson: How to Use t-SNE Effectively, *Distill* (2016). <https://distill.pub/2016/misread-tsne/>
- [59] K. Pearson: On Lines and Planes of Closest Fit to Systems of Points in Space, *Philosophical Magazine*, Series 6, 2(11), pp. 559–572 (1901).
- [60] H. Hotelling: Analysis of a Complex of Statistical Variables into Principal Components, *Journal of Educational Psychology*, 24, pp. 417–441, 498–520 (1933).
- [61] R. N. Shepard: The Analysis of Proximities: Multidimensional Scaling with an Unknown Distance Function. I, *Psychometrika*, 27(2), pp. 125–140 (1962).
- [62] R. N. Shepard: Multidimensional Scaling, Tree-Fitting, and Clustering, *Science*, 210(4468), pp. 390–398 (1980).
- [63] M. Belkin and P. Niyogi: Laplacian Eigenmaps for Dimensionality Reduction and Data Representation, *Neural Computation*, 15(6), pp. 1373–1396 (2003).
- [64] T. Chari and L. Pachter: The Specious Art of Single-Cell Genomics, *PLOS Computational Biology*, 19(8), e1011288 (2023).
- [65] J. Lause, P. Berens, and D. Kobak: The Art of Seeing the Elephant in the Room: 2D Embeddings of Single-Cell Data Do Make Sense, *PLOS Computational Biology*, 20(10), e1012403 (2024).
- [66] F. Murtagh and P. Legendre: Ward’s Hierarchical Agglomerative Clustering Method: Which Algorithms Implement Ward’s Criterion?, *Journal of Classification*, 31(3), pp. 274–295 (2014).
- [67] M. Belkin, D. Hsu, S. Ma, and S. Mandal: Reconciling Modern Machine-learning Practice and the Classical Bias–Variance Trade-off, *PNAS*, 116(32), pp. 15849–15854 (2019).
- [68] P. Nakkiran, G. Kaplun, Y. Bansal, T. Yang, B. Barak and I. Sutskever: Deep Double Descent: Where Bigger Models and More Data Hurt, *Journal of Statistical Mechanics: Theory and Experiment*, 2021(12), 124003 (2021). 初出は *ICLR 2020*.
- [69] J. Ho, T. Tumkaya, S. Aryal, H. Choi and A. Claridge-Chang: Moving Beyond P Values: Data Analysis with Estimation Graphics, *Nature Methods*, 16, pp. 565–566 (2019).
- [70] J. Demšar: Statistical Comparisons of Classifiers over Multiple Data Sets, *Journal of Machine Learning Research*, 7, pp. 1–30 (2006).
- [71] P. Nakkiran, P. Venkat, S. Kakade and T. Ma: Optimal Regularization Can Mitigate Double Descent, *Proc. ICLR 2021* (2021).
- [72] L. Grinsztajn, E. Oyallon, and G. Varoquaux: Why Do Tree-based Models Still Outperform Deep Learning on Typical Tabular Data?, *Proc. NeurIPS 2022 Datasets and Benchmarks*

- Track* (2022).
- [73] Y. Zhang, M. Li, D. Long, X. Zhang, H. Lin, B. Yang, et al.: Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models, arXiv:2506.05176 (2025). <https://arxiv.org/abs/2506.05176>
 - [74] 東北大学自然言語処理研究グループ: bert-base-japanese-v3(Hugging Face のモデルカード). <https://huggingface.co/tohoku-nlp/bert-base-japanese-v3>
 - [75] R. Sutton: The Bitter Lesson (2019 年 3 月 13 日). <http://www.incompleteideas.net/IncIdeas/BitterLesson.html>
 - [76] D. Kobak, G. Linderman, S. Steinerberger, Y. Kluger, and P. Berens: Heavy-Tailed Kernels Reveal a Finer Cluster Structure in t-SNE Visualisations, *Proc. ECML PKDD 2019* (arXiv:1902.05804).
 - [77] S. Greenland, S. J. Senn, K. J. Rothman, J. B. Carlin, C. Poole, S. N. Goodman, and D. G. Altman: Statistical Tests, P Values, Confidence Intervals, and Power: A Guide to Misinterpretations, *European Journal of Epidemiology*, 31(4), 337–350 (2016).
 - [78] 岡部正隆, 伊藤啓: 色覚の多様性と色覚バリアフリーなプレゼンテーション, *細胞工学*, 21(7–9) (2002).
 - [79] J. A. Nelder and R. W. M. Wedderburn: Generalized Linear Models, *Journal of the Royal Statistical Society, Series A*, 135(3), pp. 370–384 (1972).
 - [80] L. Breiman: Random Forests, *Machine Learning*, 45, 5–32 (2001).
 - [81] L. Breiman: Statistical Modeling: The Two Cultures (with comments and a rejoinder by the author), *Statistical Science*, 16(3), 199–231 (2001).
 - [82] T. Hastie, R. Tibshirani, and J. Friedman: *The Elements of Statistical Learning*, 2nd ed., Springer (2009).
 - [83] T. Chen and C. Guestrin: XGBoost: A Scalable Tree Boosting System, *Proc. KDD 2016*, pp. 785–794 (2016).
 - [84] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu: LightGBM: A Highly Efficient Gradient Boosting Decision Tree, *Proc. NIPS 2017* (2017).
 - [85] L. S. Shapley: A Value for n -Person Games, in *Contributions to the Theory of Games II*, Princeton University Press, pp. 307–317 (1953).
 - [86] S. M. Lundberg and S.-I. Lee: A Unified Approach to Interpreting Model Predictions, *Proc. NIPS 2017* (2017).
 - [87] S. M. Lundberg, G. Erion, H. Chen, et al.: From Local Explanations to Global Understanding with Explainable AI for Trees, *Nature Machine Intelligence*, 2, 56–67 (2020).
 - [88] C. J. van Rijsbergen: *Information Retrieval*, 2nd ed., Butterworths (1979).
 - [89] Y. Sasaki: The Truth of the F-measure, teaching materials, University of Manchester (2007).
 - [90] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman: Leakage in Data Mining: Formulation, Detection, and Avoidance, *ACM Transactions on Knowledge Discovery from Data*, 6(4), 15 (2012).
 - [91] Kaggle: TGS Salt Identification Challenge (2018). <https://www.kaggle.com/c/>

`tgs-salt-identification-challenge`

- [92] S. Kapoor and A. Narayanan: Leakage and the Reproducibility Crisis in Machine-learning-based Science, *Patterns*, 4(9), 100804 (2023).
- [93] M. Roberts, D. Driggs, M. Thorpe, et al.: Common Pitfalls and Recommendations for Using Machine Learning to Detect and Prognosticate for COVID-19 Using Chest Radiographs and CT Scans, *Nature Machine Intelligence*, 3, 199–217 (2021).
- [94] D. Trehan and P. Chopra: Why LLMs Aren't Scientists Yet: Lessons from Four Autonomous Research Attempts, arXiv:2601.03315 (2026).
- [95] Kaggle Team: Profiling Top Kagglers: Bestfitting, Currently #1 in the World, Kaggle Blog (2018).
- [96] V. C. Bradley, S. Kuriwaki, M. Isakov, D. Sejdinovic, X.-L. Meng and S. Flaxman: Unrepresentative Big Surveys Significantly Overestimated US Vaccine Uptake, *Nature*, 600, pp. 695–700 (2021).
- [97] C. M. Bennett, A. A. Baird, M. B. Miller and G. L. Wolford: Neural Correlates of Interspecies Perspective Taking in the Post-mortem Atlantic Salmon: An Argument for Proper Multiple Comparisons Correction, *Journal of Serendipitous and Unexpected Results*, 1(1), pp. 1–5 (2010).
- [98] D. Lazer, R. Kennedy, G. King and A. Vespignani: The Parable of Google Flu: Traps in Big Data Analysis, *Science*, 343(6176), pp. 1203–1205 (2014).
- [99] C. Dwork, V. Feldman, M. Hardt, T. Pitassi, O. Reingold and A. Roth: The Reusable Holdout: Preserving Validity in Adaptive Data Analysis, *Science*, 349(6248), pp. 636–638 (2015).
- [100] R. van den Goorbergh, M. van Smeden, D. Timmerman and B. Van Calster: The Harm of Class Imbalance Corrections for Risk Prediction Models, *Journal of the American Medical Informatics Association*, 29(9), pp. 1525–1534 (2022).
- [101] C. Nadeau and Y. Bengio: Inference for the Generalization Error, *Machine Learning*, 52(3), pp. 239–281 (2003).
- [102] G. W. Brier: Verification of Forecasts Expressed in Terms of Probability, *Monthly Weather Review*, 78(1), pp. 1–3 (1950).
- [103] A. H. Murphy: A New Vector Partition of the Probability Score, *Journal of Applied Meteorology*, 12(4), pp. 595–600 (1973).
- [104] A. H. Murphy and R. L. Winkler: Reliability of Subjective Probability Forecasts of Precipitation and Temperature, *Journal of the Royal Statistical Society, Series C (Applied Statistics)*, 26(1), pp. 41–47 (1977).
- [105] J. A. Hanley and B. J. McNeil: The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve, *Radiology*, 143(1), pp. 29–36 (1982).
- [106] S. Lewis and M. Clarke: Forest Plots: Trying to See the Wood and the Trees, *BMJ*, 322, pp. 1479–1480 (2001).
- [107] Z. Obermeyer, B. Powers, C. Vogeli and S. Mullainathan: Dissecting Racial Bias in an

- Algorithm Used to Manage the Health of Populations, *Science*, 366(6464), pp. 447–453 (2019).
- [108] P. Juola: Rowling and “Galbraith”: an authorial analysis, *Language Log* (2013 年 7 月 16 日). <https://languagelog.ldc.upenn.edu/n11/?p=5315>
- [109] J. X. Morris, V. Kuleshov, V. Shmatikov and A. M. Rush: Text Embeddings Reveal (Almost) As Much As Text, *Proc. EMNLP 2023*, pp. 12448–12460 (2023). <https://arxiv.org/abs/2310.06816>
- [110] W. S. Cleveland, P. Diaconis, and R. McGill: Variables on Scatterplots Look More Highly Correlated When the Scales Are Increased, *Science*, 216(4550), 1138–1141 (1982).
- [111] F. J. Anscombe: Graphs in Statistical Analysis, *The American Statistician*, 27(1), pp. 17–21 (1973).
- [112] J. Matejka and G. Fitzmaurice: Same Stats, Different Graphs: Generating Datasets with Varied Appearance and Identical Statistics through Simulated Annealing, *Proceedings of CHI 2017*, pp. 1290–1294 (2017).
- [113] W. S. Robinson: Ecological Correlations and the Behavior of Individuals, *American Sociological Review*, 15(3), 351–357 (1950).
- [114] M. te Grotenhuis, R. Eisinga, and S. V. Subramanian: Robinson’s Ecological Correlations and the Behavior of Individuals: Methodological Corrections, *International Journal of Epidemiology*, 40(4), 1123–1125 (2011).
- [115] T. O. Kvålseth: Cautionary Note about R^2 , *The American Statistician*, 39(4), pp. 279–285 (1985).
- [116] A.-N. Spiess and N. Neumeyer: An Evaluation of R^2 as an Inadequate Measure for Non-linear Models in Pharmacological and Biochemical Research: A Monte Carlo Approach, *BMC Pharmacology*, 10, 6 (2010).
- [117] D. Chicco, M. J. Warrens and G. Jurman: The Coefficient of Determination R-squared is More Informative than SMAPE, MAE, MAPE, MSE and RMSE in Regression Analysis Evaluation, *PeerJ Computer Science*, 7, e623 (2021).
- [118] J. F. Pimentel, L. Murta, V. Braganholo and J. Freire: A Large-Scale Study About Quality and Reproducibility of Jupyter Notebooks, *Proceedings of MSR 2019*, pp. 507–517 (2019).
- [119] J. F. Pimentel, L. Murta, V. Braganholo and J. Freire: Understanding and Improving the Quality and Reproducibility of Jupyter Notebooks, *Empirical Software Engineering*, 26, 65 (2021).
- [120] M. Ziemann, Y. Eren and A. El-Osta: Gene Name Errors are Widespread in the Scientific Literature, *Genome Biology*, 17, 177 (2016).
- [121] M. Abeysooriya, M. Soria, M. S. Kasu and M. Ziemann: Gene Name Errors: Lessons Not Learned, *PLOS Computational Biology*, 17(7), e1008984 (2021).
- [122] E. A. Bruford, B. Braschi, P. Denny, T. E. M. Jones, R. L. Seal, and S. Tweedie: Guidelines for Human Gene Nomenclature, *Nature Genetics*, 52(8), pp. 754–758 (2020).
- [123] J. Clark and D. Amodei: Faulty Reward Functions in the Wild, *OpenAI Blog* (2016).

- <https://openai.com/index/faulty-reward-functions/>
- [124] Y. Bengio and Y. Grandvalet: No Unbiased Estimator of the Variance of K -Fold Cross-Validation, *Journal of Machine Learning Research*, 5, pp. 1089–1105 (2004).
- [125] R. Bellman: *Dynamic Programming*, Princeton University Press (1957).
- [126] G. F. Hughes: On the Mean Accuracy of Statistical Pattern Recognizers, *IEEE Transactions on Information Theory*, 14(1), 55–63 (1968).
- [127] D. L. Donoho: High-Dimensional Data Analysis: The Curses and Blessings of Dimensionality, AMS Math Challenges Lecture (2000).
- [128] T. M. Cover: Geometrical and Statistical Properties of Systems of Linear Inequalities with Applications in Pattern Recognition, *IEEE Transactions on Electronic Computers*, EC-14(3), 326–334 (1965).
- [129] 青空文庫: 青空文庫収録ファイルの取り扱い規準 (2022 年改訂). <https://www.aozora.gr.jp/guide/kijyunn.html>

アンチパターンと定石の一覧

本書に散らばる ×(アンチパターン) と ○(定石) を、登場順に集めた。分析の途中で「この操作、何かまずくなかったか」と思ったら、ここから引いてほしい。

× 2.1 両対数の直線を言語の証拠として使う	14
× 2.2 頻出する内容語で著者を判別する	14
○ 2.1 著者を当てるなら文書全体に様に散らばる単語を選ぶ	17
× 2.3 ワードクラウドや共起ネットワークを分析の結論として出す	18
○ 2.2 刻み幅を自分で決めたら刻み幅のいらない見方でも確かめる	22
× 3.1 ルビや注記を取り除かずに文字を数える	27
○ 3.1 捨てるものはその情報が誰に由来するかで決める	27
× 3.2 分析に使う CSV を表計算ソフトで開く	28
× 3.3 正規化と標準化を混同する	30
○ 3.2 散布図は全体図と拡大図の 2 枚を描く	36
× 3.4 分散は必ず $n - 1$ で割ると覚える	38
× 3.5 分布を見ずに平均だけを取る	39
× 3.6 連続した値を中央値で 2 つに割ってから分析する	40
○ 3.3 著者を当てる特徴に求める 3 条件	43
× 3.7 比率どうしの相関をそのまま解釈する	44
○ 3.4 ゼロを埋める前にそのゼロの由来を確かめる	52
× 3.8 対数比を保ちたいのに、比率へ一律に 1 を足す	53
○ 4.1 長さの違いを消したいときにコサイン距離を選ぶ	60
× 4.1 定番だからという理由で距離を選ぶ	61
× 4.2 単位の違う列を混ぜたまま距離を測る	63
× 4.3 順序を考えずに正規化と標準化を混ぜる	65
× 4.4 標準化すれば組成データの制約が消えると思う	65
○ 4.2 標準化の要否を 1 行で判定する	70
× 4.5 距離を正解ラベルで選ぶ	74
× 4.6 散布図の見た目の細さから相関の強さを判断する	79
○ 4.3 要約した数値を報告する前に必ず散布図を描く	79
× 4.7 相関を連鎖させて推論する	84
× 4.8 集計した単位の相関をその中の個体の話として読む	86
× 4.9 列の数だけを見て次元の呪いを心配する	90
○ 4.4 距離を使う手法にかける前に次元を落とす	92
× 5.1 シルエット係数が最大の k を採用する	102

○ 5.1 前処理は結果ではなく測り方の理屈で選ぶ	107
× 5.2 合計が 1 に固定された比率の表を列ごとに標準化する	108
○ 5.2 Ward 法はユークリッド距離と組み合わせる	108
○ 5.3 k-means は初期値を変えて複数回試す	111
× 5.3 k-means を 1 回だけ実行する	111
× 5.4 エルボー法だけでクラスタ数を決める	113
× 6.1 寄与率を見ずに 2 次元の図で「近い」と判断する	123
○ 6.1 分かれた理由を説明したいときはパイプロットを使う	127
× 6.2 t-SNE や UMAP が見せた図を、そのまま信じる	138
○ 6.2 t-SNE や UMAP の図には、必ずパラメータを書き添える	142
× 6.3 t-SNE や UMAP の軸に意味を読む	143
× 6.4 片方の手法だけ調整して次元削減を比べる	147
× 6.5 t-SNE や UMAP の図で距離を語る	148
○ 6.3 次元削減は複数の手法を並べて見る	149
× 7.1 基準線を置かずに精度を報告する	153
× 7.2 相関の強い列を並べたまま係数の大小を比べる	158
× 7.3 ブースティングの木をランダムフォレストと同じつもりで増やす	167
○ 7.1 ブースティングのパラメータは 3 手に分けて触る	170
○ 7.2 分類手法はデータの規模と目的で選ぶ	172
× 7.4 訓練データで性能を報告する	173
○ 7.3 設定値を探索したかどうかをはっきり書く	176
○ 7.4 成績が並んだときは境界の形か誤りの型で選ぶ	178
× 7.5 不純度重要度だけを見る	180
× 7.6 特徴重要度を因果や本質と読む	181
× 7.7 L1 が残した列を「重要な列」と読む	182
○ 8.1 分割数は 5 か 10 から始めてデータが少ないときだけ増やす	186
○ 8.2 成績を報告するときはばらつきの幅を添える	192
× 8.1 エラーバーが何かを書かずに図を出す	194
× 8.2 並べた区間の重なりを見て手法に順位をつける	198
○ 8.3 比べたいものが差なら差を軸にした図を描く	200
○ 8.4 報告する指標と同じ指標で基準線を測る	202
× 8.3 別々のデータで測った決定係数を並べて優劣を論じる	203
○ 8.5 回帰は誤差と基準線を組にして報告する	205
× 8.4 全員が満点近くになる課題で手法の優劣を論じる	208
× 8.5 不均衡データで AUC だけを見る	208
○ 8.6 しきい値は誤りのコストで決める	209
○ 8.7 確率の値を使うなら較正まで確かめる	213
× 8.6 不均衡を「補正」して確率を壊す	213
× 8.7 「パラメータを大きくすると複雑になる」と覚える	215

○ 8.8 モデルをいじる前に学習曲線を描く	216
○ 9.1 前処理は Pipeline に入れて分割の内側で fit する	222
× 9.1 特徴選択を前処理として分割の前で済ませる	224
× 9.2 落差が小さいことを「漏れない」の証明として使う	226
× 9.3 行数をデータ量だと思う	227
× 9.4 何を当てたいかを考えずに n-gram を入れる	229
× 9.5 試行回数を報告しない	234
× 9.6 未来で訓練して過去を予測する	238
× 9.7 訓練データの範囲の外を平均を返すモデルに予測させる	240
○ 9.2 成績が悪いときは偏りとばらつきのどちらが原因かを先に見る	244
× 9.8 二重降下を「モデルは大きいほどよい」の根拠にする	246
× 9.9 距離を使う手法にとりあえず特徴を全部入れる	247
○ 9.3 列を足して成績が落ちたらまず列を減らす	248
× 9.10 AI が当てられたことを「この特徴で判別できる」証拠にする	248
× 9.11 AI の相づちを裏付けに数える	249
○ 9.4 AI が出した数字は 1 つ選んで自分で再計算する	249
× 10.1 分割の乱数を 1 つ選んで手法を比べる	257
× 10.2 「収束するまで回した」とだけ書く	263
× 10.3 測れば確かめられる原因の説明を測らずに書く	271
○ 10.1 前処理を 1 つ足したらモデルごとに測り直す	272
○ 10.2 深層学習を使う前に素朴なモデルの成績を出す	274
× 10.4 前処理を省いてモデルに任せる	274
× 11.1 最も単純なルールを試さずに高い精度を誇る	280
○ 11.1 独立した単位がいくつあるかを先に数える	283
× 11.2 答えの候補が出そろっている前提に気づかない	285

索引

A

Adam	263
Adjusted Rand Index	51, 98
Aitchison	46
Aitchison 距離	47
Anscombe の四重奏	79
AUC	206

B

bagging	164
benchmark contamination	248
BERT	266
bias	241
biplot	125
boosting	164
bootstrap	163
Brier score	211
Brier スコア	211
burstiness	20

C

calibration	210
CD ダイアグラム	200
ceiling effect	208
chaining effect	96
Chebyshev distance	58
closed-set assumption	283
clr 変換	47
clustering	93
coefficient of determination	69
coefficient of variation	20
compositional data	43
concentration of distances	87

confounding	280
confusion matrix	190
correlation coefficient	76
cosine distance	59
covariance matrix	119
coverage probability	192
Cover の定理	298
critical difference	200
critical difference diagram	200
cross entropy	155
cross-validation	186
curse of dimensionality	88

D

data leakage	184
decision tree	162
Delta	73
dendrogram	93
dimensionality reduction	115
double descent	245
drift	237

E

effect size	70
eigenvalue problem	119
embedding	252
entropy	162
estimation plot	200
Euclidean distance	58
eureka instinct	248
explained variance ratio	122
exponential distribution	19

F

F-statistic 106
 feature 7, 276
 feature engineering 55
 fold 153
 forest plot 196
 Friedman 検定 201
 function word 14
F 値 106

G

Gardner–Altman プロット 200
 generalized linear model 159
 generative AI 248
 geodesic distance 133
 Gini impurity 163
 gradient boosting 166
 Gram matrix 120
 Group Lasso 182
 GroupKFold 225

H

HistGradientBoostingClassifier 169
 hypercube 133
 hyperparameter 215

I

ilr 変換 47
 information gain 162
 intrinsic dimension 131
 Isomap 133, 145

J

Johnson–Lindenstrauss 297

K

k-means 8, 61, 109, 290, 299

k-means++ 111
 k-nearest neighbors 153
 Kaggle 168
 kernel 160

L

Lance–Williams 96
 lasso 67
 Lasso 回帰 67
 lazy learning 154
 learning curve 215
 learning rate 166
 LightGBM 168
 LLE 145
 log-normal distribution 36
 logistic regression 155

M

macro-average 189
 Manhattan distance 58
 manifold hypothesis 119
 margin 160
 marimo i, 4, 290
 maximum likelihood 37
 memorylessness 19
 micro-average 189
 Minkowski distance 57
 multilayer perceptron 260
 mutual information 162

N

n-gram 23, 228
 Nemenyi 検定 201
 normalization 29

O

overfitting 173

P

partial correlation 86
 permutation importance 180
 Pipeline 222
 Poisson distribution 15
 Poisson process 20
 Polars 38
 power law 11
 precision 189
 principal component analysis 115
 PR 曲線 208

R

random forest 163
 recall 189
 regularization term 67
 residual IDF 17
 ridge regression 67
 Ridge 回帰 67
 ROC 曲線 8, 206, 284

S

scikit-learn 5, 67, 111, 155, 223, 263, 287
 SHAP 183
 Shapley 値 183
 sigmoid function 154
 silhouette coefficient 100
 softmax function 155
 standardization 30, 63
 StratifiedKFold 187
 subcompositional incoherence 45
 supervised learning 152
 support vector machine 68, 160
 Swiss roll 131

T

t-SNE 129, 215, 254

ternary plot 32
 TF-IDF 18

U

UMAP 129, 248, 254
 unbiasedness 37
 uv 290

V

variance 241
 VIF 158
 viridis 124

W

Ward 法 52, 61, 95

X

XGBoost 168

Z

z-score 63
 Zipf の法則 8, 11

イ

一般化線形モデル 159
 入れ子交差検証 170, 231

ウ

埋め込み 252

エ

エポック 262
 ℓ_1 正規化 29
 ℓ_2 正規化 29, 61
 エルボー法 112

オ

オートエンコーダ 150

カ

カーネル 160
階層クラスタリング 8, 93
過学習 8, 67, **173**, 214, 218, 262, 298
学習曲線 **215**, 244
学習率 **166**, 215, 261
過剰適合 173
数え上げゼロ **51**
偏り **241**
完全連結 95
ガンマ分布 20

キ

幾何分布 22
基準線 6, 66, 152, 216, 232, 274, 278
機能語 **14**, 180, 230
偽発見率 235
教師あり学習 **152**, 266
凝集型 93
寄与率 32, 69, **122**, 286, 299
距離の公理 75, 128
距離の集中 9, **87**, 134, 294

ク

鎖効果 **96**
クラスタリング 2, 53, 68, **93**, 288
グラム行列 **120**
グループの漏れ 219
群平均法 94

ケ

形態素解析 **10**
計量文献学 73
計量文体論 **1**

k 近傍法 .. 8, 66, 153, 207, 220, 279, 282, 289,
299

決定株 164, 279

決定木 8, 52, 66, **162**, 214, **240**, 260, 279

決定係数 **69**, 237

コ

効果量 **70**

交差エントロピー **155**

交差エントロピー損失 **260**

交差検証 ... 8, 39, 66, 153, 174, 186, 218, 252,
287

較正 8, **210**

構造ゼロ **51**

勾配降下法 113, **261**

勾配ブースティング 8, 66, **166**, 240, 260

交絡 240, **280**

コサイン距離 8, 30, 59, 103, 256

コサイン類似度 60, 299

古典的 MDS 120

固有値問題 **119**

混同行列 8, 92, 114, 178, **190**, 250

サ

再現率 8, **189**

最尤推定 **37**, 155

サポートベクトルマシン 68, **160**, 298

三角関 **32**

三角不等式 57, 128

残差 IDF **17**

シ

シェパード図 123

色覚多様性 125

シグモイド関数 **154**

時系列の漏れ 203, 219

次元削減 91, **115**, 248, 290

次元の呪い 8, **88**, 154, 246, 292

指数分布 19
 ジニ不純度 163
 主成分分析 8, 32, 69, 115, 259
 情報エントロピー 162
 乗法的置換 52
 情報利得 162, 299
 シルエット係数 100, 254
 信用区間 192
 信頼度曲線 210

ス

スイスロール 131
 推定プロット 200
 スクリープロット 122
 スペクトル埋め込み 145

セ

正規化 29, 63, 112, 118, 228, 264
 生成 AI 248
 正則化項 67
 生存者バイアス 7
 生態学的誤謬 86
 z 得点 63
 前処理の漏れ 219

ソ

相関距離 76
 相関係数 43, 76, 117
 早期打ち切り 167
 相互情報量 162
 層別化 8, 173, 187
 層別交差検証 39, 66, 174, 186
 測地距離 133
 組成データ ii, 8, 43, 65, 107, 143, 160
 ソフトマックス関数 155

タ

ターゲットの漏れ 219

対数正規分布 36
 対数損失 155
 怠惰学習 154
 多次元尺度構成法 8, 115
 多重共線性 158
 多重テストの漏れ 219
 多層パーセプトロン 260
 多様体仮説 91, 119, 298
 単体 31
 単連結 95

チ

チェビシェフ距離 58
 置換重要度 180
 超立方体 133

ツ

追従性 248

テ

データ漏洩 8, 184, 218
 適合率 8, 189
 天井効果 208
 デンドログラム 93, 290

ト

特徴選択の漏れ 219
 特徴量 ... i, 7, 26, 60, 105, 223, 258, 276, 289
 特徴量エンジニアリング 55
 ドリフト 237

ナ

内在次元 90, 131
 内容語 14, 56, 228

ニ

二重降下 245

ハ

バースト性.....20
ハイパーパラメータ.....215, 231
バイプロット.....125
バギング.....164
バッチ.....262
ハブ.....91
ばらつき.....241

ヒ

1 つ抜き交差検証.....186
被覆確率.....192
標準化. 8, 30, 63, 97, 115, 157, 219, 256, 289

フ

ブースティング.....8, 66, 164, 244, 260
ブートストラップ.....163
フォールド.....153, 174, 186, 238
フォレストプロット.....196
負の二項分布.....17
部分組成の非整合性.....45
不偏性.....37
分割型.....93
分岐エントロピー.....24
分散共分散行列.....119

ヘ

閉集合の仮定.....283
べき乗則.....11
偏差ベクトル.....76
偏相関係数.....86
ベンチマーク汚染.....248
変動係数.....20

ホ

ポアソン過程.....20
ポアソン分布.....8, 15, 159

ホールドアウト.....185
ボンフェローニ補正.....197
ボンフェローニ補正.....235

マ

マイクロ平均.....189
マクロ平均.....189
マージン.....160
待ち時間のパラドックス.....21
マンハッタン距離.....8, 58, 105

ミ

ミンコフスキー距離.....57, 105

ム

無記憶性.....19

ユ

ユークリッド距離. 8, 30, 58, 96, 128, 161, 237
ユーレカ本能.....248

ラ

ラグランジュ未定乗数法.....119
ランダムフォレスト. 8, 54, 66, 163, 187, 218,
260, 278, 279

リ

臨界差.....200
臨界差図.....200

レ

レインボー.....124

ロ

ロジスティック回帰... 66, 155, 172, 207, 256

アンチパターンで学ぶデータ分析

作家の判別を題材に

著者	久保山 哲二 (くぼやま てつじ) 学習院大学 計算機センター
版	バージョン 1.3.0
初版発行	2026 年 8 月 24 日
本版発行	2026 年 9 月 27 日
組版	LuaLaTeX(ltjsbook + luatexja) 本文フォント: 原ノ味明朝・原ノ味ゴシック 図版: TikZ / PGFPlots
データ	近代文学 74 作品 (青空文庫) ライトノベル 6 シリーズ 60 区間 (特徴量のみ)
付属教材	marimo ノートブック 5 本
使い方	付録 A を参照
AI の利用	コーディング・実験・執筆に Claude(Anthropic) を利用
ライセンス	本文・図版: CC BY 4.0 / コード: MIT

近代文学の本文は青空文庫 (<https://www.aozora.gr.jp/>) に拠る。ライトノベルについては、著作権に配慮し、本文からは復元できない要約統計量 (特徴量) のみを扱った。